

Matemáticas y Algoritmos en Ciencia de Datos Aplicada

Fundamentos matemáticos, algoritmos y práctica computacional

César Galindo

2026-07-13

Tabla de contenidos

Prefacio	23
Orientación para el lector	25
Estructura de los capítulos	25
Cómo leer un algoritmo	26
Código, datos y ejercicios	26
 Parte I: Datos y preguntas	 28
Observaciones, variables y preguntas	30
Un caso para comenzar	30
Unidades de observación y niveles de análisis	31
Variables, valores y mediciones	33
El diccionario de datos	34
Población, marco de observación y muestra	35
De una pregunta amplia a una pregunta precisa	36
Familias de tareas	38
De la tabla a la notación matemática	38
Modelo, algoritmo y resultado ajustado	40
Disponibilidad temporal y filtración de información	41
Calidad de datos como propiedad de la pregunta	41
Análisis completo del caso de Bogotá	42
Una ficha mínima para iniciar un análisis	43
Síntesis	43
Términos clave	44
Ejercicios	44
Respuestas seleccionadas	46
 Parte II: Regresión, optimización y clasificación	 47
Capítulo 1: Regresión lineal múltiple	49
Pregunta aplicada	49
Objetivos del capítulo	49
De las filas observadas a una observación nueva	50
Por qué aparece la media condicional	50
Del objetivo poblacional al problema calculable	51
Modelo lineal probabilístico	51
El problema de regresión	52
De una recta a una matriz	53

Dimensiones: la primera defensa contra errores	54
Residuales y pérdida	54
Derivación del gradiente	55
Ecuación normal	57
Costo computacional y estabilidad	58
Interpretación geométrica	58
Ejemplo resuelto 1: datos exactos	59
Ejemplo resuelto 2: datos con ruido	59
Baseline de regresión	60
Caso aplicado: 32 subzonas de Bogotá	60
Interpretación de coeficientes	63
Multicolinealidad y rango	63
Errores comunes	64
Checklist de estudio	64
Para explorar más	64
Revisión del capítulo	64
Términos clave	65
Ejercicios	65
Capítulo 2: Descenso del gradiente	67
Pregunta aplicada	67
Objetivos del capítulo	67
Qué función estamos optimizando	67
Optimización como búsqueda	68
Idea geométrica del gradiente	69
Algoritmo básico	70
Cómo leer una curva de pérdida	71
Ejemplo resuelto: una variable escalada	71
Escalamiento y geometría	72
Condicionamiento	72
Comparación con ecuación normal	73
Por qué converge en la cuadrática	73
Costo de una iteración	74
Batch, stochastic y mini-batch	75
Tasa de aprendizaje: una rutina práctica	75
Errores comunes	75
Checklist de estudio	76
Para explorar más	76
Revisión del capítulo	76
Términos clave	76
Ejercicios	77
Capítulo 3: Validación y regularización	79
Pregunta aplicada	79
Objetivos del capítulo	79
El modelo ajustado también es aleatorio	80
Feature engineering	80
Regresión polinomial	81

Underfitting y overfitting	81
Separación de datos	82
Leakage	82
Regularización	83
Ridge	84
Efecto de λ	85
Ridge visto en las direcciones singulares	85
Lasso	85
Por qué Lasso puede producir ceros	86
Ridge vs Lasso	87
Estandarización antes de regularizar	87
Selección de modelo	87
Ejemplo resuelto: grado polinomial y Ridge	88
Errores comunes	88
Checklist de estudio	89
Para explorar más	89
Revisión del capítulo	89
Términos clave	89
Ejercicios	90
Capítulo 4: Regresión logística	92
Pregunta aplicada	92
Objetivos del capítulo	92
Clasificación binaria	94
La función sigmoide	95
Modelo logístico	95
Log-odds	96
Por qué no usamos MSE	96
Gradiente de la pérdida logística	97
Hessiana, convexidad y existencia de la solución	98
Algoritmos y costo	99
De probabilidades a clases	99
Matriz de confusión	99
Métricas	100
Ejemplo resuelto: umbral y matriz de confusión	101
Elegir métricas según la decisión	102
Umbrales	102
Baselines de clasificación	103
Calibración	103
Errores comunes	104
Checklist de estudio	104
Para explorar más	104
Revisión del capítulo	104
Términos clave	105
Ejercicios	105
Ejercicios integradores: regresión, optimización y clasificación	107

Cómo usar este banco	108
Resultados de práctica	108
Mapa del banco	108
Columna probabilística del módulo	109
Semana 2: regresión lineal	110
A. Dimensiones y representación	110
B. Mínimos cuadrados	110
C. Implementación	110
D. Interpretación	111
Semana 3: descenso del gradiente	112
A. Gradiente	112
B. Iteraciones	112
C. Diagnóstico	112
D. Código	112
Semana 4: features y validación	113
A. Complejidad	113
B. Particiones	113
C. Feature engineering	113
D. Código	113
Semana 5: regularización	114
A. Ridge	114
B. Lasso	114
C. Selección	114
D. Código	114
Semana 6: clasificación logística	115
A. Probabilidades	115
B. Log-loss	115
C. Métricas	115
D. Umbrales	115
Problemas integradores	116
Problema 1: regresión de principio a fin	116
Problema 2: regularización y estabilidad	116
Problema 3: clasificación con umbral	117
Problema 4: diseño de parcial	117
Rúbrica de autoevaluación	118
Guía de verificación seleccionada	119

Parte III: Redes neuronales	120
Perceptron, neurona logística y forward propagation	122
Pregunta aplicada	122
Objetivos del capítulo	122
Distribución predictiva y riesgo	122
Perceptron como unidad básica	123
Neurona logística	123
De una neurona a una capa	124
Red de una capa oculta	124
ReLU	125
Softmax	125
Entropía cruzada multiclase	126
Por qué hace falta una no linealidad	126
Costo de una pasada forward	126
Ejemplo resuelto: softmax y pérdida	127
Ejemplo resuelto: dimensiones	128
Caso longitudinal: dígitos escritos a mano	128
Punto de control	128
Verificaciones seleccionadas	129
Ejemplo resuelto: auditoría de formas en dos capas	129
Para explorar más	129
Revisión del capítulo	130
Términos clave	130
Ejercicios	130
Backpropagation	132
Pregunta aplicada	132
Objetivos del capítulo	132
Del riesgo esperado al gradiente calculable	132
El grafo de cómputo	133
Gradiente de softmax con entropía cruzada	134
Gradientes de la segunda capa	134
Propagar hacia la capa oculta	135
Backpropagation como algoritmo	135
Costo, memoria y alcance de la garantía	136
Verificación por diferencias finitas	137
Ejemplo resuelto: diferencia finita escalar	137
Ejemplo resuelto: formas de los gradientes	138
Errores frecuentes	138
Punto de control	138
Caso longitudinal: backpropagation en dígitos	139
Verificaciones seleccionadas	139
Para explorar más	139
Revisión del capítulo	139
Términos clave	140
Ejercicios	140

Activaciones, inicialización, regularización y diagnóstico	142
Pregunta aplicada	142
Objetivos del capítulo	142
Fuentes distintas de aleatoriedad	142
Activaciones	143
Inicialización	143
De la propagación de varianza a Xavier y He	144
Regularización L2 en redes	145
Ejemplo resuelto: L2 en pérdida y gradiente	145
Dropout como idea	146
Curvas de entrenamiento	146
Diagnósticos comunes	146
Ejemplo resuelto: leer una curva	147
Checkpoint técnico del proyecto	147
Caso longitudinal: curva de entrenamiento en dígitos	147
Verificaciones seleccionadas	148
Ejemplo resuelto: regla de parada	148
Lectura de curvas: tres patrones frecuentes	148
Punto de control	149
Para explorar más	149
Revisión del capítulo	149
Términos clave	150
Ejercicios	150
 Optimizadores y PyTorch	 152
Pregunta aplicada	152
Objetivos del capítulo	153
Gradiente estocástico y filtración	153
Mini-batch gradient descent	153
Momentum	154
Ejemplo resuelto: dos pasos con momentum	154
Derivación guiada: momentum como memoria exponencial	155
RMSProp y Adam	155
Ejemplo resuelto: Adam en una coordenada	156
Qué puede afirmarse sobre convergencia	157
Costo y memoria del optimizador	157
PyTorch: qué automatiza	157
Loop mínimo	158
Ejemplo resuelto: lectura de un loop	158
Comparación justa	159
Caso longitudinal: experimento reproducible en dígitos	159
Punto de control	159
Verificaciones seleccionadas	159
Ejemplo resuelto: presupuesto de entrenamiento	160
Convergencia no es validación	160
Para explorar más	160
Revisión del capítulo	161
Términos clave	161

Ejercicios	161
Ejercicios integradores: redes neuronales	163
Resultados de práctica	163
Mapa del banco	163
Cómo usar esta sección	163
Columna probabilística del módulo	164
Bloque A: dimensiones y forward	164
Bloque B: backpropagation	164
Bloque C: diagnóstico	165
Bloque D: PyTorch	165
Respuestas seleccionadas	165
 Parte IV: Evaluación y estrategia de modelado	 166
Métricas y particiones	168
Pregunta aplicada	168
Objetivos del capítulo	168
Una métrica es un estadístico	168
Matriz de confusión poblacional y empírica	169
El condicionamiento inverso y la prevalencia	170
Métrica principal	171
Accuracy no siempre basta	172
Ejemplo resuelto: accuracy engañosa	172
Ejemplo resuelto: costo de falsos negativos	172
Derivación guiada: F1 como equilibrio operativo	173
De costos a una regla de decisión	173
Baseline	174
Particiones	174
Test se toca una vez	174
Estratificación	175
Ejemplo resuelto: conteos en una partición estratificada	175
Leakage	175
Pipeline como defensa	176
Caso longitudinal: clasificación con slice reciente	176
Punto de control	176
Verificaciones seleccionadas	177
Para explorar más	177
Revisión del capítulo	177
Términos clave	177
Ejercicios	178
 Validación cruzada y curvas de aprendizaje	 180
Pregunta aplicada	180
Objetivos del capítulo	180
Qué aleatoriedad intenta representar la validación	180
Bootstrap y unidad de remuestreo	181

Cross-validation	181
Qué reportar	181
Ejemplo resuelto: elegir entre dos modelos	181
Derivación guiada: media y variabilidad de CV	182
Grid search	182
Selección y validación anidada	183
Costo computacional de validar	183
Learning curve	184
Ejemplo resuelto: leer una learning curve	184
Validation curve	185
Caso longitudinal: estabilidad del modelo de clasificación	185
Ejemplo resuelto: decisión con diferencia pequeña	186
Sesgo, varianza y ruido	186
Punto de control	186
Verificaciones seleccionadas	186
Ejemplo resuelto: cuándo no hacer grid más grande	187
Para explorar más	187
Criterio práctico de decisión	187
Revisión del capítulo	187
Términos clave	188
Ejercicios	188
Error analysis y data mismatch	190
Pregunta aplicada	190
Objetivos del capítulo	190
Riesgo condicional por slice	190
Cambio de distribución como cambio de medida	191
Error analysis	191
Slices	192
Incertidumbre y búsqueda entre slices	192
Data mismatch	193
Diagnóstico de mismatch	193
Ejemplo resuelto: mismatch por proporción de clase	193
Derivación guiada: qué métricas pueden promediarse por slices	194
Recomendación técnica	194
Ejemplo resuelto: dos modelos con el mismo F1	194
Ejemplo resuelto: brecha contra el promedio	195
Caso longitudinal: slice reciente	195
Punto de control	196
Verificaciones seleccionadas	196
Procedimiento de auditoría por slice	196
Para explorar más	196
Revisión del capítulo	197
Términos clave	197
Ejercicios	197
Ejercicios integradores: estrategia de machine learning	199
Resultados de práctica	199

Mapa del banco	199
Criterio de respuesta	199
Columna probabilística del módulo	200
Bloque A: métricas	200
Bloque B: particiones y leakage	200
Bloque C: validación y curvas	201
Bloque D: error analysis	201
Respuestas seleccionadas	201
Parte V: Aprendizaje no supervisado	202
SVD y PCA	204
Pregunta aplicada	204
Objetivos del capítulo	204
PCA poblacional y PCA empírico	205
SVD	206
PCA como SVD del dato centrado	206
Proyección	207
Varianza explicada	207
Ejemplo resuelto: error desde valores singulares	207
Derivación guiada: reconstrucción y pérdida de información	208
Costo y elección del método numérico	209
Ejemplo resuelto: elegir k	209
Reconstrucción	209
Ejemplo resuelto: proyección y reconstrucción	210
Caso longitudinal: PCA sintético	211
PCA no es interpretabilidad automática	211
Punto de control	211
Verificaciones seleccionadas	212
Ejemplo resuelto: PCA dentro de un pipeline	212
Para explorar más	212
Revisión del capítulo	212
Términos clave	213
Ejercicios	213
K-Means y clustering	215
Pregunta aplicada	215
Objetivos del capítulo	215
Distorsión poblacional y objetivo empírico	216
Función objetivo	216
Algoritmo	217
Por qué la inercia no aumenta	217
Inercia	218
Silhouette score	218
Ejemplo resuelto: por qué escalar cambia clusters	218
Ejemplo resuelto: asignación a centroides	219
Ejemplo resuelto: una iteración completa	219

Derivación guiada: por qué el centroide es el promedio	220
Complejidad y casos degenerados	220
Escalamiento	221
Limitaciones	221
Caso longitudinal: clusters sintéticos	221
Estabilidad por inicialización	221
Punto de control	222
Verificaciones seleccionadas	222
Ejemplo resuelto: elegir k con información incompleta	222
Para explorar más	223
Revisión del capítulo	223
Términos clave	223
Ejercicios	223
Recomendación básica y estructura latente	225
Pregunta aplicada	225
Objetivos del capítulo	225
El mecanismo de observación no es neutral	225
Riesgo offline y utilidad de uso	226
Matriz usuario-ítem	226
Similitud coseno	226
Ejemplo resuelto: similitud coseno	227
Derivación guiada: qué ignora la similitud coseno	227
Recomendación item-item	227
Ejemplo resuelto: recomendación item-item	228
Evaluación offline: Precision@k	228
Baseline de popularidad	229
SVD para factores latentes	229
Factorización sobre entradas observadas	230
Alternancia, costo e identificación	231
Caso longitudinal: interacciones de recomendación	232
Riesgos de recomendación	232
Punto de control	232
Verificaciones seleccionadas	232
Ejemplo resuelto: cobertura mínima	233
Para explorar más	233
Revisión del capítulo	233
Términos clave	233
Ejercicios	234
Ejercicios integradores: aprendizaje no supervisado	235
Resultados de práctica	235
Mapa del banco	235
Antes de responder	235
Columna probabilística del módulo	236
Bloque A: PCA	236
Bloque B: K-Means	236
Bloque C: recomendación	237

Respuestas seleccionadas	237
Parte VI: Reproducibilidad y comunicación	238
Síntesis conceptual: redes, estrategia y no supervisado	240
Pregunta aplicada	240
Alcance	240
Objetivos del capítulo	240
Mapa probabilístico de síntesis	240
Mapa de contenidos	241
Redes neuronales	241
Softmax y entropía cruzada	242
Diagnóstico de modelos	242
No supervisado	242
Forma del Parcial 2	242
Regla de preparación	243
Cómo leer una pregunta integradora	243
Ejemplo resuelto: softmax estable en síntesis	243
Ejemplo resuelto: estructura no supervisada dentro de una respuesta	244
Ejemplo resuelto: respuesta integradora	244
Caso longitudinal: respuesta integradora	245
Verificaciones seleccionadas	245
Ejemplo resuelto: matriz de decisión integradora	245
Mini-rúbrica para una respuesta integradora	246
Para explorar más	246
Revisión del capítulo	246
Términos clave	247
Ejercicios	247
Reproducibilidad y tracking	248
Pregunta aplicada	248
Qué significa reproducir	248
Objetivos del capítulo	249
Reproducibilidad computacional y replicación estadística	249
El paquete mínimo reproducible	249
Semillas	250
Manifest de experimento	250
Ejemplo resuelto: manifest mínimo	250
Ejemplo resuelto: resultado no reproducible	251
Ejemplo resuelto: auditar un manifest	251
Tracking de experimentos	252
Persistencia de modelos	252
Hash de artefactos	253
Checklist de reproducibilidad	253
Punto de control	253
Caso longitudinal: manifest del clasificador	253
Verificaciones seleccionadas	254

Ejemplo resuelto: manifest mínimo en JSON	254
Qué debe poder volver a ejecutarse	255
Para explorar más	255
Revisión del capítulo	255
Términos clave	255
Ejercicios	256
Comunicación técnica	257
Pregunta aplicada	257
Tesis de un reporte	257
Objetivos del capítulo	258
Comunicar una cantidad aleatoria	258
Estructura recomendada	258
Figuras útiles	259
Lenguaje de alcance	259
Ejemplo resuelto: de bitácora a argumento	259
Ejemplo resuelto: mejorar una conclusión	260
Ejemplo resuelto: mejora absoluta y relativa	260
Respuesta oral de 45 segundos	261
Caso longitudinal: conclusión del clasificador	261
Verificaciones seleccionadas	261
Ejemplo resuelto: tabla de soporte de afirmaciones	261
Plantilla de resultados	262
De resultado a recomendación	262
Para explorar más	263
Revisión del capítulo	263
Términos clave	263
Ejercicios	263
Entrega final y defensa	265
Pregunta aplicada	265
Paquete final	265
Objetivos del capítulo	265
Defensa del fundamento probabilístico	265
Estructura del repositorio de proyecto	266
Criterio de paquete ejecutable	266
Ejemplo resuelto: contribución individual	266
Peso del proyecto en el curso	267
Rúbrica del reporte y repositorio	267
Ejemplo resuelto: cálculo de nota ponderada	267
Defensa oral individual	268
Rúbrica de defensa 0/1/2	269
Caso longitudinal: defensa del clasificador	269
Verificaciones seleccionadas	270
Ejemplo resuelto: pregunta difícil	270
Checklist individual antes de entrar a defensa	270
Carga docente mínima	271
Contribución individual y trazabilidad	271

Para explorar más	271
Revisión del capítulo	271
Términos clave	272
Ejercicios	272
Ejercicios integradores: reproducibilidad y defensa	273
Resultados de práctica	273
Mapa del banco	273
Criterio de calidad	273
Columna probabilística del cierre	274
Ejercicio 1: Softmax estable	274
Ejercicio 2: Diagnóstico	274
Ejercicio 3: PCA y reconstrucción	275
Ejercicio 4: Reproducibilidad	275
Ejercicio 5: Defensa	275
Respuestas seleccionadas	275
Herramientas probabilísticas y estadísticas	277
Variables aleatorias, distribuciones y muestras	279
La incertidumbre antes de observar	280
Espacios de probabilidad y eventos	280
Variables aleatorias y realizaciones	281
La distribución de una variable aleatoria	282
Esperanza y transformaciones	284
Varianza y desviación estándar	285
Algunas distribuciones de referencia	286
Distribuciones conjuntas y marginales	288
Independencia	288
Covarianza y correlación	289
Muestras aleatorias	290
Distribución empírica	291
Resúmenes muestrales	292
Estadísticos y distribuciones muestrales	292
Por qué se estabilizan los promedios	293
Qué aporta y qué no aporta el modelo probabilístico	294
Síntesis	295
Términos clave	295
Ejercicios	295
Respuestas seleccionadas	297
Condicionamiento, estimación, riesgo e incertidumbre	299
Probabilidad condicional	300
Distribuciones condicionales	302
Esperanza condicional	302
Objetivos poblacionales en aprendizaje supervisado	303
Ruido, residual y error de medición	305

Estimandos, estimadores y estimaciones	306
Pérdida y riesgo esperado	308
Entrenamiento, validación y prueba	310
Incertidumbre de una métrica	311
Bootstrap	313
Cambio de distribución	314
Ejemplo completo: clasificación de vinos	315
Síntesis	317
Términos clave	317
Ejercicios	318
Respuestas seleccionadas	320
Herramientas de estudio	322
Guía de estudio del estudiante	323
Cómo se conectan las páginas del curso	323
Ruta mínima por semana	323
Cómo leer un capítulo técnico	324
Señales de dominio	324
Uso de respuestas seleccionadas	325
Preparación para parciales	325
Preparación para el proyecto	325
Cuando te bloqueas	326
Checklist antes de publicar una entrega	326
Formatos y descargas	327
Lectura principal	327
Guías de inicio	327
Datos de práctica	328
Trazabilidad de publicación	328
Estado de uso	329
Qué no se descarga desde el libro	329
Datos y recursos reproducibles	330
Paquete descargable del libro	330
Caso Bogotá: vivienda nueva por subzona	331
Datasets incluidos en scikit-learn	331
Datos generados para práctica	332
Regla de reproducibilidad	332
Advertencias de interpretación	332
Checklist para datasets de proyecto	332
Casos longitudinales del libro	334
Caso A: regresión sintética con escala y regularización	334
Caso B: clasificación binaria con slice reciente	335
Caso C: estructura no supervisada	336
Cómo usar los casos al estudiar	336

Atlas visual de modelos y decisiones	337
Manifiesto editorial	337
Regresión lineal	337
Regularización	338
Descenso del gradiente	339
Validación y curvas de aprendizaje	340
Particiones y evaluación	341
Regresión logística y umbrales	342
Métricas para decidir	342
Error analysis	343
Backpropagation	344
Optimizadores	345
PCA y SVD	346
K-Means	346
Recomendación latente	347
Reproducibilidad	347
Comunicación y defensa	348
Resultados de aprendizaje y alineación	350
Resultados de aprendizaje globales	350
Alineación por parte del libro	350
Alineación con evaluación	351
Criterios de evidencia	352
Progresión de autonomía	352
Cómo usar esta página	352
Mapa de objetivos de aprendizaje	354
Cómo leer los códigos	354
Cobertura por parte	355
Mapa por capítulo principal	355
Uso para estudiantes	358
Uso para instructores	358
Criterio de mantenimiento	359
Mapa de cierres de capítulo	360
Rasgos de cierre	360
Mapa por capítulo principal	360
Bancos integradores	362
Relación con respuestas seleccionadas	362
Criterio editorial	363
Apéndices de consulta	364
Glosario y notación	365
Términos clave	365
Notación frecuente	367
Convención de formas	368

Índice temático	369
Cómo usar este índice	369
Modelación y representación	369
Álgebra lineal y optimización	370
Regresión, regularización y clasificación	370
Validación, métricas y diagnóstico	371
Redes neuronales	371
Aprendizaje no supervisado y recomendación	371
Reproducibilidad y comunicación	372
Recursos de consulta rápida	372
Criterio de mantenimiento	373
 Índice de algoritmos, datasets y funciones	 374
Cómo usar este apéndice	374
Mapa por primer uso	374
Referencia de API por capítulo	375
Algoritmos principales	376
Datasets y generadores	377
Funciones NumPy frecuentes	378
Herramientas scikit-learn frecuentes	379
Métricas y diagnósticos	379
PyTorch mínimo del curso	380
Regla de lectura rápida	380
 Taxonomía de ejercicios y banco de preguntas	 381
Propósito	381
Tipos de ejercicio	381
Niveles cognitivos	381
Evidencia esperada	382
Banco público por módulo	382
Criterios de calibración	383
Uso para estudiantes	384
Uso para instructores	384
Señales de mala pregunta	384
Mantenimiento y revisión	385
 Prerrequisitos matemáticos mínimos	 386
Cómo usar este apéndice	386
Álgebra lineal mínima	386
Normas, distancias y pérdida cuadrática	387
Cálculo y gradientes mínimos	388
Notación probabilística de primera aparición	388
Notación NumPy y PyTorch	389
Checklist de formas	389
Ejemplo resuelto: gradiente de MSE en una línea	389
Respuestas rápidas de autoverificación	390

Formularios y respuestas seleccionadas	391
Cómo usar esta parte	391
Mapa de apéndices	391
Política de respuestas	391
Apéndice Módulo 1: formulario y respuestas seleccionadas	393
Cómo usar este apéndice	394
Notación mínima	394
Formulario mínimo	394
Patrones de código	397
Checklist antes de entregar	398
Respuestas seleccionadas	398
Guía de estudio para el Parcial 1	400
Apéndice Módulo 2: formulario y respuestas seleccionadas	401
Cómo usar este apéndice	402
Notación mínima	402
Fórmulas clave de forward	402
Fórmulas clave de backward	403
Diagnóstico de entrenamiento	404
Patrones de código	404
Checklist antes de entregar	404
Respuestas seleccionadas	405
Apéndice Módulo 3: formulario y respuestas seleccionadas	407
Cómo usar este apéndice	408
Notación mínima	408
Métricas de clasificación binaria	408
Validación cruzada	409
Reglas operativas	409
Checklist de evaluación	409
Patrones de decisión	409
Patrones de código	410
Respuestas seleccionadas	410
Apéndice Módulo 4: formulario y respuestas seleccionadas	412
Cómo usar este apéndice	413
Notación mínima	413
SVD	413
PCA	414
K-Means	414
Silhouette	414
Cosine similarity	414
Checklist de interpretación	415
Patrones de código	415


Respuestas seleccionadas	415
Apéndice Módulo 5: formulario y respuestas seleccionadas	418
Cómo usar este apéndice	419
Notación mínima	419
Fórmulas clave	419
Checklist de paquete reproducible	420
Estructura mínima de manifest	420
Lenguaje de defensa	421
Respuestas seleccionadas	421
Información editorial y publicación	424
Información editorial	425
Audiencia	425
Prerrequisitos recomendados	425
Alcance	425
Formato recomendado	426
Cómo citar	426
Accesibilidad	426
Errata y mejoras	427
Separación de materiales	427
Accesibilidad	428
Objetivo de accesibilidad	428
Alcance evaluado	428
Evidencia automática	429
Revisión manual requerida	429
Matemática, código y figuras	429
Barreras conocidas	430
Reporte de barreras	430
Plantillas de revisión	431
Criterio de cierre	431
Equipo, revisión y reconocimientos	432
Autoría y responsabilidad editorial	432
Estado de revisión	432
Cómo reportar una corrección	433
Reconocimientos	433
Criterio para versión publicable	433
Protocolo de revisión externa	435
Propósito de la revisión	435
Roles de revisión	435
Evidencia que recibe el revisor	436
Plantillas de revisión	436
Rúbrica matemática	436

Rúbrica pedagógica	437
Rúbrica computacional	437
Dictamen de revisión	437
Registro de revisiones externas	438
Criterio de cierre	438
Matriz de preparación editorial	439
Niveles de preparación	439
Matriz por partes	440
Matriz por capítulo principal	440
Evidencia mínima por nueva edición	442
Señales de riesgo editorial	443
Características pedagógicas	444
Estructura recurrente	444
Figuras guía	445
Tipos de recursos	445
Estándar de ejercicios	446
Relación con evaluación	446
Estándar de revisión	447
Recursos para estudiantes e instructores	448
Recursos públicos para estudiantes	448
Guías públicas de inicio	448
Recursos restringidos para instructores	449
Cómo estudiar con los recursos	450
Cómo usar los recursos como instructor	450
Flujo de publicación	450
Política de respuestas	451
Guía pública de adopción docente	452
Sistema de sincronización del curso	452
Rutina mínima del profesor	452
Usos posibles del libro	453
Diseño semanal recomendado	453
Separación entre recursos públicos y privados	454
Evaluación con baja carga manual	454
Alineación mínima antes de dictar	454
Adaptación a otro contexto	455
Revisión de calidad antes de publicar	455
Señales de una adopción saludable	455
Referencias y atribuciones	456
Referencia editorial	456
Referencias matemáticas y algorítmicas	456
Documentación técnica	457
Evaluación automatizada	457
Datasets y generadores	457

Figuras	458
Cómo citar este libro	458
Integridad académica y uso de IA	459
Principio central	459
Uso permitido	459
Uso que requiere declaración	459
Uso no permitido	460
Evidencia de trabajo propio	460
Defensa oral	460
Regla práctica antes de entregar	461
Respuestas, solucionarios y recursos restringidos	462
Principio editorial	462
Tipos de recurso	462
Qué puede aparecer en respuestas públicas	463
Qué no debe publicarse	463
Política por tipo de pregunta	463
Respuestas de proyectos	464
Proceso para liberar una respuesta	464
Plantillas de control	464
Criterio de auditoría	465
Errata, revisión y control de calidad	466
Qué cuenta como errata	466
Severidad	466
Flujo de corrección	466
Plantillas de errata	467
Evidencia de cierre	467
Registro público	467
Separación de errata pública y docente	468
Registro público de errata	469
Estado actual	469
Estados de un reporte	469
Errata abierta	469
Errata cerrada	470
Cambios editoriales de edición	470
Criterio de publicación de errata	470
Reportes privados	471
Cómo reportar	471
Criterio de cierre	471
Edición, versión y publicación	472
Ficha de edición	472
Criterio de versión estable	472
Canales de publicación	473
Checklist de publicación	474

Registro de edición	474
Registros de candidato	475
Paquete de publicación	476
Artefactos públicos	476
Manifiesto de publicación	477
Comandos de construcción	478
Comandos de validación	478
Criterio de aceptación	479
Guía de impresión y PDF	480
Relación entre web, PDF e impresión	480
Especificación de PDF	480
Revisión visual obligatoria	481
Prueba de impresión	481
Plantillas de revisión	482
Estado de impresión de esta edición	482
Criterio de aceptación para impresión	482
Licencia y uso del material	483
Estado de licencia	483
Uso permitido en el curso	483
Uso no permitido sin autorización	483
Cita sugerida	484
Materiales de terceros	484
Integridad académica	484
Decisión de licencia abierta	485
Por qué esta decisión importa	485
Opciones razonables	485
Separación por tipo de material	486
Criterios de decisión	486
Registro de decisión pendiente	487
Procedimiento de cierre	487

Prefacio



Este libro fue escrito para el curso **MATE-2105 Matemáticas y Algoritmos en Ciencia de Datos Aplicada**. Presenta algunos de los modelos fundamentales y de uso más frecuente en ciencia de datos. Para cada uno estudia la formulación matemática, los algoritmos utilizados para estimarlo o calcularlo a partir de datos y la interpretación de sus resultados, supuestos y limitaciones.

El texto supone familiaridad con cálculo diferencial y vectorial, álgebra lineal, estadística descriptiva y programación básica en Python. La notación probabilística se introduce a medida que los modelos la requieren: la esperanza condicional aparece en regresión, el riesgo en la formulación de una pérdida, las distribuciones condicionales en clasificación y la variación muestral en validación. Una parte de consulta reúne después estos conceptos en una exposición sistemática. En todo el libro, definiciones, derivaciones, ejemplos resueltos y ejercicios conectan las ideas matemáticas con su implementación y con problemas concretos de ciencia de datos.

La idea que orienta el libro es sencilla: las matemáticas, los algoritmos y el análisis de datos deben estudiarse juntos. Una fórmula adquiere sentido cuando se entiende qué objeto describe, bajo qué supuestos se obtiene y cómo conduce a un procedimiento que puede ejecutarse. De manera recíproca, ejecutar un algoritmo no basta para comprenderlo; también es necesario saber qué objetivo persigue, qué garantías ofrece y en qué situaciones puede fallar.

Por esta razón, los capítulos parten de problemas concretos y avanzan desde su formulación hasta la evaluación de los resultados. Las derivaciones se presentan con suficiente detalle para que el lector pueda reconstruir los argumentos. Los ejemplos resueltos, el código y los ejercicios permiten comprobar las ideas y examinar su comportamiento en casos particulares. Una implementación correcta, sin embargo, no compensa una pregunta mal formulada; tampoco una métrica bien calculada garantiza que las conclusiones sean válidas para la población en la que se quiere utilizar el modelo.

El recorrido comienza con el significado de los datos y con la formulación de preguntas que puedan estudiarse a partir de ellos. La regresión introduce después la primera relación entre una cantidad poblacional, una pérdida empírica y un algoritmo de ajuste. A partir de allí se desarrollan optimización, regularización, clasificación y redes neuronales. Los capítulos posteriores se ocupan de validación, análisis de errores, reducción de dimensión, agrupamiento y recomendación. El libro concluye con reproducibilidad, comunicación técnica y evaluación crítica de los resultados; las herramientas probabilísticas y los apéndices permiten profundizar o consultar las definiciones utilizadas durante el recorrido.

El propósito no es ofrecer un catálogo exhaustivo de métodos de aprendizaje automático, sino estudiar un conjunto representativo con el detalle suficiente para comprender sus fundamentos, derivar sus algoritmos, implementarlos, analizar su comportamiento y reconocer sus limitaciones. Aunque el texto nació para acompañar un curso semestral, sus capítulos están organizados para que también puedan leerse de manera continua y consultarse de forma independiente.

César Galindo
Bogotá, 2026

Orientación para el lector

Este libro puede recorrerse de distintas maneras. La lectura lineal comienza con el significado de los datos y avanza hacia regresión, redes neuronales, evaluación de modelos, aprendizaje no supervisado y reproducibilidad. Los conceptos probabilísticos aparecen dentro de ese recorrido cuando una pregunta los hace necesarios y vuelven a utilizarse en contextos diferentes. Una sección posterior los reúne de forma sistemática para consulta o profundización.

Una lectura temática permite concentrarse en una de las partes, siempre que se consulten los conceptos previos señalados en cada capítulo. El glosario, los índices y los apéndices ofrecen una tercera forma de uso: localizar una definición, un algoritmo, un conjunto de datos o una respuesta seleccionada sin seguir el orden completo del libro.

Cuando una derivación requiera notación que no resulte familiar, conviene revisar el apéndice de [prerrequisitos matemáticos](#). Este reúne la notación de álgebra lineal y cálculo que se usa con mayor frecuencia. Para probabilidad y estadística, los capítulos de [variables, distribuciones y muestras](#) y de [condicionamiento, estimación y riesgo](#) ofrecen una referencia más extensa.

Estructura de los capítulos

Los capítulos comienzan con sus objetivos y, en la mayoría de los casos, con una pregunta que sitúa el problema. A continuación se introducen los objetos matemáticos, los supuestos y los algoritmos necesarios. Las definiciones fijan el lenguaje; las proposiciones y derivaciones explican las relaciones centrales; los ejemplos resueltos muestran cómo se utilizan esas ideas en casos concretos.




Figura 1: Etapas de la modelación: la pregunta inicial orienta el modelo matemático, el algoritmo y la implementación; la validación de los resultados permite revisar las decisiones tomadas.

La Figura 1 resume un recorrido que reaparece a lo largo del libro. Una pregunta conduce a una formulación matemática; el algoritmo y el código permiten trabajar con ella; la validación y la interpretación de los resultados pueden llevar a revisar la pregunta inicial.

El código forma parte del desarrollo. Se usa para hacer explícitas las dimensiones, comprobar identidades, ejecutar algoritmos y estudiar situaciones en las que los cálculos manuales dejan de ser prácticos. Al final de cada capítulo se reúnen los conceptos principales, ejercicios de distinta naturaleza y, cuando corresponde, respuestas seleccionadas.

No todas las páginas requieren la misma velocidad de lectura. Una definición puede necesitar varias consultas; una derivación conviene reconstruirla con lápiz; un ejemplo numérico debe poder repetirse sin mirar la solución; y un fragmento de código se comprende mejor después de anticipar qué objetos recibe y qué resultado debería producir.

Cómo leer un algoritmo

Un algoritmo no queda descrito únicamente por una sucesión de instrucciones. Para comprenderlo es necesario relacionar su representación matemática, el objetivo que persigue y las condiciones bajo las cuales se utiliza. Las siguientes preguntas sirven como guía durante la lectura:

Pregunta	Elemento que conviene identificar
¿Qué recibe y qué produce?	dominio, codominio, dimensiones y tipos de datos
¿Qué objetivo persigue?	riesgo, pérdida, distancia, proyección o factorización
¿De dónde surge cada actualización?	derivada, proyección, minimización parcial o identidad algebraica
¿Qué garantiza?	optimalidad, descenso, convergencia o solamente una heurística
¿Cuál es su costo?	operaciones dominantes, memoria y número de iteraciones
¿Qué puede fallar?	escala, condicionamiento, inicialización, muestreo o cambio de distribución

Cuando un paso no sea claro, suele ser útil localizar la definición o la identidad empleada, comprobar las dimensiones y separar lo que se ha demostrado de lo que se ha supuesto. El propósito no es memorizar la fórmula final, sino poder reconstruir el argumento y reconocer cuándo deja de ser válido.

Código, datos y ejercicios

Los ejemplos de código están escritos principalmente en Python y utilizan NumPy, pandas, scikit-learn y PyTorch. Su función es acompañar el argumento matemático: una implementación permite verificar una derivación, comparar métodos y observar efectos numéricos que no siempre son visibles

en la notación. Antes de ejecutar un bloque conviene anticipar las formas de sus entradas, la salida esperada y una comprobación sencilla del resultado.

Algunos conjuntos de datos reaparecen en distintos capítulos. Esta continuidad permite estudiar cómo cambia una misma pregunta al introducir nuevos modelos o criterios de evaluación. La página de [casos longitudinales](#) describe esos conjuntos, su procedencia y los capítulos en los que se utilizan.

Los ejercicios incluyen preguntas conceptuales, cálculos manuales, interpretaciones, implementaciones y problemas integradores. Las respuestas seleccionadas permiten comprobar resultados concretos, pero no sustituyen la argumentación. En los problemas abiertos puede haber más de una solución razonable; en esos casos importan tanto los supuestos y el procedimiento como la respuesta final.

Parte I: Datos y preguntas

En un conjunto de datos, una fila puede representar una persona, una transacción, una región o el resultado de un experimento. Su significado depende del procedimiento con el que fue registrada, de las variables disponibles y de la población sobre la que se quiere formular una conclusión. Identificar estos elementos es el primer paso para construir un modelo.

La tabla, por sí sola, no determina la pregunta. Un mismo archivo puede utilizarse para describir lo observado, predecir una respuesta futura o investigar una relación causal, pero cada propósito exige supuestos y métodos diferentes. Antes de elegir un algoritmo conviene precisar la unidad de observación, el momento en que se conocen las variables, la población de interés y el tipo de conclusión que los datos permiten sostener.

El capítulo de esta parte desarrolla ese paso inicial. Muestra cómo pasar de la documentación de un conjunto de datos a una formulación matemática con variables de entrada, una posible respuesta y una familia de tareas. También distingue una tabla original de la matriz que recibe un algoritmo y examina dos problemas que aparecen antes de cualquier ajuste: la calidad de la medición y la filtración de información.

La incertidumbre aparecerá a medida que avancemos. En regresión preguntaremos qué cantidad poblacional aproxima una predicción; al comparar modelos estudiaremos por qué el resultado cambia con la muestra; en clasificación necesitaremos probabilidades condicionales, y en PCA surgirá la diferencia entre una covarianza poblacional y su versión empírica. De esta manera, el lenguaje probabilístico se introducirá donde cada problema lo haga necesario.

Observaciones, variables y preguntas

Cómo definir los objetos de un problema con datos

Un conjunto de datos no es solamente una colección de números. Cada fila procede de una persona, un objeto, un lugar, un instante o un experimento; cada columna resume una característica registrada mediante algún procedimiento. Antes de elegir un modelo es necesario establecer qué representan esos registros, de qué población proceden y qué preguntas permiten responder.

Este capítulo desarrolla ese trabajo preliminar y define con precisión los objetos que más adelante aparecerán en las fórmulas. Una matriz de diseño, una variable objetivo o una predicción solo tienen sentido después de fijar su interpretación.

Al terminar el capítulo, el lector podrá:

1. distinguir unidad de observación, unidad de análisis y nivel de agregación;
2. describir una variable mediante su dominio, unidad y procedimiento de medición;
3. diferenciar población objetivo, marco de observación y muestra disponible;
4. formular preguntas descriptivas, predictivas y causales sin confundir sus alcances;
5. traducir una tabla a una representación matemática conservando su significado;
6. distinguir una familia de modelos, un algoritmo de ajuste y un modelo ajustado;
7. reconocer problemas de cobertura, medición, disponibilidad temporal y calidad de los datos.

Un caso para comenzar

La Secretaría Distrital del Hábitat publica una caracterización de precios de vivienda nueva en Bogotá. Para los ejemplos de este libro se congeló un subconjunto de 32 subzonas y siete columnas. Cinco filas tienen la forma siguiente.

subzona	precio reportado	estrato prom.	área prom.
Rosales	16.365	5.922	177.316
Chicó	13.939	5.905	128.044
Bosque Medina	10.751	4.699	151.226
Multicentro	10.365	5.647	94.071
Centro	9.504	3.195	63.383

subzona	alcobas prom.	baños prom.	parqueaderos prom.
Rosales	2.673	3.776	2.981
Chicó	2.225	3.105	2.152
Bosque Medina	2.533	3.037	2.467
Multicentro	2.086	2.625	1.786
Centro	1.744	1.799	0.988

La tabla puede leerse de varias maneras equivocadas. Una fila no representa una vivienda, sino una subzona. Las columnas numéricas son promedios o indicadores de esa subzona, no mediciones individuales. Además, el archivo fuente llama **precios** a una de las columnas, pero no documenta su unidad en el recurso descargado. Por esta razón usamos el nombre **precio_reportado** y no afirmamos que la cifra esté expresada en pesos, millones de pesos o precio por metro cuadrado.



Figura 2: Las 32 filas representan subzonas de Bogotá y no viviendas individuales. El eje horizontal usa el campo de precio reportado, cuya unidad no está documentada en el archivo fuente.

La figura permite comparar el orden y la dispersión del indicador dentro de las 32 filas. No permite valorar una vivienda particular ni completar una unidad de medida ausente. Esta diferencia entre lo que muestran los datos y lo que quisiéramos saber será recurrente a lo largo del libro.

Unidades de observación y niveles de análisis

Unidad de observación. La unidad de observación es la entidad, evento o intervalo representado por un registro. Puede ser una persona, una transacción, una imagen, una subzona, un paciente en una visita o el resultado de un experimento.

La descripción de la unidad debe incluir más que un sustantivo. También interesa el periodo de registro, el lugar, los criterios de inclusión y el procedimiento que produjo la fila. “Paciente” y “visita de un paciente” definen unidades distintas. Si una misma persona aparece en cinco visitas, las cinco filas no constituyen cinco personas independientes.

La **unidad de análisis** es la entidad sobre la cual se formula la conclusión. Con frecuencia coincide con la unidad de observación, pero no siempre. Una tabla puede registrar transacciones y utilizarse para estudiar comercios; puede registrar estudiantes y utilizarse para comparar colegios; puede registrar subzonas y pretender describir viviendas. Cuando las unidades no coinciden, es necesario especificar cómo se agregan los registros y qué información se pierde.

Ejemplo 1: registros hospitalarios. Un archivo contiene una fila por consulta. La pregunta “¿qué consultas terminarán en hospitalización?” tiene la consulta como unidad de observación y de análisis. La pregunta “¿qué pacientes tendrán al menos una hospitalización durante el año?” exige agrupar consultas por paciente y fijar un intervalo temporal. Usar cada consulta como si fuera un paciente alteraría el denominador y podría colocar consultas de una misma persona en conjuntos distintos.

Identificadores y repetición

Un identificador permite reconocer la unidad registrada. No siempre es una variable útil para predecir. Un número de documento puede ser indispensable para detectar duplicados y, al mismo tiempo, ser inadecuado como entrada de un modelo.

Conviene distinguir:

- **identificador de registro**, que diferencia filas;
- **identificador de unidad**, que permite reconocer observaciones repetidas de la misma entidad;
- **identificador de grupo**, que señala hospital, colegio, región o dispositivo;
- **marca temporal**, que sitúa la observación y permite reconstruir el orden.

Estas columnas determinan dependencias que no se ven en una matriz numérica. Más adelante condicionarán la manera de construir muestras de entrenamiento y evaluación.

Agregación y falacia ecológica

En la tabla de Bogotá, **area_promedio** es un resumen de subzona. Una relación entre **area_promedio** y **precio_reportado** describe asociaciones entre subzonas. No se deduce de ella la relación correspondiente entre viviendas dentro de cada subzona.

Inferir un comportamiento individual a partir de datos agregados se conoce como **falacia ecológica**. El problema no se resuelve aumentando el número de subzonas: la información individual fue reemplazada por resúmenes. Tampoco puede recuperarse la variación interna de cada grupo a partir de un promedio aislado.

Ejemplo 2: dos subzonas con el mismo promedio. En una subzona, las áreas de dos viviendas pueden ser 80 y 120 metros cuadrados; en otra, 99 y 101. Ambas tienen promedio 100, pero su variación interna es diferente. Una tabla que conserva solo el promedio no permite distinguirlas.

Variables, valores y mediciones

Variable. Una variable es una característica que puede tomar distintos valores en las unidades consideradas. Su definición incluye un dominio de valores posibles y una regla, explícita o implícita, para asignar un valor a cada unidad.

Una columna es la representación computacional de los valores registrados para una variable. Variable y columna no son sinónimos perfectos. Una variable puede requerir varias columnas, como una fecha separada en año, mes y día; una columna puede ser un identificador técnico sin interpretación sustantiva; y una variable no observada directamente puede construirse a partir de otras mediciones.

Dominio y tipo de variable

El dominio describe qué valores admite una variable. Algunas categorías útiles son:

Tipo conceptual	Ejemplo	Operaciones con sentido
binaria	hospitalización: sí/no	proporción, comparación de categorías
categórica nominal	localidad	igualdad, conteos, frecuencias
categórica ordinal	nivel bajo/medio/alto	orden y comparaciones ordinales
conteo	número de visitas	suma, diferencia, razón bajo condiciones
continua	área construida	diferencias, promedios, transformaciones
temporal	fecha de venta	orden, duración, estacionalidad
texto, imagen o señal	descripción, radiografía, audio	representación específica del objeto

El tipo almacenado por un programa no decide el tipo conceptual. Un código postal puede aparecer como entero y seguir siendo categórico; convertirlo a `float` no hace razonable promediarlo. De forma inversa, un número guardado como texto puede representar una medición continua que necesita limpieza.

Escala y unidad

La unidad determina la interpretación de diferencias y proporciones. Una longitud en metros y la misma longitud en centímetros contienen la misma información, pero producen coeficientes numéricos diferentes. Una temperatura en grados Celsius admite diferencias con sentido, aunque la razón “20 es el doble de 10” no tenga la interpretación física usual de una escala con cero absoluto.

Por ello, antes de calcular conviene registrar:

1. definición de la variable;
2. unidad y escala;

3. instante o periodo al que se refiere;
4. instrumento o fuente;
5. transformaciones aplicadas;
6. códigos especiales y valores faltantes.

Medición y construcción

No toda variable es observada de manera directa. “Ingreso mensual” puede proceder de una declaración, un registro tributario o una imputación. “Satisfacción” puede ser la respuesta a una escala. “Riesgo” puede ser un índice construido a partir de varias columnas. Cada procedimiento define un objeto diferente, aunque los nombres se parezcan.

Procedimiento de medición. Es la regla mediante la cual una propiedad de una unidad se transforma en un valor registrado. Incluye instrumento, protocolo, momento, resolución, redondeo y tratamiento de casos no observables.

El error de medición es la diferencia entre el valor registrado y la cantidad que se pretendía medir. No es lo mismo que un residual de un modelo, que se calcula después de comparar una observación con una predicción. La distinción se retomará al estudiar modelos probabilísticos.

Datos faltantes

Un valor faltante no es necesariamente cero y tampoco constituye una categoría ordinaria. Puede faltar porque la medición no aplica, porque no se realizó, porque el participante no respondió o porque el sistema perdió el registro. Esas causas pueden contener información.

Antes de imputar o eliminar filas deben responderse al menos tres preguntas:

- ¿qué significa la ausencia en esta variable?;
- ¿puede conocerse la causa con las demás columnas?;
- ¿cambia la frecuencia de ausencia entre grupos, periodos o valores del resultado?

La teoría estadística de los mecanismos de ausencia requiere supuestos adicionales. En esta etapa basta con no ocultar la ausencia bajo una transformación automática.

El diccionario de datos

Un diccionario de datos conserva el significado que se pierde al convertir una tabla en un arreglo. Para cada columna debería indicar, cuando corresponda:

Campo	Pregunta que debe responder
nombre	¿cómo se identifica en el archivo?
descripción	¿qué propiedad representa?
dominio	¿qué valores son admisibles?
unidad	¿en qué escala se expresa?
procedencia	¿qué sistema o instrumento la produjo?

Campo	Pregunta que debe responder
disponibilidad	¿en qué momento se conoce?
transformación	¿es original, agregada o derivada?
faltantes	¿qué códigos y causas de ausencia existen?

Para el subconjunto de Bogotá puede escribirse un diccionario parcial:

variable	papel	interpretación disponible	limitación principal
subzona	identificador	nombre de la subzona	no identifica viviendas
precio_reportado	posible salida	indicador llamado precios en la fuente	unidad no documentada
estrato_promedio	entrada	promedio reportado por subzona	oculta variación interna
area_promedio	entrada	área promedio reportada	tipo de área no documentado aquí
alcobas_promedio	entrada	promedio de alcobas	no es conteo de una vivienda
banos_promedio	entrada	promedio de baños	no es conteo de una vivienda
parqueaderos_promedio	entrada	promedio de parqueaderos	no es conteo de una vivienda

Este diccionario no completa información ausente. Su valor consiste precisamente en separar lo conocido de lo supuesto.

Población, marco de observación y muestra

Una tabla contiene unidades observadas. Para interpretar una conclusión también debemos precisar el conjunto más amplio al que se refiere.

Población objetivo. Es el conjunto de unidades, lugares y periodos sobre los que se desea formular una conclusión.

Marco de observación. Es el conjunto de unidades que el procedimiento de recolección podía identificar o incluir. Puede ser más pequeño o diferente de la población objetivo.

Muestra observada. Es el conjunto de unidades del marco que finalmente aparece en los datos después de aplicar criterios de inclusión, respuesta, disponibilidad y limpieza.

Estas tres colecciones pueden diferir. Si la población objetivo son todos los hogares de una ciudad y el marco contiene solo hogares con conexión fija a internet, ningún tamaño de muestra dentro de ese marco incluye a quienes quedaron fuera. El problema es de cobertura, no de precisión numérica.

La relación puede resumirse así:

población objetivo $\rightarrow$ marco de observación $\rightarrow$ muestra registrada $\rightarrow$ tabla analizada.

Cada flecha corresponde a un mecanismo: cobertura, selección, respuesta, medición o procesamiento. Una conclusión sobre la población requiere que esos mecanismos sean compatibles con la comparación que se pretende realizar.

Un censo también tiene alcance limitado

Observar todas las unidades de un marco en un instante elimina el error asociado a seleccionar solo algunas de ellas, pero no resuelve otros problemas. El marco puede excluir unidades, las mediciones pueden contener errores y la población futura puede cambiar. Un “censo” de transacciones de 2025 sigue siendo una muestra de los periodos posibles si la pregunta se refiere a 2026.

¿Qué población corresponde al caso de Bogotá?

La respuesta depende de la pregunta. Podríamos interesarnos por las 32 subzonas en el periodo documentado, por todas las subzonas de Bogotá, por proyectos de vivienda nueva o por viviendas particulares. La tabla no convierte automáticamente una de estas opciones en población objetivo. Además, no conocemos aquí el mecanismo de selección de las 32 subzonas ni la unidad del indicador. Por ello, el caso sirve para estudiar asociaciones entre los resúmenes disponibles, no para valorar viviendas individuales ni para describir sin reservas toda la ciudad.

El capítulo siguiente representará muestras y poblaciones mediante distribuciones de probabilidad. Esa formalización no reemplaza la descripción del marco: primero debe quedar claro de qué proceso podría ser muestra la tabla.

De una pregunta amplia a una pregunta precisa

“Analizar vivienda en Bogotá” expresa un tema, pero no una pregunta matemática. Una pregunta precisa debe indicar qué unidad se estudia, qué cantidad se quiere obtener y a qué población se refiere.

Preguntas descriptivas

Una pregunta descriptiva resume lo observado:

¿Cómo se distribuye `precio_reportado` entre las 32 subzonas del archivo?

La respuesta puede incluir tablas, gráficos, medias o cuantiles. Su alcance inmediato son las filas observadas. Extenderla a otras subzonas o periodos exige un argumento adicional sobre la manera en que se obtuvo la muestra.

Preguntas predictivas

Una pregunta predictiva busca anticipar un resultado que no estará disponible en el momento de aplicar la regla. Conviene especificar cinco elementos:

1. **unidad:** ¿para qué tipo de caso se produce la predicción?;
2. **salida:** ¿qué valor o categoría se quiere anticipar?;
3. **momento:** ¿cuándo se realiza la predicción y para qué horizonte?;
4. **información disponible:** ¿qué variables se conocen en ese instante?;
5. **población de uso:** ¿sobre qué casos se aplicará el procedimiento?

Una formulación compatible con el ejemplo sería:

Para una subzona descrita por los promedios disponibles, estimar el indicador `precio_reportado` y evaluar el procedimiento en subzonas comparables que no participaron en el ajuste.

Esta formulación no promete valorar viviendas ni explicar por qué cambia el indicador.

Preguntas causales

Una pregunta causal se refiere al efecto de una intervención o exposición:

¿Cómo cambiaría el resultado si, manteniendo lo demás apropiadamente comparable, se modificara una condición determinada?

Una asociación útil para predecir no identifica por sí sola ese efecto. Si `estrato_promedio` y `precio_reportado` cambian juntos, un modelo puede aprovechar la asociación sin que una modificación administrativa del estrato produzca el cambio predicho. Para sostener una afirmación causal se necesita definir la intervención, establecer qué comparación la representa y justificar supuestos sobre asignación, confusión y medición.

Una misma tabla admite preguntas diferentes

El conjunto `load_wine` de `scikit-learn` contiene mediciones químicas de vinos y tres clases de cultivar. La misma tabla permite formular, entre otras, estas preguntas:

- describir la distribución de una concentración en la muestra;
- predecir la clase de cultivar a partir de las mediciones;
- estimar una concentración continua usando las demás variables;
- explorar una representación de baja dimensión sin escoger una salida.

La tabla no determina por sí sola la tarea. El papel de una columna depende de la pregunta. Una variable puede ser entrada en un análisis y salida en otro.

Familias de tareas

Una vez definida la pregunta, la forma de la salida orienta la familia de métodos.

Pregunta	Salida matemática	Familia habitual
estimar una cantidad	número real	regresión
asignar una categoría	elemento de un conjunto finito	clasificación
estimar una probabilidad	vector de probabilidades	clasificación probabilística
ordenar alternativas	puntaje u orden	ranking y recomendación
representar estructura sin salida	coordenadas, grupos o factores	aprendizaje no supervisado
estimar efecto de una intervención	contraste entre resultados potenciales	inferencia causal

Las fronteras no siempre son absolutas. Una variable ordinal puede tratarse como categoría o como valor ordenado; un conteo puede modelarse mediante regresión con una distribución específica; una probabilidad estimada puede convertirse en una decisión después de fijar costos y umbrales. La elección debe corresponder al significado de la salida, no únicamente al tipo almacenado en el archivo.

De la tabla a la notación matemática

Sea una tabla con m registros. Denotamos el registro observado en la fila i por

$$z_i = (z_{i1}, \dots, z_{ip}),$$

donde cada coordenada representa una variable registrada. La colección ordenada de registros es

$$d_m = (z_1, \dots, z_m).$$

Usamos aquí letras minúsculas porque los valores ya fueron observados. En el capítulo siguiente introduciremos las variables aleatorias Z_i y reservaremos $D_m = (Z_1, \dots, Z_m)$ para la muestra antes de observarla.

Problemas supervisados

Si una variable cumple el papel de salida, escribimos

$$z_i = (x_i, y_i),$$

donde x_i reúne la información de entrada y y_i es el resultado observado. Cuando todas las entradas son numéricas y tienen una representación de dimensión d , se organizan como

$$X = \begin{bmatrix} x_1^\top \\ \vdots \\ x_m^\top \end{bmatrix} \in \mathbb{R}^{m \times d}, \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}.$$

La fila i de X y la entrada i de y deben referirse a la misma unidad. La forma de los arreglos es parte del contrato matemático:

- m es el número de observaciones;
- d es el número de características después de la representación;
- $x_i \in \mathbb{R}^d$ describe una observación;
- y_i pertenece al espacio de salidas, que puede ser $\mathbb{R}$, un conjunto de clases u otro dominio.

Para el caso de Bogotá podríamos seleccionar cinco entradas:

```
features = [
    "estrato_promedio",
    "area_promedio",
    "alcobas_promedio",
    "banos_promedio",
    "parqueaderos_promedio",
]

X = tabla[features]
y = tabla["precio_reportado"]

assert X.shape == (32, 5)
assert y.shape == (32,)
```

Tabla original y matriz de diseño

No toda tabla puede introducirse directamente en $\mathbb{R}^{m \times d}$. Las categorías necesitan una codificación; las fechas pueden transformarse en duraciones o componentes estacionales; el texto y las imágenes requieren una representación; los valores faltantes necesitan un tratamiento explícito.

Podemos escribir una transformación de características como

$$\phi : \mathcal{X}_{\text{raw}} \longrightarrow \mathbb{R}^d, \quad x_i = \phi(x_i^{\text{raw}}).$$

La matriz formada por los vectores $\phi(x_i^{\text{raw}})$ es una **matriz de diseño**. La transformación ϕ puede estar completamente fijada de antemano o contener cantidades aprendidas de los datos, como medias para estandarizar o categorías observadas. En el segundo caso, su ajuste forma parte del procedimiento estadístico y debe realizarse sin consultar observaciones reservadas.

 La matriz no conserva toda la información

Al convertir una tabla a **numpy**, los valores y las dimensiones permanecen, pero pueden desaparecer nombres, unidades, identificadores y fechas. La representación numérica debe

acompañarse de un diccionario y de las reglas que produjeron cada columna.

Modelo, algoritmo y resultado ajustado

En este libro un **modelo predictivo** es una familia de funciones

$$\mathcal{F} = \{f_\theta : \theta \in \Theta\}, \quad f_\theta : \mathcal{X} \longrightarrow \mathcal{Y}.$$

El parámetro θ identifica una función dentro de la familia. Por ejemplo, en una familia lineal,

$$f_{\beta_0, \beta}(x) = \beta_0 + x^\top \beta,$$

los parámetros son el intercepto β_0 y el vector de coeficientes β .

Un **algoritmo de ajuste** recibe datos y produce parámetros. Si lo denotamos por A , entonces

$$A(d_{\text{train}}) = \hat{\theta}.$$

La función $f_{\hat{\theta}}$ es el **modelo ajustado**. Para una entrada nueva x produce

$$\hat{y} = f_{\hat{\theta}}(x).$$

Estos objetos no deben confundirse:

Objeto	Ejemplo	Qué lo determina
familia de modelos	funciones lineales	decisión de modelación
parámetro	coeficientes β	algoritmo y datos de ajuste
hiperparámetro	intensidad de regularización	procedimiento de selección
modelo ajustado	$f_{\hat{\theta}}$	familia, algoritmo y muestra
predicción	$f_{\hat{\theta}}(x)$	modelo ajustado y entrada nueva

Un hiperparámetro controla la familia o el algoritmo, pero no se obtiene en el ajuste ordinario de parámetros. Su elección también utiliza datos y, por tanto, debe incluirse al describir el procedimiento completo.

Ajustar y aplicar son operaciones distintas

Durante el ajuste,

$$d_{\text{train}} \mapsto \hat{\theta}.$$

Durante la aplicación,

$$x_{\text{nuevo}} \mapsto f_{\hat{\theta}}(x_{\text{nuevo}}),$$

con $\hat{\theta}$ ya fijado. Esta distinción permite preguntar qué información estaba disponible en cada momento. Si una variable solo se conoce después del resultado, no puede formar parte de x_{nuevo} en un sistema que intenta anticiparlo.

Disponibilidad temporal y filtración de información

Para cada variable predictora conviene registrar un tiempo de disponibilidad. Si t_0 es el momento de predicción, una entrada válida debe estar disponible en t_0 bajo las condiciones reales de uso.

Filtración de información. Hay filtración, o *data leakage*, cuando el procedimiento utiliza para ajustar, seleccionar o representar un caso información que no estaría disponible en el momento de uso o que pertenece a observaciones reservadas para evaluación.

Ejemplos frecuentes son:

- predecir hospitalización con un código registrado al dar de alta;
- predecir fraude con el resultado de la investigación posterior;
- calcular una media de estandarización con toda la tabla antes de separar datos;
- imputar faltantes utilizando observaciones reservadas;
- permitir que registros de una misma persona aparezcan a ambos lados de una partición que pretende evaluar personas nuevas.

Una transformación determinista fijada de antemano, como elevar una medición al cuadrado, no consulta otras filas. En cambio, una transformación que estima medias, categorías, componentes principales o variables seleccionadas aprende de la muestra y debe tratarse como parte del algoritmo A .

Calidad de datos como propiedad de la pregunta

La calidad no es una propiedad absoluta del archivo. Una columna puede ser suficiente para una descripción agregada e insuficiente para una predicción individual. Por eso la revisión debe relacionarse con la pregunta.

Dimensión	Pregunta de revisión
cobertura	¿qué unidades de la población no podían aparecer?
selección	¿por qué unas unidades quedaron incluidas y otras no?
medición	¿qué se midió y con qué precisión?
completitud	¿qué valores faltan y por qué?
unicidad	¿hay duplicados o registros repetidos legítimos?
consistencia	¿las definiciones se mantienen entre fuentes y periodos?
temporalidad	¿cada variable estaba disponible al producir la salida?
granularidad	¿la unidad registrada coincide con la unidad de la pregunta?
trazabilidad	¿puede reconstruirse la transformación desde la fuente?

La revisión establece qué afirmaciones admite un conjunto de datos para la pregunta formulada y cuáles requerirían información diferente.

Análisis completo del caso de Bogotá

Podemos ahora describir el ejemplo sin atribuirle información que no contiene.

Unidad de observación. Una subzona de Bogotá resumida por la fuente.

Nivel de agregación. Cada fila contiene promedios o indicadores de la subzona; no hay registros de viviendas individuales.

Muestra disponible. Un subconjunto congelado de 32 subzonas. El archivo del libro conserva la fuente y las transformaciones en un manifiesto, pero no completa la unidad ausente de `precio_reportado`.

Pregunta descriptiva admisible. Comparar los valores registrados y las asociaciones entre columnas dentro de las 32 subzonas.

Pregunta predictiva posible. Estudiar si los promedios disponibles contienen información para anticipar `precio_reportado` en subzonas comparables, declarando que el tamaño es pequeño y que la población de uso debe justificarse.

Afirmaciones no sustentadas. Valorar una vivienda, interpretar el coeficiente como efecto causal, asignar una unidad al indicador o generalizar automáticamente a todos los proyectos de la ciudad.

El archivo puede inspeccionarse con:

```
import pandas as pd

ruta = "datos/vivienda_nueva_bogota_subzonas.csv"
tabla = pd.read_csv(ruta)

print(tabla.shape)
print(tabla.dtypes)
print(tabla.isna().sum())
print(tabla.head())
```

Estas operaciones verifican forma, tipos computacionales y faltantes. No verifican por sí solas la interpretación. Para ello siguen siendo necesarios la ficha de la fuente, el diccionario de datos y el análisis de la unidad de observación.

Una ficha mínima para iniciar un análisis

Antes de ajustar un modelo resulta útil escribir una ficha breve:

1. **Fuente y versión:** procedencia, fecha de descarga y licencia.
2. **Unidad de observación:** qué representa una fila y cómo se identifica.
3. **Población objetivo:** dónde y cuándo se quiere aplicar la conclusión.
4. **Marco y selección:** qué unidades podían aparecer y cómo fueron incluidas.
5. **Variables:** significado, dominio, unidad y tiempo de disponibilidad.
6. **Pregunta:** descriptiva, predictiva o causal; salida y uso previsto.
7. **Representación:** cómo se transformará la tabla en objetos matemáticos.
8. **Limitaciones iniciales:** información ausente, agregación, medición y posibles dependencias.

Esta ficha no reemplaza el análisis exploratorio. Evita que el análisis comience con objetos mal definidos y ofrece un punto de referencia cuando cambian las decisiones de modelación.

Síntesis

Una fila representa una unidad registrada mediante un procedimiento concreto. La unidad puede diferir de aquella sobre la que se desea concluir, especialmente en datos repetidos o agregados. Una columna representa valores observados de una variable, pero su nombre y su tipo computacional no sustituyen la definición, la unidad ni el mecanismo de medición.

La muestra disponible procede de un marco de observación y este puede diferir de la población objetivo. Cobertura, selección, medición y tiempo determinan el alcance de los datos. Una pregunta descriptiva resume lo observado; una pregunta predictiva anticipa una salida para casos de uso definidos; una pregunta causal compara intervenciones y requiere supuestos adicionales.

La traducción matemática organiza los registros como $d_m = (z_1, \dots, z_m)$ y, en un problema supervisado, como pares (x_i, y_i) . Una familia de modelos $\{f_\theta\}$, un algoritmo de ajuste A y un modelo ajustado $f_{\hat{\theta}}$ son objetos diferentes. Esta separación será esencial cuando la muestra misma se represente como aleatoria y se estudie la variación de los resultados obtenidos a partir de ella.

Términos clave

- **Unidad de observación:** entidad, evento o intervalo representado por una fila.
- **Unidad de análisis:** entidad sobre la que se formula la conclusión.
- **Nivel de agregación:** escala a la que se resumen o registran los datos.
- **Variable:** característica con un dominio de valores y una regla de medición.
- **Procedimiento de medición:** mecanismo que produce un valor registrado.
- **Población objetivo:** conjunto sobre el que se desea concluir.
- **Marco de observación:** unidades que podrían ser identificadas por la recolección.
- **Muestra observada:** unidades que finalmente aparecen en la tabla analizada.
- **Matriz de diseño:** representación numérica de las entradas de un problema.
- **Parámetro:** cantidad que identifica una función dentro de una familia de modelos.
- **Hiperparámetro:** configuración del modelo o algoritmo elegida por un procedimiento de selección.
- **Filtración de información:** uso de información no disponible en el momento o la muestra apropiados.

Ejercicios

Comprensión conceptual

1. Un archivo de transporte contiene una fila por validación de tarjeta. Proponga una pregunta cuya unidad de análisis sea la validación y otra cuya unidad sea la persona. ¿Qué identificadores necesitaría para la segunda?
2. Explique por qué 32 promedios de subzona no equivalen a 32 mediciones de viviendas. Construya dos conjuntos de valores individuales con el mismo promedio y distinta variación.
3. Dé un ejemplo en el que el tipo `int` de una columna no corresponda a una variable cuantitativa. Indique qué operaciones carecerían de sentido.
4. Distinga población objetivo, marco de observación y muestra en una encuesta enviada por correo institucional a estudiantes matriculados.
5. Explique por qué un censo de todas las ventas realizadas durante un mes puede seguir siendo insuficiente para una pregunta sobre ventas del año siguiente.
6. Formule sobre un mismo conjunto de datos una pregunta descriptiva, una predictiva y una causal. Identifique qué información adicional exige cada una.
7. ¿Por qué el papel de “variable objetivo” no es una propiedad permanente de una columna?
8. Distinga familia de modelos, algoritmo de ajuste, parámetro, hiperparámetro y predicción mediante un ejemplo de regresión.

Representación y cálculo

9. Una tabla contiene 240 pacientes, 12 variables numéricas, 3 variables categóricas y una salida binaria. Si cada variable categórica se codifica con 4 columnas indicadoras, ¿cuál es la dimensión de la matriz de diseño sin contar intercepto? Declare cualquier supuesto necesario.
10. Escriba explícitamente la matriz X y el vector y para las observaciones $(x_1, y_1) = ((1, 2), 5)$, $(x_2, y_2) = ((0, 3), 4)$ y $(x_3, y_3) = ((-1, 1), 0)$. Indique las dimensiones.
11. Una tabla registra 800 visitas de 300 pacientes. Explique por qué una partición de filas puede colocar información de un mismo paciente en ajuste y evaluación. Proponga una unidad apropiada para formar los grupos.
12. Para una variable de fecha t , proponga una transformación $\phi(t)$ que represente mes y día de la semana. Indique qué información se conserva y cuál se pierde.
13. Considere $f_{\beta_0, \beta}(x) = \beta_0 + x^\top \beta$ con $x \in \mathbb{R}^5$. ¿Cuántos parámetros escalares tiene el modelo? ¿Cambia ese número si hay 32 o 3200 observaciones?
14. Una variable se expresa primero en metros y luego en centímetros. Explique cómo cambia su columna y por qué la realidad medida no cambia. Anticipe qué ocurriría con el coeficiente de una regresión lineal que utiliza esa variable.

Datos y código

15. Cargue el CSV de Bogotá. Verifique forma, nombres, tipos y faltantes. Produzca un diccionario de datos en una tabla separada; no complete unidades que la fuente no documenta.
16. Busque duplicados en `subzona`. Explique qué significaría encontrar uno y qué información necesitaría antes de eliminarlo.
17. Escriba una función que reciba una tabla, una lista de predictores y una salida, y verifique que las columnas existen, que la salida no está entre los predictores y que X y y tienen el mismo número de filas.
18. Con `load_wine`, identifique unidad de observación, salida, número de entradas y dominio de cada tipo de variable. Formule dos preguntas distintas que usen la misma tabla.
19. Construya un ejemplo pequeño donde una categoría nueva aparezca después de haber definido una codificación. Explique por qué la transformación debe especificar cómo tratar categorías desconocidas.

Análisis y formulación

20. Un hospital quiere predecir reingreso a 30 días. Para cada una de estas variables, determine si estaría disponible al momento del alta: diagnóstico inicial, medicación de alta, número de llamadas posteriores y código del reingreso. Justifique.
21. Una aplicación recoge datos solo de usuarios que aceptan compartir su ubicación. Describa la población objetivo, el marco observado y una posible diferencia sistemática entre usuarios incluidos y excluidos.

22. Redacte una pregunta predictiva completa para un problema de su interés. Debe indicar unidad, salida, momento, información disponible y población de uso.
23. Para el caso de Bogotá, escriba dos conclusiones admisibles y dos conclusiones que excedan la información disponible. Señale exactamente qué dato o supuesto falta en cada caso.
24. Prepare la ficha mínima de un conjunto de datos que considere para un proyecto. Identifique al menos una limitación de cobertura, una de medición y una de temporalidad.

Respuestas seleccionadas

2. Los conjuntos $(80, 120)$ y $(99, 101)$ tienen promedio 100, pero el primero presenta mucha mayor dispersión. El promedio no permite reconstruir la distribución interna de una subzona.
4. La población objetivo podría ser todo el estudiantado sobre el que se desea concluir. El marco contiene estudiantes matriculados con correo institucional activo. La muestra observada contiene quienes recibieron y respondieron la encuesta. Cada transición puede excluir unidades diferentes.
9. Bajo el supuesto de cuatro columnas por cada una de las tres variables categóricas, la dimensión es $240 \times (12 + 3 \cdot 4) = 240 \times 24$. Si se elimina una categoría de referencia por variable, la dimensión cambia a 240×21 .

10.

$$X = \begin{bmatrix} 1 & 2 \\ 0 & 3 \\ -1 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 2}, \quad y = \begin{bmatrix} 5 \\ 4 \\ 0 \end{bmatrix} \in \mathbb{R}^3.$$

13. El intercepto aporta un parámetro y $\beta \in \mathbb{R}^5$ aporta cinco; hay seis parámetros escalares. El número no depende del tamaño de muestra, aunque la información disponible para estimarlos sí cambia.
20. El diagnóstico inicial y la medicación de alta pueden estar disponibles al alta si el sistema los registra a tiempo. Las llamadas posteriores y el código de reingreso ocurren después y producirían filtración para una predicción realizada al alta.

Parte II: Regresión, optimización y clasificación

Predecir una cantidad numérica obliga a distinguir dos problemas. Con los datos observados podemos minimizar una suma de errores; fuera de ellos queremos que la regla conserve un desempeño adecuado en nuevas observaciones. La regresión lineal permite estudiar ambos problemas con una combinación especialmente clara de probabilidad, álgebra lineal y cálculo.

El primer capítulo presenta la media condicional como objetivo poblacional bajo pérdida cuadrática y los mínimos cuadrados como su aproximación dentro de una familia lineal. El segundo convierte el gradiente de esa pérdida en un algoritmo iterativo y estudia cómo el escalamiento y el condicionamiento afectan su convergencia. Cuando la familia de modelos se vuelve más flexible, la variación entre muestras conduce de manera natural a regularización y validación.

El último modelo de esta parte cambia una respuesta numérica por una etiqueta. La regresión logística introduce entonces una probabilidad condicional, un modelo Bernoulli y la log-loss. El modelo produce una probabilidad estimada; la decisión final requiere además una métrica, un umbral y una descripción de los errores que resultan relevantes en el problema.




Figura 3: Geometría de mínimos cuadrados: las predicciones forman una proyección de y sobre el espacio columna de X ; el residual queda perpendicular a ese espacio.

La figura muestra la geometría del ajuste lineal. La predicción se encuentra en el espacio generado por las columnas de la matriz de diseño y el residual queda perpendicular a ese espacio. Esta interpretación geométrica reaparecerá al estudiar proyecciones, regularización y reducción de dimensión.

Capítulo 1: Regresión lineal múltiple

Matrices, mínimos cuadrados, ecuación normal e interpretación

Pregunta aplicada

¿Cómo podemos predecir una cantidad numérica usando varias variables, escribir el modelo como álgebra matricial y defender si supera una regla simple?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. representar una observación nueva mediante un par aleatorio (X, Y) ;
2. explicar por qué la media condicional minimiza la pérdida cuadrática esperada;
3. distinguir riesgo poblacional, pérdida empírica, estimador y estimación;
4. representar un problema de regresión con una matriz de diseño;
5. distinguir variables, parámetros, predicciones y residuales;
6. escribir MSE como norma cuadrática y derivar su gradiente;
7. derivar la ecuación normal;
8. implementar mínimos cuadrados con `np.linalg.lstsq` y explicar por qué se evita formar una inversa explícita;
9. comparar un modelo lineal contra un baseline;
10. interpretar coeficientes con cuidado.

La regresión lineal parece elemental, pero contiene la gramática de muchos de los modelos que estudiaremos después: datos como matrices, parámetros como vectores, predicciones como operaciones vectorizadas y pérdidas como funciones que un algoritmo debe minimizar. También introduce una distinción que acompañará todo el libro: ajustar bien las filas observadas no es lo mismo que predecir bien una observación nueva.

De las filas observadas a una observación nueva

Supongamos que la tabla contiene pares

$$(x_1, y_1), \dots, (x_m, y_m),$$

donde $x_i \in \mathbb{R}^d$ reúne las variables disponibles y $y_i \in \mathbb{R}$ es la respuesta. Si el único propósito fuera reproducir esos valores, bastaría guardar la tabla. Una tarea predictiva pregunta, en cambio, por una respuesta Y asociada con unas variables X que todavía no hemos observado.

Utilizamos letras mayúsculas para representar ese par antes de observarlo:

$$Z = (X, Y) \sim P, \quad X \in \mathbb{R}^d, \quad Y \in \mathbb{R}.$$

El vector X y la respuesta Y son variables aleatorias; Z las reúne en un solo vector aleatorio. Aquí P representa su distribución conjunta en la población de interés. Los pares (x_i, y_i) son valores ya observados. Escribir $Z_i \stackrel{\text{iid}}{\sim} P$ para las filas es un supuesto de modelación: afirma que las observaciones son independientes y que cada una tiene distribución P . Una tabla con mediciones repetidas, series temporales o selección no aleatoria puede violar una o ambas partes del supuesto.

El capítulo de referencia *Variables aleatorias, distribuciones y muestras* ofrece una construcción formal de estos objetos. Por ahora necesitamos una consecuencia concreta: una función ajustada con los datos se utilizará para predecir la respuesta de otra realización de (X, Y) .

Por qué aparece la media condicional

Fijemos unas variables $X = x$ y consideremos una predicción numérica a . Su error cuadrático esperado dentro de las unidades con esas características es

$$r_x(a) = \mathbb{E}[(Y - a)^2 \mid X = x].$$

Si $\mu(x) = \mathbb{E}[Y \mid X = x]$, podemos escribir

$$Y - a = (Y - \mu(x)) + (\mu(x) - a).$$

Al expandir el cuadrado y tomar esperanza condicional, el término cruzado se anula porque $\mathbb{E}[Y - \mu(x) \mid X = x] = 0$. Por tanto,

$$r_x(a) = \text{Var}(Y \mid X = x) + (\mu(x) - a)^2.$$

El primer término no depende de a y el segundo es no negativo. La predicción que minimiza el error cuadrático esperado es entonces

$$f^*(x) = \mathbb{E}[Y \mid X = x].$$

La esperanza condicional no aparece aquí como un requisito previo: es la respuesta matemática a la pregunta de cuál sería la mejor predicción numérica bajo pérdida cuadrática. La varianza condicional representa la variación de Y que permanece incluso si conociéramos exactamente esa media.

Del objetivo poblacional al problema calculable

La regresión lineal restringe la búsqueda a funciones afines

$$f_{\theta}(x) = \theta_0 + x^{\top} \theta_{1:d}$$

y define el riesgo poblacional

$$R_P(\theta) = \frac{1}{2} \mathbb{E}_P[(f_{\theta}(X) - Y)^2].$$

Con una muestra $D_m = ((X_1, Y_1), \dots, (X_m, Y_m))$, solo podemos minimizar

$$\widehat{R}_m(\theta) = \frac{1}{2m} \sum_{i=1}^m (f_{\theta}(X_i) - Y_i)^2 = \frac{1}{2m} \|X\theta - y\|_2^2.$$

El resultado $\widehat{\theta}(D_m)$ es un **estimador aleatorio** antes de observar la muestra. La solución numérica para un dataset concreto es una realización de ese estimador. Otra muestra produciría, en general, otros coeficientes. Esta variación será central cuando estudiemos regularización y validación.

Modelo lineal probabilístico

Una interpretación adicional parte del modelo

$$Y = X^{\top} \beta + \varepsilon, \quad \mathbb{E}[\varepsilon \mid X] = 0.$$

La condición de media cero implica $\mathbb{E}[Y \mid X] = X^{\top} \beta$. No implica normalidad ni varianza constante. Si además se supone $\text{Var}(\varepsilon \mid X) = \sigma^2$, se obtiene un modelo homocedástico. Esos son supuestos sobre el proceso generador, no propiedades que aparezcan por ejecutar **LinearRegression**.

Inesgamiento condicional de OLS. Si la matriz de diseño observada X tiene rango columna completo y $y = X\beta + \varepsilon$ con $\mathbb{E}[\varepsilon \mid X] = 0$, entonces

$$\widehat{\beta} = (X^{\top} X)^{-1} X^{\top} y \implies \mathbb{E}[\widehat{\beta} \mid X] = \beta.$$

Demostración. Sustituir $y = X\beta + \varepsilon$ produce $\widehat{\beta} = \beta + (X^{\top} X)^{-1} X^{\top} \varepsilon$. Al condicionar en X , el segundo término tiene esperanza cero. En cómputo seguiremos usando **lstsq**; la fórmula inversa aparece aquí para estudiar el estimador. $\square$




Figura 4: Geometría de mínimos cuadrados: las predicciones forman una proyección de y sobre el espacio columna de X ; el residual queda perpendicular a ese espacio.

Lectura de la figura. Mínimos cuadrados busca una predicción $\hat{y} = X\theta$ dentro del espacio generado por las columnas de X . En la solución óptima, el residual $r = y - \hat{y}$ queda perpendicular a ese espacio.

El problema de regresión

En regresión queremos predecir una cantidad numérica. Algunos ejemplos:

- precio de una vivienda;
- consumo de energía;
- tiempo de entrega;
- concentración de una sustancia;
- puntaje de riesgo continuo.

Cada observación tiene variables de entrada y una respuesta.

Objeto	Ejemplo
Entrada x_i	área, habitaciones, ubicación codificada
Salida y_i	precio
Modelo	regla que transforma x_i en y_{hat_i}
Error	diferencia entre y_i y y_{hat_i}

Definición 1.1: problema supervisado de regresión.

Un conjunto de entrenamiento de regresión es una colección de pares (x_i, y_i) , donde x_i contiene variables explicativas y y_i es una cantidad real. El objetivo es aprender una función f tal que $f(x_i)$ aproxime y_i y generalice a observaciones no usadas para entrenar.

De una recta a una matriz

La recta clásica es

$$\hat{y}_i = \theta_0 + \theta_1 x_i.$$

Con varias variables:

$$\hat{y}_i = \theta_0 + \theta_1 x_{i1} + \theta_2 x_{i2} + \cdots + \theta_d x_{id}.$$

Para escribir esto como producto matricial agregamos una columna de unos. Si hay m observaciones y d variables originales, la matriz de diseño tiene $p = d + 1$ columnas:

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1d} \\ 1 & x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{m1} & x_{m2} & \cdots & x_{md} \end{bmatrix} \in \mathbb{R}^{m \times p}.$$

El vector de parámetros es

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_d \end{bmatrix}.$$

Entonces todas las predicciones se escriben como:

$$\hat{y} = X\theta.$$

Definición 1.2: matriz de diseño.

La matriz de diseño X contiene las variables que el modelo usa para producir predicciones. Puede incluir una columna de intercepto, variables originales, variables transformadas, interacciones o codificaciones de variables categóricas.

En Python:

```
import numpy as np

def add_intercept(X):
    X = np.asarray(X, dtype=float)
    ones = np.ones((X.shape[0], 1))
    return np.hstack([ones, X])

X_design = add_intercept(X_raw)
y_hat = X_design @ theta
```

Dimensiones: la primera defensa contra errores

Antes de derivar o programar, revisa dimensiones.

Objeto	Forma
<code>X</code>	(m, p)
<code>theta</code>	$(p,)$ o $(p, 1)$
<code>X @ theta</code>	$(m,)$ o $(m, 1)$
<code>y</code>	$(m,)$
<code>X.T @ X</code>	(p, p)
<code>X.T @ y</code>	$(p,)$

Chequeo rápido. Si `X @ theta` no produce un vector con una predicción por observación, el problema no es estadístico todavía: es de representación.

Residuales y pérdida

El residual de la observación i es

$$r_i = y_i - \hat{y}_i.$$

En vector:

$$r = y - X\theta.$$

La pérdida de mínimos cuadrados mide el promedio de errores cuadrados:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 = \frac{1}{2m} \|X\theta - y\|_2^2.$$

El factor $1/2$ se usa para que el 2 de la derivada desaparezca.

Definición 1.3: MSE y pérdida cuadrática.

El error cuadrático medio es

$$\text{MSE}(\theta) = \frac{1}{m} \|X\theta - y\|_2^2.$$

La pérdida

$$J(\theta) = \frac{1}{2} \text{MSE}(\theta)$$

tiene el mismo minimizador, pero un gradiente más limpio.

En el ejemplo controlado $x = (0, 1, 2, 3)$ y $y = (1.1, 2.9, 5.2, 6.8)$, cada par (θ_0, θ_1) determina una recta y, por tanto, un valor de J . La figura muestra esa pérdida como una superficie de contornos.




Figura 5: La pérdida cuadrática del ejemplo es convexa. El punto candidato queda cerca del mínimo calculado con `lstsq`, y el gradiente local señala cómo reducir la pérdida.

Lectura de la figura. Los contornos son conjuntos de parámetros con pérdida constante. La convexidad implica que el mínimo local también es global; no implica que formar $(X^T X)^{-1}$ sea el método numérico apropiado para encontrarlo.

Implementación:

```
def mse_loss(X, y, theta):
    residual = y - X @ theta
    return np.mean(residual ** 2)

def half_mse_loss(X, y, theta):
    residual = y - X @ theta
    return 0.5 * np.mean(residual ** 2)
```

Derivación del gradiente

Partimos de:

$$J(\theta) = \frac{1}{2m}(X\theta - y)^T(X\theta - y).$$

Expandiendo:

$$J(\theta) = \frac{1}{2m} (\theta^\top X^\top X \theta - 2y^\top X \theta + y^\top y).$$

Usamos dos reglas:

$$\nabla_\theta(\theta^\top A \theta) = (A + A^\top)\theta,$$

y si A es simétrica:

$$\nabla_\theta(\theta^\top A \theta) = 2A\theta.$$

Como $X^\top X$ es simétrica:

$$\nabla J(\theta) = \frac{1}{2m} (2X^\top X \theta - 2X^\top y).$$

Por tanto:

$$\nabla J(\theta) = \frac{1}{m} X^\top (X \theta - y).$$

Proposición 1.1: gradiente de MSE escalado.

Para

$$J(\theta) = \frac{1}{2m} \|X\theta - y\|_2^2,$$

el gradiente es

$$\nabla J(\theta) = \frac{1}{m} X^\top (X \theta - y).$$

Implementación:

```
def mse_gradient(X, y, theta):  
    m = X.shape[0]  
    residual = y - X @ theta  
    return -(X.T @ residual) / m
```


Ecuación normal

Un mínimo interior de una función diferenciable satisface:

$$\nabla J(\theta) = 0.$$

Entonces:

$$\frac{1}{m} X^\top (X\theta - y) = 0.$$

Multiplicando por m :

$$X^\top X\theta - X^\top y = 0.$$

Reordenando:

$$X^\top X\theta = X^\top y.$$

Esta es la **ecuación normal**.

Si $X^\top X$ es invertible:

$$\theta^* = (X^\top X)^{-1} X^\top y.$$

Proposición 1.2: solución de mínimos cuadrados.

Si X tiene rango columna completo, entonces $X^\top X$ es invertible y el minimizador único de la pérdida cuadrática es

$$\theta^* = (X^\top X)^{-1} X^\top y.$$

La expresión con inversa es una identidad algebraica bajo rango completo, no una receta numérica. Para calcular el minimizador preferimos operar sobre X :

```
def fit_lstsq(X, y):
    theta, residuals, rank, singular_values = np.linalg.lstsq(
        X,
        y,
        rcond=None,
    )
    return theta, rank, singular_values
```

Criterio numérico. `np.linalg.solve(X.T @ X, X.T @ y)` es mejor que formar una inversa y resulta útil en ejemplos pequeños de rango completo. `np.linalg.lstsq` evita formar $X^T X$, informa rango y valores singulares, y también funciona cuando la solución en parámetros no es única.

En norma 2, si X tiene rango columna completo,

$$\kappa_2(X^T X) = \kappa_2(X)^2.$$

Por eso formar $X^T X$ puede amplificar un problema de condicionamiento. Para diagnosticarlo conviene inspeccionar `np.linalg.cond(X)`, no únicamente la matriz de las ecuaciones normales.

Costo computacional y estabilidad

La identidad algebraica y el método numérico deben distinguirse. Supongamos $m \geq p$. Formar $X^T X$ cuesta del orden de mp^2 operaciones y resolver el sistema resultante cuesta del orden de p^3 . Una factorización QR trabaja directamente con X y tiene también costo $O(mp^2)$, pero evita elevar al cuadrado el número de condición. La SVD es más costosa en constantes, aunque permite diagnosticar rango y construir una solución de norma mínima cuando la solución no es única.

Método	Objeto principal	Costo dominante	Comentario
ecuaciones normales	$X^T X$	$O(mp^2 + p^3)$	simple, pero empeora el condicionamiento
QR	$X = QR$	$O(mp^2)$	estable para mínimos cuadrados de rango completo
SVD / <code>lstsq</code>	$X = U\Sigma V^T$	$O(mp^2)$ si $m \geq p$	revela rango y valores singulares

Almacenar la matriz densa requiere $O(mp)$ números. Cuando m y p son muy grandes o X es dispersa, formar matrices densas puede ser el verdadero obstáculo y conviene usar métodos iterativos. Por eso «tener solución cerrada» no significa «tener el mejor algoritmo para cualquier tamaño».

Decisión numérica. En este curso, `np.linalg.lstsq` es la referencia para ajustes densos pequeños o medianos. Las ecuaciones normales se derivan porque explican la geometría y la condición de optimalidad, no porque debamos invertir $X^T X$ en código.

Interpretación geométrica

El modelo busca un vector $\mathbf{X} \text{ theta}$ en el espacio generado por las columnas de $\mathbf{X}$. Ese espacio es un subespacio de $\mathbb{R}^m$. El vector observado y puede no estar exactamente en ese subespacio. Mínimos cuadrados encuentra la proyección de y sobre el espacio columna de $\mathbf{X}$.

En la solución:

$$X^{\top}(y - X\theta^*) = 0.$$

Esto dice que los residuales de **entrenamiento** son ortogonales a cada columna de **X**. Es una propiedad algebraica del ajuste muestral; no afirma independencia, no elimina estructura no lineal y no garantiza el mismo patrón fuera de entrenamiento.

Ejemplo resuelto 1: datos exactos

Supongamos:

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

El patrón exacto es:

$$y = 1 + 2x.$$

La solución esperada es:

$$\theta = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

```
X = np.array([[1, 0], [1, 1], [1, 2]], dtype=float)
y = np.array([1, 3, 5], dtype=float)
theta = np.linalg.lstsq(X, y, rcond=None)[0]
theta
```

Ejemplo resuelto 2: datos con ruido

Ahora supón:

$$y = \begin{bmatrix} 1.1 \\ 2.9 \\ 5.2 \\ 6.8 \end{bmatrix}, \quad x = \begin{bmatrix} 0 \\ 1 \\ 2 \\ 3 \end{bmatrix}.$$

No existe una recta que pase exactamente por todos los puntos. Mínimos cuadrados elige la recta que minimiza la suma de residuales cuadrados.

```
x = np.array([0, 1, 2, 3], dtype=float).reshape(-1, 1)
y = np.array([1.1, 2.9, 5.2, 6.8], dtype=float)
X = add_intercept(x)
theta = np.linalg.lstsq(X, y, rcond=None)[0]
y_hat = X @ theta
residuals = y - y_hat
mse = np.mean(residuals ** 2)
```

Una buena explicación debe incluir:

- los coeficientes estimados;
- el MSE;
- una inspección de residuales;
- comparación contra baseline.

Baseline de regresión

Un baseline es una regla simple que el modelo debe superar. Para regresión, el baseline más común predice siempre el promedio de `y_train`:

$$\hat{y}_i = \bar{y}_{\text{train}}.$$

Su MSE en prueba es:

$$\text{MSE}_{\text{baseline}} = \frac{1}{m_{\text{test}}} \sum_{i \in \text{test}} (y_i - \bar{y}_{\text{train}})^2.$$

Criterio aplicado. Un modelo lineal que no mejora el baseline en datos de prueba no ha mostrado que sus variables añadan capacidad predictiva en esa evaluación, aunque sus coeficientes estén bien calculados.

```
baseline = np.mean(y_train)
y_pred_base = np.full_like(y_test, fill_value=baseline, dtype=float)
mse_base = np.mean((y_test - y_pred_base) ** 2)
```

Caso aplicado: 32 subzonas de Bogotá

El subconjunto congelado del curso contiene 32 filas agregadas. Cada fila es una subzona, no una vivienda. Usaremos cinco variables promedio para predecir el campo `precio_reportado`, cuya unidad no está documentada en el archivo fuente.





Figura 6: Estrato promedio y precio reportado presentan una asociación positiva en las 32 subzonas, pero la gráfica no identifica una relación causal.

Con una partición fija de 24 subzonas para entrenamiento y 8 para prueba, el baseline predice la media de entrenamiento. La comparación es:

Método	MAE	RMSE
media de entrenamiento	1.723	1.954
regresión lineal	0.615	0.647

Partición fija: MAE baseline 1.723; modelo 0.615



Ejemplo docente con 32 filas agregadas; no constituye validación operativa.

Figura 7: En la partición con semilla 2105, el modelo mejora el baseline. Los dos paneles muestran predicciones fuera del ajuste y residuales definidos como observado menos predicho.

Ocho filas de prueba producen una comparación frágil. Repetir el mismo procedimiento con varias semillas muestra cuánto cambia el MAE por la composición de la partición.




Figura 8: El MAE cambia entre particiones. Con una muestra pequeña, la semilla forma parte de la variación observada y no debe elegirse por producir el menor error.

Una conclusión ajustada a este experimento es: el modelo reduce MAE y RMSE frente al baseline en la partición fijada, pero el conjunto es pequeño, las filas son agregadas, el resultado varía entre

particiones y la unidad del objetivo no está documentada. El ejercicio permite estudiar mínimos cuadrados; no permite valorar una vivienda ni recomendar una política urbana.

Interpretación de coeficientes

En un modelo lineal:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d.$$

El coeficiente `theta_j` se interpreta como el cambio esperado en la predicción cuando `x_j` aumenta una unidad y las demás variables se mantienen constantes.

Esta frase tiene tres condiciones:

1. habla de la predicción, no necesariamente de causalidad;
2. depende de la escala de `x_j`;
3. mantiene las demás variables constantes, lo cual puede ser poco realista si las variables están correlacionadas.

No confundas asociación con causalidad. Un coeficiente grande no prueba que una variable cause el resultado. Para causalidad se necesita diseño, supuestos y argumento adicional.

Multicolinealidad y rango

Si una columna de `X` puede escribirse como combinación lineal de otras columnas, entonces `X` no tiene rango columna completo. En ese caso `X.T @ X` no es invertible.

Ejemplo:

```
x1 = np.array([1, 2, 3, 4], dtype=float)
x2 = 2 * x1
X = np.column_stack([np.ones_like(x1), x1, x2])
```

Aquí la tercera columna contiene exactamente la misma información que la segunda.

Síntomas prácticos:

- error de matriz singular al resolver la ecuación normal;
- coeficientes muy inestables;
- cambios grandes en coeficientes cuando se modifica poco el dataset;
- interpretaciones contradictorias.

Errores comunes

1. Olvidar la columna de intercepto.
2. Usar `np.linalg.inv` innecesariamente.
3. Entrenar y evaluar sobre los mismos datos.
4. Reportar solo coeficientes sin métrica.
5. Comparar modelos sin baseline.
6. Interpretar coeficientes sin revisar escala.
7. Ignorar multicolinealidad.
8. Confundir buen ajuste en entrenamiento con generalización.

Checklist de estudio

Antes de pasar al Capítulo 2, deberías poder responder:

- ¿Cuál es la forma de X , θ , y $X @ \theta$?
- ¿Por qué agregamos una columna de unos?
- ¿Qué mide un residual?
- ¿Por qué usamos errores cuadrados?
- ¿Cómo se deriva $X.T @ X \theta = X.T @ y$?
- ¿Cuándo puede fallar la ecuación normal?
- ¿Cuál es el baseline natural en regresión?

Para explorar más

- **Extensión matemática:** rehace la derivación del gradiente usando diferenciales y verifica que la forma final sea compatible con las dimensiones de X , y y θ .
- **Extensión computacional:** compara `np.linalg.solve`, `np.linalg.lstsq` y `LinearRegression` sobre el mismo dataset; registra cuándo cambian los coeficientes.
- **Conexión con proyecto:** documenta la matriz de diseño de tu baseline: variables, intercepto, transformaciones y forma final de X .

Revisión del capítulo

En este capítulo conectamos un problema de predicción numérica con álgebra matricial. La media condicional apareció como la mejor predicción poblacional bajo pérdida cuadrática; la regresión lineal restringió esa búsqueda a funciones afines, y el promedio observado de pérdidas convirtió el objetivo en un problema calculable. Los coeficientes ajustados son una estimación obtenida con una muestra particular, no parámetros que permanecerían idénticos si cambiáramos los datos.

La matriz de diseño organiza las variables, el vector de parámetros define el modelo y la pérdida MSE mide el error promedio de predicción en los datos utilizados para calcularla.

El resultado central es que mínimos cuadrados puede leerse de dos formas equivalentes: como optimización de una norma cuadrática y como proyección geométrica de y sobre el espacio columna de X . La ecuación normal $X^\top X\theta = X^\top y$ aparece cuando el gradiente de la pérdida se anula.

Para usar regresión lineal con cuidado, no basta resolver la ecuación. Hay que comparar contra un baseline, revisar formas, evitar inversiones numéricas innecesarias e interpretar coeficientes solo bajo las condiciones del diseño y del preprocesamiento.

Términos clave

- **Par aleatorio** (X, Y) : representación de variables de entrada y respuesta antes de observar una unidad nueva.
- **Media condicional**: función $x \mapsto \mathbb{E}[Y \mid X = x]$, óptima bajo pérdida cuadrática esperada.
- **Riesgo poblacional**: esperanza de la pérdida sobre la distribución de interés.
- **Riesgo empírico**: promedio de pérdidas calculado con una muestra observada.
- **Estimador**: regla que transforma una muestra en un valor o una función ajustada.
- **Regresión supervisada**: aprendizaje de una función que predice una cantidad real a partir de variables observadas.
- **Matriz de diseño**: matriz que organiza intercepto, variables y transformaciones usadas por el modelo.
- **Residual**: diferencia entre el valor observado y la predicción del modelo.
- **MSE**: promedio de errores cuadrados usado para medir ajuste en regresión.
- **Ecuación normal**: sistema $X^\top X\theta = X^\top y$ que caracteriza mínimos cuadrados.
- **Baseline**: regla simple que un modelo debe superar para justificar su complejidad.
- **Multicolinealidad**: dependencia lineal o casi lineal entre columnas de la matriz de diseño.

Ejercicios

Preguntas conceptuales

1. Distingue el par aleatorio (X, Y) de una fila observada (x_i, y_i) .
2. Demuestra con la descomposición del texto por qué la media condicional minimiza el error cuadrático esperado para un valor fijo de $X = x$.
3. Explica en tus palabras qué significa que X sea una matriz de diseño.
4. ¿Por qué el intercepto puede representarse con una columna de unos?
5. ¿Qué diferencia hay entre residual y error de generalización?
6. ¿Por qué un modelo puede tener MSE bajo en entrenamiento y aun así ser malo?
7. Explica por qué un coeficiente no implica causalidad.

Problemas cuantitativos

8. Sea

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad y = \begin{bmatrix} 2 \\ 2 \\ 5 \end{bmatrix}.$$

Calcula $X^T @ X$, $X^T @ y$ y resuelve la ecuación normal.

9. Para

$$J(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2,$$

reproduce la derivación del gradiente sin mirar el texto.

10. Demuestra que si $X^T @ (y - X \theta) = 0$, los residuales son ortogonales a cada columna de X .

Práctica computacional

11. Implementa `add_intercept(X)` sin usar ciclos.
12. Implementa `mse_loss(X, y, theta)`.
13. Implementa `fit_lstsq(X, y)` usando `np.linalg.lstsq` y devuelve también rango y valores singulares.
14. Simula datos con $y = 3 - 2x + \text{ruido}$ y estima los parámetros.
15. Compara el MSE del modelo contra el baseline del promedio.

Interpretación y pensamiento crítico

16. Un modelo obtiene MSE de entrenamiento 4.1 y MSE de prueba 18.7. ¿Qué hipótesis harías?
17. Un modelo no mejora el baseline. Escribe dos posibles razones técnicas.
18. Si una variable está medida en pesos y otra en millones de pesos, ¿por qué sus coeficientes no son directamente comparables?

Profundización matemática y algorítmica

19. Compara ecuaciones normales, QR y SVD en términos de objeto factorizado, costo asintótico y efecto sobre el número de condición.
20. Construye una matriz de diseño de rango deficiente y muestra dos vectores de parámetros distintos que producen las mismas predicciones.
21. Explica por qué `lstsq` puede devolver una solución de norma mínima aunque los coeficientes no sean identificables de manera única.

Proyecto de cierre

22. Elige un dataset tabular de regresión o genera uno pequeño con semilla fija. Define la matriz de diseño, ajusta mínimos cuadrados, compara contra el baseline del promedio y escribe una recomendación de máximo 150 palabras que incluya métrica, limitación y siguiente verificación.

Capítulo 2: Descenso del gradiente

Optimización, escalamiento y condicionamiento

Pregunta aplicada

¿Cómo ajustamos parámetros cuando no queremos o no podemos depender de una fórmula cerrada, y cómo diagnosticamos si el algoritmo realmente está aprendiendo?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. explicar qué significa minimizar una función de pérdida;
2. implementar descenso del gradiente para MSE;
3. interpretar una curva de pérdida;
4. escoger una tasa de aprendizaje razonable por diagnóstico;
5. explicar por qué el escalamiento afecta la optimización;
6. reconocer problemas de condicionamiento;
7. comparar una solución iterativa con la ecuación normal.
8. relacionar la tasa de aprendizaje con el espectro de la Hessiana;
9. estimar el costo de una iteración y distinguir convergencia matemática de buena generalización.

En el Capítulo 1 resolvimos mínimos cuadrados con una fórmula cerrada. En este capítulo estudiamos un método iterativo. Esta transición es importante porque muchos modelos útiles no tienen una solución cerrada conveniente.

Qué función estamos optimizando

Para una pérdida por observación $\ell(\theta; Z)$ distinguimos

$$R_P(\theta) = \mathbb{E}_{Z \sim P}[\ell(\theta; Z)] \quad \text{y} \quad \widehat{R}_m(\theta) = \frac{1}{m} \sum_{i=1}^m \ell(\theta; Z_i).$$

El computador deriva y minimiza $\widehat{R}_m$. El objetivo científico es que el parámetro obtenido tenga riesgo pequeño bajo una distribución de uso. Una curva de pérdida de entrenamiento solo describe el primer problema.

Si B es un mini-batch elegido uniformemente de la muestra, definimos

$$g_B(\theta) = \frac{1}{|B|} \sum_{i \in B} \nabla_{\theta} \ell(\theta; Z_i).$$

Gradiente de mini-batch como estimador. Si las posiciones del mini-batch se seleccionan uniformemente, entonces, condicionado en la muestra,

$$\mathbb{E}_B[g_B(\theta) \mid D_m] = \nabla \widehat{R}_m(\theta).$$

Reducir $|B|$ no cambia esa esperanza, pero aumenta la variación del gradiente. Por eso SGD introduce ruido algorítmico aun cuando el dataset permanezca fijo.

Optimización como búsqueda

Tenemos una función de pérdida:

$$J(\theta).$$

Queremos encontrar parámetros con pérdida pequeña:

$$\theta^* = \arg \min_{\theta} J(\theta).$$

En regresión lineal con MSE, J es convexa. Eso significa que no hay mínimos locales malos: cualquier mínimo local es global. Pero que el problema sea convexo no significa que cualquier algoritmo llegue rápido.

Definición 2.1: optimización.

Optimizar un modelo es buscar parámetros que minimicen una función objetivo. En aprendizaje supervisado, esa función suele medir discrepancia entre predicciones y observaciones, posiblemente más una penalización.

Idea geométrica del gradiente

El gradiente $\text{grad } J(\theta)$ apunta en la dirección de mayor crecimiento local de la función. Para bajar la pérdida, nos movemos en la dirección contraria:

$$\theta_{\text{nuevo}} = \theta_{\text{actual}} - \alpha \nabla J(\theta_{\text{actual}}).$$

Aquí α es la tasa de aprendizaje.

Descenso del gradiente: trayectoria, escala

Cada actualización usa el gradiente local para reducir la pérdida, pero el tamar




Figura 9: Descenso del gradiente: la trayectoria avanza sobre contornos de pérdida y la tasa de aprendizaje controla si el avance es lento, estable u oscilatorio.

Lectura de la figura. Los puntos rojos no son evaluaciones independientes: son iteraciones del mismo algoritmo. El gradiente define la dirección local de descenso y la tasa de aprendizaje define cuánto se avanza. Un paso pequeño puede ser correcto pero lento; un paso grande puede saltar sobre el valle de la pérdida y producir oscilación.

Definición 2.2: tasa de aprendizaje.

La tasa de aprendizaje **alpha** controla el tamaño del paso en cada iteración del descenso del gradiente. Si es demasiado pequeña, el algoritmo avanza lentamente. Si es demasiado grande, puede oscilar o divergir.

Algoritmo básico

Para MSE:

$$J(\theta) = \frac{1}{2m} \|X\theta - y\|_2^2,$$

el gradiente es:

$$\nabla J(\theta) = \frac{1}{m} X^\top (X\theta - y).$$

El algoritmo es:

```
inicializar theta
para t = 1, ..., max_iter:
    grad = (X.T @ (X @ theta - y)) / m
    theta = theta - alpha * grad
    guardar pérdida
```

Implementación:

```
def half_mse_loss(X, y, theta):
    error = X @ theta - y
    return 0.5 * np.mean(error ** 2)

def gradient_descent(X, y, alpha=0.1, max_iter=1000, tol=1e-8):
    m, p = X.shape
    theta = np.zeros(p)
    history = [half_mse_loss(X, y, theta)]

    for _ in range(max_iter):
        grad = (X.T @ (X @ theta - y)) / m
        if not np.all(np.isfinite(grad)):
            raise FloatingPointError("gradiente no finito")
        if np.linalg.norm(grad) <= tol:
```

```

        break

    theta = theta - alpha * grad
    loss = half_mse_loss(X, y, theta)
    if not np.isfinite(loss):
        raise FloatingPointError("pérdida no finita")
    history.append(loss)

return theta, np.array(history)

```

`history[t]` corresponde al parámetro después de t actualizaciones, y el criterio de parada usa la norma del gradiente. Así la última pérdida guardada coincide con el `theta` devuelto. Una tolerancia por cambio de parámetros también es posible, pero depende explícitamente de `alpha`.

Cómo leer una curva de pérdida

La curva de pérdida es una herramienta de diagnóstico. No basta con mirar el resultado final.

Patrón observado	Interpretación probable	Acción
Baja de forma suave	<code>alpha</code> razonable	Continuar
Baja muy lentamente	<code>alpha</code> pequeño o mala escala	Aumentar <code>alpha</code> o escalar
Oscila	<code>alpha</code> grande	Reducir <code>alpha</code>
Explota a infinito	<code>alpha</code> demasiado grande	Reducir mucho <code>alpha</code>
Baja y se estanca alto	modelo limitado o pocas iteraciones	revisar features/modelo
Entrena bien, prueba mal	overfitting o leakage	revisar validación

Criterio práctico. Una curva de pérdida sin eje, escala ni lectura no permite diagnosticar el algoritmo. Debes decir si converge, oscila o se estabiliza y qué comprobación harías después.

Ejemplo resuelto: una variable escalada

Supón dos variables:

- `x1`: edad en años, rango aproximado 18 a 80;
- `x2`: ingreso anual en pesos, rango aproximado 10,000,000 a 500,000,000.

En la matriz `X`, la segunda columna puede dominar el gradiente por escala, aunque no sea más importante conceptualmente. El algoritmo tendrá que usar una tasa de aprendizaje muy pequeña para no explotar en esa dirección.

La solución no es cambiar la pregunta, sino cambiar la representación:

$$z_j = \frac{x_j - \mu_j}{s_j}.$$

Donde μ_j y s_j se calculan con entrenamiento.

```
mu = X_train.mean(axis=0)
sigma = X_train.std(axis=0)
sigma[sigma == 0] = 1

X_train_scaled = (X_train - mu) / sigma
X_test_scaled = (X_test - mu) / sigma
```

Regla anti-leakage. El promedio y la desviación estándar se calculan con entrenamiento. Luego se aplican a validación y prueba. No se ajustan con todo el dataset.

Escalamiento y geometría

Si las variables tienen escalas muy distintas, las curvas de nivel de la pérdida pueden ser alargadas. El descenso del gradiente avanza en zigzag porque la dirección de máximo descenso local no apunta directamente al mínimo.

Escalar variables suele transformar el problema para que las curvas de nivel sean menos alargadas. Esto no cambia la información esencial, pero sí cambia la geometría del algoritmo.

Definición 2.3: estandarización.

Estandarizar una variable es restarle su media de entrenamiento y dividirla por su desviación estándar de entrenamiento. La variable resultante tiene media cercana a cero y escala comparable con otras variables.

Condicionamiento

El condicionamiento mide qué tan sensible es un problema numérico a cambios pequeños. Para mínimos cuadrados, la geometría viene de la matriz de diseño X y de la Hessiana

$$H = \frac{1}{m} X^\top X.$$

El número de condición de una matriz invertible A se define como:

$$\kappa(A) = \|A\| \|A^{-1}\|.$$

Con norma espectral:

$$\kappa(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}.$$

Si X tiene rango columna completo, en norma 2,

$$\kappa_2(H) = \kappa_2(X^\top X) = \kappa_2(X)^2.$$

Por eso conviene diagnosticar primero X . Un valor grande indica direcciones con escalas o dependencias muy distintas y puede producir avance en zigzag e inestabilidad de coeficientes.

```
cond_X = np.linalg.cond(X)
cond_H = np.linalg.cond((X.T @ X) / X.shape[0])
```

Lectura práctica. Un número de condición grande no invalida automáticamente un modelo, pero alerta sobre inestabilidad, colinealidad o necesidad de regularización.

Comparación con ecuación normal

Para regresión lineal con MSE, la ecuación normal y descenso del gradiente buscan el mismo mínimo. Por eso podemos usarlas como verificación mutua:

```
theta_ref = np.linalg.lstsq(X, y, rcond=None)[0]
theta_gd, history = gradient_descent(X, y, alpha=0.1)

np.linalg.norm(theta_ref - theta_gd)
```

Si la diferencia es grande, puede ocurrir:

- faltaron iteraciones;
- la tasa de aprendizaje es inadecuada;
- las variables no están escaladas;
- hay un error en el gradiente;
- la matriz está mal condicionada.

Por qué converge en la cuadrática

Para mínimos cuadrados, la Hessiana es constante:

$$H = \nabla^2 J(\theta) = \frac{1}{m} X^\top X.$$

Supongamos primero que X tiene rango columna completo. Entonces H es definida positiva y existe un único minimizador θ^* . Como $\nabla J(\theta) = H(\theta - \theta^*)$, el error $e_t = \theta_t - \theta^*$ satisface

$$e_{t+1} = e_t - \alpha H e_t = (I - \alpha H) e_t.$$

Si $H = Q\Lambda Q^\top$, cada componente del error en la dirección propia q_j se multiplica por $1 - \alpha\lambda_j$ en una iteración. Por tanto, todas las componentes se contraen cuando

$$|1 - \alpha\lambda_j| < 1 \quad \text{para todo } j,$$

lo cual equivale a

$$0 < \alpha < \frac{2}{\lambda_{\max}(H)}.$$

Esta deducción explica tres observaciones del código: un paso demasiado grande diverge, un paso muy pequeño converge lentamente y un espectro muy desigual produce direcciones con velocidades muy distintas. Para paso constante, la elección que minimiza la peor contracción de esta cuadrática es

$$\alpha_{\text{opt}} = \frac{2}{\lambda_{\min}(H) + \lambda_{\max}(H)},$$

con factor

$$\rho = \frac{\kappa_2(H) - 1}{\kappa_2(H) + 1}.$$

No usamos esta fórmula como receta general porque calcular el espectro puede ser tan costoso como resolver el problema y porque, fuera de una cuadrática, la Hessiana cambia con θ . Su valor pedagógico es mostrar con precisión por qué el condicionamiento controla la velocidad.

Convergencia para mínimos cuadrados de rango completo. Si $0 < \alpha < 2/\lambda_{\max}(H)$, el descenso del gradiente con paso constante converge linealmente al único minimizador de la pérdida cuadrática. Si H es singular, el método puede converger a un minimizador, pero la componente inicial en el espacio nulo no se modifica y los parámetros no tienen por qué ser únicos.

Costo de una iteración

Calcular $X\theta$ cuesta $O(mp)$, y multiplicar el residual por $X^\top$ cuesta otro $O(mp)$. Una iteración batch requiere entonces $O(mp)$ operaciones y $O(p)$ memoria adicional, aparte de almacenar los datos. Tras T iteraciones, el costo es $O(Tmp)$.

Esta comparación aclara cuándo un método iterativo resulta atractivo. Una factorización directa paga un costo mayor al comienzo, pero termina en un número fijo de pasos algebraicos. Gradiente evita formar $X^\top X$, puede explotar datos dispersos y permite detenerse temprano, pero su costo depende de cuántas iteraciones exige el condicionamiento.

Con mini-batches de tamaño b , el costo por paso baja a $O(bp)$, aunque ahora el gradiente varía entre pasos. Ese ruido no cambia el objetivo empírico esperado, pero sí cambia el análisis de convergencia y obliga a decidir un esquema de tasas.

Batch, stochastic y mini-batch

En este módulo usamos descenso del gradiente batch: cada paso calcula el gradiente con todos los datos.

Variante	Usa en cada paso	Ventaja	Costo
Batch	todo el dataset	gradiente estable	caro en datasets grandes
Stochastic	una observación	pasos baratos	ruidoso
Mini-batch	un subconjunto	balance práctico	requiere más diseño

En redes neuronales usaremos mini-batches. La idea central sigue siendo la misma: mover parámetros en dirección contraria al gradiente.

Tasa de aprendizaje: una rutina práctica

Una estrategia razonable para este módulo:

1. Escala las variables.
2. Prueba **alpha** en una lista: 0.001, 0.01, 0.05, 0.1, 0.5.
3. Grafica la pérdida.
4. Descarta valores que divergen u oscilan.
5. Elige el mayor valor que baje de forma estable.
6. Elige la tasa con comportamiento estable y desempeño de validación.
7. Una vez fijado todo el procedimiento, reporta prueba una sola vez.

```
alphas = [0.001, 0.01, 0.05, 0.1, 0.5]
results = {}
for alpha in alphas:
    theta, history = gradient_descent(X_train_scaled, y_train, alpha=alpha)
    results[alpha] = history
```

Errores comunes

1. No guardar la historia de pérdida.
2. Reportar solo el último **theta** sin diagnóstico de convergencia.
3. Usar **alpha** grande y no detectar divergencia.
4. Escalar entrenamiento y prueba por separado.
5. Incluir la columna de intercepto en el escalamiento.
6. Comparar gradiente contra **lstsq** sin usar la misma matriz **X**.
7. Creer que más iteraciones arreglan un mal modelo.

Checklist de estudio

- ¿Puedes escribir la actualización de descenso del gradiente?
- ¿Puedes explicar el papel de `alpha`?
- ¿Puedes implementar el gradiente de MSE sin ciclos?
- ¿Puedes interpretar una curva que oscila?
- ¿Sabes por qué se escala con parámetros de entrenamiento?
- ¿Puedes comparar `theta_gd` con una solución de `lstsq`?

Para explorar más

- **Extensión matemática:** analiza cómo cambia la cota de estabilidad del paso cuando el valor propio dominante de $X^T X$ aumenta.
- **Extensión computacional:** grafica curvas de pérdida para tres tasas de aprendizaje y marca divergencia, convergencia lenta y convergencia estable.
- **Conexión con proyecto:** registra en tu bitácora qué variables necesitan escalamiento antes de entrenar y cómo lo verificaste.

Revisión del capítulo

El descenso del gradiente convierte cálculo diferencial en un algoritmo iterativo. En lugar de resolver directamente una ecuación cerrada, actualiza los parámetros en la dirección opuesta al gradiente de la pérdida.

La tasa de aprendizaje controla el tamaño de cada paso. Una tasa demasiado pequeña produce avance lento; una tasa demasiado grande puede provocar oscilación o divergencia. El escalamiento de variables mejora el condicionamiento y hace que las direcciones de descenso sean más comparables.

Una implementación confiable debe registrar la pérdida, verificar que las formas de matrices coincidan y comparar el resultado contra una referencia. La curva de pérdida permite detectar convergencia, oscilación o un problema de escala, tasa o código.

Términos clave

- **Optimización:** búsqueda de parámetros que minimizan una función objetivo.
- **Gradiente:** dirección de mayor aumento local de una función diferenciable.
- **Tasa de aprendizaje:** escala del paso en cada actualización iterativa.
- **Convergencia:** estabilización del algoritmo hacia pérdida o gradiente suficientemente pequeños.
- **Estandarización:** transformación que centra y escala variables usando estadísticas de entrenamiento.
- **Condicionamiento:** sensibilidad numérica de un sistema o problema ante pequeñas perturbaciones.
- **Mini-batch:** subconjunto de observaciones usado para aproximar un paso de optimización.

Ejercicios

Preguntas conceptuales

1. Explica por qué el gradiente apunta en la dirección de mayor aumento.
2. ¿Por qué usamos `theta - alpha * grad` y no `theta + alpha * grad`?
3. ¿Qué evidencia usarías para afirmar que el algoritmo convergió?
4. ¿Por qué escalar variables puede acelerar el descenso del gradiente?
5. Explica qué problema produce escalar prueba con su propia media.

Problemas cuantitativos

6. Para

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}, \quad \theta = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

calcula el gradiente de `J(theta)`.

7. Ejecuta manualmente dos pasos de descenso del gradiente con `alpha=0.1` para el ejercicio anterior.
8. Si una curva de pérdida pasa de 100 a 80, luego a 130, luego a 70, ¿qué sospechas sobre `alpha`?

Práctica computacional

9. Implementa `gradient_descent(X, y, alpha, max_iter)`.
10. Agrega un criterio de parada por norma del gradiente.
11. Compara tres tasas de aprendizaje en un dataset generado con semilla fija.
12. Estandariza variables sin tocar la columna de intercepto.
13. Calcula `np.linalg.cond(X)` y `np.linalg.cond(X.T @ X)` antes y después de escalar; verifica la relación entre ambos valores.

Interpretación y pensamiento crítico

14. Tu modelo con gradiente obtiene MSE mayor que la ecuación normal. Escribe tres hipótesis técnicas.
15. Tu curva converge en entrenamiento, pero el error de prueba es malo. ¿El problema es necesariamente el optimizador?
16. ¿Qué decisión tomarías si `alpha=0.1` converge en 200 iteraciones y `alpha=0.01` converge en 5000?

Profundización matemática y algorítmica

17. Sea $H = \text{diag}(1, 25)$. Determina el intervalo de tasas constantes para el que gradiente converge y calcula el factor de contracción para $\alpha = 0.04$.
18. A partir de $e_{t+1} = (I - \alpha H)e_t$, demuestra la condición $0 < \alpha < 2/\lambda_{\max}(H)$.
19. Compara el costo $O(Tmp)$ de gradiente con $O(mp^2)$ de una factorización directa. Describe un régimen de m, p, T donde cada alternativa sea razonable.

Proyecto de cierre

20. Construye un experimento pequeño con dos variables en escalas muy distintas. Ejecuta descenso del gradiente antes y después de estandarizar, grafica la pérdida y redacta un diagnóstico que explique qué cambió y qué no demuestra el experimento.

Capítulo 3: Validación y regularización

Features, complejidad, Ridge, Lasso y selección de modelo

Pregunta aplicada

¿Cómo elegimos la complejidad de un modelo sin engañarnos con el entrenamiento ni contaminar la evaluación final?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. construir features polinomiales e interacciones;
2. explicar underfitting y overfitting;
3. separar entrenamiento, validación y prueba;
4. evitar leakage en preprocesamiento;
5. formular Ridge y Lasso;
6. interpretar el efecto de `lambda`;
7. seleccionar modelos con una métrica de validación;
8. justificar un modelo final sin mirar la prueba repetidamente.
9. explicar el efecto espectral de Ridge y la condición de optimalidad de Lasso;
10. distinguir la solución matemática de un problema regularizado del algoritmo usado para calcularla.

El Capítulo 1 mostró cómo una muestra produce un estimador de los coeficientes y el Capítulo 2 mostró cómo calcularlo de manera iterativa. La pregunta que sigue no puede responderse mirando solo la pérdida de entrenamiento: ¿cómo sabemos si ese modelo servirá fuera de los datos con los que fue ajustado?

Para contestarla imaginaremos repetir el proceso con otras muestras de la misma población. Los modelos ajustados cambiarían, aun si el código y el algoritmo permanecieran fijos. Esta variación hace visibles el sesgo, la varianza y el overfitting, y explica por qué entrenamiento, validación y prueba deben cumplir papeles diferentes. Cada métrica de validación estima un riesgo poblacional; no lo convierte en una constante conocida.

El modelo ajustado también es aleatorio

Sea $D_m \sim P^m$ la muestra de entrenamiento y $\hat{f}_{D_m}$ el procedimiento ajustado. Si repitiéramos el muestreo, obtendríamos otra función. Para pérdida cuadrática y un punto x , la descomposición clásica es

$$\mathbb{E}_{D_m, Y|x} [(Y - \hat{f}_{D_m}(x))^2] = \text{Var}(Y | X = x) + \text{Bias}(x)^2 + \text{Var}_{D_m}(\hat{f}_{D_m}(x)),$$

donde

$$\text{Bias}(x) = \mathbb{E}_{D_m}[\hat{f}_{D_m}(x)] - \mathbb{E}[Y | X = x].$$

Aquí “varianza del modelo” significa sensibilidad a la muestra de entrenamiento, no la varianza descriptiva de una columna. Ridge puede aumentar sesgo y reducir variación del estimador; el balance se estudia con datos de validación.

Validación estima el riesgo del procedimiento fijado. Si el conjunto de validación es independiente del ajuste y contiene observaciones iid de P , entonces para una función ya fijada f ,

$$\mathbb{E}[\hat{R}_{\text{val}}(f) | f] = R_P(f).$$

Después de escoger entre muchos modelos usando esa misma validación, el máximo o mínimo observado incorpora sesgo de selección. Por eso test se reserva para el procedimiento completo ya fijado.

Feature engineering

Un modelo lineal es lineal en sus parámetros, no necesariamente en las variables originales. Podemos transformar entradas para darle más flexibilidad.

Si tenemos una variable $\mathbf{x}$, podemos crear:

$$1, \quad x, \quad x^2, \quad x^3.$$

El modelo:

$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

sigue siendo lineal en θ , aunque sea polinomial en $\mathbf{x}$.

Definición 3.1: feature engineering.

Feature engineering es el proceso de construir variables de entrada a partir de datos originales usando conocimiento del problema, transformaciones matemáticas o codificaciones computacionales.

Ejemplos:

Transformación	Uso
x^2, x^3	curvatura
$x_1 * x_2$	interacción
$\log(x)$	escala multiplicativa
$1\{x > c\}$	umbral
one-hot encoding	variables categóricas
estandarización	optimización y regularización

Regresión polinomial

Con una variable:

```
def polynomial_features_1d(x, degree):
    x = np.asarray(x, dtype=float).reshape(-1, 1)
    cols = [np.ones((x.shape[0], 1))]
    for k in range(1, degree + 1):
        cols.append(x ** k)
    return np.hstack(cols)
```

Para grados pequeños, la regresión polinomial puede capturar curvatura. Para grados altos, puede memorizar ruido.

Criterio aplicado. Una feature nueva debe tener una razón: mejorar ajuste, capturar conocimiento del dominio, resolver no linealidad o facilitar una decisión. Agregar features sin validación no es progreso.

Underfitting y overfitting

Definición 3.2: underfitting.

Ocurre cuando el modelo es demasiado simple para capturar la estructura relevante de los datos. Suele verse como error alto tanto en entrenamiento como en validación.

Definición 3.3: overfitting.

Ocurre cuando el modelo se ajusta demasiado a patrones accidentales del conjunto de entrenamiento. Suele verse como error bajo en entrenamiento y error alto en validación o prueba.

Situación	Error entrenamiento	Error validación	Diagnóstico
Underfitting	alto	alto	falta complejidad o mejores features
Buen ajuste	bajo/moderado	bajo/moderado	generaliza razonablemente
Overfitting	muy bajo	alto	demasiada complejidad o poca regularización




Figura 10: Curvas de aprendizaje: un caso de overfitting mantiene una brecha entre entrenamiento y validación, un caso de underfitting mantiene ambos desempeños bajos, y un caso estable cierra la brecha con más datos.

Lectura de la figura. Una curva de aprendizaje no es un resultado decorativo: debe sugerir una acción técnica. La brecha entre entrenamiento y validación apunta a regularización, más datos, menor complejidad o revisión de leakage.

Separación de datos

Usaremos tres conjuntos cuando sea posible:

Conjunto	Uso
Entrenamiento	ajustar parámetros y preprocesamiento
Validación	elegir grado, <code>lambda</code> , umbral o variante
Prueba	estimar desempeño final una sola vez

Si el dataset es pequeño, puede usarse validación cruzada. Pero el principio no cambia: no se debe usar la prueba como herramienta de diseño.

Regla de prueba. El conjunto de prueba no es un tablero para experimentar. Si lo consultas muchas veces para tomar decisiones, deja de ser una estimación honesta del desempeño final.

Leakage

Leakage ocurre cuando información que no estaría disponible en producción entra al entrenamiento o a la validación.

Ejemplos comunes:

- escalar con media y desviación de todo el dataset;

- imputar valores usando prueba;
- seleccionar features mirando el desempeño de prueba;
- crear una variable que usa información posterior al momento de predicción;
- duplicar observaciones de un mismo individuo en entrenamiento y prueba.

Pregunta anti-leakage. En el momento real de hacer la predicción, ¿esa información ya existiría? Si la respuesta es no, no debe entrar al modelo.

Conviene distinguir dos tipos de transformación:

- una transformación determinista por fila, como $x \mapsto x^2$, no aprende estadísticas de otras observaciones y no produce leakage por aplicarse a toda la tabla;
- una transformación aprendida, como estandarización, imputación, selección de variables o codificación de categorías observadas, debe ajustarse exclusivamente con entrenamiento.

Aunque un polinomio determinista no aprenda información, mantener todas las transformaciones dentro de una tubería reduce errores y asegura que la selección de grado ocurra con validación, no con test.


Regularización

La regularización modifica el objetivo para penalizar modelos demasiado complejos. En lugar de minimizar solo error de entrenamiento, minimizamos:

pérdida de datos + penalización.

La intuición es que, entre modelos con desempeño parecido, preferimos uno más estable y menos extremo.

Regularizacion: controlar complejidad sin cambiar la pregunta



Idea matemática: minimizar pérdida + penalización; validar lambda antes de decidir.

Figura 11: Regularización: OLS puede producir coeficientes grandes, Ridge reduce magnitudes y Lasso puede llevar coeficientes exactamente a cero.

Lectura de la figura. Ridge y Lasso expresan dos preferencias distintas: Ridge encoge coeficientes hacia valores más estables; Lasso puede producir soluciones esparsas. Ninguna de las dos preferencias reemplaza la validación.

Ridge

Ridge agrega una penalización L2:

$$J_{\text{ridge}}(\theta) = \frac{1}{2m} \|X\theta - y\|_2^2 + \frac{\lambda}{2} \|\theta_{1:p}\|_2^2.$$

Usualmente no penalizamos el intercepto `theta_0`.

El gradiente para los coeficientes no intercepto es:

$$\nabla J_{\text{ridge}}(\theta) = \frac{1}{m} X^\top (X\theta - y) + \lambda \tilde{\theta},$$

donde:

$$\tilde{\theta} = \begin{bmatrix} 0 \\ \theta_1 \\ \vdots \\ \theta_{p-1} \end{bmatrix}.$$

Si penalizamos todos los parámetros, la solución cerrada es:

$$\theta_{\text{ridge}}^* = (X^\top X + m\lambda I)^{-1} X^\top y.$$

Si no penalizamos el intercepto, usamos una matriz diagonal D con $D_{00}=0$ y $D_{jj}=1$ para $j>0$:

$$\theta_{\text{ridge}}^* = (X^\top X + m\lambda D)^{-1} X^\top y.$$

```
def ridge_closed_form(X, y, lam):
    p = X.shape[1]
    D = np.eye(p)
    D[0, 0] = 0
    return np.linalg.solve(X.T @ X + X.shape[0] * lam * D, X.T @ y)
```

Esta convención usa pérdida promedio. `sklearn.linear_model.Ridge` minimiza una forma equivalente escrita como

$$\|y - Xw\|_2^2 + \alpha \|w\|_2^2.$$

Por tanto, con las convenciones anteriores, $\alpha = m\lambda$. Comparar el mismo número para `alpha` y `lambda` sin revisar la normalización puede producir modelos distintos. `Ridge(fit_intercept=True)` maneja el intercepto internamente y no lo penaliza.

Efecto de lambda

lambda	Efecto
0	regresión lineal sin regularización
pequeño	reduce coeficientes extremos suavemente
mediano	mejora estabilidad si hay colinealidad
grande	puede causar underfitting

Lectura aplicada. Ridge no elimina variables; reduce coeficientes. Es útil cuando muchas variables aportan algo y queremos estabilidad.

Ridge visto en las direcciones singulares

Para ver qué significa «encoger», ignoremos por un momento el intercepto y escribamos la SVD $X = U\Sigma V^\top$. La solución Ridge es

$$\hat{\theta}_\lambda = V(\Sigma^\top \Sigma + m\lambda I)^{-1} \Sigma^\top U^\top y.$$

En la dirección singular v_j , el factor que multiplica la componente de $U^\top y$ es

$$\frac{\sigma_j}{\sigma_j^2 + m\lambda}.$$

Cuando σ_j es pequeño, mínimos cuadrados puede amplificar ruido mediante $1/\sigma_j$. Ridge reemplaza ese factor por uno acotado y reduce especialmente las direcciones peor determinadas por los datos. Esta es la conexión precisa entre regularización, multicolinealidad y estabilidad. El precio es sesgo: incluso con una muestra sin ruido, $\lambda > 0$ desplaza la solución hacia cero.

La matriz $X^\top X + m\lambda I$ tiene valores propios $\sigma_j^2 + m\lambda$. Si se penalizan todas las direcciones, $\lambda > 0$ la hace invertible aunque X no tenga rango completo. Cuando el intercepto no se penaliza, la afirmación debe hacerse sobre el bloque de variables centradas.

Lasso

Lasso agrega una penalización L1:

$$J_{\text{lasso}}(\theta) = \frac{1}{2m} \|X\theta - y\|_2^2 + \lambda \|\theta_{1:p}\|_1.$$

La norma L1 es:

$$\|\theta\|_1 = \sum_j |\theta_j|.$$

Lasso puede llevar algunos coeficientes exactamente a cero. Por eso se usa como herramienta de selección de variables, aunque esa selección debe interpretarse con cuidado.

Lectura aplicada. Lasso es atractivo cuando se espera que pocas variables sean dominantes. Pero con variables muy correlacionadas puede elegir una y descartar otra de forma inestable.

Por qué Lasso puede producir ceros

La función $|t|$ no es diferenciable en $t = 0$. Su subdiferencial es

$$\partial|t| = \begin{cases} \{1\}, & t > 0, \\ [-1, 1], & t = 0, \\ \{-1\}, & t < 0. \end{cases}$$

Sea x_j la columna j de X y supongamos que el intercepto está tratado por separado. Una solución Lasso satisface la condición

$$0 \in \frac{1}{m} x_j^\top (X\hat{\theta} - y) + \lambda \partial|\hat{\theta}_j|.$$

Si $\hat{\theta}_j = 0$, esta condición puede cumplirse siempre que

$$\left| \frac{1}{m} x_j^\top (y - X\hat{\theta}) \right| \leq \lambda.$$

Es decir, una variable queda en cero cuando su correlación residual no supera el umbral impuesto por la penalización. No es un efecto misterioso de la librería; proviene de la esquina de la norma L1.

Una forma de calcular Lasso es descenso por coordenadas. Manteniendo fijas las demás coordenadas, la actualización usa el operador de umbral suave

$$S(a, \lambda) = \text{sign}(a) \max\{|a| - \lambda, 0\}.$$

Si $r_{-j} = y - \sum_{k \neq j} x_k \theta_k$, entonces

$$\theta_j \leftarrow \frac{S(x_j^\top r_{-j}/m, \lambda)}{\|x_j\|_2^2/m}.$$

Una barrida por las p coordenadas cuesta $O(mp)$ si el residual se actualiza de forma incremental. La convergencia es hacia un minimizador global porque el objetivo es convexo, pero el vector de coeficientes puede no ser único cuando hay dependencias entre columnas. La selección de variables, por tanto, puede ser inestable aun cuando las predicciones sean parecidas.

Ridge vs Lasso

Aspecto	Ridge	Lasso
Penalización	L2	L1
Coefficientes	se encogen	algunos quedan en cero
Colinealidad	reparte peso	puede escoger una variable
Solución cerrada simple	sí	no en general
Uso típico	estabilidad	selección de variables

Estandarización antes de regularizar

Ridge y Lasso penalizan coeficientes. Si las variables están en escalas distintas, la penalización no es comparable. Por eso se estandarizan variables antes de regularizar.

Pipeline correcto:

1. separar entrenamiento, validación y prueba;
2. ajustar `StandardScaler` con entrenamiento;
3. transformar entrenamiento, validación y prueba con ese scaler;
4. ajustar modelos regularizados;
5. elegir `lambda` con validación;
6. reportar prueba una vez.

Con `scikit-learn`, la forma más clara es dejar las variables sin columna manual de unos:

```
from sklearn.linear_model import Ridge
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

model = make_pipeline(
    StandardScaler(),
    Ridge(alpha=alpha, fit_intercept=True),
)
model.fit(X_train_raw, y_train)
```

En una implementación manual, primero se ajusta el escalador sobre las variables originales de entrenamiento y **después** se agrega la columna de unos. Esa columna no se estandariza ni se penaliza.

Selección de modelo

Una rutina básica:

```

lambdas = [0.0, 0.001, 0.01, 0.1, 1.0, 10.0]
records = []

X_train_design = add_intercept(X_train_scaled)
X_val_design = add_intercept(X_val_scaled)

for lam in lambdas:
    theta = ridge_closed_form(X_train_design, y_train, lam)
    pred_train = X_train_design @ theta
    pred_val = X_val_design @ theta
    records.append({
        "lambda": lam,
        "mse_train": np.mean((y_train - pred_train) ** 2),
        "mse_val": np.mean((y_val - pred_val) ** 2),
        "coef_norm": np.linalg.norm(theta[1:])
    })

```

La selección no se hace por el menor error de entrenamiento, sino por validación.

Ejemplo resuelto: grado polinomial y Ridge

Supón que comparas grados 1, 3, 8 con λ en $[0, 0.01, 0.1, 1]$.

Un resultado típico puede ser:

grado	lambda	MSE train	MSE val	diagnóstico
1	0	alto	alto	underfitting
8	0	muy bajo	alto	overfitting
8	0.1	bajo	moderado	mejor control
3	0.01	moderado	bajo	candidato final

La conclusión debe explicar el compromiso, no solo señalar el mínimo.

Errores comunes

1. Elegir el grado polinomial después de mirar prueba.
2. Elegir grado por error de entrenamiento.
3. Usar prueba para escoger λ .
4. Regularizar sin escalar.
5. Penalizar el intercepto sin intención.
6. Concluir que Lasso descubrió causalidad.
7. Comparar modelos con particiones distintas.
8. No reportar baseline.

Checklist de estudio

- ¿Puedes explicar overfitting con errores train/val?
- ¿Puedes construir features polinomiales?
- ¿Sabes qué es leakage?
- ¿Puedes escribir el objetivo de Ridge?
- ¿Puedes explicar por qué Lasso puede hacer selección de variables?
- ¿Sabes por qué se escala antes de regularizar?
- ¿Puedes elegir un modelo usando validación y no prueba?

Para explorar más

- **Extensión matemática:** compara el efecto de Ridge y Lasso sobre dos variables altamente correlacionadas y explica por qué sus coeficientes pueden comportarse distinto.
- **Extensión computacional:** construye una curva de validación para λ y reporta no solo el mejor valor, sino la región de desempeño estable.
- **Conexión con proyecto:** define qué transformación, partición o hiperparámetro queda prohibido ajustar con el conjunto de test.

Revisión del capítulo

Este capítulo introduce el problema central de generalización. Un modelo puede reducir mucho el error de entrenamiento y, aun así, fallar en datos nuevos. La validación separa el ajuste de parámetros de la selección de modelo.

Feature engineering y modelos polinomiales aumentan capacidad, pero también aumentan el riesgo de overfitting. Ridge controla coeficientes grandes mediante penalización L2; Lasso usa penalización L1 y puede llevar algunos coeficientes a cero. En ambos casos, el escalamiento es parte del modelo, no un detalle secundario.

La regla operativa es simple: entrenamiento ajusta parámetros, validación elige configuraciones y test estima desempeño final una sola vez. Cualquier transformación que aprenda estadísticas o categorías fuera de train puede introducir leakage; una transformación determinista por fila no tiene ese problema por sí sola.

Términos clave

- **Feature engineering:** construcción de variables a partir de datos originales y conocimiento del problema.
- **Underfitting:** error alto por modelo demasiado simple o mal especificado.
- **Overfitting:** ajuste excesivo al entrenamiento con pobre generalización.
- **Train/validation/test:** separación de datos para ajustar, seleccionar y estimar desempeño final.
- **Leakage:** uso accidental de información que no estaría disponible en predicción real.

- **Ridge:** regularización L2 que penaliza la magnitud cuadrática de coeficientes.
- **Lasso:** regularización L1 que puede llevar coeficientes exactamente a cero.
- **Hiperparámetro:** decisión de configuración elegida por validación, no aprendida directamente como parámetro del modelo.

Ejercicios

Preguntas conceptuales

1. Explica por qué un polinomio de grado alto puede sobreajustar.
2. ¿Por qué no se debe escoger `lambda` con el conjunto de prueba?
3. ¿Qué diferencia conceptual hay entre Ridge y Lasso?
4. ¿Por qué la estandarización es especialmente importante antes de Lasso?
5. Da dos ejemplos de leakage en un proyecto real.

Problemas cuantitativos

6. Escribe el objetivo Ridge para un modelo con intercepto y dos variables.
7. Deriva el gradiente Ridge cuando no se penaliza el intercepto.
8. Para

$$\theta = (3, 4, -1),$$

calcula la penalización L2 y L1 sin incluir el intercepto.

9. Explica qué ocurre con la solución Ridge cuando `lambda -> infinity`.

Práctica computacional

10. Implementa `polynomial_features_1d(x, degree)`.
11. Implementa `ridge_closed_form(X, y, lam)` sin penalizar intercepto.
12. Divide un dataset en train/validation/test con semilla fija.
13. Ajusta scaler en train y aplícalo a validation/test.
14. Compara al menos cinco valores de `lambda`.
15. Grafica `mse_train` y `mse_val` contra `lambda`.

Interpretación y pensamiento crítico

16. Un modelo con `lambda=0` tiene MSE train 1.2 y MSE val 30.0; con `lambda=0.1` tiene MSE train 4.5 y MSE val 8.0. ¿Cuál prefieres y por qué?
17. Lasso deja una variable en cero. ¿Qué puedes afirmar y qué no puedes afirmar?
18. Si Ridge mejora validación pero empeora entrenamiento, ¿eso es necesariamente malo?

Profundización matemática y algorítmica

19. Usa la SVD para mostrar cómo cambia el factor $\sigma_j/(\sigma_j^2 + m\lambda)$ cuando σ_j es grande o pequeño.
20. Verifica la condición de subgradiente de Lasso para una coordenada igual a cero y explica por qué permite soluciones esparsas.
21. Deriva la actualización de umbral suave de descenso por coordenadas en el caso de una sola variable estandarizada.

Proyecto de cierre

22. Diseña una comparación reproducible entre regresión polinomial sin regularización y Ridge. Usa una partición train/validation/test, reporta una tabla de resultados y escribe una conclusión que mencione explícitamente cómo evitaste leakage.

Capítulo 4: Regresión logística

Clasificación binaria, log-loss, métricas y umbrales

Pregunta aplicada

¿Cómo obtiene un modelo una probabilidad estimada de clase positiva y cómo se fija una regla de clasificación cuando los errores tienen costos distintos?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. formular clasificación binaria con probabilidades;
2. explicar la función sigmoide;
3. interpretar log-odds;
4. escribir la log-loss binaria;
5. derivar el gradiente de la pérdida logística;
6. calcular matriz de confusión, accuracy, precision, recall y F1;
7. elegir un umbral con validación según costos de error;
8. comparar un clasificador contra un baseline.
9. obtener la log-loss a partir del modelo Bernoulli y justificar su convexidad;
10. reconocer separabilidad, regularización y costo computacional como parte del análisis del algoritmo.

La regresión logística se llama “regresión”, pero se usa para clasificación. Supongamos que $Y = 1$ representa la clase positiva y $Y = 0$ la clase negativa. Si conocemos que una unidad tiene características $X = x$, la cantidad poblacional de interés es

$$\eta(x) = \mathbb{P}(Y = 1 \mid X = x).$$

Cuando X toma valores discretos, esta probabilidad puede leerse como

$$\mathbb{P}(Y = 1 \mid X = x) = \frac{\mathbb{P}(Y = 1, X = x)}{\mathbb{P}(X = x)},$$

si $\mathbb{P}(X = x) > 0$. Para variables continuas, la expresión se interpreta a través de la distribución condicional de Y dado $X = x$, no como el cociente de dos probabilidades puntuales que suelen ser cero.

No observamos $\eta(x)$ directamente. La regresión logística construye una aproximación parametrizada $\hat{p}_\theta(x)$. Distinguir ambas evita presentar la salida del modelo como una probabilidad verdadera conocida. La necesidad de aproximar η es precisamente la razón por la que aparece un modelo.

Formalmente, podemos escribir

$$Y \mid X = x \sim \text{Bernoulli}(\eta(x)), \quad \eta(x) = \mathbb{P}(Y = 1 \mid X = x).$$

Una variable Bernoulli toma el valor 1 con probabilidad $\eta(x)$ y el valor 0 con probabilidad $1 - \eta(x)$. Su esperanza condicional es

$$\mathbb{E}[Y \mid X = x] = \eta(x).$$

Así, en una respuesta binaria, la media condicional estudiada en regresión es al mismo tiempo la probabilidad condicional de la clase positiva. El problema ha cambiado de forma, pero no de principio: buscamos una cantidad poblacional a partir de observaciones finitas.

La familia logística supone $\eta_\theta(x) = \sigma(x^\top \theta)$. Al ajustar, minimizamos log-loss empírica; la cantidad poblacional correspondiente es

$$R_{\log}(\theta) = \mathbb{E}[-Y \log \eta_\theta(X) - (1 - Y) \log(1 - \eta_\theta(X))].$$

Exceso de log-loss y divergencia. Condicionado en $X = x$, si la probabilidad verdadera es $\eta(x)$ y el modelo reporta $q(x)$, entonces

$$L_x(q) - L_x(\eta) = \text{KL}(\text{Bern}(\eta) \parallel \text{Bern}(q)) \geq 0.$$

La log-loss no solo penaliza clases equivocadas: evalúa una distribución predictiva completa y es estrictamente propia.




Figura 12: Regresión logística: la curva sigmoide produce probabilidades; un umbral convierte probabilidades en clases y modifica la matriz de confusión.

Lectura de la figura. El modelo y la decisión son dos pasos distintos. La sigmoide produce probabilidades; el umbral τ convierte esas probabilidades en clases y cambia los errores observados.

Clasificación binaria

En clasificación binaria, la variable objetivo toma dos valores:

$$y_i \in \{0, 1\}.$$

Ejemplos:

Contexto	Clase positiva 1
diagnóstico	paciente con condición
fraude	transacción fraudulenta
retención	cliente abandona
calidad	producto defectuoso
admisión	solicitud aprobada

La elección de cuál clase es positiva no es neutral. Las métricas y los costos se interpretan respecto a esa clase.

Criterio aplicado. Antes de calcular métricas, declara qué significa la clase positiva y por qué importa.

La función sigmoide

La regresión lineal produce valores en toda la recta real. Para modelar probabilidades necesitamos valores entre 0 y 1. Usamos:

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Propiedades:

- si z es grande positivo, $\sigma(z)$ se acerca a 1;
- si z es grande negativo, $\sigma(z)$ se acerca a 0;
- si $z=0$, $\sigma(z)=0.5$.

```
def sigmoid(z):  
    z = np.asarray(z, dtype=float)  
    out = np.empty_like(z)  
    pos = z >= 0  
    out[pos] = 1 / (1 + np.exp(-z[pos]))  
    exp_z = np.exp(z[~pos])  
    out[~pos] = exp_z / (1 + exp_z)  
    return out
```

La implementación anterior evita overflow numérico cuando z es muy negativo o muy positivo.

Modelo logístico

Definimos:

$$z_i = x_i^\top \theta.$$

La probabilidad estimada por el modelo es:

$$\hat{p}_\theta(x_i) = \sigma(x_i^\top \theta).$$

En forma vectorizada:

$$\hat{p} = \sigma(X\theta).$$

```
z = X @ theta  
p_hat = sigmoid(z)
```

La igualdad

$$\eta(x) = \sigma(x^\top \theta)$$

es un supuesto de especificación, no una consecuencia de aplicar la sigmoide. La calidad de $\hat{p}_\theta$ debe evaluarse fuera del ajuste.

Log-odds

La regresión logística es lineal en los log-odds de su probabilidad estimada:

$$\log \left(\frac{\hat{p}_\theta(x)}{1 - \hat{p}_\theta(x)} \right) = x^\top \theta.$$

Esto significa que un aumento de una unidad en $\mathbf{x}_j$, manteniendo lo demás constante, aumenta los log-odds en θ_j .

Si exponenciamos:

$$e^{\theta_j}$$

es el factor multiplicativo sobre los odds asociado con una unidad adicional de $\mathbf{x}_j$, manteniendo las demás variables constantes.

Cuidado interpretativo. Los coeficientes logísticos no son cambios directos en probabilidad. Son cambios en log-odds. La variación en probabilidad depende del punto donde se evalúe.

Por qué no usamos MSE

Podríamos intentar ajustar probabilidades con MSE, pero la pérdida natural para clasificación probabilística es la log-loss. Viene de máxima verosimilitud para una variable Bernoulli.

Si $y_i=1$, queremos que p_i sea grande. Si $y_i=0$, queremos que $1-p_i$ sea grande. La verosimilitud de una observación es:

$$p_i^{y_i} (1 - p_i)^{1-y_i}.$$

La log-verosimilitud promedio es:

$$\frac{1}{m} \sum_{i=1}^m [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)].$$

Como optimizamos minimizando, usamos la negativa:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Definición 4.1: log-loss binaria.

La log-loss penaliza probabilidades confiadas en la dirección equivocada. Una predicción $p=0.99$ cuando $y=0$ recibe una penalización mucho mayor que una predicción $p=0.55$ cuando $y=0$.

La misma pérdida puede escribirse directamente con el *logit* $z_i = x_i^\top \theta$:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [\log(1 + e^{z_i}) - y_i z_i].$$

Esta forma permite una implementación estable sin construir primero probabilidades:

```
def log_loss_from_logits(y, z):
    y = np.asarray(y, dtype=float)
    z = np.asarray(z, dtype=float)
    return np.mean(np.logaddexp(0.0, z) - y * z)
```

Si ya se tienen probabilidades, se pueden recortar para evitar $\log(0)$:

```
def log_loss_binary(y, p, eps=1e-15):
    p = np.clip(p, eps, 1 - eps)
    return -np.mean(y * np.log(p) + (1 - y) * np.log(1 - p))
```

Gradiente de la pérdida logística

Para regresión logística:

$$\hat{p} = \sigma(X\theta).$$

La pérdida es:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Para derivar el gradiente, considere primero una observación. Como

$$\frac{d\sigma(z)}{dz} = \sigma(z)(1 - \sigma(z)),$$

la regla de la cadena produce

$$\frac{\partial}{\partial z_i} [-y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i)] = \hat{p}_i - y_i.$$

Además, $\nabla_{\theta} z_i = x_i$. Al sumar las m contribuciones:

$$\nabla J(\theta) = \frac{1}{m} X^{\top} (\hat{p} - y).$$

Proposición 4.1: gradiente logístico.

Para regresión logística binaria con log-loss, el gradiente respecto a `theta` es

$$\nabla J(\theta) = \frac{1}{m} X^{\top} (\sigma(X\theta) - y).$$

Implementación:

```
def logistic_gradient(X, y, theta):  
    p = sigmoid(X @ theta)  
    return (X.T @ (p - y)) / X.shape[0]
```

Hessiana, convexidad y existencia de la solución

La derivada anterior permite estudiar la geometría del objetivo. Sea $W(\theta)$ la matriz diagonal con entradas

$$W_{ii} = \hat{p}_i(1 - \hat{p}_i).$$

Al derivar de nuevo,

$$\nabla^2 J(\theta) = \frac{1}{m} X^{\top} W(\theta) X.$$

Para cualquier vector v ,

$$v^{\top} \nabla^2 J(\theta) v = \frac{1}{m} (Xv)^{\top} W(\theta) (Xv) = \frac{1}{m} \sum_{i=1}^m \hat{p}_i(1 - \hat{p}_i) (x_i^{\top} v)^2 \geq 0.$$

La log-loss logística es, por tanto, convexa. No tiene mínimos locales malos. La convexidad no asegura, sin embargo, que exista un minimizador finito. Si los datos son linealmente separables, puede haber una dirección que empuje las probabilidades de todas las clases hacia 0 o 1 mientras la pérdida se acerca a cero y $\|\theta\|$ crece sin cota.

Añadir una penalización L2 produce

$$J_{\lambda}(\theta) = J(\theta) + \frac{\lambda}{2} \|\theta_{1:p}\|_2^2.$$

Además de controlar variación, esta penalización evita el crecimiento indefinido de los coeficientes en las direcciones penalizadas. El intercepto suele quedar fuera de la penalización y las variables deben escalarse antes de comparar magnitudes.

Convexidad de la pérdida logística. La log-loss empírica de regresión logística es convexa porque su Hessiana tiene la forma $X^\top W X/m$ con $W \succeq 0$. Es estrictamente convexa si no quedan direcciones no identificadas por X y los pesos son positivos, pero la separabilidad puede impedir que el ínfimo se alcance en un parámetro finito.

Algoritmos y costo

Un paso de gradiente calcula logits, probabilidades y $X^\top(\hat{p} - y)$; su costo es $O(mp)$ y necesita $O(m + p)$ memoria auxiliar. El método de Newton usa además la Hessiana: formarla cuesta $O(mp^2)$ y resolver el sistema cuesta $O(p^3)$. Newton puede requerir menos iteraciones, pero resulta poco atractivo cuando p es grande.

Las bibliotecas suelen usar variantes de Newton, quasi-Newton, gradiente o descenso por coordenadas según la penalización y el tamaño. «Ajustar regresión logística» no identifica un único algoritmo. Lo que permanece fijo es el objetivo; el solver determina cómo se aproxima su minimizador y qué criterio de parada se usa.

La evaluación debe incluir dos comprobaciones distintas: convergencia del solver y desempeño fuera del ajuste. Un solver puede converger con precisión a un modelo mal especificado; una buena métrica de validación tampoco demuestra que el solver haya resuelto el objetivo con la tolerancia declarada.

De probabilidades a clases

El modelo produce probabilidades. Para tomar una decisión binaria usamos un umbral:

$$\hat{y}_i = \begin{cases} 1, & \hat{p}_i \geq \tau, \\ 0, & \hat{p}_i < \tau. \end{cases}$$

El valor común es `tau=0.5`, pero no siempre es el mejor.

```
def predict_class(p, threshold=0.5):
    return (p >= threshold).astype(int)
```

Matriz de confusión

	Predicho 1	Predicho 0
Real 1	TP	FN
Real 0	FP	TN

Donde:

- TP: verdaderos positivos;
- TN: verdaderos negativos;
- FP: falsos positivos;
- FN: falsos negativos.

```
def confusion_counts(y_true, y_pred):
    y_true = np.asarray(y_true)
    y_pred = np.asarray(y_pred)
    tp = np.sum((y_true == 1) & (y_pred == 1))
    tn = np.sum((y_true == 0) & (y_pred == 0))
    fp = np.sum((y_true == 0) & (y_pred == 1))
    fn = np.sum((y_true == 1) & (y_pred == 0))
    return tp, fp, tn, fn
```

Métricas

Accuracy:

$$\frac{TP + TN}{TP + TN + FP + FN}.$$

Precision:

$$\frac{TP}{TP + FP}.$$

Recall:

$$\frac{TP}{TP + FN}.$$

F1:

$$2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}.$$

```
def classification_metrics(y_true, y_pred):
    tp, fp, tn, fn = confusion_counts(y_true, y_pred)
    accuracy = (tp + tn) / (tp + tn + fp + fn)
    precision = tp / (tp + fp) if (tp + fp) else 0.0
    recall = tp / (tp + fn) if (tp + fn) else 0.0
    f1 = (
        2 * precision * recall / (precision + recall)
        if (precision + recall) else 0.0
    )
    return {
```

```
"accuracy": accuracy,  
"precision": precision,  
"recall": recall,  
"f1": f1,  
}
```

Ejemplo resuelto: umbral y matriz de confusión

Supón seis observaciones con etiquetas reales:

$$y = (1, 0, 1, 0, 1, 0)$$

y probabilidades predichas:

$$\hat{p} = (0.92, 0.61, 0.55, 0.40, 0.20, 0.10).$$

Con umbral $\tau = 0.5$:

$$\hat{y} = (1, 1, 1, 0, 0, 0).$$

Los conteos son:

- $TP = 2$: observaciones 1 y 3;
- $FP = 1$: observación 2;
- $TN = 2$: observaciones 4 y 6;
- $FN = 1$: observación 5.

Por tanto:

$$\text{accuracy} = \frac{2+2}{6} = 0.667, \quad \text{precision} = \frac{2}{2+1} = 0.667, \quad \text{recall} = \frac{2}{2+1} = 0.667.$$

Como precision y recall son iguales, $F1 = 0.667$.

Si subimos el umbral a $\tau = 0.7$, entonces:

$$\hat{y} = (1, 0, 0, 0, 0, 0).$$

Ahora $TP = 1$, $FP = 0$, $TN = 3$, $FN = 2$. La precision sube a 1.0, pero recall baja a 1/3. El modelo no cambió; cambió la regla de decisión.

Elegir métricas según la decisión

No hay una métrica universal.




Figura 13: Selección de métricas: el costo relativo de falsos positivos y falsos negativos orienta si conviene mirar accuracy, precisión, recall o una métrica F beta.

Lectura de la figura. La métrica traduce el costo de equivocarse. Si el falso negativo y el falso positivo no tienen el mismo impacto, accuracy rara vez basta como criterio principal.

Situación	Riesgo principal	Métrica prioritaria
enfermedad grave	falso negativo	recall
fraude con revisión humana costosa	falso positivo	precision
clases balanceadas y costos similares	error global	accuracy
balance precision/recall	ambos errores importan	F1
ranking de candidatos	calidad del orden	ROC-AUC o PR-AUC

Criterio aplicado. La métrica se elige antes de mirar cuál modelo gana. Si eliges la métrica después, puedes estar optimizando la historia que te conviene.

Umbrales

Cambiar el umbral cambia la matriz de confusión.

- Umbral bajo: más positivos predichos, mayor recall, menor precision.
- Umbral alto: menos positivos predichos, mayor precision, menor recall.

Ejemplo de función para elegir el umbral más alto que mantiene un recall mínimo:

```
def choose_threshold_for_recall(y_true, p, min_recall=0.90):
    candidates = np.sort(np.unique(p))
    best = None
    for threshold in candidates:
        y_pred = (p >= threshold).astype(int)
        metrics = classification_metrics(y_true, y_pred)
        if metrics["recall"] >= min_recall:
            best = threshold
    return best
```

La función debe recibir etiquetas y probabilidades de **validación**. La lógica depende del problema: en algunos contextos se maximiza F1; en otros se impone un recall mínimo o un máximo de falsos positivos. Después de fijar el umbral, test se consulta una sola vez. Elegir τ con test contamina la estimación final.

Baselines de clasificación

Baselines comunes:

1. predecir siempre la clase mayoritaria;
2. predecir con frecuencia igual a la prevalencia;
3. regla simple basada en una variable fuerte;
4. modelo logístico sin features complejas.

Si el dataset tiene 95 % de clase 0, un clasificador que siempre predice 0 tiene 95 % de accuracy. Por eso accuracy puede ser engañosa en clases desbalanceadas.

Calibración

Un modelo está calibrado si, entre observaciones con probabilidad predicha cercana a 0.8, aproximadamente 80 % pertenecen a la clase positiva.

La calibración es distinta de la clasificación. Un modelo puede ordenar bien pero producir probabilidades mal calibradas.

En este módulo basta con recordar:

- la salida logística es una probabilidad estimada bajo una familia de modelo;
- esa probabilidad debe evaluarse empíricamente;
- el umbral transforma probabilidad en decisión.

Errores comunes

1. Tratar probabilidades como clases sin declarar umbral.
2. Usar accuracy en clases muy desbalanceadas sin mirar precision/recall.
3. Elegir umbral con el conjunto de prueba.
4. No definir la clase positiva.
5. Confundir coeficientes logísticos con cambios lineales en probabilidad.
6. Reportar F1 sin explicar el costo de FP y FN.
7. Comparar modelos usando umbrales distintos sin justificar.

Checklist de estudio

- ¿Puedes explicar por qué usamos sigmoide?
- ¿Puedes escribir la log-loss?
- ¿Puedes derivar o reconocer el gradiente logístico?
- ¿Puedes calcular TP, FP, TN, FN?
- ¿Puedes distinguir precision y recall?
- ¿Puedes justificar un umbral?
- ¿Puedes identificar cuándo accuracy engaña?

Para explorar más

- **Extensión matemática:** deriva el gradiente de la log-loss para una observación y luego generaliza a forma matricial.
- **Extensión computacional:** dibuja precisión, recall y F1 como funciones del umbral; identifica si existe un rango estable de decisión.
- **Conexión con proyecto:** escribe cuál error es más costoso en tu problema y justifica el umbral desde esa asimetría.

Revisión del capítulo

La regresión logística produce probabilidades estimadas para clasificación binaria. La función sigmoide transforma puntajes lineales en valores entre 0 y 1, y la log-loss penaliza predicciones probabilísticas incompatibles con la etiqueta observada.

El gradiente logístico tiene una forma compacta, $X^\top(\hat{p} - y)/m$, que conecta de nuevo matrices, pérdida y optimización. La clasificación final no aparece hasta elegir un umbral, y ese umbral cambia la matriz de confusión.

Por eso la evaluación debe ir más allá de accuracy. Precision, recall, F1 y la selección de umbral dependen del costo relativo de falsos positivos y falsos negativos. Una recomendación técnica debe declarar ese costo o, al menos, el riesgo que está priorizando.

Términos clave

- **Clase positiva:** evento o condición que se codifica como 1 y define la interpretación de métricas.
- **Sigmoide:** función que transforma un score real en un valor entre 0 y 1.
- **Log-odds:** logaritmo de la razón $p/(1-p)$.
- **Log-loss:** pérdida que penaliza probabilidades equivocadas, especialmente si son confiadas.
- **Matriz de confusión:** conteo de verdaderos/falsos positivos y negativos.
- **Precision:** proporción de predicciones positivas que fueron correctas.
- **Recall:** proporción de positivos reales detectados.
- **Umbral:** regla que convierte una probabilidad o score en clase.
- **Calibración:** correspondencia entre probabilidades predichas y frecuencias observadas.

Ejercicios

Preguntas conceptuales

1. ¿Por qué regresión logística no produce directamente una clase?
2. Explica qué significa que el modelo produzca $\hat{p}(x) = 0.8$ y qué no puede afirmarse sin estudiar calibración.
3. ¿Por qué una predicción muy confiada y equivocada recibe alta log-loss?
4. ¿Qué diferencia hay entre precision y recall?
5. Da un ejemplo donde prefieras recall sobre precision.

Problemas cuantitativos

6. Calcula `sigma(0)`, `sigma(2)` y `sigma(-2)` aproximadamente.
7. Si TP=40, FP=10, TN=80, FN=20, calcula accuracy, precision, recall y F1.
8. Para $y=1$ y $p=0.9$, calcula la contribución a log-loss. Repite con $p=0.1$.
9. Si $\theta_j=0.7$, ¿cuánto se multiplican los odds por una unidad adicional de x_j ?

Práctica computacional

10. Implementa `sigmoid(z)` de forma estable.
11. Implementa `log_loss_binary(y, p)`.
12. Implementa `logistic_gradient(X, y, theta)`.
13. Implementa `classification_metrics(y_true, y_pred)`.
14. Evalúa métricas para umbrales 0.2, 0.5 y 0.8.
15. Elige en validación un umbral que mantenga recall al menos 0.95; después evalúalo una sola vez en test.

Interpretación y pensamiento crítico

16. Un modelo tiene accuracy 0.94, pero recall de la clase positiva 0.20. ¿Qué puede estar pasando?
17. En fraude, subir el umbral aumenta precision y baja recall. ¿Cómo explicarías el tradeoff a una persona no técnica?
18. Si dos modelos tienen F1 similar, pero uno tiene mejor calibración, ¿en qué situación preferirías el calibrado?

Profundización matemática y algorítmica

19. Deriva la Hessiana $X^T W X / m$ y demuestra que es semidefinida positiva.
20. Construye un dataset linealmente separable y explica por qué la log-loss puede disminuir mientras la norma de los coeficientes crece.
21. Compara el costo de un paso de gradiente con el de un paso de Newton para m observaciones y p variables.
22. Para costos $C_{FP} = 2$ y $C_{FN} = 8$, deriva el umbral de Bayes suponiendo probabilidades calibradas. Explica por qué debe comprobarse con validación.

Proyecto de cierre

23. Entrena o simula un clasificador binario con probabilidades. Evalúa tres umbrales, reporta matriz de confusión, precision, recall y F1, y recomienda un umbral para un contexto donde el falso negativo sea más costoso que el falso positivo.

Ejercicios integradores: regresión, optimización y clasificación

Práctica para laboratorios, parcial y proyecto

Cómo usar este banco

Este capítulo contiene ejercicios para estudiar el Módulo 1 de forma activa. No están pensados para resolverse todos de una vez. Usa esta ruta:

1. resuelve primero los ejercicios conceptuales de cada bloque;
2. pasa a cálculo manual;
3. implementa funciones pequeñas;
4. cierra con interpretación aplicada;
5. compara tus respuestas con el apéndice solo después de intentar.

Regla de práctica. Si puedes ejecutar código pero no puedes explicar el objeto matemático que estás calculando, todavía falta estudio. Si puedes derivar una fórmula pero no puedes implementarla, todavía falta práctica computacional.

Resultados de práctica

Al terminar este banco deberías poder:

1. representar regresión lineal y logística con matrices;
2. calcular pérdidas, gradientes y métricas en casos pequeños;
3. implementar mínimos cuadrados, descenso del gradiente y Ridge;
4. diagnosticar underfitting, overfitting y leakage;
5. justificar regularización, métrica y umbral a partir de resultados verificables.

Mapa del banco

Bloque	Propósito
Semanas 2-3	álgebra matricial, mínimos cuadrados y optimización
Semanas 4-5	validación, features, Ridge, Lasso y selección
Semana 6	clasificación logística, métricas y umbrales
Problemas integradores	síntesis para laboratorio, parcial y proyecto

Columna probabilística del módulo

P1. Objeto poblacional y estimador. Para regresión con pérdida cuadrática, identifique: distribución P , regla poblacional óptima, familia lineal, estimador $\hat{\theta}(D_m)$ y estimación obtenida para una muestra concreta.

P2. Media condicional. Demuestre que $\mathbb{E}[(Y - a)^2 \mid X = x]$ se minimiza en $a = \mathbb{E}[Y \mid X = x]$. Separe el término irreducible del término que depende de a .

P3. Ruido y residual. En el modelo $Y = X^\top \beta + \varepsilon$, explique por qué ε es aleatorio y no observado, mientras $r_i = y_i - x_i^\top \hat{\beta}$ se calcula después del ajuste. Dé dos razones por las que r_i puede ser grande.

P4. Insesgamiento. Bajo $\mathbb{E}[\varepsilon \mid X] = 0$ y rango completo, derive $\mathbb{E}[\hat{\beta} \mid X]$. Indique por qué esta propiedad no implica que una estimación particular sea cercana a β .

P5. Variación de mini-batch. Compare dos estimadores del gradiente con mini-batches de tamaños 8 y 128. Ambos son insesgados para el gradiente empírico. ¿Cuál espera que tenga mayor varianza y qué efecto produce sobre la trayectoria?

P6. Selección. Explique por qué $\hat{R}_{\text{val}}(f)$ puede ser insesgado para una función fija y, sin embargo, el menor valor entre cien modelos evaluados en la misma validación puede ser optimista.

P7. Bernoulli y log-loss. Para $Y \mid X = x \sim \text{Bernoulli}(\eta)$, derive el riesgo condicional de reportar q y compruebe que su único minimizador es $q = \eta$.

P8. Simulación. Genere cien muestras de una misma regresión lineal, ajuste OLS en cada una y grafique la distribución de un coeficiente y del MAE de test. Distinga variación del estimador, ruido irreducible y error numérico.

Semana 2: regresión lineal

A. Dimensiones y representación

1. Tienes un dataset con $m = 250$ observaciones y $d = 6$ variables originales. Si agregas intercepto, ¿cuál es la forma de X y de θ ? Use $p = d + 1$ para las columnas de la matriz de diseño.
2. Explica qué significa cada fila y cada columna de la matriz de diseño.
3. Escribe la predicción de la observación i usando sumatoria.
4. Escribe la misma predicción usando producto punto.
5. ¿Qué error esperas si `theta` tiene forma `(d,)` pero `X` incluye intercepto?

B. Mínimos cuadrados

6. Para

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad y = \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix},$$

calcula $X.T @ X$ y $X.T @ y$.

7. Resuelve la ecuación normal del ejercicio anterior.
8. Calcula las predicciones y los residuales.
9. Calcula el MSE.
10. Compara contra el baseline que predice el promedio de y .

C. Implementación

11. Escribe una función `add_intercept(X)`.
12. Escribe una función `predict_linear(X, theta)`.
13. Escribe una función `mse_loss(X, y, theta)`.
14. Escribe una función `fit_lstsq(X, y)` que devuelva parámetros, rango y valores singulares.
15. Simula $y = 5 + 0.8x + \text{ruido}$ y verifica si recuperas parámetros cercanos.

D. Interpretación

16. Tu modelo mejora el baseline en entrenamiento, pero no en prueba. Da tres posibles explicaciones.
17. Un coeficiente estimado es negativo. ¿Qué significa y qué no significa?
18. ¿Por qué debes revisar unidades antes de comparar coeficientes?

Semana 3: descenso del gradiente

A. Gradiente

1. Escribe la pérdida $J(\mathbf{\theta})$ para mínimos cuadrados.
2. Deriva el gradiente usando expansión matricial.
3. Deriva el gradiente usando residuales.
4. Explica por qué el gradiente tiene la misma dimensión que $\mathbf{\theta}$.
5. ¿Qué significa que el gradiente sea cero?

B. Iteraciones

6. Con

$$\theta^{(0)} = (0, 0), \quad \alpha = 0.1,$$

ejecuta dos pasos manuales para el dataset:

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, y = \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix}.$$

7. ¿Qué pasa si duplicas todas las columnas de X excepto el intercepto?
8. ¿Por qué la tasa de aprendizaje estable puede cambiar?

C. Diagnóstico

9. Describe qué harías si la pérdida aumenta en las primeras iteraciones.
10. Describe qué harías si la pérdida baja, pero muy lentamente.
11. Describe qué harías si la pérdida de entrenamiento baja y la de validación sube.
12. ¿Cómo usarías `np.linalg.lstsq` para probar tu implementación de gradiente?

D. Código

13. Implementa `mse_gradient(X, y, theta)`.
14. Implementa `gradient_descent`.
15. Guarda `history` y grafica pérdida contra iteración.
16. Compara `theta_gd` contra `theta_ref` obtenido con `np.linalg.lstsq`.
17. Repite con datos sin escalar y escalados.

Semana 4: features y validación

A. Complejidad

1. Explica por qué un modelo polinomial de grado 1 puede subajustar.
2. Explica por qué un modelo polinomial de grado 20 puede sobreajustar.
3. ¿Qué patrón esperas en errores train/validation para cada caso?
4. ¿Qué tipo de problema no se arregla solo aumentando el grado?

B. Particiones

5. Define train, validation y test en una frase cada uno.
6. ¿Por qué no se debe usar test para escoger grado?
7. ¿Qué harías si solo tienes 80 observaciones?
8. Da un ejemplo de leakage temporal.
9. Explique por qué calcular x^2 fila por fila no aprende información de test, mientras que elegir el grado después de mirar test sí lo hace.

C. Feature engineering

10. Construye manualmente features para $\mathbf{x}$: 1, $\mathbf{x}$, $\mathbf{x}^2$, $\mathbf{x}^3$.
11. Para dos variables $\mathbf{x}_1$, $\mathbf{x}_2$, propone tres interacciones posibles.
12. ¿Cuándo usarías $\log(\mathbf{x})$?
13. ¿Qué problema aparece si $\mathbf{x}$ puede ser cero o negativo?

D. Código

14. Implementa `polynomial_features_1d`.
15. Entrena grados 1 a 10.
16. Grafica MSE train y MSE validation contra grado.
17. Escoge un grado y justifica la elección.

Semana 5: regularización

A. Ridge

1. Escribe el objetivo Ridge.
2. Explica por qué no se suele penalizar el intercepto.
3. Deriva la solución cerrada cuando se penalizan todos los coeficientes.
4. Modifica la solución para no penalizar intercepto.
5. Explica qué ocurre cuando `lambda=0`.
6. Si el objetivo manual usa $\|X\theta - y\|^2/(2m) + \lambda\|\theta\|^2/2$, ¿qué relación debe tener `alpha` de `sklearn.linear_model.Ridge` con λ ?

B. Lasso

7. Escribe el objetivo Lasso.
8. ¿Por qué Lasso puede producir coeficientes exactamente cero?
9. ¿Qué precaución tomarías con variables correlacionadas?
10. ¿Por qué Lasso no prueba causalidad?

C. Selección

11. Diseña una tabla para comparar `lambda`, MSE train, MSE validation y norma de coeficientes.
12. ¿Qué `lambda` escogerías si el menor MSE validation está empatado entre dos valores?
13. ¿Qué resultados reportarías para justificar el modelo final?

D. Código

14. Implementa `ridge_closed_form`.
15. Compara `lambda` en escala logarítmica.
16. Grafica norma de coeficientes contra `lambda`.
17. Compara con `sklearn.linear_model.Ridge` después de hacer compatible la convención de penalización.
18. Si usas Lasso de `sklearn`, revisa cuántos coeficientes quedan en cero.

Semana 6: clasificación logística

A. Probabilidades

1. Explica por qué una regresión lineal no es ideal para probabilidades.
2. Grafica mentalmente la sigmoide.
3. ¿Qué significa $\sigma(z)=0.5$?
4. ¿Qué significa log-odds?

B. Log-loss

5. Escribe la log-loss binaria.
6. Calcula la pérdida para $y=1$, $p=0.9$.
7. Calcula la pérdida para $y=1$, $p=0.1$.
8. Explica por qué la segunda es mayor.
9. Deriva el gradiente $X.T @ (p - y) / m$.

C. Métricas

10. Con TP=25, FP=5, TN=60, FN=10, calcula accuracy, precision, recall y F1.
11. Explica cuándo accuracy puede engañar.
12. Da un caso donde un falso negativo sea más costoso que un falso positivo.
13. Da un caso donde un falso positivo sea más costoso que un falso negativo.

D. Umbrales

14. Si bajas el umbral, ¿qué suele pasar con recall?
15. Si subes el umbral, ¿qué suele pasar con precision?
16. Diseña una regla de umbral para un sistema de alerta médica.
17. Diseña una regla de umbral para revisión manual de fraude con capacidad limitada.

Problemas integradores

Problema 1: regresión de principio a fin

Toma un dataset de regresión, por ejemplo `load_diabetes`.

1. Separa train/validation/test.
2. Define un baseline de promedio.
3. Ajusta regresión lineal.
4. Reporta MSE train y validation durante la selección.
5. Estandariza variables y repite.
6. Ajusta Ridge con varios `lambda`.
7. Escoge un modelo con validación.
8. Consulta test una vez y escribe una conclusión técnica de máximo 150 palabras.

La conclusión debe responder:

- ¿mejora el baseline?
- ¿cuál métrica usaste?
- ¿qué limitación principal observas?
- ¿qué harías después?

Problema 2: regularización y estabilidad

Construye un dataset generado con variables correlacionadas:

```
rng = np.random.default_rng(42)
m = 200
x1 = rng.normal(size=m)
x2 = x1 + 0.05 * rng.normal(size=m)
x3 = rng.normal(size=m)
y = 2 + 3 * x1 + 0.5 * x3 + rng.normal(scale=0.5, size=m)
```

1. Ajusta regresión lineal.
2. Ajusta Ridge.
3. Ajusta Lasso.
4. Compara coeficientes.
5. Explica qué ocurre con `x1` y `x2`.

Problema 3: clasificación con umbral

Usa `load_breast_cancer` o un dataset binario similar.

1. Define clase positiva.
2. Separa train/validation/test con estratificación.
3. Estandariza variables.
4. Ajusta regresión logística.
5. Reporta métricas de validación para umbral 0.5.
6. Escoge en validación un umbral para recall mínimo 0.95.
7. Fija el umbral, consulta test una vez y reporta su matriz de confusión.
8. Explica el tradeoff en lenguaje no técnico.

Problema 4: diseño de parcial

Escribe una pregunta de parcial para cada tema:

1. forma matricial;
2. gradiente de MSE;
3. escalamiento;
4. Ridge;
5. log-loss;
6. precision/recall.

Para cada pregunta incluye:

- respuesta correcta;
- error común esperado;
- por qué la pregunta evalúa comprensión y no memoria.

Rúbrica de autoevaluación

Nivel	Indicador
Inicial	puedo ejecutar notebooks siguiendo instrucciones
Básico	puedo completar funciones pequeñas con ayuda
Competente	puedo derivar fórmulas centrales e implementarlas
Sólido	puedo diagnosticar fallas y justificar decisiones
Excelente	puedo conectar matemática, código, métrica y contexto aplicado

Antes del Parcial 1, deberías estar al menos en nivel competente en todos los temas y sólido en los temas que uses en tu proyecto.

Guía de verificación seleccionada

Semana 2, ejercicio 1. Si hay $d = 6$ variables originales y se agrega intercepto, entonces $p = 7$, X tiene forma $(250, 7)$ y `theta` debe tener 7 entradas.

Semana 5, ejercicio 6. Al multiplicar el objetivo manual por $2m$ se obtiene $\|X\theta - y\|^2 + m\lambda\|\theta\|^2$. Por tanto, con la convención documentada por `Ridge`, debe usarse `alpha = m * lambda`.

Semana 6, ejercicio 10. Con TP=25, FP=5, TN=60, FN=10, accuracy es $85/100 = 0.85$, precision es $25/30$, recall es $25/35$ y F1 se calcula como media armónica de precision y recall.

Parte III: Redes neuronales

Una regresión logística transforma una combinación lineal de las variables en una probabilidad. Una red neuronal conserva esa idea y la repite en varias capas: cada capa aplica una transformación afín y una función no lineal, y la composición completa representa una familia mucho más flexible de funciones.

El estudio comienza con la propagación hacia adelante y con las dimensiones de los tensores que intervienen. La entropía cruzada extiende la log-loss a varias clases y permite interpretar la salida *softmax* como una distribución condicional estimada. Después, la regla de la cadena conduce a *backpropagation*, no como una fórmula para memorizar, sino como un procedimiento que recorre en sentido inverso el grafo de cálculo.

Las capas adicionales también introducen nuevos problemas. La inicialización es aleatoria, los gradientes pueden calcularse con minibatches y distintas corridas pueden producir modelos diferentes. Los capítulos finales de esta parte separan esas fuentes de variación, estudian regularización y optimizadores, y muestran qué automatiza PyTorch y qué debe seguir verificando quien implementa el modelo.




Figura 14: Backpropagation como grafo: el forward calcula activaciones y pérdida; el backward propaga gradientes usando la cache.

La figura resume las dos direcciones del cálculo. La pasada *forward* conserva las cantidades que serán necesarias después; la pasada *backward* combina derivadas locales para obtener los gradientes de los parámetros. Seguir las formas de esos objetos es una de las comprobaciones más eficaces de toda implementación.

Perceptron, neurona logística y forward propagation

Pregunta aplicada

Suponga que tenemos imágenes pequeñas de dígitos escritos a mano. Una regresión logística puede separar dos clases simples, pero ¿qué ocurre cuando la frontera entre clases requiere interacciones no lineales entre píxeles?

Una red neuronal densa permite aprender representaciones intermedias. La idea central puede escribirse sin metáforas:

Una **red neuronal feedforward** es una composición de transformaciones afines y funciones no lineales.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. reconocer una neurona logística como una capa lineal seguida de una activación;
2. escribir las dimensiones correctas de una capa densa;
3. explicar por qué una activación no lineal cambia la capacidad del modelo;
4. implementar softmax de forma estable;
5. interpretar entropía cruzada como pérdida para clasificación multiclase.
6. contar parámetros y estimar el costo de una pasada forward;
7. distinguir capacidad expresiva, estabilidad numérica y calidad estadística.

Distribución predictiva y riesgo

Para K clases, representamos

$$Y \mid X = x \sim \text{Categorical}(\pi_1(x), \dots, \pi_K(x)), \quad \sum_{k=1}^K \pi_k(x) = 1.$$

Una red produce logits $z(x; \theta)$ y probabilidades $q_\theta(x) = \text{softmax}(z(x; \theta))$. La entropía cruzada empírica aproxima el riesgo poblacional

$$R_{\text{CE}}(\theta) = \mathbb{E}[-\log q_{\theta,Y}(X)].$$

La distribución verdadera minimiza entropía cruzada. Condicionado en $X = x$, para cualquier vector de probabilidades q ,

$$-\sum_{k=1}^K \pi_k(x) \log q_k = H(\pi(x)) + \text{KL}(\pi(x) \| q) \geq H(\pi(x)).$$

El mínimo se alcanza en $q = \pi(x)$. La red aproxima esa distribución dentro de su familia paramétrica; softmax por sí solo no garantiza calibración.

Si al inicio todas las clases reciben probabilidad $1/K$, la pérdida esperada por observación es $\log K$. Este valor es una comprobación probabilística del forward, no una meta de entrenamiento.

Perceptron como unidad básica

Dada una observación $x \in \mathbb{R}^p$, un perceptron calcula:

$$z = w^\top x + b.$$

Si se aplica una regla de decisión:

$$\hat{y} = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0, \end{cases}$$

obtenemos un clasificador lineal.

Advertencia

El perceptron clásico produce una decisión dura. Para entrenar con gradientes resulta más conveniente usar funciones diferenciables y pérdidas suaves.

Neurona logística

La regresión logística ya puede verse como una neurona:

$$\hat{p} = \sigma(w^\top x + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

La salida $\hat{p}$ es la probabilidad **estimada por el modelo** para la clase positiva. No es una probabilidad poblacional conocida: depende de los datos, la especificación y el ajuste. Esta construcción conecta el Módulo 1 con redes neuronales:

`regresión logística = una capa lineal + sigmoide`

De una neurona a una capa

Una capa densa con h neuronas calcula, para m observaciones y d variables de entrada:

$$Z^{[1]} = XW^{[1]} + b^{[1]},$$

donde:

- $X \in \mathbb{R}^{m \times d}$;
- $W^{[1]} \in \mathbb{R}^{d \times h}$;
- $b^{[1]} \in \mathbb{R}^h$;
- $Z^{[1]} \in \mathbb{R}^{m \times h}$.

Luego aplicamos una activación elemento a elemento:

$$A^{[1]} = g(Z^{[1]}).$$

Red de una capa oculta

Para clasificación multiclase con k clases:

$$Z^{[1]} = XW^{[1]} + b^{[1]},$$

$$A^{[1]} = \text{ReLU}(Z^{[1]}),$$

$$Z^{[2]} = A^{[1]}W^{[2]} + b^{[2]},$$

$$\hat{P} = \text{softmax}(Z^{[2]}).$$

Esta escritura define una función parametrizada

$$f_{\theta} : \mathbb{R}^d \longrightarrow \Delta^{k-1},$$

donde Δ^{k-1} es el simplex de probabilidades sobre k clases y

$$\theta = (W^{[1]}, b^{[1]}, W^{[2]}, b^{[2]}).$$

Con h unidades ocultas, el número de parámetros escalares es

$$dh + h + hk + k.$$

El ancho h modifica simultáneamente la capacidad del modelo, el costo de cómputo y el número de cantidades estimadas a partir de la muestra. Aumentarlo no es una mejora gratuita.

ReLU

$$\text{ReLU}(z) = \max(0, z).$$

ReLU introduce no linealidad y evita parte de la saturación que aparece con sigmoides en redes profundas.

Su derivada por partes es:

$$\text{ReLU}'(z) = \begin{cases} 1, & z > 0, \\ 0, & z \leq 0. \end{cases}$$

En $z = 0$ la derivada clásica no existe. En este curso, y en el laboratorio, usamos el valor computacional 0.

Softmax

Para logits $z_1, \dots, z_k$:

$$\text{softmax}(z)_j = \frac{e^{z_j}}{\sum_{\ell=1}^k e^{z_\ell}}.$$

En implementación usamos una versión estable:

```
shifted = Z - np.max(Z, axis=1, keepdims=True)
exp_scores = np.exp(shifted)
probs = exp_scores / np.sum(exp_scores, axis=1, keepdims=True)
```

Restar el máximo no cambia las probabilidades, pero evita overflow.

La invariancia se verifica directamente. Para cualquier constante c ,

$$\text{softmax}(z + c\mathbf{1})_j = \frac{e^{z_j+c}}{\sum_{\ell} e^{z_\ell+c}} = \frac{e^c e^{z_j}}{e^c \sum_{\ell} e^{z_\ell}} = \text{softmax}(z)_j.$$

Elegir $c = -\max_j z_j$ hace que el mayor exponente sea $e^0 = 1$ y que los demás no excedan 1. Esta transformación resuelve overflow; no evita por sí sola que probabilidades muy pequeñas se redondeen a cero. Para calcular la pérdida es preferible usar una operación `logsumexp` estable sobre logits.

Entropía cruzada multiclase

Si Y es one-hot y $\hat{P}$ contiene probabilidades estimadas:

$$J = -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^k Y_{ij} \log(\hat{P}_{ij}).$$

La pérdida premia asignar alta probabilidad a la clase correcta.

Por qué hace falta una no linealidad

Antes del cálculo numérico, conviene entender por qué una activación no lineal importa. Supón dos capas lineales sin activación:

$$H = XW^{[1]} + b^{[1]}, \quad Z = HW^{[2]} + b^{[2]}.$$

Sustituyendo H :

$$Z = (XW^{[1]} + b^{[1]})W^{[2]} + b^{[2]} = X(W^{[1]}W^{[2]}) + b^{[1]}W^{[2]} + b^{[2]}.$$

Si definimos $W^* = W^{[1]}W^{[2]}$ y $b^* = b^{[1]}W^{[2]} + b^{[2]}$, entonces:

$$Z = XW^* + b^*.$$

Dos capas afines sin activación equivalen a una sola transformación afín. La activación no lineal es lo que evita ese colapso.

La conclusión es estructural, no una afirmación de que cualquier red con ReLU aprenderá una buena frontera. ReLU hace que la función sea afín por regiones; la cantidad y disposición de esas regiones dependen de pesos, profundidad y ancho. La optimización todavía debe encontrar parámetros útiles y la evaluación debe determinar si la representación generaliza.

Costo de una pasada forward

Para un lote de m observaciones, la multiplicación $XW^{[1]}$ cuesta $O(mdh)$ y $A^{[1]}W^{[2]}$ cuesta $O(mhk)$. ReLU y softmax añaden $O(mh + mk)$. El costo dominante es, por tanto,

$$O(mh(d + k)).$$

Durante entrenamiento se guardan activaciones y preactivaciones para calcular gradientes. En esta red pequeña, la cache ocupa $O(mh + mk)$ números, además de los parámetros. En inferencia no hace falta conservar todo el grafo y la memoria puede reducirse.

Esta cuenta permite detectar un error conceptual frecuente: la notación de una capa puede caber en una línea, pero su costo crece con el tamaño del lote, la entrada, el ancho y la salida. Una comparación de arquitecturas debe reportar al menos parámetros, presupuesto de actualizaciones y tamaño de lote.

Ejemplo resuelto: softmax y pérdida

Supón que una observación produce tres logits:

$$z = (2, 1, 0).$$

Para calcular softmax de forma estable restamos el máximo, que es 2:

$$z - \max(z) = (0, -1, -2).$$

Entonces:

$$e^{z - \max(z)} = (1, e^{-1}, e^{-2}) \approx (1, 0.368, 0.135).$$

La suma es aproximadamente 1.503, así que:

$$\text{softmax}(z) \approx (0.665, 0.245, 0.090).$$

Si la clase correcta es la primera, la entropía cruzada para esta observación es:

$$-\log(0.665) \approx 0.408.$$

Si la clase correcta fuera la tercera, la pérdida sería:

$$-\log(0.090) \approx 2.408.$$

La misma predicción puede ser buena o mala según la etiqueta verdadera. Por eso no basta mirar logits grandes: hay que mirar la probabilidad asignada a la clase correcta.

Ejemplo resuelto: dimensiones

Suponga:

- $m = 100$ observaciones;
- $d = 64$ píxeles por imagen;
- $h = 32$ neuronas ocultas;
- $k = 10$ clases.

Entonces:

Objeto	Forma
X	100×64
$W^{[1]}$	64×32
$b^{[1]}$	32
$A^{[1]}$	100×32
$W^{[2]}$	32×10
$\hat{P}$	100×10

Caso longitudinal: dígitos escritos a mano

En los capítulos de redes usaremos como referencia conceptual el dataset `load_digits`: imágenes pequeñas de 8×8 píxeles, convertidas en vectores de 64 entradas. Este dataset no representa visión por computador moderna; su valor pedagógico es que permite ver todas las formas de una red pequeña sin depender de internet ni de archivos pesados.

Objeto	Forma típica	Interpretación
X	$m \times 64$	intensidad de píxeles aplanados
$W^{[1]}$	$64 \times h$	pesos de entrada a capa oculta
$A^{[1]}$	$m \times h$	representación intermedia
$W^{[2]}$	$h \times 10$	pesos hacia diez clases
$\hat{P}$	$m \times 10$	probabilidades estimadas por dígito

La primera comparación no debe ser contra una red grande. Debe ser contra un baseline simple: clase mayoritaria, regresión logística o una red pequeña sin tuning agresivo. Si la red mejora el baseline, todavía falta revisar validación, errores por clase y reproducibilidad del entrenamiento.

Punto de control

Antes de pasar a backpropagation, verifica que puedes responder sin mirar la tabla:

1. Si una capa recibe 64 variables y produce 32 activaciones, ¿qué forma tiene su matriz de pesos?
2. Si una red produce 10 logits por observación, ¿por qué softmax se aplica por fila?

3. Si se quita ReLU, ¿qué tipo de frontera queda después de componer capas lineales?

Respuesta corta. La matriz tiene forma 64×32 . Softmax se aplica por fila porque cada fila contiene las probabilidades de una observación sobre las 10 clases. Sin activaciones no lineales, la composición de capas sigue siendo una transformación lineal.

Verificaciones seleccionadas

1. Si X tiene forma 50×64 y $W^{[1]}$ tiene forma 64×16 , entonces $Z^{[1]}$ tiene forma 50×16 .
2. Si una red multiclase produce logits 50×10 , la suma de softmax debe ser 1 en cada fila, no en cada columna.
3. Si se eliminan todas las activaciones no lineales, la red completa equivale a una transformación lineal; por eso no aumenta capacidad geométrica real.

Ejemplo resuelto: auditoría de formas en dos capas

Supón un lote $X \in \mathbb{R}^{32 \times 8}$, una capa oculta con 5 neuronas y una salida de 3 clases. Una implementación consistente debe declarar

$$W^{[1]} \in \mathbb{R}^{8 \times 5}, \quad b^{[1]} \in \mathbb{R}^5, \quad W^{[2]} \in \mathbb{R}^{5 \times 3}, \quad b^{[2]} \in \mathbb{R}^3.$$

Entonces $Z^{[1]} = XW^{[1]} + b^{[1]}$ tiene forma 32×5 , la activación $A^{[1]}$ conserva esa forma y los logits finales tienen forma 32×3 . Softmax se aplica sobre las 3 columnas de cada fila, porque cada fila representa una observación. Si softmax se aplicara por columna, se estarían normalizando observaciones distintas entre sí, lo cual no tiene interpretación como distribución de clases para un caso individual.

Esta auditoría debe hacerse antes de entrenar. El notebook verifica formas en puntos intermedios, porque un error de broadcasting puede producir un arreglo numérico sin representar el modelo matemático esperado.

Para explorar más

- **Extensión matemática:** calcula manualmente una pasada forward con dos observaciones, dos entradas y dos neuronas ocultas.
- **Extensión computacional:** implementa la misma red con `numpy` y luego con `PyTorch`; compara formas y valores intermedios.
- **Conexión con proyecto:** identifica si tu problema necesita una arquitectura no lineal o si un modelo lineal regularizado sigue siendo un baseline suficiente.

Revisión del capítulo

Este capítulo construye una red neuronal desde sus operaciones de forward pass. Una neurona combina una transformación lineal con una activación; una red densa apila esas operaciones para producir logits y probabilidades.

La no linealidad es esencial. Sin activaciones no lineales, varias capas lineales se pueden reescribir como una sola transformación lineal. ReLU introduce capacidad adicional y softmax convierte logits multiclase en una distribución de probabilidad por observación.

El criterio de dominio de este capítulo es la trazabilidad de formas. Antes de entrenar, debes poder decir la forma de W , b , Z , A , logits, probabilidades y etiquetas. Sin esa auditoría, los errores de broadcasting pueden parecer resultados válidos.

Términos clave

- **Perceptron:** unidad que combina entradas con pesos y sesgo para producir un puntaje real.
- **Capa densa:** transformación afín $XW + b$ aplicada a un lote de observaciones.
- **Activación:** función no lineal aplicada a los scores de una capa.
- **ReLU:** activación $\max(0, z)$ usada para introducir no linealidad.
- **Logit:** score real antes de convertirlo en probabilidad.
- **Softmax:** transformación que convierte logits multiclase en probabilidades por fila.
- **One-hot:** codificación de clases como vectores indicadores.
- **Entropía cruzada:** pérdida que penaliza baja probabilidad asignada a la clase correcta.

Ejercicios

Preguntas conceptuales

1. Explique por qué una red sin activaciones no lineales se reduce a una transformación lineal.
2. ¿Qué diferencia hay entre logits y probabilidades?

Problemas cuantitativos

3. Si X tiene forma $(250, 20)$ y una capa oculta tiene 12 neuronas, ¿qué forma deben tener $W1$, $b1$ y $Z1$?
4. Para una salida con 5 clases y batch de 32 observaciones, indique la forma de los logits, las probabilidades softmax y la matriz one-hot Y .

Práctica computacional

5. Implemente una función `softmax_stable(Z)` y verifique que cada fila suma 1.
6. Implemente un `forward_pass(X, params)` para una red con una capa oculta ReLU y salida softmax.

Interpretación y pensamiento crítico

7. Una red obtiene probabilidades casi uniformes para todas las clases. Proponga dos hipótesis técnicas.

Profundización matemática y algorítmica

8. Demuestre que $\text{softmax}(\mathbf{z} + \mathbf{c})$ coincide con $\text{softmax}(\mathbf{z})$ para cualquier constante c y explique por qué se elige $c = -\max_j z_j$.
9. Para $d = 64$, $h = 32$ y $k = 10$, calcule el número de parámetros de la red, incluidos sesgos.
10. Estime el costo dominante de un forward con lote $m = 128$ y compare qué ocurre al duplicar h .
11. Explique por qué mayor número de regiones lineales no garantiza menor riesgo de validación.

Proyecto de cierre

12. Use un dataset multiclase generado con semilla fija o una muestra pequeña de imágenes. Defina dimensiones, implemente forward propagation y entregue una tabla con formas de cada objeto intermedio.

Backpropagation

Pregunta aplicada

Forward propagation nos dice cómo una red produce predicciones. Pero entrenar exige responder:

¿Cómo cambia la pérdida si modificamos cada peso de la red?

Backpropagation es una forma eficiente de aplicar la regla de la cadena a una composición de funciones.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. leer una red como grafo de cómputo;
2. derivar las formas de $dW^{[2]}$, $db^{[2]}$, $dW^{[1]}$ y $db^{[1]}$;
3. explicar por qué softmax con entropía cruzada produce $dZ^{[2]} = (\hat{P} - Y)/m$;
4. usar una cache de forward para calcular backward;
5. diseñar una prueba básica de gradientes.
6. derivar el Jacobiano de softmax y la regla de una capa afín;
7. explicar por qué backward tiene costo comparable con forward y por qué necesita una cache.

Del riesgo esperado al gradiente calculable

El objetivo poblacional de una red es

$$R_P(\theta) = \mathbb{E}_{Z \sim P}[\ell(\theta; Z)],$$

pero backpropagation se aplica a la pérdida empírica

$$\hat{R}_m(\theta) = \frac{1}{m} \sum_{i=1}^m \ell(\theta; Z_i).$$

Bajo condiciones que permiten intercambiar derivada y esperanza,

$$\nabla R_P(\theta) = \mathbb{E}[\nabla_{\theta} \ell(\theta; Z)].$$

Esta identidad explica por qué gradientes de observaciones o mini-batches pueden usarse como estimadores del gradiente poblacional. En el curso, la igualdad que podemos verificar exactamente es la correspondiente al riesgo empírico.

Una prueba de gradientes comprueba derivadas para una muestra y parámetros fijos. No comprueba representatividad de los datos, calibración ni bajo riesgo de uso.

El grafo de cómputo

Para una red de una capa oculta:

- entrada X ;
- preactivación Z_1 ;
- activación A_1 ;
- logits Z_2 ;
- probabilidades P ;
- pérdida J .

Cada flecha representa una operación diferenciable o casi diferenciable. Backpropagation recorre el grafo en sentido inverso:

- primero J ;
- luego P , Z_2 , A_1 y Z_1 ;
- finalmente los parámetros.

forward pass




Figura 15: Backpropagation como grafo: el forward calcula X , Z_1 , A_1 , Z_2 , P y J ; el backward propaga dJ hacia dZ_2 , dW_2 , dA_1 , dZ_1 y dW_1 usando la cache.

Lectura de la figura. Forward produce valores intermedios; backward reutiliza esa cache para construir gradientes. Si una forma no coincide con el parámetro correspondiente, el error está en el recorrido del grafo o en una transposición.

Gradiente de softmax con entropía cruzada

La simplificación no se toma como una regla memorizada. Para una observación, escribamos

$$p_a = \frac{e^{z_a}}{\sum_{r=1}^k e^{z_r}}.$$

Al derivar p_a respecto a z_b aparecen dos casos, que se reúnen con la delta de Kronecker δ_{ab} :

$$\frac{\partial p_a}{\partial z_b} = p_a(\delta_{ab} - p_b).$$

Si $L = -\sum_{a=1}^k y_a \log p_a$, la regla de la cadena da

$$\begin{aligned} \frac{\partial L}{\partial z_b} &= -\sum_{a=1}^k \frac{y_a}{p_a} \frac{\partial p_a}{\partial z_b} \\ &= -\sum_{a=1}^k y_a (\delta_{ab} - p_b) \\ &= -y_b + p_b \sum_{a=1}^k y_a \\ &= p_b - y_b, \end{aligned}$$

porque una etiqueta one-hot satisface $\sum_a y_a = 1$. Al promediar m observaciones:

$$\frac{\partial J}{\partial Z^{[2]}} = \frac{1}{m}(\hat{P} - Y).$$

La cancelación entre el Jacobiano de softmax y la derivada del logaritmo es una de las razones por las que esta combinación es estándar. Si se cambia la pérdida o la transformación de salida, esta identidad debe derivarse de nuevo.

Gradientes de la segunda capa

Con:

$$Z^{[2]} = A^{[1]}W^{[2]} + b^{[2]},$$

definimos:

$$dZ^{[2]} = \frac{1}{m}(\hat{P} - Y).$$

Entonces:

$$dW^{[2]} = (A^{[1]})^\top dZ^{[2]},$$

$$db^{[2]} = \sum_i dZ_i^{[2]}.$$

Estas tres fórmulas provienen de una sola regla de capa. Para $Z = AW + \mathbf{1}_m b^\top$ y una perturbación diferencial,

$$dZ = dA W + A dW + \mathbf{1}_m (db)^\top.$$

Al emparejar cada término con el gradiente que llega desde la pérdida se obtiene

$$\nabla_W J = A^\top \nabla_Z J, \quad \nabla_b J = \mathbf{1}^\top \nabla_Z J, \quad \nabla_A J = \nabla_Z J W^\top.$$

La regla no depende de que la capa sea la primera o la última. Lo que cambia entre capas es la derivada de la activación y el gradiente que llega desde arriba.

Propagar hacia la capa oculta

Primero pasamos el gradiente hacia las activaciones:

$$dA^{[1]} = dZ^{[2]}(W^{[2]})^\top.$$

Luego atravesamos ReLU:

$$dZ^{[1]} = dA^{[1]} \odot \mathbf{1}\{Z^{[1]} > 0\}.$$

Finalmente:

$$dW^{[1]} = X^\top dZ^{[1]},$$

$$db^{[1]} = \sum_i dZ_i^{[1]}.$$

Backpropagation como algoritmo

Las identidades anteriores ya contienen la deducción. El algoritmo debe conservar los valores del forward correspondiente, iniciar con $dZ^{[2]} = (\hat{P} - Y)/m$ y aplicar la regla de capa en orden inverso. El código para dos capas es:

```
def backward_pass(X, Y, cache, params):
    P = cache["P"]
    A1 = cache["A1"]
    Z1 = cache["Z1"]
    W2 = params["W2"]

    dZ2 = (P - Y) / len(X)
    dW2 = A1.T @ dZ2
    db2 = np.sum(dZ2, axis=0)

    dA1 = dZ2 @ W2.T
    dZ1 = dA1 * (Z1 > 0)
    dW1 = X.T @ dZ1
    db1 = np.sum(dZ1, axis=0)

    return {"W1": dW1, "b1": db1, "W2": dW2, "b2": db2}
```

Para una red con L capas, el mismo argumento se recorre desde $\ell = L$ hasta 1:

```
calcular el gradiente de la pérdida respecto a la salida
para ell = L, ..., 1:
    atravesar la activación de la capa ell
    calcular dW[ell] y db[ell]
    propagar el gradiente hacia A[ell-1]
```

Backpropagation no es una fórmula particular de dos capas. Es evaluación en modo reverso de la regla de la cadena sobre un grafo acíclico de operaciones.

Costo, memoria y alcance de la garantía

Cada producto matricial del forward reaparece con dimensiones transpuestas en el backward. Por ello, el costo de backpropagation es del mismo orden que el forward: para la red de una capa oculta,

$$O(mh(d + k)).$$

El ahorro frente a diferencias finitas es decisivo. Si hay P parámetros, verificar todas las coordenadas por diferencias centrales requiere aproximadamente $2P$ evaluaciones forward; backpropagation obtiene los P gradientes en un solo recorrido inverso de costo comparable a unas pocas pasadas.

El precio es memoria. El backward necesita los valores de X , $Z^{[1]}$, $A^{[1]}$ y las probabilidades producidas por el mismo forward. Recalcularlos puede ahorrar memoria a cambio de más cómputo, estrategia conocida como *checkpointing*.

La eficiencia no es una garantía de encontrar el mínimo global. Backpropagation calcula, salvo errores numéricos y puntos no diferenciables elegidos por convención, el gradiente de la pérdida

empírica para los parámetros actuales. El optimizador decide cómo usarlo; la no convexidad de una red permanece.

Verificación por diferencias finitas

Una forma de detectar errores en backpropagation es comparar contra una aproximación numérica:

$$\frac{\partial J}{\partial \theta_j} \approx \frac{J(\theta_j + \varepsilon) - J(\theta_j - \varepsilon)}{2\varepsilon}.$$

Esta técnica no se usa para entrenar porque es costosa, pero es excelente para depurar.

Ejemplo resuelto: diferencia finita escalar

Considera la función simple:

$$J(w) = (w - 3)^2.$$

Su derivada exacta es:

$$J'(w) = 2(w - 3).$$

En $w = 2$, la derivada exacta es:

$$J'(2) = 2(2 - 3) = -2.$$

Ahora usa diferencia finita central con $\varepsilon = 0.01$:

$$\frac{J(2 + \varepsilon) - J(2 - \varepsilon)}{2\varepsilon} = \frac{J(2.01) - J(1.99)}{0.02}.$$

Calculamos:

$$J(2.01) = (-0.99)^2 = 0.9801, \quad J(1.99) = (-1.01)^2 = 1.0201.$$

Por tanto:

$$\frac{0.9801 - 1.0201}{0.02} = -2.$$

La aproximación coincide con la derivada exacta. En una red real comparamos el error relativo, no una igualdad exacta. Un ε demasiado grande introduce error de aproximación y uno demasiado pequeño puede sufrir cancelación numérica. Si la diferencia sigue siendo grande, revisamos signos, escalas, transpuestas y la división por m .

Ejemplo resuelto: formas de los gradientes

Supón que:

- $X \in \mathbb{R}^{100 \times 64}$;
- $W^{[1]} \in \mathbb{R}^{64 \times 32}$;
- $A^{[1]} \in \mathbb{R}^{100 \times 32}$;
- $W^{[2]} \in \mathbb{R}^{32 \times 10}$;
- $\hat{P}, Y \in \mathbb{R}^{100 \times 10}$.

Entonces:

Gradiente	Cálculo	Forma
$dZ^{[2]}$	$(\hat{P} - Y)/100$	100×10
$dW^{[2]}$	$(A^{[1]})^\top dZ^{[2]}$	32×10
$db^{[2]}$	suma por filas de $dZ^{[2]}$	10
$dA^{[1]}$	$dZ^{[2]}(W^{[2]})^\top$	100×32
$dW^{[1]}$	$X^\top dZ^{[1]}$	64×32

El primer chequeo es simple: cada gradiente debe tener la misma forma que el parámetro que actualiza. Pasar este chequeo no demuestra que sus valores sean correctos.

Errores frecuentes

1. Olvidar dividir por m .
2. Confundir $Y - P$ con $P - Y$.
3. Sumar db sin `axis=0`.
4. Usar las formas transpuestas incorrectas.
5. Usar valores de un forward distinto al que produjo la pérdida.
6. No estabilizar softmax.

Punto de control

Si el autograder dice que `dW2` tiene forma incorrecta, no empieces cambiando signos. Primero revisa:

1. ¿`A1.T @ dZ2` produce la misma forma que `W2`?
2. ¿`db2` suma sobre observaciones y no sobre clases?
3. ¿dividiste por m exactamente una vez?

Caso longitudinal: backpropagation en dígitos

En el caso `load_digits`, el forward produce probabilidades para diez clases. El backward debe producir gradientes con las mismas formas que los parámetros:

Parámetro	Forma si $h = 32$	Gradiente esperado
$W^{[1]}$	64×32	$dW^{[1]}$, misma forma
$b^{[1]}$	32	$db^{[1]}$, una entrada por neurona
$W^{[2]}$	32×10	$dW^{[2]}$, misma forma
$b^{[2]}$	10	$db^{[2]}$, una entrada por clase

La prueba de gradiente no se hace sobre todo el dataset. Se hace sobre un caso pequeño, con pocas observaciones y parámetros controlados, porque ahí se puede comparar contra diferencias finitas. Una red que “entrena” sin pasar una prueba de gradiente puede estar reduciendo la pérdida por accidente o por un error de implementación no detectado.

Verificaciones seleccionadas

1. Si $A^{[1]}$ tiene forma $m \times h$ y $dZ^{[2]}$ tiene forma $m \times k$, entonces $dW^{[2]} = (A^{[1]})^\top dZ^{[2]}$ tiene forma $h \times k$.
2. Una diferencia finita central usa $(J(\theta + \epsilon) - J(\theta - \epsilon))/(2\epsilon)$; suele ser más estable que usar solo $J(\theta + \epsilon) - J(\theta)$.
3. Un error de forma que NumPy resuelve con broadcasting puede producir un valor numérico sin representar el gradiente correcto.

Para explorar más

- **Extensión matemática:** verifica por diferencias finitas un solo peso de la primera capa y un solo peso de la segunda capa.
- **Extensión computacional:** agrega chequeos automáticos de forma para cada gradiente antes de actualizar parámetros.
- **Conexión con proyecto:** decide qué prueba mínima de gradientes o sanity check usarías antes de confiar en un entrenamiento propio.

Revisión del capítulo

Backpropagation aplica la regla de la cadena de forma organizada sobre un grafo de cómputo. El forward produce activaciones, logits, probabilidades y pérdida; el backward usa esos valores guardados para calcular gradientes.

La simplificación $dZ^{[2]} = (\hat{P} - Y)/m$ para softmax con entropía cruzada permite propagar gradientes hacia la segunda capa y luego hacia la capa oculta. Cada gradiente debe tener exactamente la misma forma que el parámetro que actualiza.

La verificación por diferencias finitas no reemplaza la derivación, pero sí detecta errores de signo, escala o forma. Una red que no mejora aunque sus formas sean correctas exige revisar inicialización, activaciones, tasa de aprendizaje y datos.

Términos clave

- **Grafo de cómputo:** representación de operaciones intermedias usadas para calcular una salida.
- **Cache:** valores guardados durante forward propagation para reutilizarlos en backward propagation.
- **Backpropagation:** aplicación eficiente de la regla de la cadena desde la pérdida hacia los parámetros.
- **Gradiente:** derivada de la pérdida respecto a un parámetro o activación.
- **Diferencias finitas:** aproximación numérica de derivadas para verificar gradientes.
- **Forma del gradiente:** dimensión que debe coincidir con el parámetro correspondiente.

Ejercicios

Preguntas conceptuales

1. Explique por qué backpropagation necesita valores guardados del forward pass.
2. Explique por qué $dZ1 = dA1 * (Z1 > 0)$ para ReLU.

Problemas cuantitativos

3. Derive la forma de $dW2$ a partir de $Z2 = A1 @ W2 + b2$.
4. Si $A^{[1]} \in \mathbb{R}^{80 \times 16}$ y $dZ^{[2]} \in \mathbb{R}^{80 \times 4}$, calcule la forma de $dW^{[2]}$ y $db^{[2]}$.

Práctica computacional

5. Diseñe una prueba pequeña para verificar que `backward_pass` devuelve gradientes con la misma forma que los parámetros.
6. Implemente una verificación por diferencias finitas para un parámetro escalar.

Durante esta verificación desactive dropout y cualquier otra operación aleatoria; la pérdida evaluada en $\theta + \varepsilon$ y $\theta - \varepsilon$ debe usar exactamente los mismos datos y el mismo grafo.

Interpretación y pensamiento crítico

7. Un gradiente tiene la forma correcta pero el entrenamiento no mejora. Proponga tres causas posibles.

Profundización matemática y algorítmica

8. Derive $\partial p_a / \partial z_b = p_a (\delta_{ab} - p_b)$ y úsela para obtener $\nabla_z L = p - y$.
9. A partir del diferencial de $Z = AW + \mathbf{1}b^\top$, obtenga los gradientes respecto a A , W y b .
10. Compare el costo de verificar P parámetros por diferencias centrales con el costo de una pasada backward.
11. Explique el intercambio memoria-cómputo de guardar activaciones frente a recalcularlas durante backward.

Proyecto de cierre

12. Tome una red pequeña de dos capas y documente una auditoría de gradientes: formas esperadas, formas obtenidas, norma de cada gradiente y resultado de una prueba numérica para un parámetro.

Activaciones, inicialización, regularización y diagnóstico

Pregunta aplicada

Una red puede fallar aunque el código no tenga errores. El entrenamiento puede divergir, saturarse, memorizar datos o quedarse sin aprender.

La implementación de backpropagation no basta:

hay que diagnosticar el entrenamiento.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. identificar fallas de saturación, overfitting y learning rate;
2. explicar por qué la inicialización afecta el entrenamiento;
3. incorporar regularización L2 en la pérdida y en los gradientes;
4. leer curvas de entrenamiento y validación;
5. convertir una curva en una hipótesis y un siguiente experimento.
6. deducir la escala de una inicialización a partir de propagación de segundos momentos;
7. explicar qué preserva dropout invertido en esperanza y qué variación añade.

Fuentes distintas de aleatoriedad

En una red aparecen al menos cuatro fuentes que conviene separar:

Fuente	Variable aleatoria	Qué cambia
muestreo	$D_m \sim P^m$	observaciones disponibles
inicialización	$W_0^{[\ell]}$	punto inicial del algoritmo
mini-batches	B_t	gradiente usado en cada paso
dropout	máscaras M_t	subred activa durante entrenamiento

Una semilla fija condiciona estas realizaciones en una ejecución; no elimina la incertidumbre del procedimiento ni demuestra estabilidad frente a otras muestras.

Para justificar reglas de inicialización usamos aproximaciones probabilísticas. Si w_j y x_j son independientes, centrados y con segundos momentos finitos,

$$\text{Var}\left(\sum_{j=1}^d w_j x_j\right) = d \text{Var}(w_j) \text{Var}(x_j).$$

Si las entradas están correlacionadas o no están centradas, aparecen términos de covarianza y la aproximación debe revisarse.

En dropout invertido, una máscara $M_j \sim \text{Bernoulli}(1 - p)$ produce

$$\tilde{A}_j = \frac{M_j}{1 - p} A_j, \quad \mathbb{E}[\tilde{A}_j \mid A_j] = A_j.$$

La igualdad conserva la activación en esperanza durante entrenamiento, pero aumenta su varianza.

Activaciones

Activación	Fórmula	Riesgo principal
Sigmoide	$\sigma(z)$	saturación y gradientes pequeños
Tanh	$\tanh(z)$	saturación en valores extremos
ReLU	$\text{máx}(0, z)$	neuronas muertas si muchos $z \leq 0$

ReLU suele ser una buena opción inicial en redes densas pequeñas por simplicidad y estabilidad.

Inicialización

La inicialización controla la escala inicial de las señales. Si una capa calcula:

$$z = \sum_{j=1}^d w_j x_j,$$

la varianza de z crece con d si los pesos se inicializan sin controlar escala. Bajo independencia aproximada y media cero:

$$\text{Var}(z) \approx d \text{Var}(w) \text{Var}(x).$$

Para que la señal no crezca sin control al pasar por capas, se escoge $\text{Var}(w)$ proporcional a $1/d$. En redes con ReLU se usa a menudo la inicialización He porque compensa que ReLU anula una parte de las activaciones.

Si los pesos empiezan demasiado grandes, las activaciones pueden saturarse. Si empiezan demasiado pequeños, las señales pueden desaparecer.

Una regla práctica para ReLU es inicialización He:

$$W \sim \mathcal{N}\left(0, \frac{2}{\text{fan_in}}\right).$$

En NumPy:

```
W = rng.normal(0, np.sqrt(2 / fan_in), size=(fan_in, fan_out))
```

De la propagación de varianza a Xavier y He

La regla $1/d$ no se elige solo por costumbre. Si x_j y w_j son independientes, centrados y con igual segundo momento dentro de la capa,

$$\mathbb{E}[z^2] = \mathbb{E}\left[\left(\sum_{j=1}^d w_j x_j\right)^2\right] = d \mathbb{E}[w_j^2] \mathbb{E}[x_j^2],$$

porque los términos cruzados tienen esperanza cero. Para una activación lineal, preservar el segundo momento en la propagación hacia adelante sugiere $\mathbb{E}[w_j^2] = 1/d_{\text{in}}$. Este es el argumento *fan-in* que está en la base de las inicializaciones de tipo Xavier. La variante Glorot/Xavier que equilibra propagación hacia adelante y hacia atrás usa con frecuencia

$$\text{Var}(w_j) = \frac{2}{d_{\text{in}} + d_{\text{out}}}.$$

Cuando $d_{\text{in}} = d_{\text{out}} = d$, ambas escalas coinciden con $1/d$. La distinción importa cuando las capas tienen anchos muy diferentes.

Si z tiene una distribución aproximadamente simétrica alrededor de cero, ReLU conserva el lado positivo y anula el negativo. Bajo esa aproximación,

$$\mathbb{E}[\text{ReLU}(z)^2] \approx \frac{1}{2} \mathbb{E}[z^2].$$

Compensar ese factor $1/2$ lleva a

$$\text{Var}(w_j) \approx \frac{2}{d},$$

que es la escala He. La deducción depende de independencia aproximada, centrado y simetría; durante el entrenamiento esas hipótesis dejan de ser exactas. La inicialización intenta evitar explosión o desaparición al comienzo, no garantiza que todas las capas mantengan la misma varianza para siempre.

Regularización L2 en redes

En este libro y en Lab 3, J es la **pérdida media de datos**. La convención de regularización es:

$$J_\lambda = J + \frac{\lambda}{2} (\|W^{[1]}\|_F^2 + \|W^{[2]}\|_F^2).$$

En los gradientes:

$$dW^{[\ell]} \leftarrow dW^{[\ell]} + \lambda W^{[\ell]}.$$

No penalizamos sesgos por defecto.

En `torch.optim.SGD`, `weight_decay=lambda` añade λW al gradiente de los parámetros incluidos en ese grupo. Para no penalizar sesgos deben ponerse en otro grupo con `weight_decay=0`. `AdamW` usa decaimiento desacoplado y no debe presentarse como la derivada exacta del objetivo anterior.

Ejemplo resuelto: L2 en pérdida y gradiente

Supón una capa con:

$$W = \begin{bmatrix} 2 & -1 \\ 0 & 3 \end{bmatrix}, \quad \lambda = 0.1.$$

La norma de Frobenius al cuadrado es:

$$\|W\|_F^2 = 2^2 + (-1)^2 + 0^2 + 3^2 = 14.$$

Si usamos la penalización $\frac{\lambda}{2} \|W\|_F^2$, el aporte a la pérdida es:

$$\frac{0.1}{2} \cdot 14 = 0.7.$$

Si el gradiente de datos fuera:

$$dW_{\text{datos}} = \begin{bmatrix} 0.4 & -0.2 \\ 0.1 & 0.3 \end{bmatrix},$$

el gradiente regularizado sería:

$$dW = dW_{\text{datos}} + \lambda W = \begin{bmatrix} 0.4 & -0.2 \\ 0.1 & 0.3 \end{bmatrix} + 0.1 \begin{bmatrix} 2 & -1 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} 0.6 & -0.3 \\ 0.1 & 0.6 \end{bmatrix}.$$

La regularización no “apaga” pesos automáticamente; agrega una fuerza que empuja los pesos hacia valores más pequeños durante la actualización.

Dropout como idea

Dropout apaga unidades al azar durante entrenamiento. En este curso se introduce conceptualmente, no como requisito central del autograder. Si la probabilidad de apagado es p , el dropout invertido usa

$$\tilde{A} = \frac{M}{1-p} A, \quad M \sim \text{Bernoulli}(1-p).$$

Condicionado en A ,

$$\mathbb{E}[\tilde{A} \mid A] = A, \quad \text{Var}(\tilde{A} \mid A) = A^2 \frac{p}{1-p}.$$

La escala $1/(1-p)$ evita tener que reescalar en evaluación, pero muestra también el costo: dropout conserva la activación en esperanza y aumenta su variación durante entrenamiento. En evaluación se desactiva la máscara; dejar dropout activo hace aleatorias las predicciones, salvo que se use deliberadamente un procedimiento como Monte Carlo dropout.

Su intuición:

- evita dependencia excesiva de una neurona;
- funciona como ensamble implícito;
- requiere cuidado al pasar de entrenamiento a evaluación.

Curvas de entrenamiento

Una curva útil muestra:

- pérdida de entrenamiento;
- pérdida de validación;
- métrica principal;
- número de épocas;
- configuración del experimento.

Diagnósticos comunes

Señal	Diagnóstico probable	Acción
Pérdidas train y validación altas	posible underfitting	más capacidad, más épocas, revisar variables
Pérdida train baja y validación alta	posible overfitting	regularización, menos capacidad, más datos
Pérdida explota	learning rate alto o gradiente incorrecto	reducir paso, revisar backward

Señal	Diagnóstico probable	Acción
Pérdida plana	paso bajo, mala inicialización o activaciones saturadas	ajustar inicialización y paso

Ejemplo resuelto: leer una curva

Supón que una red obtiene:

Época	Train loss	Val loss	Train acc	Val acc
5	0.82	0.88	0.74	0.71
20	0.24	0.43	0.94	0.86
50	0.05	0.78	0.99	0.78

Lectura:

1. El entrenamiento sí aprende: **train loss** baja.
2. La validación mejora hasta cierto punto y luego empeora.
3. El diagnóstico probable es overfitting después de la época 20.
4. Acciones razonables: early stopping, más regularización, menor capacidad o más datos.

La conclusión no es “la red es mala”; la conclusión es “esta configuración debe controlarse”.

Checkpoint técnico del proyecto

En semana 9, el proyecto debe mostrar avance real desde el baseline:

1. Métrica de baseline.
2. Modelo mejorado o experimento técnico nuevo.
3. Análisis de errores.
4. Siguiendo experimento y resultado que permitiría evaluarlo.
5. Riesgo técnico o de datos.

Caso longitudinal: curva de entrenamiento en dígitos

Supón que en `load_digits` una red con $h = 64$ obtiene este patrón:

Configuración	Train acc	Dev acc	Lectura
sin regularización	0.99	0.86	posible overfitting
L2 moderado	0.96	0.90	mejor resultado de validación en esta partición

Configuración	Train acc	Dev acc	Lectura
red muy pequeña	0.82	0.80	posible underfitting

Para esta partición y esta arquitectura, L2 moderado reduce la brecha train/dev; la tabla no demuestra que siempre generalice mejor. El registro debe conservar semilla, partición, tamaño de red, learning rate y número de épocas para que la comparación sea reproducible.

Verificaciones seleccionadas

1. Si train accuracy sube y dev accuracy cae después de cierta época, el diagnóstico principal es overfitting, no falta de capacidad.
2. Si train y dev son bajos, aumentar regularización rara vez es la primera acción; primero se revisan capacidad, features, épocas o learning rate.
3. Si cambias arquitectura y regularización al mismo tiempo, no puedes atribuir la mejora a una sola causa sin un experimento adicional.

Ejemplo resuelto: regla de parada

Supón que el dev loss por época es:

Época	Dev loss
10	0.58
20	0.44
30	0.41
40	0.43
50	0.49

Una regla de early stopping con paciencia de 2 revisiones guardaría el modelo de la época 30 y se detendría después de observar que las épocas 40 y 50 no mejoran. La acción correcta no es usar el modelo de la última época por costumbre; es usar el mejor modelo según validación y reportar la regla usada.

Lectura de curvas: tres patrones frecuentes

Una curva se lee comparando entrenamiento y validación, no mirando una sola línea. Hay tres patrones básicos.

Primero, si train loss baja de forma sostenida y dev loss también baja, el entrenamiento todavía mejora la pérdida medida. No conviene detenerlo solo porque ya pasaron muchas épocas. Segundo, si train loss baja pero dev loss sube, la red está memorizando estructura específica del conjunto de entrenamiento. La acción natural es guardar el mejor modelo de validación, revisar regularización,

reducir capacidad o aumentar datos. Tercero, si train y dev loss se mantienen altos, el problema no se resuelve aumentando regularización; probablemente faltan capacidad, variables, épocas, una tasa de aprendizaje adecuada o una revisión de etiquetas.

El reporte debe nombrar el patrón observado. Es distinto decir “el modelo no mejora” que decir “hay overfitting después de la época 30” o “hay underfitting persistente en train y dev”. Esa diferencia reduce ambigüedad para el lector y para quien califica.

Punto de control

Antes de reportar una red como mejora, responde:

- ¿contra qué baseline compite?
- ¿la mejora aparece en validación o solo en entrenamiento?
- ¿qué error específico sigue siendo importante?
- ¿qué hiperparámetro cambiarías primero y por qué?

Para explorar más

- **Extensión matemática:** relaciona la penalización L_2 con el tamaño de los pesos y explica por qué puede reducir varianza.
- **Extensión computacional:** compara curvas train/dev con y sin dropout, manteniendo fija la semilla y el tamaño de red.
- **Conexión con proyecto:** define una regla de parada basada en dev loss y explica qué patrón indicaría sobreentrenamiento.

Revisión del capítulo

Entrenar una red no termina cuando baja la pérdida de entrenamiento. La lectura compara entrenamiento y validación para distinguir aprendizaje, overfitting, underfitting, saturación y problemas de tasa.

La inicialización afecta la escala de activaciones y gradientes. La regularización L2, dropout y early stopping son herramientas para controlar capacidad efectiva, pero ninguna reemplaza una partición de validación ni un análisis de errores.

El producto final del capítulo es una hipótesis concreta. La curva permite proponer una causa probable y elegir una sola modificación verificable: tasa, capacidad, regularización, datos o regla de parada.

Términos clave

- **Activación saturada:** zona donde una activación cambia poco y dificulta el flujo de gradientes.
- **Inicialización:** regla para asignar valores iniciales a pesos antes de entrenar.
- **Regularización L2:** penalización sobre pesos que busca reducir sobreajuste.
- **Dropout:** técnica que desactiva aleatoriamente unidades durante entrenamiento.
- **Curva de entrenamiento:** evolución de pérdida o métrica por época.
- **Early stopping:** detención del entrenamiento cuando validación deja de mejorar.
- **Análisis de error:** revisión de fallas concretas para decidir el siguiente experimento.

Ejercicios

Preguntas conceptuales

1. Explique por qué una red con train accuracy 99 % y validation accuracy 70 % no debe reportarse como exitosa.
2. ¿Por qué la regularización no reemplaza una partición de validación?

Problemas cuantitativos

3. Dada una tabla de pérdidas por época, identifique la primera señal de overfitting y proponga una época candidata para early stopping.
4. Si la penalización L2 es $\frac{\lambda}{2} \sum_j w_j^2$, calcule la penalización para $w = (2, -1, 0.5)$ y $\lambda = 0.1$, y escriba el término que se añade al gradiente.

Práctica computacional

5. Diseñe un experimento para comparar dos valores de `lambda` sin usar el conjunto de test.
6. Grafique pérdida de entrenamiento y validación para al menos dos configuraciones.

Interpretación y pensamiento crítico

7. ¿Qué señal en la curva de pérdida sugeriría revisar el learning rate antes de cambiar la arquitectura?
8. Un modelo mejora la métrica global pero empeora un subconjunto importante. ¿Qué decisión técnica tomaría?

Profundización matemática y algorítmica

9. Deduzca la escala *fan-in* $1/d_{\text{in}}$ a partir de la conservación aproximada del segundo momento en una capa lineal. Explique por qué la variante Glorot/Xavier $2/(d_{\text{in}} + d_{\text{out}})$ coincide con ella cuando ambos anchos son iguales.
10. Justifique el factor 2 de la inicialización He bajo una entrada simétrica y una activación ReLU.
11. Calcule esperanza y varianza condicional de dropout invertido para una activación fija $A = a$ y probabilidad de apagado p .

Proyecto de cierre

12. Redacte un memo técnico de una página sobre una red entrenada: baseline, curva, diagnóstico, cambio propuesto, riesgo y siguiente experimento.

Optimizadores y PyTorch

Pregunta aplicada

Hasta ahora actualizamos parámetros con descenso del gradiente simple:

$$\theta \leftarrow \theta - \alpha \nabla J(\theta).$$

Pero redes neuronales reales suelen entrenarse con variantes que usan memoria del gradiente, escalamiento adaptativo o mini-batches.



Figura 16: Optimizadores: SGD usa el gradiente actual, momentum suaviza direcciones recientes y Adam combina memoria con escala adaptativa por coordenada.

Lectura de la figura. Sin regularización incorporada al optimizador, SGD, momentum y Adam conservan el objetivo y cambian la regla que convierte gradientes en actualizaciones. Por eso el optimizador debe reportarse como parte del experimento, junto con tasa de aprendizaje, batch size, épocas y métrica de validación.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. distinguir batch, mini-batch y época;
2. explicar la intuición de momentum, RMSProp y Adam;
3. ubicar forward, loss, backward y actualización en un loop de PyTorch;
4. comparar una implementación desde cero con PyTorch sin cambiar la pregunta experimental;
5. reconocer que un optimizador no reemplaza validación.
6. escribir las ecuaciones completas de Adam y explicar la corrección de sesgo;
7. comparar costo, memoria y alcance de las garantías de SGD, momentum y Adam.

Gradiente estocástico y filtración

Condicionado en el dataset, el historial de entrenamiento puede verse como un proceso aleatorio generado por mini-batches e inicialización. Si $\mathcal{F}_t$ contiene toda la información disponible antes de escoger el lote B_t , un gradiente de mini-batch uniforme satisface

$$\mathbb{E}[g_t \mid \mathcal{F}_t] = \nabla \hat{R}_m(\theta_t).$$

La diferencia

$$\xi_t = g_t - \nabla \hat{R}_m(\theta_t)$$

es ruido de gradiente con media condicional cero bajo ese esquema de muestreo. Momentum y Adam transforman la secuencia de gradientes; no convierten automáticamente g_t en un mejor estimador del riesgo poblacional.

Comparar optimizadores exige conservar distribución de mini-batches, presupuesto de actualizaciones, inicialización y partición. Cambiar esas fuentes simultáneamente confunde efectos algorítmicos y muestrales.

Mini-batch gradient descent

En lugar de usar todo el dataset en cada paso, usamos lotes pequeños:

```
dataset -> mini-batches -> actualización por batch -> época completa
```

Esto reduce costo por actualización y agrega ruido útil al entrenamiento.

Ese ruido no es una garantía de mejora. El tamaño del lote modifica la varianza del gradiente, el número de actualizaciones por época y el uso de memoria.

Momentum

Momentum acumula una dirección suavizada:

$$v_t = \beta v_{t-1} + (1 - \beta) \nabla J(\theta_t),$$

$$\theta_{t+1} = \theta_t - \alpha v_t.$$

Intuición: evita que cada gradiente aislado cambie la dirección con demasiada fuerza.

Esta es la convención de promedio exponencial usada en el desarrollo del curso. Algunas bibliotecas, incluido `torch.optim.SGD`, parametrizan el buffer sin el factor $(1 - \beta)$; por eso no se comparan tasas de aprendizaje sin revisar la regla exacta del optimizador.

Ejemplo resuelto: dos pasos con momentum

Supón un parámetro escalar $\theta_0 = 5$, tasa $\alpha = 0.1$, momentum $\beta = 0.9$ y velocidad inicial $v_0 = 0$. Los dos primeros gradientes son:

$$g_1 = 4, \quad g_2 = 2.$$

Primer paso:

$$v_1 = 0.9(0) + 0.1(4) = 0.4, \quad \theta_1 = 5 - 0.1(0.4) = 4.96.$$

Segundo paso:

$$v_2 = 0.9(0.4) + 0.1(2) = 0.56, \quad \theta_2 = 4.96 - 0.1(0.56) = 4.904.$$

Aunque el segundo gradiente es menor que el primero, la velocidad conserva parte de la dirección previa. Esa memoria suaviza actualizaciones ruidosas, pero también puede sostener una mala dirección si el learning rate o β no son adecuados.

Derivación guiada: momentum como memoria exponencial

La fórmula

$$v_t = \beta v_{t-1} + (1 - \beta)g_t$$

parece local, pero al expandirla se ve su memoria. Como

$$v_{t-1} = \beta v_{t-2} + (1 - \beta)g_{t-1},$$

entonces

$$v_t = (1 - \beta)g_t + \beta(1 - \beta)g_{t-1} + \beta^2 v_{t-2}.$$

Si repetimos la sustitución:

$$v_t = (1 - \beta)g_t + \beta(1 - \beta)g_{t-1} + \beta^2(1 - \beta)g_{t-2} + \dots.$$

Los gradientes recientes pesan más que los antiguos, pero los antiguos no desaparecen de inmediato. Por eso momentum puede avanzar de forma más estable en valles alargados de la pérdida. La contraparte es que una memoria demasiado alta puede retrasar la reacción cuando la dirección útil cambia.

RMSProp y Adam

RMSProp mantiene un promedio exponencial de gradientes al cuadrado y divide cada coordenada por su escala reciente. Adam añade un promedio exponencial del gradiente. Con g_t como gradiente de mini-batch:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1)g_t,$$

$$s_t = \beta_2 s_{t-1} + (1 - \beta_2)g_t \odot g_t.$$

Como $m_0 = s_0 = 0$, los primeros momentos están sesgados hacia cero. Si, para entender el efecto, imaginamos un gradiente constante g , entonces

$$m_t = (1 - \beta_1^t)g, \quad s_t = (1 - \beta_2^t)(g \odot g).$$

Esto motiva las correcciones

$$\widehat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \widehat{s}_t = \frac{s_t}{1 - \beta_2^t}.$$

La actualización es

$$\theta_{t+1} = \theta_t - \alpha \frac{\widehat{m}_t}{\sqrt{\widehat{s}_t} + \varepsilon},$$

donde raíz, división y suma se aplican por coordenadas. El término ε evita división por cero y también influye en la escala efectiva cuando $\widehat{s}_t$ es muy pequeño. Usamos s_t para el segundo momento de Adam y reservamos v_t para la velocidad de momentum.

Adam suele ser un punto de partida útil, pero no elimina la necesidad de validar tasa, regularización y arquitectura. Tampoco debe confundirse Adam con AdamW: este último desacopla el decaimiento de pesos de la normalización adaptativa del gradiente.

Ejemplo resuelto: Adam en una coordenada

Supón una coordenada con gradiente inicial $g_1 = 4$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $m_0 = 0$ y $s_0 = 0$. El primer momento queda:

$$m_1 = 0.9(0) + 0.1(4) = 0.4.$$

El segundo momento queda:

$$s_1 = 0.999(0) + 0.001(4^2) = 0.016.$$

Como ambos promedios empiezan en cero, Adam usa corrección de sesgo:

$$\widehat{m}_1 = \frac{m_1}{1 - \beta_1} = 4, \quad \widehat{s}_1 = \frac{s_1}{1 - \beta_2} = 16.$$

La dirección adaptativa es aproximadamente:

$$\frac{\widehat{m}_1}{\sqrt{\widehat{s}_1} + \epsilon} \approx 1.$$

La lectura no es que Adam normaliza todo perfectamente. La lectura es que usa información sobre magnitud reciente del gradiente para ajustar el tamaño efectivo del paso por coordenada.

Qué puede afirmarse sobre convergencia

Para SGD sobre una función suave, con gradientes inesgados, varianza controlada y una secuencia de pasos que disminuye apropiadamente, pueden obtenerse resultados de convergencia hacia puntos estacionarios en promedio. Con una tasa constante, el ruido del mini-batch suele impedir convergencia exacta y deja iteraciones en una región cuyo tamaño depende del paso y la varianza.

Las redes hacen el problema no convexo. Llegar a $\|\nabla J\|$ pequeño no prueba que se alcanzó un mínimo global ni que el riesgo de validación sea bajo. Para Adam, la adaptatividad exige hipótesis y variantes técnicas adicionales; no es correcto afirmar que siempre converge mejor que SGD. En este curso, las garantías teóricas orientan el diagnóstico, mientras la comparación empírica se hace con presupuesto y protocolo fijados.

Costo y memoria del optimizador

Sea P el número de parámetros y C_B el costo de forward más backward para un mini-batch. La actualización de SGD cuesta $O(P)$ y almacena parámetros y gradientes. Momentum añade un vector de velocidad de tamaño P . Adam añade dos vectores, m_t y s_t , de modo que su estado auxiliar es aproximadamente $2P$ números.

Método	Estado adicional	Costo de actualización
SGD	ninguno	$O(P)$
momentum	P	$O(P)$
Adam	$2P$	$O(P)$

El costo total por paso sigue dominado normalmente por C_B , pero el estado del optimizador puede ser relevante en modelos grandes. Reportar solo «usamos Adam» omite tasa, betas, epsilon, decaimiento, batch size y número de pasos: todos forman parte del algoritmo ejecutado.

PyTorch: qué automatiza

PyTorch ofrece:

- tensores;
- autograd;
- módulos `nn.Module`;
- pérdidas;
- optimizadores;
- entrenamiento en CPU/GPU.

El ciclo conceptual no cambia:

```
forward -> loss -> backward -> optimizer.step()
```

Para clasificación multiclase, `torch.nn.CrossEntropyLoss` recibe **logits** y etiquetas enteras. Aplicar softmax antes cambia el cálculo y pierde la implementación numéricamente estable que ya combina la función de pérdida.

Loop mínimo

```
model.train()
for X_batch, y_batch in loader:
    optimizer.zero_grad()
    logits = model(X_batch)
    loss = criterion(logits, y_batch)
    loss.backward()
    optimizer.step()
```

La diferencia es que PyTorch construye el grafo de cómputo y calcula los gradientes.

Ejemplo resuelto: lectura de un loop

En el loop mínimo:

```
optimizer.zero_grad()
logits = model(X_batch)
loss = criterion(logits, y_batch)
loss.backward()
optimizer.step()
```

la interpretación es:

Línea	Significado
<code>zero_grad()</code>	borra gradientes acumulados
<code>model(X_batch)</code>	forward propagation
<code>criterion(...)</code>	calcula la pérdida
<code>backward()</code>	backpropagation automático
<code>step()</code>	actualiza parámetros

Si olvidas `zero_grad()`, PyTorch acumula gradientes entre batches. Eso rara vez es lo que quieres en este curso.

Comparación justa

Al comparar NumPy y PyTorch:

- use la misma partición de datos;
- use la misma métrica;
- reporte semilla;
- compare curvas o resultados finales;
- no confunda diferencia de implementación con diferencia de modelo.

Caso longitudinal: experimento reproducible en dígitos

Para `load_digits`, una comparación interpretable entre NumPy y PyTorch debe fijar:

Elemento	Valor que debe registrarse
partición	semilla y proporciones train/dev/test
arquitectura	64 entradas, h ocultas, 10 salidas
pérdida	entropía cruzada multiclase
optimizador	SGD, momentum o Adam
presupuesto	épocas, batch size y learning rate
resultados	curva train/dev y métrica final

Si PyTorch obtiene mejor resultado, hay que preguntar si cambió el modelo, el optimizador, el número de épocas o la inicialización. El nombre de la biblioteca no explica la diferencia; la comparación requiere condiciones controladas.

Punto de control

Una comparación NumPy vs PyTorch solo puede interpretarse si:

1. usa la misma partición;
2. usa la misma métrica;
3. entrena una arquitectura comparable;
4. reporta semilla y número de épocas;
5. interpreta diferencias con cautela.

Verificaciones seleccionadas

1. Con 1024 observaciones y batch size 64 hay $1024/64 = 16$ batches por época.
2. Si se entrenan 20 épocas con 16 batches por época, `optimizer.step()` se ejecuta 320 veces.
3. `zero_grad()` debe ejecutarse antes del siguiente `backward()` para evitar acumular gradientes entre batches, salvo que la acumulación sea intencional.

Ejemplo resuelto: presupuesto de entrenamiento

Comparar dos optimizadores exige presupuesto comparable. Si Adam se entrena 100 épocas y SGD se entrena 20, la diferencia de métrica no aísla el efecto del optimizador. Una comparación mínima fija:

Elemento	Mismo valor
partición	sí
arquitectura	sí
batch size	sí
épocas máximas	sí
criterio de parada	sí
métrica final	sí

Solo después de fijar esos elementos se puede discutir si momentum o Adam mejoraron estabilidad, velocidad o desempeño.

Convergencia no es validación

Un optimizador puede hacer que la pérdida de entrenamiento baje con más rapidez sin producir el mejor modelo para datos nuevos. Por eso el criterio de éxito no es “Adam bajó la pérdida antes”, sino “bajo la misma partición, presupuesto y métrica, el modelo obtiene una mejora de validación”. En particular, una curva suave de train loss puede esconder overfitting si no se acompaña de dev loss o de una métrica externa.

En una entrega, la comparación debe separar tres afirmaciones: velocidad de optimización, estabilidad de la curva y desempeño de validación. La primera se mide por épocas o pasos; la segunda por oscilaciones o sensibilidad a la tasa; la tercera por una métrica en datos no usados para ajustar parámetros.

Para explorar más

- **Extensión matemática:** compara una actualización de SGD con una de Adam en una dimensión y explica qué cambia por los momentos adaptativos.
- **Extensión computacional:** guarda `seed`, arquitectura, optimizador, tasa de aprendizaje y época del mejor modelo en un registro reproducible.
- **Conexión con proyecto:** define qué configuración mínima necesitas reportar para que otra persona pueda repetir tu entrenamiento.

Revisión del capítulo

Los optimizadores modernos modifican la forma de usar gradientes, pero no cambian la lógica experimental. Mini-batch gradient descent estima el gradiente con subconjuntos; momentum acumula dirección; RMSProp y Adam adaptan escalas por parámetro.

PyTorch automatiza autograd y actualización de parámetros, pero el usuario sigue siendo responsable de particiones, métricas, semillas, arquitectura y lectura de curvas. `zero_grad()`, `backward()` y `step()` son operaciones con significado, no rituales de código.

Una comparación justa entre NumPy y PyTorch exige misma pregunta experimental: datos, partición, arquitectura comparable, métrica y presupuesto de entrenamiento. Velocidad de entrenamiento no equivale automáticamente a mejor modelo.

Términos clave

- **Mini-batch:** subconjunto usado para estimar un paso de gradiente.
- **Momentum:** acumulación suavizada de direcciones de actualización pasadas.
- **RMSProp:** adaptación de pasos según magnitudes recientes de gradientes.
- **Adam:** optimizador adaptativo que combina ideas de momentum y RMSProp.
- **Autograd:** mecanismo de diferenciación automática de PyTorch.
- **`zero_grad()`:** instrucción que limpia gradientes acumulados.
- **`backward()`:** cálculo automático de gradientes desde la pérdida.
- **`step()`:** actualización de parámetros del optimizador.

Ejercicios

Preguntas conceptuales

1. Explique por qué Adam no reemplaza la validación.
2. ¿Por qué PyTorch acumula gradientes y por qué normalmente llamamos `zero_grad()`?

Problemas cuantitativos

3. Si un dataset tiene 1024 observaciones y batch size 64, ¿cuántos batches tiene una época?
4. Si se entrenan 20 épocas con 16 batches por época, ¿cuántas veces se ejecuta `optimizer.step()`?

Práctica computacional

5. Identifique en el loop de PyTorch dónde ocurren forward, pérdida, backward y actualización.
6. Implemente un loop mínimo que registre pérdida promedio por época.

Interpretación y pensamiento crítico

7. Proponga una comparación justa entre una red NumPy pequeña y una red PyTorch equivalente.
8. Si PyTorch entrena más rápido que NumPy, ¿qué comparación necesita antes de afirmar que el modelo es mejor?

Profundización matemática y algorítmica

9. Expandir la recurrencia de momentum y determine el peso de g_{t-r} en v_t .
10. Para un gradiente constante, derive los factores $1 - \beta_1^t$ y $1 - \beta_2^t$ que motivan la corrección de sesgo de Adam.
11. Compare la memoria auxiliar de SGD, momentum y Adam para P parámetros.
12. Explique por qué convergencia a un punto estacionario de entrenamiento no implica optimalidad global ni bajo riesgo de validación.

Proyecto de cierre

13. Reproduzca el mismo experimento con NumPy y PyTorch usando la misma partición, semilla y métrica. Entregue una tabla comparativa y una conclusión cautelosa.

Ejercicios integradores: redes neuronales

Estos ejercicios están diseñados para estudiar el módulo como un sistema completo: forward, backward, diagnóstico y entrenamiento con herramientas modernas. La meta no es memorizar fórmulas aisladas, sino verificar que cada objeto matemático tiene forma, propósito e interpretación.

Resultados de práctica

Al terminar este banco deberías poder:

1. seguir las formas de tensores en una red densa;
2. explicar forward propagation como composición de funciones;
3. derivar gradientes de segunda y primera capa;
4. diagnosticar entrenamiento con curvas y métricas;
5. leer un loop PyTorch sin tratarlo como caja negra.

Mapa del banco

Bloque	Qué comprueba
A	compatibilidad de dimensiones y forward pass
B	backpropagation y verificación de gradientes
C	diagnóstico de entrenamiento y generalización
D	lectura de un loop de PyTorch

Cómo usar esta sección

Trabaja primero sin mirar las respuestas. Después revisa:

1. si las formas de matrices son compatibles;
2. si cada gradiente actualiza un parámetro con la misma forma;
3. si tu diagnóstico distingue resultado, causa probable y comprobación;
4. si puedes explicar cada línea crítica de un loop de entrenamiento.

Columna probabilística del módulo

P1. Categórica y softmax. Para tres clases con distribución condicional $\pi = (0.2, 0.5, 0.3)$, calcule la entropía cruzada de reportar $q = (0.1, 0.7, 0.2)$ y compare con reportar $q = \pi$.

P2. Baseline probabilístico. Demuestre que asignar $1/K$ a cada clase produce pérdida $\log K$ para cualquier etiqueta observada. Explique qué diagnóstico permite hacer al inicializar una red.

P3. Gradiente estocástico. Explique respecto de qué aleatoriedad un gradiente de mini-batch es insesgado y por qué eso no implica que sea igual al gradiente poblacional.

P4. Propagación de varianza. Derive $\text{Var}(\sum_j w_j x_j)$ bajo independencia y media cero. Indique qué términos faltan cuando las entradas están correlacionadas.

P5. Dropout. Verifique la esperanza de dropout invertido y calcule su varianza condicional dado $A_j = a$.

P6. Repetición. Entrene la misma red con cinco inicializaciones y reporte media, desviación y valores individuales de la métrica. Explique por qué esto todavía no cuantifica variación por una nueva muestra de la población.

Bloque A: dimensiones y forward

A1. Una red recibe `X.shape == (400, 64)`, tiene 20 unidades ocultas y 10 clases. Escriba las formas de `W1`, `b1`, `Z1`, `A1`, `W2`, `b2`, `Z2` y `P`.

A2. Explique por qué softmax se aplica por fila cuando `Z2` tiene forma `(m, k)`.

A3. Muestre con una frase por qué restar `max(Z, axis=1)` antes de `exp` no cambia softmax.

A4. Para una red $d \rightarrow h \rightarrow k$, derive el número total de parámetros y el costo dominante de un forward con lote de tamaño m . Compare duplicar h con duplicar m .

Bloque B: backpropagation

B1. Partiendo de $dZ2 = (P - Y) / m$, derive las formas de $dW2$ y $db2$.

B2. Describa qué debe guardarse en `cache` durante forward para poder ejecutar backward sin recalcular todo.

B3. Diseñe una prueba de gradientes por diferencias finitas para un solo peso de `W1`.

B4. Derive el Jacobiano de softmax y muestre paso a paso por qué, con entropía cruzada, el gradiente respecto a los logits es $p - y$.

B5. Si una red tiene P parámetros, compare el número de pasadas forward requerido por diferencias centrales para todas las coordenadas con el costo de backpropagation.

Bloque C: diagnóstico

- C1.** Una red tiene pérdida de entrenamiento decreciente y pérdida de validación creciente después de la época 20. ¿Qué diagnóstico haría y qué dos acciones probaría?
- C2.** Si al aumentar el learning rate la pérdida explota, ¿qué resultado reportaría y qué ajuste haría?
- C3.** Explique por qué un checkpoint técnico de proyecto debe incluir análisis de errores, no solo una métrica agregada.
- C4.** Bajo independencia, media cero y entradas simétricas, derive las escalas Xavier y He. Identifique en qué paso se usa la aproximación sobre ReLU.
- C5.** Para dropout invertido con probabilidad de apagado p , calcule esperanza y varianza condicional de una activación fija. Explique la diferencia entre modo entrenamiento y evaluación.

Bloque D: PyTorch

- D1.** En un loop de entrenamiento de PyTorch, explique el propósito de `optimizer.zero_grad()`.
- D2.** ¿Qué significa que `loss.backward()` use diferenciación automática?
- D3.** Proponga dos razones por las que una implementación NumPy y una PyTorch podrían producir métricas distintas aun usando el mismo dataset.
- D4.** Escriba las cuatro ecuaciones de Adam: dos momentos, dos correcciones de sesgo y actualización. Justifique los factores $1 - \beta_1^t$ y $1 - \beta_2^t$.
- D5.** Compare memoria auxiliar y costo por actualización de SGD, momentum y Adam para P parámetros. Separe ese costo del forward y backward.

Respuestas seleccionadas

- A1.** Una convención compatible es: `W1.shape == (64, 20)`, `b1.shape == (20,)`, `Z1.shape == (400, 20)`, `A1.shape == (400, 20)`, `W2.shape == (20, 10)`, `b2.shape == (10,)`, `Z2.shape == (400, 10)` y `P.shape == (400, 10)`.
- B1.** Si `dZ2.shape == (400, 10)` y `A1.shape == (400, 20)`, entonces `dW2 = A1.T @ dZ2` tiene forma `(20, 10)`, igual que `W2`. Además, `db2 = dZ2.sum(axis=0)` tiene forma `(10,)`, igual que `b2`.
- C1.** El patrón es compatible con overfitting después de la época 20. Dos experimentos son early stopping y aumentar regularización L2, uno por vez; también podría reducirse capacidad o ampliar datos si el proyecto lo permite.
- D1.** `optimizer.zero_grad()` borra gradientes acumulados antes del siguiente batch. Si no se llama, PyTorch suma gradientes de batches anteriores y la actualización ya no corresponde al gradiente del batch actual.

Parte IV: Evaluación y estrategia de modelado

Una mejora en la pérdida de entrenamiento no responde por sí sola si un modelo será útil. Para comparar procedimientos es necesario definir qué población y qué errores importan, reservar datos para una evaluación honesta y reconocer que toda métrica calculada con una muestra tiene variación.

Esta parte comienza tratando una métrica como un estadístico. La matriz de confusión deja de ser solo una tabla de conteos y pasa a estimar probabilidades conjuntas y condicionales. La elección de umbral conecta esas probabilidades con los costos del problema. A continuación, la validación cruzada y las curvas de aprendizaje ayudan a separar falta de señal, exceso de complejidad y variación muestral.

El análisis termina localizando los errores en grupos de observaciones y comparando la distribución de los datos disponibles con la distribución de uso. Esta perspectiva permite distinguir una fluctuación pequeña de una falla sistemática y evita que una sola métrica oculte dónde deja de funcionar el modelo.



Figura 17: Selección de métricas: el costo relativo de falsos positivos y falsos negativos orienta si conviene mirar accuracy, precisión, recall o una métrica F beta.

La figura organiza las métricas según el costo relativo de los errores. No ofrece una selección automática: obliga a declarar qué significa la clase positiva, qué decisión seguirá a la predicción y qué denominadores sostienen cada cifra.

Métricas y particiones

Pregunta aplicada

Un modelo puede tener buena accuracy y aun así ser inaceptable si falla en los casos importantes. Antes de entrenar más modelos, debemos decidir:

¿qué error cuesta más y qué comparación será suficiente para elegir?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. elegir una métrica principal alineada con el costo de error;
2. explicar por qué accuracy falla en clases desbalanceadas;
3. construir un baseline útil;
4. separar train, dev y test sin leakage;
5. usar pipelines como defensa contra preprocesamiento incorrecto.
6. interpretar métricas como estimadores de probabilidades poblacionales;
7. deducir un umbral de decisión a partir de costos de error y reconocer cuándo esa deducción no basta;
8. explicar mediante la fórmula de Bayes por qué la prevalencia modifica la precision de un clasificador.

Una métrica es un estadístico

Sea f un procedimiento ya fijado y $L = \ell(f(X), Y)$. El riesgo de uso es

$$R_{P_{\text{uso}}}(f) = \mathbb{E}[L],$$

mientras que una evaluación de n casos produce

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L_i.$$

El segundo objeto cambia si cambia la muestra. Bajo casos iid y varianza finita,

$$\text{se}(\widehat{R}_n) = \sqrt{\frac{\text{Var}(L)}{n}}.$$

Para accuracy, $L_i = \mathbf{1}\{f(X_i) \neq Y_i\}$ es Bernoulli con probabilidad de error p_e . Por tanto,

$$\text{Var}(\widehat{\text{accuracy}}) = \frac{a(1-a)}{n},$$

donde $a = 1 - p_e$. En una muestra reemplazamos a por la accuracy observada para obtener un error estándar aproximado. Esta fórmula no corrige selección del modelo, dependencia ni cambio de población.

Matriz de confusión poblacional y empírica

Cada celda de la matriz de confusión estima una probabilidad conjunta, por ejemplo

$$\mathbb{P}(\widehat{Y} = 1, Y = 0) \quad \text{mediante} \quad \frac{\#\{i : \widehat{y}_i = 1, y_i = 0\}}{n}.$$

Precision y recall son probabilidades condicionales estimadas:

$$\text{precision} = \mathbb{P}(Y = 1 \mid \widehat{Y} = 1), \quad \text{recall} = \mathbb{P}(\widehat{Y} = 1 \mid Y = 1).$$

El denominador efectivo de cada métrica puede ser mucho menor que n , por lo que su incertidumbre puede ser grande incluso en un test aparentemente amplio.

Las definiciones poblacionales requieren denominadores positivos:

$$\text{precision} = \frac{\mathbb{P}(\widehat{Y} = 1, Y = 1)}{\mathbb{P}(\widehat{Y} = 1)}, \quad \text{recall} = \frac{\mathbb{P}(\widehat{Y} = 1, Y = 1)}{\mathbb{P}(Y = 1)}.$$

Si el clasificador no predice positivos, precision no está definida; asignarle cero es una convención de software, no una identidad matemática. Si el conjunto evaluado no contiene positivos, recall tampoco está definido para esa muestra. Un reporte debe mostrar conteos para que el lector pueda detectar estos casos.

Para recall, el tamaño efectivo es $TP + FN$, es decir, el número de positivos observados. Bajo una aproximación binomial condicional, su error estándar es

$$\widehat{\text{se}}(\widehat{\text{recall}}) \approx \sqrt{\frac{\widehat{r}(1-\widehat{r})}{TP + FN}}.$$

La fórmula análoga para precision usa $TP + FP$. Estas aproximaciones requieren casos independientes y un procedimiento fijado; no incluyen la incertidumbre por haber escogido modelo y umbral con los mismos datos.

El condicionamiento inverso y la prevalencia

Recall y precision condicionan en direcciones diferentes. Recall pregunta por la predicción entre los casos realmente positivos; precision pregunta por el estado real entre los casos que el modelo declaró positivos. La fórmula de Bayes conecta ambas direcciones:

$$\mathbb{P}(Y = 1 \mid \hat{Y} = 1) = \frac{\mathbb{P}(\hat{Y} = 1 \mid Y = 1)\mathbb{P}(Y = 1)}{\mathbb{P}(\hat{Y} = 1)}.$$

Si llamamos r al recall, s a la especificidad y $\pi = \mathbb{P}(Y = 1)$ a la prevalencia, entonces

$$\mathbb{P}(\hat{Y} = 1) = r\pi + (1 - s)(1 - \pi),$$

y por tanto

$$\text{precision} = \frac{r\pi}{r\pi + (1 - s)(1 - \pi)}.$$

Esta identidad muestra por qué precision puede cambiar entre poblaciones aunque recall y especificidad permanezcan aproximadamente constantes: depende de la prevalencia. En aplicaciones diagnósticas o de detección, reportar solo una de estas cantidades oculta parte del problema.

Ejemplo: una clase poco frecuente. Supongamos $r = 0.90$, $s = 0.95$ y una prevalencia $\pi = 0.01$. Entonces

$$\text{precision} = \frac{0.90(0.01)}{0.90(0.01) + 0.05(0.99)} \approx 0.154.$$

Aunque el clasificador detecta el 90% de los positivos y descarta correctamente el 95% de los negativos, menos de una de cada seis alertas corresponde a un caso positivo. La baja prevalencia no invalida el modelo, pero cambia el uso que puede darse a sus alertas.

Particiones: ajustar, seleccionar y estimar

La partición no es un detalle administrativo: define para qué puede usarse cada resultado.




Figura 18: Particiones: train ajusta parámetros, dev selecciona modelos y test estima desempeño final; mezclar esos roles produce evaluaciones optimistas.

Lectura de la figura. Cada partición tiene un uso. Train puede aprender parámetros y transformaciones; dev puede guiar elecciones de modelo; test se reserva para estimar el desempeño final. Si test participa en selección, la comparación queda contaminada.

Métrica principal

La **métrica principal** es la regla cuantitativa que se usará para seleccionar modelos durante el desarrollo.

Ejemplos:

Problema	Métrica razonable	Motivo
Diagnóstico médico	recall o F1	falsos negativos costosos
Filtro de alertas	precision	falsos positivos saturan al usuario
Ranking general	ROC-AUC o PR-AUC	importa ordenar riesgos
Regresión de demanda	MAE o RMSE	depende del costo de error

Accuracy no siempre basta

En clases desbalanceadas, un modelo que predice siempre la clase mayoritaria puede tener alta accuracy.

Por eso, en clasificación binaria se debe revisar:

- matriz de confusión;
- precision;
- recall;
- F1;
- ROC-AUC o PR-AUC;
- costo de falsos positivos y falsos negativos.

Ejemplo resuelto: accuracy engañosa

Supón un problema con 1000 observaciones:

- 950 son negativas;
- 50 son positivas;
- un modelo predice todo como negativo.

La accuracy es:

$$\frac{950}{1000} = 0.95.$$

Pero el recall de la clase positiva es:

$$\frac{TP}{TP + FN} = \frac{0}{0 + 50} = 0.$$

Si detectar positivos era el objetivo, este modelo no sirve aunque su accuracy parezca alta.

Ejemplo resuelto: costo de falsos negativos

Supón un problema con 50 positivos y 950 negativos. Comparamos dos umbrales:

Umbral	TP	FP	FN	TN
A	35	40	15	910
B	25	10	25	940

El umbral A tiene:

$$\text{precision}_A = \frac{35}{35 + 40} \approx 0.467, \quad \text{recall}_A = \frac{35}{35 + 15} = 0.70.$$

El umbral B tiene:

$$\text{precision}_B = \frac{25}{25 + 10} \approx 0.714, \quad \text{recall}_B = \frac{25}{25 + 25} = 0.50.$$

Si un falso positivo cuesta 1 unidad y un falso negativo cuesta 10 unidades, el costo total observado de cada umbral es:

$$C_A = 40(1) + 15(10) = 190, \quad C_B = 10(1) + 25(10) = 260.$$

Aunque B tiene mayor precision, A es preferible bajo esta función de costo porque reduce falsos negativos. Si se quisiera un costo promedio por caso, se dividiría cada total por 1000. La métrica correcta depende del uso y de los costos declarados, no de cuál número se ve más alto.

Derivación guiada: F1 como equilibrio operativo

Precision y recall miden errores distintos:

$$\text{precision} = \frac{TP}{TP + FP}, \quad \text{recall} = \frac{TP}{TP + FN}.$$

F1 es la media armónica de ambas:

$$F1 = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}.$$

La media armónica penaliza valores muy bajos. Por eso un modelo con precision alta pero recall casi cero no obtiene buen F1. Esto es útil cuando ambos tipos de desempeño importan, pero no reemplaza una función de costo si los errores tienen costos muy asimétricos.

De costos a una regla de decisión

Supongamos que el modelo entrega la probabilidad condicional bien calibrada $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$. Si predecir 1 cuando $Y = 0$ cuesta C_{FP} y predecir 0 cuando $Y = 1$ cuesta C_{FN} , los costos condicionales son

$$\mathcal{C}(1 \mid x) = C_{FP}[1 - \eta(x)], \quad \mathcal{C}(0 \mid x) = C_{FN}\eta(x).$$

Elegimos la clase 1 cuando $\mathcal{C}(1 \mid x) \leq \mathcal{C}(0 \mid x)$. Al reordenar,

$$\eta(x) \geq \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Con costos iguales se obtiene el umbral $1/2$. Si los falsos negativos son más costosos, el umbral disminuye. La deducción muestra que el umbral pertenece a la decisión, no al ajuste de la distribución predictiva.

En datos reales usamos $\hat{p}(x)$, no $\eta(x)$ conocida. El umbral teórico solo es aplicable si las probabilidades están suficientemente calibradas, los costos representan el uso y no hay restricciones adicionales de capacidad. Por eso se comprueba y, cuando hace falta, se selecciona con validación; después se fija antes de evaluar test.

Regla de Bayes con dos costos. Bajo probabilidades condicionales conocidas y costos constantes $C_{FP}, C_{FN} > 0$, la regla que minimiza el costo esperado condicional predice 1 exactamente cuando $\eta(x) \geq C_{FP}/(C_{FP} + C_{FN})$.

Baseline

Ningún modelo se reporta sin baseline.

Un baseline puede ser:

- clase mayoritaria;
- promedio de entrenamiento;
- modelo lineal simple;
- regla de negocio;
- modelo anterior del proyecto.

Particiones

La estructura estándar es:

```
train -> ajustar parámetros
dev/validation -> elegir modelo e hiperparámetros
test -> estimar desempeño final
```

Test se toca una vez

Si se usa test para tomar decisiones, deja de ser una estimación honesta del desempeño final.

Advertencia

El conjunto de test no es una herramienta de diseño. Es una auditoría final.

La misma regla se aplica al umbral. Se elige con validación; después se fija y se evalúa una vez en test junto con el modelo final.

Estratificación

En clasificación, la partición debe preservar proporciones de clase cuando sea razonable:

```
train_test_split(X, y, stratify=y, random_state=42)
```

Si no se estratifica un dataset pequeño o desbalanceado, una partición puede cambiar artificialmente la dificultad.

Ejemplo resuelto: conteos en una partición estratificada

Supón un dataset con 2000 observaciones y clase positiva de 8 %. Entonces hay:

$$2000(0.08) = 160$$

observaciones positivas. En una división 60/20/20 estratificada, los tamaños esperados son:

Conjunto	Observaciones	Positivos esperados	Negativos esperados
train	$2000(0.60) = 1200$	$160(0.60) = 96$	1104
dev	$2000(0.20) = 400$	$160(0.20) = 32$	368
test	$2000(0.20) = 400$	$160(0.20) = 32$	368

La tabla no garantiza que cada partición sea perfecta en todos los rasgos del problema. Solo preserva, aproximadamente, la proporción de la clase usada para estratificar. Si hay tiempo, grupos, hospitales, sedes o usuarios repetidos, esas restricciones pueden ser más importantes que una estratificación simple.

Leakage

Leakage ocurre cuando información no disponible en producción entra al entrenamiento o a la evaluación.

Ejemplos:

- escalar usando todo el dataset antes de partir;
- seleccionar variables usando test;
- usar variables creadas después del evento a predecir;
- duplicados entre train y test;
- elegir hiperparámetros mirando test.

Pipeline como defensa

Los pipelines ayudan a aplicar `fit` solo donde corresponde:

```
Pipeline([
    ("scaler", StandardScaler()),
    ("model", LogisticRegression())
])
```

En cross-validation, cada fold ajusta sus transformaciones solo con el train fold.

Caso longitudinal: clasificación con slice reciente

El archivo `clasificacion_binaria_sintetica.csv` acompaña varios capítulos. Tiene variables `x1`, `x2`, una etiqueta binaria `target` y una columna `slice` con valores `base` y `reciente`. El objetivo pedagógico es discutir qué pasa cuando un modelo parece razonable en promedio, pero cambia su comportamiento en una subpoblación o periodo.

Para este caso, una primera partición debe declarar:

Decisión	Criterio
baseline	clase mayoritaria o logística simple
métrica primaria	F1 o recall si la clase positiva importa
partición	train/dev/test con semilla fija
estratificación	preservar proporción de <code>target</code> cuando sea razonable
auditoría	revisar desempeño por <code>slice</code> antes de recomendar

La columna `slice` no debe usarse automáticamente como variable predictora. A veces se usa para diagnóstico, no para entrenamiento. Esa distinción evita que el modelo aprenda un marcador de origen que no estará disponible o que no se quiere usar en producción.

Punto de control

Antes de comparar modelos, escribe explícitamente:

1. métrica principal;
2. baseline;
3. partición;
4. transformación dentro de pipeline;
5. regla para no tocar test.

Verificaciones seleccionadas

1. Si la clase positiva representa 8 % de 2000 observaciones, hay 160 positivos.
2. En una división estratificada 60/20/20, se esperan aproximadamente 96 positivos en train, 32 en dev y 32 en test.
3. Si se ajusta `StandardScaler` antes de partir datos, el promedio de dev/test ya contaminó el preprocesamiento.

Para explorar más

- **Extensión matemática:** calcula precisión, recall, F1 y balanced accuracy para dos matrices de confusión con el mismo accuracy.
- **Extensión computacional:** repite una partición estratificada con varias semillas y mide la variación de la métrica principal.
- **Conexión con proyecto:** escribe qué métrica será primaria, cuál será secundaria y qué baseline debe superar tu modelo.

Revisión del capítulo

Este capítulo separa entrenamiento de evaluación. La métrica principal debe elegirse antes de comparar modelos y debe estar alineada con el costo de error. Accuracy puede ser engañosa cuando las clases están desbalanceadas o cuando un tipo de error pesa más que otro. Precision y recall condicionan en direcciones diferentes; la fórmula de Bayes muestra que la precision también depende de la prevalencia de la clase positiva en la población evaluada.

Las particiones train, dev y test cumplen funciones distintas. Train ajusta parámetros, dev guía decisiones de modelo y test estima desempeño final. La estratificación, las particiones temporales o por grupo deben elegirse según el problema, no por costumbre.

El leakage suele entrar por preprocesamiento aprendido con demasiados datos. Un **Pipeline** no es solo comodidad de código: es una barrera operativa para que escalamiento, imputación y selección de variables se ajusten donde corresponde. No evita por sí solo variables posteriores al evento, duplicados entre personas o una partición temporal mal construida; esos riesgos pertenecen al diseño del dataset.

Términos clave

- **Métrica principal:** cantidad que guía la selección del modelo.
- **Baseline:** regla simple que fija un punto mínimo de comparación.
- **Prevalencia:** probabilidad poblacional de la clase positiva.
- **Fórmula de Bayes:** identidad que invierte el condicionamiento combinando verosimilitud y prevalencia.
- **Train/dev/test:** separación para entrenar, seleccionar y estimar desempeño final.
- **Estratificación:** partición que preserva proporciones de clase.

- **Leakage:** entrada de información no disponible en producción al entrenamiento o evaluación.
- **Pipeline:** objeto que encadena preprocesamiento y modelo para evitar ajustes fuera de lugar.

Ejercicios

Preguntas conceptuales

1. Para un problema de fraude, explique cuándo preferiría recall y cuándo precision.
2. ¿Por qué accuracy puede ser una mala métrica en clases desbalanceadas?

Problemas cuantitativos

3. Diseñe una partición `train/dev/test` para un dataset de 2000 observaciones con clases desbalanceadas.
4. Si una clase positiva representa 8 % de los datos, estime cuántos positivos deberían aparecer en cada partición de una división 60/20/20 estratificada.

Práctica computacional

5. Implemente una partición estratificada con semilla fija.
6. Construya un `Pipeline` que escale variables numéricas y ajuste un modelo.

Interpretación y pensamiento crítico

7. Identifique el leakage: se imputa la media de cada variable usando todo el dataset antes de `train_test_split`.
8. Escriba una regla concreta para decidir cuándo se permite tocar el conjunto de test.

Profundización matemática y estadística

9. Derive el umbral de Bayes para costos C_{FP} y C_{FN} a partir de los dos costos condicionales.
10. Compare el error estándar aproximado de recall 0.80 con 10 y con 500 positivos.
11. Construya un caso donde precision no esté definida y distinga la definición matemática de la convención de una biblioteca.
12. Explique por qué seleccionar el umbral con test invalida la interpretación de su métrica final, aunque el modelo no se vuelva a entrenar.
13. Derive la expresión de precision en términos de recall, especificidad y prevalencia. Evalúela para prevalencias 0.01, 0.10 y 0.50 manteniendo fijos recall y especificidad, e interprete el cambio.

Proyecto de cierre

14. Para su proyecto, escriba una ficha de evaluación con métrica principal, baseline, partición, riesgo de leakage y regla de uso del test.

Validación cruzada y curvas de aprendizaje

Pregunta aplicada

Un solo split puede ser afortunado o desafortunado. Necesitamos estimar variabilidad:

¿el modelo funciona de forma estable o solo tuvo suerte en una partición?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. explicar qué estima cross-validation;
2. reportar media y variabilidad de una métrica;
3. usar grid search sin contaminar test;
4. leer learning curves y validation curves;
5. distinguir problemas de sesgo, varianza y ruido.
6. distinguir validación para selección de validación para estimación;
7. diseñar validación anidada y calcular su costo en número de ajustes.

Qué aleatoriedad intenta representar la validación

Idealmente evaluamos un **procedimiento** A que transforma una muestra de entrenamiento en un modelo $A(D_m)$. Su desempeño esperado para tamaño m es

$$\mathcal{R}_m(A) = \mathbb{E}_{D_m \sim P^m} \mathbb{E}_{Z \sim P} [\ell(A(D_m); Z)].$$

Cross-validation reutiliza una muestra finita para aproximar esta esperanza sobre posibles conjuntos de entrenamiento y observaciones de validación. Los folds no son réplicas independientes: comparten datos y sus modelos están correlacionados. Por eso la desviación entre folds es descriptiva y no debe convertirse automáticamente en un intervalo de confianza.

Independencia de test. Si el procedimiento completo A queda fijado sin usar test y D_{test} es independiente con distribución P , entonces el promedio de pérdidas de test es condicionalmente insesgado para el riesgo de $A(D_m)$:

$$\mathbb{E}[\widehat{R}_{\text{test}}(A(D_m)) \mid D_m] = R_P(A(D_m)).$$

La igualdad deja de describir el protocolo si test modifica hiperparámetros, features, umbral o selección del reporte.

Bootstrap y unidad de remuestreo

El bootstrap empírico genera réplicas $D_n^{*(b)}$ muestreando con reemplazo desde D_n y recalcula un estadístico $T^{*(b)}$. La distribución de las réplicas aproxima la variación muestral de T bajo la distribución empírica.

Si hay varias filas por paciente, colegio o periodo, la unidad independiente no es la fila. En ese caso se requiere bootstrap por grupos, bloques temporales u otro esquema que preserve la dependencia relevante.

Cross-validation

En k -fold cross-validation:

1. Se divide el conjunto de entrenamiento en k folds.
2. Se entrena k veces.
3. Cada fold actúa una vez como validación.
4. Se reporta media y variabilidad.

```
scores = cross_val_score(pipeline, X_train, y_train, cv=5, scoring="f1")
```

Qué reportar

Un reporte no debe decir solo:

```
F1 = 0.84
```

Dice:

```
F1 CV = 0.84 ± 0.03
```

La desviación describe dispersión entre folds. No es, por sí sola, el error estándar de la media ni define un intervalo de confianza: los folds comparten gran parte de sus datos de entrenamiento y sus puntajes no son independientes.

Ejemplo resuelto: elegir entre dos modelos

Supón dos modelos evaluados con 5-fold CV:

Modelo	F1 medio	Desviación
A	0.84	0.02
B	0.86	0.10

El modelo B tiene mayor promedio, pero también mucha mayor variabilidad. Si el contexto exige estabilidad, A puede ser preferible. Si se elige B, debe justificarse y revisarse en slices o con más datos.

La selección no mira solo el máximo promedio.

Derivación guiada: media y variabilidad de CV

Si los puntajes de cinco folds son:

0.80, 0.84, 0.83, 0.86, 0.87,

la media es:

$$\bar{s} = \frac{0.80 + 0.84 + 0.83 + 0.86 + 0.87}{5} = 0.84.$$

La desviación resume qué tanto cambian los resultados entre folds. No convierte la validación cruzada en garantía absoluta, pero sí evita tratar una partición afortunada como regla universal. En reportes del curso, escribe media y variabilidad juntas:

F1 CV = 0.84 ± 0.03

En Lab 4 usaremos la regla explícita

$$s_{\text{cons}} = \bar{s} - s_{\text{folds}}$$

para ordenar candidatos cuando mayor es mejor. Es un **puntaje conservador heurístico**: penaliza dispersión, pero no tiene cobertura probabilística ni reemplaza la inspección de los folds.

Grid search

Para seleccionar hiperparámetros:

```
GridSearchCV(
    estimator=pipeline,
    param_grid=grid,
    scoring="f1",
    cv=5
)
```

El grid search debe ocurrir dentro de entrenamiento/desarrollo, no sobre test.

Selección y validación anidada

Supongamos que comparamos M configuraciones y escogemos

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} \hat{R}_{CV}(A_{\lambda}).$$

El mismo ruido que hace fluctuar los puntajes también influye en qué configuración gana. El mínimo observado tiende a ser optimista porque se escogió después de mirar M estimaciones. Aumentar la grilla puede aumentar este sesgo de selección aunque ninguna configuración nueva sea realmente mejor.

La validación cruzada anidada separa ambos papeles:

```
para cada fold exterior:
    reservar el fold exterior para evaluación
    dentro de los datos restantes:
        comparar hiperparámetros con folds interiores
        escoger una configuración
        reajustar con todo el train exterior
    evaluar una vez en el fold exterior
agregar los puntajes exteriores
```

Los folds exteriores estiman el desempeño del **procedimiento de selección**, no de una configuración elegida de antemano. Después de cerrar el análisis, se selecciona una configuración con todos los datos de desarrollo, se reajusta y se usa el test externo una sola vez si existe.

Cuándo usarla. En el curso, un train/dev/test bien definido suele ser suficiente para laboratorios y proyecto. La CV anidada resulta apropiada cuando el dataset es pequeño, se comparan muchas configuraciones y se necesita una estimación menos optimista del procedimiento de selección.

Costo computacional de validar

Si una búsqueda evalúa M configuraciones con k folds, requiere Mk ajustes, más el ajuste final. Con validación anidada de r folds exteriores y k interiores, la búsqueda requiere aproximadamente

$$r(Mk + 1)$$

ajustes, antes del modelo final. El costo real depende de que cada fold usa menos datos y de si la biblioteca reutiliza cálculos, pero el orden explica por qué una grilla indiscriminada puede consumir el presupuesto sin aportar comprensión.

La comparación debe fijar también el presupuesto. Si una configuración recibe más épocas, más semillas o una grilla más favorable, el resultado mezcla calidad del modelo con esfuerzo de búsqueda.

Learning curve

Una curva de aprendizaje compara desempeño al aumentar el tamaño del conjunto de entrenamiento.




Figura 19: Curvas de aprendizaje: un caso de overfitting mantiene una brecha entre entrenamiento y validación, un caso de underfitting mantiene ambos desempeños bajos, y un caso estable cierra la brecha con más datos.

Lectura de la figura. Una learning curve no se interpreta por el valor final aislado, sino por la relación entre entrenamiento y validación. La brecha sugiere varianza; valores bajos en ambas curvas sugieren sesgo; curvas que se acercan pueden indicar que más datos ayudan.

Señales típicas:

Señal	Diagnóstico	Acción
Train alto y val bajo	overfitting	regularizar, simplificar, más datos
Train bajo y val bajo	underfitting	modelo más expresivo, mejores features
Train y val se acercan Val mejora con más datos	estabilidad conseguir más datos puede ayudar	evaluar límite por ruido

Ejemplo resuelto: leer una learning curve

Supón que una curva de aprendizaje produce:

Tamaño train	F1 train	F1 validación
200	0.98	0.63
800	0.95	0.74

Tamaño train	F1 train	F1 validación
2000	0.92	0.82
5000	0.90	0.86

Lectura:

1. El desempeño de entrenamiento baja al aumentar datos, lo cual es normal.
2. El desempeño de validación sube de forma sostenida.
3. La brecha train-validación se reduce de 0.35 a 0.04.
4. El diagnóstico es alta varianza inicial que mejora con más datos.

La acción razonable no es aumentar complejidad. Primero conviene conseguir más datos, usar regularización moderada o mantener el modelo si el costo de más datos es alto.

Validation curve

Una validation curve varía un hiperparámetro:

```
regularización baja -> modelo flexible
regularización alta -> modelo simple
```

Permite detectar si el hiperparámetro está empujando al modelo hacia overfitting o underfitting.

Caso longitudinal: estabilidad del modelo de clasificación

En `clasificacion_binaria_sintetica.csv`, una validación de cinco folds puede producir algo como:

Modelo	F1 CV medio	Desviación	Lectura
logística simple	0.71	0.03	baseline estable
logística con features polinomiales	0.76	0.09	mejora media, alta varianza
modelo regularizado	0.74	0.04	balance entre mejora y estabilidad

La selección no es automática. Si el contexto tolera variabilidad y luego se hará error analysis por `slice`, podría explorarse el modelo polinomial. Si se quiere una selección conservadora, el modelo regularizado puede ser preferible. El punto es que media y desviación se leen juntas.

Ejemplo resuelto: decisión con diferencia pequeña

Supón que dos modelos tienen:

Modelo	F1 CV medio	Desviación
A	0.812	0.018
B	0.819	0.061

La diferencia de medias es 0.007, menor que la variabilidad reportada de B. Una lectura cuidadosa no diría que B “gana” de forma clara. Diría que B tiene una mejora media pequeña, pero su inestabilidad exige revisar folds, slices o una partición temporal antes de cambiar la recomendación. En validación, ganar por una milésima no equivale a ganar una decisión.

Sesgo, varianza y ruido

La generalización puede entenderse como una combinación de:

- **sesgo:** error sistemático por modelo demasiado restrictivo;
- **varianza:** sensibilidad a cambios en entrenamiento;
- **ruido:** parte no explicable por las variables disponibles.

No todo error se arregla con un modelo más complejo.

Punto de control

Si una learning curve muestra train alto y validación bajo, no concluyas “necesito una red más grande”. Primero pregunta:

1. ¿hay leakage?
2. ¿la métrica está alineada con la decisión?
3. ¿el modelo ya tiene demasiada varianza?
4. ¿más datos podría cerrar la brecha?

Verificaciones seleccionadas

1. Evaluar 4 valores de **C**, 3 valores de **penalty** y 5 folds entrena $4 \cdot 3 \cdot 5 = 60$ ajustes.
2. Si la media CV mejora poco pero la desviación se triplica, la mejora puede no justificar el cambio de modelo.
3. **GridSearchCV** debe recibir el pipeline completo cuando hay escalamiento, imputación o selección de variables.

Ejemplo resuelto: cuándo no hacer grid más grande

Si una grilla inicial muestra que todos los valores de regularización fuerte tienen train y dev bajos, aumentar la grilla alrededor de regularización más fuerte probablemente no ayudará. La acción más razonable es revisar features, capacidad del modelo o métrica. Grid search no reemplaza diagnóstico: solo prueba combinaciones dentro del espacio que tú definiste.

Para explorar más

- **Extensión matemática:** interpreta una curva con alto sesgo y otra con alta varianza usando brechas train/dev.
- **Extensión computacional:** genera curvas de aprendizaje para dos tamaños de entrenamiento y reporta si más datos parecen útiles.
- **Conexión con proyecto:** decide qué experimento harías primero: más datos, más regularización, más features o modelo más flexible.

Criterio práctico de decisión

Cuando dos modelos tienen métricas cercanas, la elección no debe depender solo del tercer decimal. Un criterio razonable compara desempeño medio, variabilidad, complejidad, costo de explicación y estabilidad por slice. Si el modelo más complejo mejora 0.003 en F1, pero tiene mayor varianza entre folds y errores más difíciles de explicar, puede conservarse el modelo simple como baseline operativo.

La validación no declara un campeón universal. Compara candidatos bajo una partición, una métrica y un presupuesto. Elegir bien también significa registrar cuándo la diferencia observada no basta para preferir una alternativa más complicada.

Revisión del capítulo

La validación cruzada estima desempeño con variabilidad. Reportar solo una media oculta si el modelo es estable o si depende demasiado de una partición particular. La desviación entre folds puede cambiar una decisión técnica.

Grid search debe evaluar pipelines completos para no contaminar cada fold. Las learning curves y validation curves ayudan a distinguir sesgo, varianza, falta de datos, hiperparámetros mal calibrados y ruido irreducible.

La pregunta no es únicamente qué modelo gana. También importa si los resultados justifican cambiar complejidad, recolectar datos, ajustar regularización o aceptar un límite. La curva debe terminar en un experimento, no solo en una imagen.

Términos clave

- **Cross-validation:** estimación de desempeño usando varias particiones train/validation.
- **Grid search:** búsqueda sistemática sobre combinaciones de hiperparámetros.
- **Learning curve:** curva que compara desempeño al variar tamaño de entrenamiento.
- **Validation curve:** curva que compara desempeño al variar un hiperparámetro.
- **Sesgo:** error sistemático por modelo demasiado restrictivo.
- **Varianza:** sensibilidad del modelo a cambios en datos de entrenamiento.
- **Ruido:** variación no explicable con las variables disponibles.

Ejercicios

Preguntas conceptuales

1. Una learning curve muestra train F1 0.99 y validation F1 0.70. Diagnostique y proponga dos acciones.
2. ¿Por qué reportar desviación estándar de cross-validation puede cambiar una decisión de modelo?

Problemas cuantitativos

3. Compare dos modelos con medias CV similares pero desviaciones estándar diferentes. ¿Cuál elegiría si la estabilidad es prioritaria?
4. Si se evalúan 4 valores de C , 3 valores de `penalty` y 5 folds, ¿cuántos ajustes se entrenan?

Práctica computacional

5. Explique por qué `GridSearchCV` debe recibir un `Pipeline` completo si hay escalamiento.
6. Genere una tabla con media y desviación estándar de CV para al menos tres configuraciones.

Interpretación y pensamiento crítico

7. Una validation curve mejora hasta cierto punto y luego cae. Explique qué sugiere sobre el hiperparámetro.
8. ¿Cuándo buscar más datos es más razonable que cambiar de algoritmo?

Profundización matemática y estadística

9. Explique por qué el mínimo entre muchas estimaciones ruidosas de CV tiende a ser optimista para la configuración seleccionada.
10. Diseñe una validación anidada con 5 folds exteriores, 4 interiores y 12 configuraciones. Calcule el número aproximado de ajustes.

11. Distinga el riesgo de una configuración fija del riesgo del procedimiento que escoge una configuración con los datos.
12. Explique por qué dividir la desviación entre folds por $\sqrt{k}$ no produce automáticamente un error estándar válido.

Proyecto de cierre

13. Construya una learning curve o validation curve para un modelo de su proyecto y escriba un diagnóstico de sesgo/varianza/ruido con una acción siguiente.

Error analysis y data mismatch

Pregunta aplicada

Dos modelos pueden tener la misma métrica agregada y fallar en casos completamente distintos.

El análisis de errores pregunta:

¿dónde falla el modelo, para quién falla y qué experimento debe seguir?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. separar errores por tipo: falsos positivos, falsos negativos y casos ambiguos;
2. definir slices relevantes para un proyecto;
3. detectar señales de data mismatch;
4. escribir una recomendación con resultado, diagnóstico y acción;
5. reconocer cuándo una métrica agregada oculta daño o riesgo.
6. cuantificar la variación de una métrica por slice usando su denominador efectivo;
7. separar slices predefinidos de hallazgos exploratorios seleccionados después de mirar los errores.

Riesgo condicional por slice

Para un slice $S \subseteq \mathcal{X} \times \mathcal{Y}$ con $\mathbb{P}_P(S) > 0$, definimos

$$R_P(f \mid S) = \mathbb{E}_P[\ell(f(X), Y) \mid (X, Y) \in S].$$

El promedio global satisface una descomposición por una partición $S_1, \dots, S_J$:

$$R_P(f) = \sum_{j=1}^J \mathbb{P}_P(S_j) R_P(f \mid S_j).$$

Un slice pequeño puede tener riesgo alto y aportar poco al promedio global. Por eso el análisis debe reportar simultáneamente tamaño, prevalencia, conteos de error y métrica condicional.

Cambio de distribución como cambio de medida

Train y uso corresponden a distribuciones P_{train} y P_{uso} sobre el mismo espacio de observaciones. Si P_{uso} es absolutamente continua respecto de P_{train} , el riesgo de uso puede escribirse formalmente como

$$R_{\text{uso}}(f) = \mathbb{E}_{P_{\text{train}}} [w(X, Y) \ell(f(X), Y)], \quad w = \frac{dP_{\text{uso}}}{dP_{\text{train}}}.$$

Esta identidad no resuelve el problema: las razones pueden ser desconocidas o muy inestables, y puede haber regiones de uso sin soporte en entrenamiento. Sirve para precisar por qué comparar histogramas no basta para garantizar transportabilidad.

Error analysis

Un análisis mínimo incluye:

1. Casos correctamente clasificados.
2. Falsos positivos.
3. Falsos negativos.
4. Subgrupos con peor desempeño.
5. Variables o condiciones asociadas al error.

Error analysis: el promedio no cuenta toda la historia

Un modelo con métrica global aceptable puede fallar en un slice que importa para el uso previsto.




Figura 20: Error analysis por slices: el promedio global puede ocultar un slice crítico con desempeño bajo y exige una recomendación con resultado, diagnóstico, acción y límite.

Lectura de la figura. El promedio global puede ser suficiente para comparar dos prototipos, pero no para recomendar una decisión si un slice importante falla. La figura propone la secuencia mínima: resultado, diagnóstico, acción y límite.

Slices

Un **slice** es un subconjunto interpretable de datos:

- pacientes mayores de cierta edad;
- observaciones con medición faltante;
- imágenes de baja calidad;
- transacciones de monto alto;
- ejemplos de una fuente específica.

El objetivo es detectar fallas ocultas por el promedio.

Incertidumbre y búsqueda entre slices

Sea n_S el número de observaciones de un slice. Para una pérdida promedio,

$$\widehat{R}_S = \frac{1}{n_S} \sum_{i: Z_i \in S} L_i, \quad \widehat{\text{se}}(\widehat{R}_S) = \frac{s_S}{\sqrt{n_S}}.$$

Si L_i es el indicador de error, una aproximación binomial usa

$$\sqrt{\frac{\widehat{e}_S(1 - \widehat{e}_S)}{n_S}}.$$

Para recall, el denominador no es n_S , sino el número de positivos del slice; para precision es el número de predicciones positivas. Una métrica extrema con denominador 6 no tiene la misma estabilidad que la misma métrica con denominador 600.

Hay además un problema de selección. Si se inspeccionan cien slices y se reporta solo el peor, parte de la caída puede deberse a variación aleatoria. Los slices ligados a riesgos conocidos deben definirse antes de mirar resultados. Los hallazgos posteriores son hipótesis exploratorias y necesitan confirmación en otro periodo o muestra.

No imponemos una prueba de hipótesis automática para cada slice. Exigimos algo más básico y útil para este nivel: tamaño, denominadores de la métrica, intervalo o error estándar cuando sea razonable, comparación contra baseline y etiqueta clara de análisis confirmatorio o exploratorio.

Data mismatch

Data mismatch ocurre cuando train, dev o test no vienen de la misma distribución relevante.

Ejemplos:

- entrenar con datos de una ciudad y probar en otra;
- entrenar con datos históricos y usar en una temporada distinta;
- usar datos limpios de laboratorio y desplegar en datos ruidosos;
- combinar fuentes sin controlar origen.

Diagnóstico de mismatch

Compare:

- distribución de variables clave;
- proporción de clases;
- desempeño por fuente;
- error por periodo;
- desempeño en dev vs test.

Si validación y test difieren mucho, no basta con cambiar hiperparámetros. Puede existir mismatch.

Ejemplo resuelto: mismatch por proporción de clase

Supón la siguiente auditoría:

Conjunto	Observaciones	Positivos	Porcentaje positivo	Recall
train	5000	1000	20 %	0.84
dev	1000	210	21 %	0.82
test	1000	80	8 %	0.55

Train y dev se parecen en proporción de clase y desempeño. Test, en cambio, tiene una clase positiva mucho menos frecuente y recall mucho menor. El cambio de prevalencia puede alterar precision, pero no explica por sí solo la caída de recall. Esa caída obliga a comparar también las distribuciones condicionadas a la clase y el proceso de medición.

La primera hipótesis no debería ser “el modelo necesita más hiperparámetros”. Una explicación más plausible es que test proviene de otra población, fuente o periodo. La acción técnica sería:

1. revisar cómo se construyó test;
2. comparar distribuciones de variables clave;
3. reportar desempeño por fuente o periodo;
4. decidir si se necesita un dev set más parecido a producción.

Si test representa producción real, el resultado indica un riesgo de despliegue, no solo una oportunidad de tuning.

Derivación guiada: qué métricas pueden promediarse por slices

Una pérdida promedio o la exactitud puede descomponerse por observación. Si un conjunto tiene dos slices con tamaños n_A, n_B y promedios L_A, L_B , entonces:

$$L_{\text{global}} = \frac{n_A L_A + n_B L_B}{n_A + n_B}.$$

Esto **no** vale en general para F1, precision o recall. Para obtener su valor global se suman primero los conteos TP , FP , FN y TN de los slices y luego se aplica la fórmula de la métrica. Un promedio ponderado de F1 por tamaño puede dar otro número. En ambos casos, un slice grande puede ocultar la caída de uno pequeño; por eso se reportan el tamaño y los conteos junto a la métrica.

Recomendación técnica

Una recomendación debe seguir la forma:

`Resultado -> diagnóstico -> acción`

Ejemplo:

`El recall cae de 0.84 a 0.62 en el grupo de mayor riesgo.`

`Diagnóstico: el modelo no generaliza bien a ese slice.`

`Acción: revisar representación de variables, ampliar datos del slice y ajustar métrica de selección.`

Ejemplo resuelto: dos modelos con el mismo F1

Supón dos modelos con F1 global 0.82.

Slice	Modelo A	Modelo B
Datos recientes	0.80	0.83
Datos antiguos	0.84	0.81
Grupo de alto riesgo	0.55	0.76

Aunque el F1 global sea igual, el Modelo B puede ser preferible si el grupo de alto riesgo es central para el uso propuesto. Antes de escogerlo hay que revisar el tamaño del slice y sus conteos de error.

Ejemplo resuelto: brecha contra el promedio

Supón que un modelo tiene F1 global de 0.81, pero el análisis por slice muestra:

Slice	Observaciones	F1
fuelle A	1400	0.84
fuelle B	900	0.80
fuelle C	220	0.57

La brecha del slice C contra el promedio global es:

$$0.81 - 0.57 = 0.24.$$

Esa diferencia es grande y afecta una fuente específica. La recomendación no debería ser simplemente “el modelo tiene F1 0.81”. Una recomendación concreta sería:

Resultado: el F1 global es 0.81, pero en fuente C cae a 0.57 con 220 casos.
Diagnóstico: el modelo generaliza mal a la fuente C o esa fuente tiene un proceso de medición distinto.
Acción: auditar variables, faltantes y distribución de fuente C; entrenar/dev con datos representativos de esa fuente antes de recomendar despliegue.
Límite: el desempeño global no debe extrapolarse a fuente C hasta cerrar la brecha.

La magnitud de la brecha no prueba por sí sola la causa. Sí prueba que el promedio global es insuficiente para tomar la decisión.

Caso longitudinal: slice reciente

En `clasificacion_binaria_sintetica.csv`, la columna `slice` permite construir una tabla mínima:

Slice	Observaciones	F1	Recall	Lectura
base	180	0.82	0.79	desempeño esperado
reciente	60	0.61	0.48	posible mismatch

Aunque el número exacto dependa de la partición y del modelo, la pregunta permanece: si el uso real se parece al slice **reciente**, el promedio global no justifica despliegue. La acción razonable es construir un dev set más parecido a producción, revisar variables que cambian en el tiempo y reportar la limitación.

Punto de control

Una recomendación técnica es incompleta si no responde:

1. ¿qué resultado observaste?;
2. ¿qué diagnóstico es compatible con ese resultado?;
3. ¿qué acción concreta sigue?;
4. ¿qué límite o riesgo debe comunicarse?

Verificaciones seleccionadas

1. Si el F1 global es 0.81 y el F1 de un slice es 0.57, la brecha es 0.24.
2. Una brecha por slice no prueba la causa; prueba que el promedio global es insuficiente para la decisión.
3. Si dev y test tienen proporciones de clase muy distintas, primero se audita la construcción de particiones antes de hacer más tuning.

Procedimiento de auditoría por slice

Una auditoría mínima por slice sigue cuatro pasos. Primero, predefine los slices que sostendrán conclusiones confirmatorias: periodo, fuente, región, rango de edad, instrumento de medición o categoría operativa relevante. Segundo, calcula para cada slice tamaño, tasa de clase positiva, métrica principal y tipo de error dominante. Tercero, compara contra el desempeño global y contra el baseline; un slice puede tener bajo desempeño absoluto pero seguir mejorando el baseline, o puede empeorar aunque el promedio global suba. Cuarto, escribe una acción: recoger más datos, cambiar partición, ajustar umbral, crear feature, separar modelo o limitar el uso.

Los slices encontrados después de inspeccionar errores son útiles para generar hipótesis, pero deben marcarse como exploratorios y confirmarse con otra muestra o periodo. De lo contrario se seleccionan, sin decirlo, los grupos con la caída más llamativa.

La auditoría también debe proteger contra conclusiones exageradas. Un slice con 12 observaciones no sostiene una afirmación fuerte, pero sí puede activar una revisión. Un slice grande con caída persistente sí cambia la recomendación. En el reporte, el tamaño del slice y la métrica deben aparecer juntos.

Para explorar más

- **Extensión matemática:** calcula tasas de error por slice y estima la brecha respecto al promedio global.
- **Extensión computacional:** crea una tabla de errores con columnas para predicción, etiqueta, slice, score y tipo de fallo.
- **Conexión con proyecto:** define dos slices que podrían revelar data mismatch y explica qué acción tomarías si fallan.

Revisión del capítulo

El análisis de errores convierte una métrica agregada en diagnóstico. Separar falsos positivos, falsos negativos, casos ambiguos y slices críticos revela fallas que un promedio puede ocultar.

Data mismatch aparece cuando train, dev o test no representan la misma población, periodo o proceso de medición. Antes de ajustar hiperparámetros, hay que revisar si la caída de desempeño se explica por cambio de distribución.

Una recomendación técnica debe tener estructura: resultado observado, diagnóstico probable, acción concreta y límite. Sin esa estructura, el reporte queda como una opinión difícil de auditar.

Términos clave

- **Error analysis:** revisión sistemática de casos donde el modelo falla.
- **Slice:** subconjunto de datos definido por una característica relevante.
- **Data mismatch:** diferencia entre distribuciones o condiciones de dev, test o producción.
- **Diagnóstico:** explicación técnica probable de un patrón de error.
- **Recomendación técnica:** acción proporcional al resultado, diagnóstico y límites.
- **Límite:** condición bajo la cual la conclusión no debe extrapolarse.

Ejercicios

Preguntas conceptuales

1. Proponga tres slices relevantes para un proyecto de predicción de abandono de clientes.
2. ¿Por qué un F1 global puede ocultar una falla grave?

Problemas cuantitativos

3. Dada una tabla de métricas por slice, identifique el slice crítico y calcule la brecha contra el desempeño global.
4. Si dev tiene 30 % de clase positiva y test 12 %, ¿qué sospecha antes de ajustar hiperparámetros?

Práctica computacional

5. Escriba una función que calcule una métrica por grupo.
6. Compare distribución de una variable clave entre dev y test con una tabla o gráfico.

Interpretación y pensamiento crítico

7. ¿Qué resultados sugerirían data mismatch entre dev y test?
8. Escriba una recomendación técnica con la estructura resultado-diagnóstico-acción.

Profundización matemática y estadística

9. Para un slice con 20 casos y tasa de error 0.30, calcule un error estándar binomial aproximado. Repita con 500 casos.
10. Explique por qué el denominador efectivo de recall por slice es el número de positivos y no el tamaño total del slice.
11. Se inspeccionaron 80 slices y se publicó solo el peor. Describa el sesgo de selección y diseñe una comprobación confirmatoria.
12. Indique qué falla en la ponderación por densidades cuando producción contiene una región sin soporte en entrenamiento.

Proyecto de cierre

13. Para su proyecto, entregue una tabla de error analysis con al menos tres slices, diagnóstico por slice y una acción concreta.

Ejercicios integradores: estrategia de machine learning

Esta sección entrena la habilidad central del módulo: convertir métricas y particiones en comparaciones verificables. Una buena respuesta nombra el resultado, explica por qué es relevante y reconoce qué todavía no se sabe.

Resultados de práctica

Al terminar este banco deberías poder:

1. elegir una métrica según costo de error;
2. diseñar particiones que respeten el problema;
3. detectar leakage antes de confiar en una métrica;
4. interpretar curvas de aprendizaje;
5. convertir error analysis en una recomendación técnica.

Mapa del banco

Bloque	Qué comprueba
A	métrica principal, métrica secundaria y baseline
B	particiones, validación y leakage
C	curvas, variabilidad y validación cruzada
D	análisis de errores por slices

Criterio de respuesta

En problemas aplicados, una respuesta completa suele tener esta forma:

`métrica elegida -> baseline -> partición -> riesgo de leakage -> decisión o siguiente experimento`

Si falta una de esas piezas, la comparación queda débil.

Columna probabilística del módulo

- P1. Accuracy aleatoria.** Un modelo fijo acierta 180 de 200 casos iid. Calcule accuracy y un error estándar aproximado. Explique qué supuesto permite usar la fórmula Bernoulli.
- P2. Denominadores.** Dos grupos tienen recall 0.80; uno contiene 10 positivos y otro 500. Compare la información que aportan ambas cifras sin usar solo el valor puntual.
- P3. Procedimiento y modelo.** Distinga el riesgo de un modelo ya fijado del riesgo esperado de un procedimiento que selecciona hiperparámetros a partir de una muestra.
- P4. Dependencia de folds.** Explique por qué los puntajes de 5-fold CV no son independientes y por qué $\text{media} \pm \text{desviación}$ no constituye automáticamente un intervalo de confianza.
- P5. Bootstrap por grupos.** Diseñe un remuestreo para datos con diez mediciones por paciente. Compare con remuestrear filas individualmente.
- P6. Riesgo por slices.** Construya dos slices con pesos poblacionales y riesgos condicionales dados; verifique la descomposición del riesgo global y muestre cómo un slice crítico puede quedar oculto.
- P7. Soporte.** Dé un ejemplo de observaciones posibles en producción con probabilidad positiva bajo P_{uso} y probabilidad cero bajo P_{train} . Explique por qué ponderar entrenamiento no basta.

Bloque A: métricas

- A1.** En un problema con falsos negativos costosos, explique por qué accuracy puede ser una mala métrica principal.
- A2.** Dada una matriz de confusión, calcule precision, recall y F1.
- A3.** Proponga una métrica principal y una métrica secundaria para un proyecto de detección temprana de riesgo.
- A4.** Derive el umbral de Bayes para costos C_{FP} y C_{FN} . Indique qué supuestos sobre calibración y costos necesita para usarlo con un score estimado.
- A5.** Dos clasificadores tienen recall 0.80, uno con 12 positivos y otro con 480. Calcule errores estándar aproximados y discuta qué comparación puede sostenerse.

Bloque B: particiones y leakage

- B1.** Explique por qué escalar antes de partir datos puede contaminar validación.
- B2.** Diseñe una partición para datos temporales. ¿Por qué `shuffle=True` puede ser inadecuado?
- B3.** Identifique dos formas de leakage en proyectos estudiantiles.
- B4.** Explique por qué elegir un umbral o una figura después de mirar test es selección, aunque los parámetros del modelo permanezcan fijos.

Bloque C: validación y curvas

- C1.** Interprete una curva con train alto y validation bajo.
- C2.** Explique cuándo más datos probablemente ayudarían.
- C3.** ¿Qué información agrega cross-validation frente a un único split?
- C4.** Diseñe una validación cruzada anidada para 20 configuraciones, 5 folds interiores y 4 exteriores. Calcule el número aproximado de ajustes.
- C5.** Explique por qué la mejor de muchas estimaciones de CV suele ser optimista para el candidato seleccionado.

Bloque D: error analysis

- D1.** Proponga slices para analizar errores en clasificación de dígitos escritos a mano.
- D2.** Escriba una recomendación técnica basada en un slice donde el F1 cae de 0.80 a 0.55.
- D3.** Explique por qué una métrica agregada no reemplaza inspección de errores.
- D4.** Se exploraron cincuenta slices y se reportó el de peor resultado. Diseñe un protocolo para distinguir hallazgo exploratorio de confirmación y especifique qué denominadores publicaría.

Respuestas seleccionadas

- A1.** Accuracy puede ser alta aunque el modelo ignore la clase importante. Si los falsos negativos son costosos, recall, F1 o una métrica ponderada por costo pueden reflejar mejor la decisión.
- B1.** Escalar antes de partir datos usa media y desviación calculadas con información de validación. Eso contamina la evaluación porque el preprocesamiento ya vio datos que debían permanecer independientes.
- C3.** Cross-validation muestra la dispersión de resultados entre folds. Un único split puede favorecer o perjudicar accidentalmente a un modelo. La desviación entre folds no es automáticamente un intervalo de confianza.
- D2.** Una recomendación mínima sería: “El F1 global es 0.80 y el del slice crítico es 0.55. El patrón es compatible con una falla de representación o mismatch. Antes de recomendar uso, se deben revisar tamaño y conteos de error del slice y confirmar la caída en otra muestra.”

Parte V: Aprendizaje no supervisado

Hasta ahora una respuesta observada ha guiado el ajuste y la evaluación. En el aprendizaje no supervisado no hay una variable objetivo que cumpla ese papel. Los algoritmos buscan estructura mediante varianza, error de reconstrucción, distancias o patrones de interacción, y la interpretación depende con mayor fuerza de las decisiones de representación.

PCA introduce primero una pregunta poblacional: ¿qué direcciones concentran mayor variación en un vector aleatorio? La matriz de covarianza muestral y la SVD proporcionan una respuesta empírica y computable. K-Means sustituye la varianza proyectada por distancias a centroides y muestra por qué el escalamiento y la inicialización pueden cambiar la solución. La recomendación, finalmente, utiliza matrices dispersas para estudiar similitud y estructura latente.

En los tres casos, descubrir una regularidad matemática no basta para asignarle un significado de dominio. La estabilidad frente a muestras, inicializaciones y transformaciones forma parte del resultado, al igual que la descripción de las unidades y variables que originaron la estructura.




Figura 21: PCA como proyección: datos centrados se factorizan con SVD; los primeros vectores de V definen ejes principales y la matriz Z contiene coordenadas de baja dimensión.

La figura presenta PCA como una proyección calculada a partir de la SVD de los datos centrados. Las coordenadas reducidas conservan una parte de la variación, pero la elección del número de componentes y su interpretación requieren volver a las variables originales y al propósito del análisis.

SVD y PCA

Pregunta aplicada

Un dataset puede tener decenas o miles de variables. ¿Podemos representarlo en menos dimensiones sin perder la estructura principal?

PCA responde:

buscar direcciones ortogonales que capturan la mayor varianza posible.




Figura 22: PCA como proyección: datos centrados se factorizan con SVD; los primeros vectores de V definen ejes principales y la matriz Z contiene coordenadas de baja dimensión.

Lectura de la figura. PCA empieza con datos centrados, usa la SVD para encontrar direcciones de alta varianza y proyecta sobre V_k . La proyección puede servir para visualizar, comprimir o alimentar otro modelo, pero no prueba causalidad.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. escribir la SVD de una matriz;
2. explicar por qué PCA requiere centrar datos;
3. calcular la forma de una proyección $Z = X_c V_k$;
4. interpretar varianza explicada y error de reconstrucción;
5. distinguir reducción de dimensión de interpretación causal.

6. derivar las direcciones principales mediante un problema restringido;
7. comparar la descomposición por covarianza con una SVD directa en costo y estabilidad.

PCA poblacional y PCA empírico

Sea $X \in \mathbb{R}^p$ un vector aleatorio con media μ y matriz de covarianza

$$\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^\top].$$

La primera dirección principal poblacional resuelve

$$v_1^* = \arg \max_{\|v\|_2=1} \text{Var}(v^\top X) = \arg \max_{\|v\|_2=1} v^\top \Sigma v.$$

Por el cociente de Rayleigh, v_1^* es un autovector asociado al mayor autovalor de Σ . No conocemos Σ ; con una muestra usamos

$$\widehat{\Sigma}_m = \frac{1}{m} X_c^\top X_c.$$

Si $X_c = U \Sigma_s V^\top$ es la SVD, entonces

$$\widehat{\Sigma}_m = V \frac{\Sigma_s^2}{m} V^\top.$$

Así, los vectores singulares derechos son direcciones principales **empíricas** y σ_j^2/m son autovalores de la covarianza empírica. Cambiar la muestra puede cambiar direcciones, especialmente cuando autovalores consecutivos son cercanos.

Máxima varianza empírica. Para X_c centrada,

$$\max_{\|v\|=1} \frac{1}{m} \|X_c v\|_2^2 = \frac{\sigma_1^2}{m},$$

y cualquier primer vector singular derecho alcanza el máximo.

La afirmación se obtiene con multiplicadores de Lagrange. Para una matriz de covarianza simétrica Σ , maximizamos $v^\top \Sigma v$ sujeto a $v^\top v = 1$. La función de Lagrange es

$$\mathcal{L}(v, \lambda) = v^\top \Sigma v - \lambda(v^\top v - 1).$$

Su condición estacionaria respecto a v es

$$2\Sigma v - 2\lambda v = 0,$$

de modo que una dirección candidata debe satisfacer $\Sigma v = \lambda v$. Además, en un autovector unitario,

$$v^\top \Sigma v = \lambda.$$

Por tanto, el máximo corresponde al mayor autovalor. Para k direcciones ortonormales, el problema se escribe

$$\max_{V_k^\top V_k = I_k} \text{tr}(V_k^\top \Sigma V_k),$$

y el máximo es la suma de los k mayores autovalores. Si hay autovalores repetidos, el subespacio principal está determinado, pero una base particular dentro de él no es única.

La indeterminación de signo de un componente no es incertidumbre muestral: v y $-v$ describen el mismo eje. La inestabilidad entre subespacios al cambiar la muestra sí es una cuestión estadística y debe estudiarse por remuestreo o particiones.

SVD

Para una matriz $X \in \mathbb{R}^{m \times p}$, su SVD reducida puede escribirse:

$$X = U_r \Sigma_r V_r^\top,$$

donde $r = \text{rank}(X)$, $U_r \in \mathbb{R}^{m \times r}$, $\Sigma_r \in \mathbb{R}^{r \times r}$ y $V_r \in \mathbb{R}^{p \times r}$.

Donde:

- U contiene direcciones en el espacio de observaciones;
- Σ contiene valores singulares no negativos;
- V contiene direcciones en el espacio de variables.

PCA como SVD del dato centrado

Primero centramos cada columna con el vector de medias $\mu \in \mathbb{R}^p$:

$$X_c = X - \mathbf{1}_m \mu^\top.$$

Luego:

$$X_c = U \Sigma V^\top.$$

Los componentes principales son las primeras filas de $V^\top$, o columnas de V , asociadas a los valores singulares más grandes.

Centrar no es una formalidad. Sin centrado se maximiza $m^{-1} \|Xv\|^2$, que mezcla variación con la distancia del promedio al origen. La primera dirección puede entonces apuntar hacia la media de las observaciones, no hacia la dirección en que fluctúan alrededor de ella. Si además se estandarizan

columnas, PCA analiza la matriz de correlaciones y responde una pregunta distinta: cada variable aporta en unidades de desviación estándar en lugar de conservar su escala original.

Proyección

Si tomamos k componentes:

$$Z = X_c V_k.$$

Aquí $Z \in \mathbb{R}^{m \times k}$ es la representación reducida.

Varianza explicada

La varianza explicada por el componente j es proporcional a:

$$\sigma_j^2.$$

La razón de varianza explicada:

$$\frac{\sigma_j^2}{\sum_{\ell} \sigma_{\ell}^2}.$$

Con la convención de covarianza empírica $1/m$, el autovalor es $\hat{\lambda}_j = \sigma_j^2/m$; el factor $1/m$ se cancela en la razón. Por eso la fórmula es exacta para la muestra observada, pero no afirma qué proporción de varianza explicaría otra muestra de la población.

Ejemplo resuelto: error desde valores singulares

Supón que una matriz centrada tiene valores singulares:

$$\sigma_1 = 9, \quad \sigma_2 = 4, \quad \sigma_3 = 1.$$

La energía total bajo la norma de Frobenius es:

$$9^2 + 4^2 + 1^2 = 98.$$

Si usamos solo $k = 1$, descartamos σ_2 y σ_3 . El error de reconstrucción cuadrático es:

$$4^2 + 1^2 = 17.$$

La varianza explicada acumulada por el primer componente es:

$$\frac{9^2}{98} \approx 0.827.$$

La lectura tiene dos partes: un componente conserva cerca de 82.7% de la variabilidad medida por PCA, pero todavía descarta una parte que puede ser importante para ciertos grupos, variables o decisiones posteriores.

Derivación guiada: reconstrucción y pérdida de información

Si usamos k componentes, retenemos:

$$X_c \approx U_k \Sigma_k V_k^\top.$$

La parte descartada corresponde a componentes $k+1, \dots, r$. Bajo la norma de Frobenius, el error de reconstrucción queda ligado a los valores singulares descartados:

$$\|X_c - \hat{X}_c\|_F^2 = \sum_{j=k+1}^r \sigma_j^2.$$

El teorema de Eckart-Young establece que esta reconstrucción truncada minimiza el error de Frobenius entre todas las matrices de rango a lo sumo k . Esta fórmula explica por qué la varianza explicada acumulada y el error de reconstrucción son dos caras del mismo cálculo. Retener pocos componentes puede ser útil para visualizar, pero siempre descarta variación.

Una forma de ver el resultado usa proyecciones ortogonales. Sea B una matriz de rango a lo sumo k y sea S su espacio columna. Entre todas las matrices cuyas columnas pertenecen a S , la más cercana a X_c es $P_S X_c$, donde P_S es la proyección ortogonal sobre S . Por Pitágoras,

$$\|X_c - P_S X_c\|_F^2 = \|X_c\|_F^2 - \|P_S X_c\|_F^2.$$

Minimizar el error equivale entonces a escoger un subespacio de dimensión k que capture la mayor energía $\|P_S X_c\|_F^2$. La caracterización variacional aplicada a $X_c X_c^\top$ selecciona $S = \text{span}(u_1, \dots, u_k)$, las primeras direcciones singulares izquierdas. Si $X_c = U \Sigma V^\top$,

$$P_S X_c = U_k U_k^\top U \Sigma V^\top = U_k \Sigma_k V_k^\top.$$

El error restante es $\sum_{j>k} \sigma_j^2$. Esta es una justificación de optimalidad respecto a error cuadrático de reconstrucción, no respecto a clasificación, interpretabilidad o utilidad de una variable minoritaria.

Costo y elección del método numérico

Hay dos rutas densas comunes. Formar la covarianza $X_c^\top X_c/m$ cuesta $O(mp^2)$ y diagonalizarla cuesta $O(p^3)$. Una SVD directa evita formar la covarianza y no eleva al cuadrado el número de condición. Si $m \geq p$, su costo denso también es del orden de $O(mp^2)$; si $p \gg m$, puede ser preferible trabajar con $X_c X_c^\top$ o con una SVD truncada.

Cuando solo se necesitan $k \ll \min(m, p)$ componentes, algoritmos iterativos o aleatorizados aproximan el subespacio dominante sin calcular toda la SVD. Deben verificarse con error de reconstrucción y estabilidad, porque ahora aparece una aproximación algorítmica adicional a la variación muestral.

Elección	Ventaja	Riesgo principal
autodescomposición de covarianza	conecta directamente con varianza	forma $X_c^\top X_c$ y empeora condicionamiento
SVD directa de X_c	mayor estabilidad numérica	puede ser costosa si solo se requieren pocos componentes
SVD truncada	aprovecha k pequeño	agrega tolerancia y posible error aproximado

El ajuste del centrado, el escalamiento y los componentes debe ocurrir dentro de cada conjunto de entrenamiento. Proyectar validación o test usa las medias, escalas y direcciones ya aprendidas; recalcularlas sería leakage.

Ejemplo resuelto: elegir k

Supón que los primeros componentes explican:

Componente	Varianza explicada	Acumulada
1	0.42	0.42
2	0.23	0.65
3	0.12	0.77
4	0.06	0.83

Si la meta es visualizar, $k = 2$ puede ser suficiente. Si la meta es reconstruir con poca pérdida, $k = 4$ puede ser más razonable. La elección depende del uso posterior y de una tolerancia declarada, no de un porcentaje universal.

Reconstrucción

Con k componentes:

$$\hat{X}_c = ZV_k^\top.$$

La reconstrucción en escala original:

$$\hat{X} = \hat{X}_c + \mathbf{1}_m \mu^\top.$$

El error de reconstrucción ayuda a medir pérdida de información.

Ejemplo resuelto: proyección y reconstrucción

Considera dos observaciones con dos variables:

$$X = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Primero centramos por columnas. La media es $\bar{X} = (1, 1)$, entonces:

$$X_c = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}.$$

Una dirección principal para estos datos es

$$v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

La proyección con $k = 1$ es:

$$Z = X_c v_1 = \begin{bmatrix} \sqrt{2} \\ -\sqrt{2} \end{bmatrix}.$$

La reconstrucción centrada queda:

$$\hat{X}_c = Z v_1^\top = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}.$$

Al sumar la media:

$$\hat{X} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.$$

En este ejemplo la reconstrucción con un componente es exacta porque los datos centrados tienen rango 1. En un dataset real, $k = 1$ normalmente conserva solo una parte de la variación.

Caso longitudinal: PCA sintético

El archivo `pca_sintetico.csv` contiene cuatro variables generadas desde una estructura latente de baja dimensión. El ejercicio consiste en justificar qué se conserva y qué se pierde.

Resultado	Pregunta
media de entrenamiento	¿con qué parámetros se centró?
varianza explicada acumulada	¿cuántos componentes se retienen?
error de reconstrucción	¿qué se pierde al reducir dimensión?
cargas principales	¿qué variables dominan cada componente?
advertencia	¿qué interpretación causal no se puede afirmar?

Si los dos primeros componentes explican mucha varianza, puedes usarlos para visualizar o comprimir. Eso no significa que los componentes sean causas, grupos naturales o factores reales del dominio. Esa lectura requiere información de dominio adicional.

PCA no es interpretabilidad automática

Advertencia

Un componente principal es una combinación lineal de variables. Puede ser útil, pero no siempre tiene una interpretación humana directa.

Interpretar PCA requiere:

- revisar cargas de variables;
- medir varianza explicada;
- visualizar proyecciones;
- conectar componentes con el dominio.

Además, el signo de cada componente es arbitrario: si v_j es una dirección principal, $-v_j$ representa el mismo eje y produce scores con signo opuesto. Dos implementaciones pueden diferir en esos signos y tener idéntica reconstrucción. Las pruebas deben comparar el subespacio o la reconstrucción, no forzar una orientación.

Punto de control

Antes de usar PCA en un proyecto, responde:

1. ¿centraste con parámetros aprendidos en entrenamiento?
2. ¿cuánta varianza explican los componentes usados?
3. ¿la proyección se usa para visualizar, modelar o comprimir?
4. ¿qué interpretación no puedes afirmar?

Verificaciones seleccionadas

1. Si X tiene forma 500×64 y se usan $k = 2$ componentes, la proyección $Z = X_c V_k$ tiene forma 500×2 .
2. Si los primeros 10 componentes explican 85 % de la varianza, todavía se pierde 15 % de la variabilidad bajo esa medida.
3. Un scatterplot PCA 2D puede sugerir separación visual, pero no prueba causalidad ni garantiza buen desempeño predictivo.

Ejemplo resuelto: PCA dentro de un pipeline

Si PCA se usa antes de un clasificador, el centrado y los componentes deben aprenderse solo con entrenamiento. En scikit-learn, la forma segura es:

```
Pipeline([
    ("scaler", StandardScaler()),
    ("pca", PCA(n_components=10)),
    ("model", LogisticRegression())
])
```

En validación cruzada, cada fold aprende su propio `scaler` y su propio PCA con el train fold. Hacer PCA con todo el dataset antes de partir datos introduce leakage porque la proyección ya vio validación o test.

`StandardScaler` también cambia la geometría: PCA sobre variables estandarizadas equivale a trabajar sobre correlaciones, mientras PCA solo centrado conserva las unidades y puede quedar dominado por variables de gran varianza. La elección debe declararse.

Para explorar más

- **Extensión matemática:** reconstruye una matriz pequeña con rango 1 y compara el error de reconstrucción con el de rango 2.
- **Extensión computacional:** grafica varianza explicada acumulada y marca el punto donde agregar componentes deja de cambiar la interpretación.
- **Conexión con proyecto:** decide si PCA se usará para visualización, compresión, diagnóstico o como paso previo de modelado.

Revisión del capítulo

SVD factoriza una matriz en direcciones y magnitudes de variación. PCA usa esa estructura sobre datos centrados para construir proyecciones de baja dimensión que conservan tanta varianza como sea posible bajo el número de componentes elegido.

La forma de los objetos importa: V_k define direcciones, $Z = X_c V_k$ contiene scores y la reconstrucción aproxima los datos originales. La varianza explicada ayuda a elegir k , pero no convierte automáticamente los componentes en causas o conceptos de dominio.

PCA es una herramienta de compresión, visualización o preprocesamiento. Su uso exige declarar qué conserva, qué pierde y qué interpretación no está justificada por la proyección.

Términos clave

- **SVD:** factorización $X = U\Sigma V^\top$ que expone direcciones principales.
- **PCA:** proyección lineal que conserva la mayor varianza posible en pocas dimensiones.
- **Dato centrado:** matriz después de restar la media de cada variable.
- **Componente principal:** dirección lineal de alta varianza.
- **Varianza explicada:** proporción de variabilidad capturada por componentes.
- **Reconstrucción:** aproximación del dato original desde una proyección de baja dimensión.

Ejercicios

Preguntas conceptuales

1. Explique por qué PCA debe centrar los datos antes de calcular componentes.
2. ¿Por qué un componente principal no es automáticamente interpretable?

Problemas cuantitativos

3. Si X tiene forma (500, 64) y usamos $k=2$, ¿qué forma tiene la proyección PCA?
4. ¿Qué significa que los primeros 10 componentes expliquen 85 % de la varianza?

Práctica computacional

5. Implemente una proyección PCA usando SVD sobre datos centrados.
6. Calcule y grafique varianza explicada acumulada.

Interpretación y pensamiento crítico

7. Si dos componentes explican poca varianza pero separan visualmente grupos, ¿qué conclusión puede y no puede afirmar?

Profundización matemática y algorítmica

8. Use multiplicadores de Lagrange para derivar el problema de máxima varianza de la primera dirección principal.
9. Demuestre que el problema de k direcciones maximiza la traza $\text{tr}(V_k^\top \Sigma V_k)$.
10. Explique el argumento central de Eckart-Young y distinga optimalidad de reconstrucción de utilidad predictiva.
11. Compare costo y estabilidad de formar la covarianza frente a calcular la SVD directa de la matriz centrada.

Proyecto de cierre

12. Aplique PCA a un dataset de su proyecto o a uno pequeño generado para práctica, justifique k , muestre una proyección y escriba una advertencia de interpretación.

K-Means y clustering

Pregunta aplicada

Si no tenemos etiquetas, aún podemos preguntar:

¿hay grupos de observaciones con patrones similares?

K-Means busca particionar datos en k grupos representados por centroides.




Figura 23: K-Means alterna dos pasos: asignar cada punto al centroide más cercano y actualizar centroides como promedio de los puntos asignados.

Lectura de la figura. K-Means alterna entre asignar observaciones al centroide más cercano y mover cada centroide al promedio de su grupo. La interpretación aplicada viene después de validar que esa geometría tenga sentido.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. escribir la función objetivo de K-Means;
2. explicar los pasos de asignación y actualización;
3. interpretar inercia y silhouette sin absolutizarlos;
4. justificar el escalamiento antes de usar distancias euclídeas;
5. reconocer cuándo un cluster no debe traducirse directamente en una decisión.
6. demostrar por qué cada paso no aumenta la función objetivo;

7. distinguir convergencia a un punto fijo de optimalidad global y estimar el costo del algoritmo.

Distorsión poblacional y objetivo empírico

Para centros $C = (\mu_1, \dots, \mu_k)$, la distorsión poblacional es

$$R_P(C) = \mathbb{E}_{X \sim P} \left[\min_{1 \leq j \leq k} \|X - \mu_j\|_2^2 \right].$$

K-Means minimiza su versión empírica

$$\hat{R}_m(C) = \frac{1}{m} \sum_{i=1}^m \min_{1 \leq j \leq k} \|x_i - \mu_j\|_2^2.$$

`inertia_` es $m\hat{R}_m(C)$ en la escala ajustada. Un valor bajo demuestra buena compactación de la muestra para ese k ; no prueba que existan clases naturales en la población.

Hay dos fuentes de variación diferentes:

- **inicialización algorítmica:** distintos centros iniciales pueden llegar a mínimos locales diferentes para el mismo dataset;
- **variación muestral:** otro conjunto de observaciones puede producir otra partición aunque el algoritmo encuentre su mejor mínimo empírico.

Una evaluación de estabilidad debe repetir semillas y remuestrear unidades independientes. Repetir solo `n_init` estudia optimización; no estudia estabilidad poblacional.

Función objetivo

Con indicadores $r_{ij} \in \{0, 1\}$ y $\sum_j r_{ij} = 1$, K-Means minimiza

$$J(R, C) = \sum_{i=1}^m \sum_{j=1}^k r_{ij} \|x_i - \mu_j\|_2^2.$$

La representación separa dos bloques de variables:

- $R = (r_{ij})$ contiene asignaciones discretas;
- $C = (\mu_1, \dots, \mu_k)$ contiene centroides continuos.

Algoritmo

1. Inicializar centroides.
2. Asignar cada punto al centroide más cercano.
3. Recalcular cada centroide como promedio del grupo.
4. Repetir hasta convergencia.

La frase «hasta convergencia» necesita una regla: ausencia de cambios en las asignaciones, desplazamiento máximo de centroides menor que una tolerancia, reducción de inercia menor que una tolerancia o número máximo de iteraciones. También debe definirse qué ocurre con empates y clusters vacíos.

Por qué la inercia no aumenta

Con centroides fijos, cada fila r_i aparece solo en

$$\sum_{j=1}^k r_{ij} \|x_i - \mu_j\|^2.$$

Asignar x_i al centroide más cercano minimiza ese término entre todas las asignaciones posibles. Por tanto, el paso de asignación no aumenta J .

Con asignaciones fijas, cada centroide resuelve un problema independiente:

$$\min_{\mu_j} \sum_{i:r_{ij}=1} \|x_i - \mu_j\|^2.$$

Como se deriva más adelante, su minimizador es el promedio del cluster. El paso de actualización tampoco aumenta J . La secuencia de inercias es no creciente y está acotada inferiormente por cero.

La monotonía implica que la secuencia de valores de J converge. Para concluir terminación finita de las asignaciones hace falta algo más: que todo cambio de asignación reduzca J estrictamente. Esto ocurre, por ejemplo, cuando no hay empates de distancia y ningún cluster queda vacío. Como solo hay un número finito de asignaciones, bajo esas condiciones el algoritmo alcanza una que ya no cambia. Con empates o degeneraciones puede haber pasos de costo idéntico; una implementación debe fijar desempate, tolerancia y número máximo de iteraciones.

Descenso por bloques de Lloyd. Cada iteración completa de asignación y actualización no aumenta la función objetivo de K-Means. Si todo cambio de asignación produce descenso estricto y no aparecen clusters vacíos, Lloyd termina en un punto fijo después de un número finito de iteraciones. Ese punto no tiene por qué ser un óptimo global.

K-Means++ escoge centros iniciales favoreciendo puntos alejados de los ya seleccionados. Reduce la probabilidad de una inicialización muy mala, pero no elimina mínimos locales. `n_init` ejecuta varias inicializaciones y conserva la de menor inercia.

Inertia

inertia es la suma de distancias cuadradas dentro de clusters. La mejor inertia alcanzable no aumenta al incrementar k : una solución con $k + 1$ centros puede reproducir una de k .

Por eso menor inertia no basta para elegir una segmentación:

- favorece valores grandes de k ;
- no está normalizada;
- puede favorecer clusters poco interpretables.

Silhouette score

Para una observación:

$$s = \frac{b - a}{\max(a, b)}.$$

Donde:

- a : distancia media al propio cluster;
- b : distancia media al cluster vecino más cercano.

Valores cercanos a 1 sugieren separación; valores cercanos a 0 sugieren solapamiento y valores negativos indican que otra asignación puede quedar más cerca. Silhouette requiere al menos dos clusters y menos clusters que observaciones.

Ejemplo resuelto: por qué escalar cambia clusters

Supón dos variables: ingreso mensual en pesos y número de visitas a una página. Dos observaciones son:

$$x_1 = (5,000,000, 10), \quad x_2 = (5,100,000, 80).$$

La diferencia en ingreso es 100,000, mientras la diferencia en visitas es 70. En distancia euclídea sin escalar, el ingreso domina casi todo:

$$\sqrt{100000^2 + 70^2} \approx 100000.$$

K-Means tenderá a agrupar por ingreso aunque visitas sea más relevante para el uso posterior. Después de estandarizar, cada variable se mide en desviaciones estándar. Esto elimina la dominancia causada únicamente por unidades, pero no demuestra que todas las variables deban tener el mismo peso.

Ejemplo resuelto: asignación a centroides

Supón dos centroides en una dimensión:

$$\mu_1 = 2, \quad \mu_2 = 8.$$

Para una observación $x = 5$:

$$|5 - 2| = 3, \quad |5 - 8| = 3.$$

La observación está empatada. En implementación debe haber una regla de desempate. Este ejemplo muestra que K-Means es geométrico: asigna por distancia, no por significado de negocio.

Ejemplo resuelto: una iteración completa

Supón cuatro puntos en una dimensión:

$$x = (1, 2, 8, 10)$$

y dos centroides iniciales:

$$\mu_1 = 1, \quad \mu_2 = 10.$$

Paso 1: asignar puntos.

Punto	Distancia a μ_1	Distancia a μ_2	Cluster
1	0	9	1
2	1	8	1
8	7	2	2
10	9	0	2

La inercia inicial con estas asignaciones es:

$$(1 - 1)^2 + (2 - 1)^2 + (8 - 10)^2 + (10 - 10)^2 = 5.$$

Paso 2: actualizar centroides.

$$\mu_1^{nuevo} = \frac{1 + 2}{2} = 1.5, \quad \mu_2^{nuevo} = \frac{8 + 10}{2} = 9.$$

Con los nuevos centroides, la inercia para las mismas asignaciones es:

$$(1 - 1.5)^2 + (2 - 1.5)^2 + (8 - 9)^2 + (10 - 9)^2 = 2.5.$$

La inercia bajó, pero eso no prueba que $k = 2$ sea la mejor decisión aplicada. Solo muestra que la actualización mejoró el objetivo geométrico de K-Means.

Derivación guiada: por qué el centroide es el promedio

Para un cluster con puntos $x_1, \dots, x_m$, K-Means escoge un centroide μ que minimiza:

$$\sum_{i=1}^m \|x_i - \mu\|_2^2.$$

En una dimensión, derivar respecto a μ da:

$$\frac{d}{d\mu} \sum_{i=1}^m (x_i - \mu)^2 = -2 \sum_{i=1}^m (x_i - \mu).$$

Igualando a cero:

$$\sum_{i=1}^m x_i - m\mu = 0 \quad \Rightarrow \quad \mu = \frac{1}{m} \sum_{i=1}^m x_i.$$

En varias dimensiones ocurre componente a componente. Por eso la actualización del centroide es el promedio de los puntos asignados.

Complejidad y casos degenerados

Calcular las distancias de m puntos en $\mathbb{R}^p$ a k centroides cuesta $O(mkp)$ por iteración. Actualizar centroides cuesta $O(mp)$. Con T iteraciones y s inicializaciones, el costo dominante es

$$O(sTmkp).$$

Una implementación vectorizada puede almacenar una matriz de distancias $m \times k$, con memoria $O(mk)$; también puede procesar bloques para reducirla.

Un cluster vacío no tiene promedio. Las implementaciones deben conservar el centro anterior, reubicarlo o reinicializarlo según una regla explícita. Los empates también necesitan desempate determinista si se quiere reproducibilidad. Estas decisiones rara vez aparecen en la fórmula del objetivo, pero forman parte del algoritmo ejecutado.

Escalamiento

K-Means usa distancia euclídea. Por tanto, las escalas importan.

```
Pipeline([
    ("scaler", StandardScaler()),
    ("kmeans", KMeans(n_clusters=3))
])
```

Limitaciones

K-Means funciona mejor cuando los clusters son:

- aproximadamente esféricos;
- de tamaños comparables;
- separables por distancia euclídea.

Puede fallar con formas no convexas, densidades distintas o variables mal escaladas.

Caso longitudinal: clusters sintéticos

El archivo `clusters_sinteticos.csv` fue generado con tres centros compactos. Eso lo hace útil para aprender K-Means, pero también peligroso si se generaliza demasiado: favorece justo la geometría que K-Means prefiere.

Resultado	Uso
scatterplot escalado	inspección geométrica inicial
inertia por k	reducción de compactación
silhouette	separación relativa
tamaños de clusters	detectar grupos diminutos
estabilidad por semilla	revisar sensibilidad

Si $k = 3$ gana en este dataset, no significa que “siempre hay tres segmentos”. Significa que, bajo esta geometría sintética y esta escala, tres centroides resumen bien la nube de puntos.

Estabilidad por inicialización

K-Means puede converger a soluciones distintas si cambian los centroides iniciales. Por eso un reporte debe fijar `random_state` y usar varias inicializaciones (`n_init`). Si dos corridas con el mismo k producen centroides muy distintos o clusters con tamaños incompatibles, la segmentación no es estable.

La estabilidad puede medirse comparando asignaciones con una cantidad invariante a permutaciones de etiquetas, como adjusted Rand index, o emparejando centroides. No convierte los clusters en categorías reales; solo indica que el algoritmo encuentra una partición parecida bajo variaciones de inicialización.

Punto de control

Antes de reportar clusters, verifica:

1. ¿las variables están en escalas comparables?
2. ¿probaste más de un k ?
3. ¿los clusters son interpretables con variables originales?
4. ¿hay un cluster demasiado grande o demasiado pequeño?
5. ¿qué decisión concreta usaría esta segmentación?

Verificaciones seleccionadas

1. El óptimo global de inercia es no creciente con k ; por eso no basta para elegir el número de clusters. Una corrida local mal inicializada puede no mostrar la monotonía esperada.
2. Si dos variables tienen escalas muy distintas, K-Means puede agrupar por la variable de mayor escala aunque no sea la más relevante.
3. Un cluster no es una categoría real hasta que se interpreta con variables originales y contexto de decisión.

Ejemplo resuelto: elegir k con información incompleta

Supón:

k	Inertia	Silhouette
2	420	0.48
3	260	0.55
4	210	0.51

La inercia baja de 3 a 4, pero silhouette cae. Puede elegirse $k = 3$ como representación candidata, siempre que los clusters tengan tamaño razonable y puedan describirse con variables originales. La tabla no prueba que existan tres grupos naturales; solo apoya que $k = 3$ es una representación útil bajo esta geometría.

Para explorar más

- **Extensión matemática:** ejecuta una iteración de K-Means a mano con cuatro puntos y dos centroides iniciales distintos.
- **Extensión computacional:** compara inercia y silueta para varios valores de k , usando la misma escala de variables.
- **Conexión con proyecto:** describe qué significaría cada cluster para una decisión real y qué variables dominan esa interpretación.

Revisión del capítulo

K-Means busca centroides que reduzcan la suma de distancias cuadráticas dentro de clusters. El algoritmo alterna asignación de puntos al centroide más cercano y actualización de centroides como promedios.

La inercia óptima no aumenta cuando crece k , por lo que no puede usarse sola como prueba de calidad. Silhouette aporta otra señal, pero también depende de geometría, escala y estructura de los datos.

Una segmentación requiere una escala justificada, varias inicializaciones, descripción con variables originales y cautela aplicada. Un cluster matemático no es automáticamente un grupo útil para una acción ni una categoría real de dominio.

Términos clave

- **Clustering:** agrupación no supervisada de observaciones.
- **Centroide:** punto representativo de un cluster.
- **Inercia:** suma de distancias cuadradas a centroides.
- **Silhouette:** métrica que compara cercanía al cluster propio frente a otros.
- **Escalamiento:** transformación necesaria cuando las variables tienen unidades distintas.
- **Segmentación:** interpretación aplicada de grupos, que requiere validación de negocio o dominio.

Ejercicios

Preguntas conceptuales

1. Explique por qué la inercia óptima no aumenta cuando crece k .
2. ¿Por qué K-Means debe usarse con escalamiento en variables de unidades distintas?

Problemas cuantitativos

3. Asigne tres puntos en una dimensión a dos centroides dados y calcule inercia.
4. Si un cluster contiene 90 % de las observaciones, ¿qué revisaría antes de reportarlo?

Práctica computacional

5. Ajuste K-Means para varios valores de k y reporte inercia y silhouette.
6. Construya un pipeline con escalamiento y K-Means.

Interpretación y pensamiento crítico

7. Proponga una situación donde clusters matemáticamente separados no deberían convertirse directamente en una decisión aplicada.
8. ¿Qué resultados usaría para nombrar un cluster sin caer en sobreinterpretación?

Profundización matemática y algorítmica

9. Demuestre que el paso de asignación y el paso de actualización no aumentan la función objetivo.
10. Explique por qué monotonía de la inercia no implica alcanzar el mínimo global.
11. Calcule el costo asintótico para T iteraciones, s inicializaciones, m observaciones, k clusters y p variables.
12. Proponga reglas reproducibles para un empate y para un cluster vacío.

Proyecto de cierre

13. Genere una segmentación con K-Means, describa cada cluster usando variables originales y escriba una recomendación cautelosa de uso.

Recomendación básica y estructura latente

Pregunta aplicada

Si sabemos qué ítems han gustado o sido usados por ciertos usuarios, podemos preguntar:

¿qué ítems son similares y qué recomendaríamos a un usuario?

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. construir una matriz usuario-ítem simple;
2. calcular e interpretar similitud coseno;
3. describir una recomendación item-item;
4. explicar la idea de factores latentes por SVD;
5. reconocer problemas de popularidad, cold start y sesgo.
6. formular una factorización regularizada sobre entradas observadas y derivar sus gradientes;
7. estimar costo, memoria y límites de identificación de los factores.

El mecanismo de observación no es neutral

Sea R_{ui} la preferencia potencial de un usuario u por un ítem i y $O_{ui} \in \{0, 1\}$ el indicador de que esa interacción fue observada. El dataset contiene principalmente valores con $O_{ui} = 1$. En plataformas reales,

$$\mathbb{P}(O_{ui} = 1 \mid R_{ui}, u, i)$$

no suele ser constante: exposición previa, posición, popularidad y políticas del sistema afectan qué llega a registrarse. Por tanto, la distribución observada

$$P(R_{ui} \mid O_{ui} = 1)$$

puede diferir de la distribución de preferencias sobre todos los pares usuario-ítem. Tratar faltantes como desagrado supone un mecanismo que rara vez está justificado.

Riesgo offline y utilidad de uso

Una métrica offline estima desempeño bajo el protocolo que generó sus pares de evaluación. La utilidad relevante sería una esperanza bajo exposición futura,

$$\mathbb{E}_{(u,i) \sim P_{\text{uso}}} [U(u, i, \text{recomendar}(u))],$$

que no se identifica automáticamente con precisión@k o recall@k histórico. Esta brecha explica por qué una comparación offline no demuestra efecto causal sobre satisfacción, diversidad o descubrimiento.

Matriz usuario-ítem

Una matriz R puede representar:

- filas: usuarios;
- columnas: ítems;
- entradas: interacción, rating, compra, vista o preferencia.

Ejemplo:

$$R_{ui} = 1$$

si el usuario u interactuó con el ítem i .

Similitud coseno

Para dos ítems representados por vectores x y y :

$$\cos(x, y) = \frac{x^\top y}{\|x\| \|y\|}.$$

La similitud coseno compara dirección más que magnitud.

Ejemplo resuelto: similitud coseno

Supón dos ítems con vectores de interacción:

$$x = (1, 1, 0, 0), \quad y = (1, 0, 1, 0).$$

Entonces:

$$x^\top y = 1, \quad \|x\| = \sqrt{2}, \quad \|y\| = \sqrt{2}.$$

Por tanto:

$$\cos(x, y) = \frac{1}{2} = 0.5.$$

La interpretación es moderada similitud: comparten un usuario, pero cada uno tiene otro usuario distinto.

Derivación guiada: qué ignora la similitud coseno

La similitud coseno normaliza por las normas:

$$\cos(x, y) = \frac{x^\top y}{\|x\| \|y\|}.$$

Eso significa que dos ítems pueden tener similitud alta si apuntan en dirección parecida, aunque uno tenga muchas más interacciones que el otro. Esta propiedad puede ser útil para reducir el sesgo por popularidad, pero no lo elimina. Si un ítem aparece en casi todos los perfiles, puede seguir dominando rankings por cobertura y disponibilidad de datos.

La lectura de una similitud debe incluir tres preguntas: qué usuarios comparten los ítems, cuántas interacciones sustentan el cálculo y qué ítems quedan invisibles por falta de datos.

Recomendación item-item

Flujo básico:

1. Construir matriz usuario-ítem.
2. Calcular similitud entre ítems.
3. Para un ítem semilla, buscar ítems similares.
4. Excluir ítems ya vistos si se recomienda a un usuario.

Ejemplo resuelto: recomendación item-item

Supón la siguiente matriz binaria de interacción:

Usuario	A	B	C	D
$u1$	1	1	0	0
$u2$	1	1	1	0
$u3$	0	0	1	1
$u4$	0	1	0	1

Los vectores de ítems son:

$$A = (1, 1, 0, 0), \quad B = (1, 1, 0, 1), \quad C = (0, 1, 1, 0), \quad D = (0, 0, 1, 1).$$

Para recomendar a partir del ítem A , calculamos similitudes:

$$\cos(A, B) = \frac{2}{\sqrt{2}\sqrt{3}} \approx 0.816,$$

$$\cos(A, C) = \frac{1}{\sqrt{2}\sqrt{2}} = 0.5, \quad \cos(A, D) = 0.$$

Si el usuario semilla interactuó con A , el ítem más similar es B . Si ese usuario ya vio B , el siguiente candidato por similitud sería C . La recomendación debe excluir ítems ya vistos y declarar que esta regla no resuelve cold start ni sesgo de popularidad.

Evaluación offline: Precision@k

Una evaluación mínima de recomendación separa algunas interacciones conocidas como si fueran futuras. Luego pregunta si el recomendador las recupera entre sus primeras sugerencias.

Si el orden temporal está disponible, se ocultan interacciones posteriores y el modelo se ajusta solo con las anteriores. Un split aleatorio puede usar el futuro para explicar el pasado. Los usuarios evaluados deben conservar al menos una interacción de entrenamiento; los casos de cold start se reportan por separado.

Si para un usuario ocultamos los ítems relevantes $\{C, D\}$ y el sistema recomienda los tres primeros ítems:

$$[B, C, E],$$

entonces solo uno de los tres recomendados es relevante. La precisión en 3 es:

$$\text{Precision@3} = \frac{1}{3}.$$

Si además queremos saber cuántos relevantes recuperó:

$$\text{Recall}@3 = \frac{1}{2}.$$

Estas métricas no prueban satisfacción real. Solo verifican si el ranking recupera interacciones ocultas bajo una simulación offline. Un reporte debe decir qué se ocultó, cómo se partió el dato y qué usuarios o ítems quedaron sin recomendación.

Baseline de popularidad

Antes de celebrar un recomendador personalizado, compáralo contra una regla simple: recomendar los ítems más populares que el usuario no ha visto. La popularidad se calcula solo con entrenamiento. Este baseline suele ser fuerte porque muchos datasets tienen concentración de interacciones en pocos ítems.

Si el modelo latente no supera popularidad en Precision@k o cobertura, todavía no hay una mejora offline de personalización. Si lo supera, el reporte debe mostrar cuánto mejora y para qué grupos de usuarios. La personalización no se presume: se compara.

SVD para factores latentes

SVD puede aproximar:

$$R \approx U_k \Sigma_k V_k^T.$$

Recomendación: completar una matriz con estructura latente



Lectura: factores latentes explican patrones; la validacion decide si recomiendan bien.

Figura 24: Sistemas de recomendación: una matriz usuario-item incompleta se aproxima mediante factores latentes de usuarios e ítems; una calificación faltante se predice con un producto punto.

Lectura de la figura. La factorización representa usuarios e ítems en una baja dimensión compartida. Una recomendación es una predicción incompleta de la matriz, pero también una intervención que puede reforzar sesgos o popularidad.

Esto produce representaciones latentes de usuarios e ítems.

Esta igualdad requiere una advertencia. Una SVD directa trata cada entrada de la matriz numérica como observada; si se rellenan ratings faltantes con cero, se impone el supuesto de que “no observado” equivale a cero. Los métodos de factorización para recomendación suelen optimizar solo sobre entradas observadas o usar objetivos propios para retroalimentación implícita. Aquí la SVD introduce la geometría latente; no resuelve por sí sola el manejo de faltantes.

Factorización sobre entradas observadas

Sea Ω el conjunto de pares (u, i) para los que existe una interacción o rating. Asignamos a cada usuario un vector $p_u \in \mathbb{R}^k$ y a cada ítem un vector $q_i \in \mathbb{R}^k$. Un objetivo básico para ratings explícitos es

$$J(P, Q) = \frac{1}{2} \sum_{(u, i) \in \Omega} (R_{ui} - p_u^\top q_i)^2 + \frac{\lambda}{2} \left(\sum_u \|p_u\|^2 + \sum_i \|q_i\|^2 \right).$$

La suma recorre solo entradas observadas; no convierte faltantes en ceros. Si $e_{ui} = R_{ui} - p_u^\top q_i$, los gradientes son

$$\nabla_{p_u} J = - \sum_{i: (u, i) \in \Omega} e_{ui} q_i + \lambda p_u,$$

$$\nabla_{q_i} J = - \sum_{u: (u, i) \in \Omega} e_{ui} p_u + \lambda q_i.$$

Para obtener actualizaciones por interacción consistentes con este mismo objetivo, definimos los grados

$$d_u = |\{i : (u, i) \in \Omega\}|,$$

$$d_i = |\{u : (u, i) \in \Omega\}|.$$

La penalización puede distribuirse exactamente entre las interacciones:

$$J(P, Q) = \frac{1}{2} \sum_{(u,i) \in \Omega} \left[e_{ui}^2 + \frac{\lambda}{d_u} \|p_u\|^2 + \frac{\lambda}{d_i} \|q_i\|^2 \right].$$

Cada vector aparece en tantas sumas como indica su grado, de modo que esta expresión coincide con el objetivo global anterior. Una actualización SGD sobre un par observado usa entonces

$$\begin{aligned} p_u &\leftarrow p_u + \alpha \left(e_{ui} q_i - \frac{\lambda}{d_u} p_u \right), \\ q_i &\leftarrow q_i + \alpha \left(e_{ui} p_u^{\text{anterior}} - \frac{\lambda}{d_i} q_i \right). \end{aligned}$$

Se conserva p_u^{anterior} en la segunda expresión para que ambas actualizaciones correspondan al mismo gradiente. Usar λp_u y λq_i en cada interacción también es posible, pero corresponde a una penalización ponderada por los grados, no al objetivo global escrito arriba. También pueden añadirse un promedio global y sesgos de usuario e ítem; sin ellos, los factores deben explicar diferencias de nivel que no son necesariamente interacciones latentes.

Alternancia, costo e identificación

El objetivo no es conjuntamente convexo en (P, Q) , pero sí es cuadrático en un bloque cuando el otro queda fijo. Alternating least squares fija Q y resuelve un problema Ridge por usuario; luego fija P y resuelve uno por ítem. Cada paso no aumenta el objetivo si los subproblemas se resuelven exactamente, pero el resultado puede depender de la inicialización.

Una época SGD que recorre $|\Omega|$ interacciones cuesta $O(|\Omega|k)$ y almacena $O((n_{\text{usuarios}} + n_{\text{ítems}})k)$ parámetros. Esta estructura aprovecha dispersión: el costo depende de interacciones observadas, no del producto completo de usuarios por ítems.

Los factores no son únicos. Si A es invertible,

$$p_u^\top q_i = (A^\top p_u)^\top (A^{-1} q_i).$$

Por tanto, una coordenada latente aislada no tiene significado intrínseco. La regularización reduce parte de la indeterminación, pero las interpretaciones de «factor de acción», «factor de drama» o similares requieren evidencia externa. Lo identificable para el objetivo son principalmente los productos y rankings, no los nombres de los ejes.

Para retroalimentación implícita, una ausencia puede significar falta de exposición. Se usan objetivos ponderados, muestreo de negativos o pérdidas de ranking; el objetivo cuadrático anterior no debe trasladarse sin declarar ese cambio de modelo.

Caso longitudinal: interacciones de recomendación

El archivo `recomendacion_interacciones.csv` contiene usuarios, ítems y ratings ficticios. Su función es mostrar la lógica de una matriz usuario-item pequeña:

Resultado	Pregunta
matriz usuario-item	¿qué entradas se observaron y cuáles faltan?
promedio por ítem	¿hay sesgo de popularidad?
similitud item-item	¿qué ítems parecen cercanos?
cobertura	¿a cuántos usuarios/ítems puede recomendar?
evaluación offline	¿qué ratings ocultos se predicen?

Un recomendador puede producir rankings plausibles y aun así amplificar popularidad, ignorar ítems nuevos o recomendar sin diversidad. Por eso la pregunta aplicada no es solo “qué ítem tiene mayor puntaje”, sino “qué se omite y a quién afecta”.

Riesgos de recomendación

Los sistemas de recomendación pueden:

- reforzar popularidad;
- encerrar usuarios en burbujas;
- amplificar sesgos;
- optimizar interacción sin optimizar bienestar;
- fallar con usuarios o ítems nuevos.

Punto de control

Antes de recomendar, responde:

1. ¿la similitud refleja preferencia o solo popularidad?
2. ¿se excluyen ítems ya vistos?
3. ¿qué ocurre con usuarios nuevos?
4. ¿qué sesgo puede amplificarse?

Verificaciones seleccionadas

1. Una entrada faltante en la matriz usuario-item no significa rating cero; significa no observado.
2. La similitud coseno alta entre dos ítems no prueba que sean equivalentes; solo indica patrones de interacción parecidos bajo los datos disponibles.
3. Un ranking sin cobertura puede verse preciso para usuarios frecuentes y fallar para usuarios o ítems con pocas interacciones.

Ejemplo resuelto: cobertura mínima

Supón un recomendador que produce al menos una recomendación para 70 de 100 usuarios y cubre 12 de 50 ítems disponibles. Entonces:

$$\text{cobertura de usuarios} = 70/100 = 70\%, \quad \text{cobertura de ítems} = 12/50 = 24\%.$$

Aunque las recomendaciones visibles parezcan razonables, el sistema deja sin recomendación a 30 % de usuarios y concentra exposición en pocos ítems. Esos conteos deben aparecer antes de afirmar que el recomendador funciona bien.

Para explorar más

- **Extensión matemática:** calcula una similitud coseno item-item y compara la recomendación con una basada en producto punto.
- **Extensión computacional:** oculta algunas interacciones conocidas y mide si el sistema las recupera entre las mejores recomendaciones.
- **Conexión con proyecto:** explica qué sesgo de popularidad podría aparecer y cómo lo reportarías sin exagerar la calidad del sistema.

Revisión del capítulo

Un sistema de recomendación básico parte de una matriz usuario-ítem y mide similitudes o factores latentes para sugerir elementos no observados. La similitud coseno compara dirección de interacción y puede mitigar parcialmente diferencias de escala.

Las recomendaciones item-item son útiles porque se pueden explicar a partir de ítems similares, pero siguen dependiendo del historial observado. La idea de factores latentes resume usuarios e ítems en representaciones de baja dimensión.

El límite central es que el comportamiento pasado no define por completo la preferencia futura. Cold start, popularidad y sesgo deben declararse antes de presentar una recomendación como útil o justa.

Términos clave

- **Matriz usuario-ítem:** tabla que representa interacciones entre usuarios e ítems.
- **Similitud coseno:** medida angular entre vectores de interacción.
- **Recomendación item-item:** recomendación basada en ítems similares a uno observado.
- **Factor latente:** representación de baja dimensión aprendida de patrones de interacción.
- **Cold start:** dificultad para recomendar a usuarios o ítems sin historial.
- **Bucle de retroalimentación:** refuerzo de patrones pasados por recomendaciones futuras.

Ejercicios

Preguntas conceptuales

1. Explique por qué similitud coseno puede ser útil cuando algunos ítems son mucho más populares que otros.
2. ¿Qué problema aparece para recomendar a un usuario nuevo sin historial?

Problemas cuantitativos

3. Calcule similitud coseno entre dos vectores binarios de interacción.
4. Dada una matriz usuario-ítem pequeña, identifique los dos ítems más similares.

Práctica computacional

5. Implemente una función de similitud coseno para matrices.
6. Construya una recomendación item-item simple excluyendo ítems ya vistos.

Interpretación y pensamiento crítico

7. Proponga una limitación ética de un sistema de recomendación basado solo en comportamiento pasado.
8. ¿Cómo detectaría si el recomendador solo amplifica popularidad?

Profundización matemática y algorítmica

9. Formule el objetivo regularizado de factorización sobre Ω y derive los gradientes respecto a un vector de usuario y uno de ítem.
10. Escriba una actualización SGD para un rating observado, distribuya la regularización mediante d_u y d_i , y explique por qué debe conservarse el valor anterior de uno de los factores.
11. Compare el costo de una época dispersa $O(|\Omega|k)$ con operar sobre toda la matriz usuario-ítem.
12. Demuestre la indeterminación de los factores bajo un cambio invertible de base y explique qué limita su interpretación.

Proyecto de cierre

13. Diseñe un recomendador item-item mínimo, reporte tres recomendaciones y escriba una advertencia sobre cold start, popularidad o sesgo.

Ejercicios integradores: aprendizaje no supervisado

En aprendizaje no supervisado no hay una etiqueta que valide automáticamente el significado. Por eso estos ejercicios combinan cálculo, visualización, estabilidad e interpretación prudente.

Resultados de práctica

Al terminar este banco deberías poder:

1. calcular formas de SVD y proyecciones PCA;
2. explicar qué sí y qué no justifica una reducción de dimensión;
3. usar inercia y silhouette como resúmenes geométricos limitados;
4. construir una recomendación item-item mínima;
5. separar estructura matemática de interpretación aplicada.

Mapa del banco

Bloque	Qué comprueba
A	PCA, SVD, proyección e interpretación cautelosa
B	K-Means, selección de k y diagnóstico geométrico
C	similitud, recomendación y sesgos de interacción

Antes de responder

Para cada ejercicio, identifica:

1. qué estructura matemática estás usando;
2. qué cantidad se puede calcular;
3. qué conclusión sí está permitida;
4. qué conclusión sería una sobreinterpretación.

Columna probabilística del módulo

P1. Covarianza y SVD. Demuestre que si $X_c = U\Sigma_s V^\top$, entonces $X_c^\top X_c/m = V\Sigma_s^2 V^\top/m$. Identifique autovalores y autovectores de la covarianza empírica.

P2. Dirección poblacional. Explique la diferencia entre maximizar $\text{Var}(v^\top X)$ y maximizar $\|X_c v\|^2/m$ para una muestra observada.

P3. Estabilidad PCA. Proponga un bootstrap para comparar subespacios de dos componentes. Explique por qué comparar signos de vectores no es suficiente.

P4. Distorsión. Distinga $R_P(C)$, $\widehat{R}_m(C)$ e `inertia_`. Indique cuál calcula `KMeans` y cuál interesa para nuevas observaciones.

P5. Dos estabildades. Diseñe un experimento que separe variación por inicialización de K-Means y variación por remuestreo del dataset.

P6. Exposición. Construya un ejemplo donde un ítem popular tenga más interacciones observadas aunque no tenga mayor preferencia promedio. Identifique la variable O_{ui} y el sesgo inducido.

P7. Evaluación offline. Explique qué distribución representa un test creado ocultando aleatoriamente interacciones históricas y qué escenarios de uso no representa.

Bloque A: PCA

A1. Derive las formas de U , Σ y $V^\top$ si X_c tiene forma $(100, 20)$.

A2. Implemente mentalmente los pasos de PCA desde cero: centrar, SVD, seleccionar componentes, proyectar.

A3. Explique por qué un componente con alta varianza no necesariamente es causal ni justo para tomar decisiones.

A4. Use multiplicadores de Lagrange para obtener la ecuación de autovectores del problema de máxima varianza.

A5. Explique por qué la SVD truncada es óptima para reconstrucción en norma de Frobenius y por qué eso no la hace óptima para una tarea supervisada posterior.

A6. Compare costo y condicionamiento de formar $X_c^\top X_c$ frente a calcular una SVD directa o truncada.

Bloque B: K-Means

B1. Escriba la función objetivo de K-Means y explique cada término.

B2. Compare `inertia` y `silhouette` como criterios geométricos para elegir k .

B3. Proponga un diagnóstico si K-Means produce un cluster con 95 % de los datos.

B4. Demuestre que los dos pasos de Lloyd no aumentan la inercia y explique por qué el resultado sigue dependiendo de la inicialización.

B5. Derive el costo $O(sTmkp)$ y proponga una regla para clusters vacíos.

Bloque C: recomendación

C1. Calcule similitud coseno entre dos vectores binarios simples.

C2. Explique cómo excluir ítems ya vistos por el usuario.

C3. ¿Qué diferencia hay entre recomendar por similitud de contenido y por comportamiento colaborativo?

C4. Formule una factorización regularizada sobre el conjunto observado Ω y derive los gradientes de usuario e ítem.

C5. Compare una época SGD de costo $O(|\Omega|k)$ con una SVD sobre una matriz densa rellena con ceros. Identifique el supuesto estadístico que cambia.

C6. Demuestre que una transformación invertible de la base puede conservar los productos usuario-ítem y discuta por qué los factores no tienen nombres intrínsecos.

Respuestas seleccionadas

A1. En SVD reducida, una forma usual es $U \in \mathbb{R}^{100 \times 20}$, $\Sigma \in \mathbb{R}^{20 \times 20}$ y $V^\top \in \mathbb{R}^{20 \times 20}$. En SVD completa, U podría tener forma 100×100 .

A3. Alta varianza significa que una dirección explica dispersión de los datos, no que represente una causa, una variable ética ni una regla justa de decisión.

B3. Un cluster con 95 % de los datos puede indicar k inadecuado, variables mal escaladas, ausencia de estructura separable o outliers que deforman centroides. Antes de interpretar, conviene revisar escalamiento, probar otros k y visualizar variables originales.

C3. La similitud de contenido compara atributos de los ítems. La similitud colaborativa compara patrones de interacción de usuarios. La segunda puede capturar comportamiento colectivo, pero también amplificar popularidad y sesgos históricos.

Parte VI: Reproducibilidad y comunicación

Un análisis no termina cuando aparece una métrica. Para que el resultado pueda examinarse, otra persona debe conocer los datos utilizados, las transformaciones, el código, el entorno y los parámetros que produjeron cada cifra. La reproducibilidad convierte esos elementos en parte del argumento, no en anexos opcionales.

Esta parte reúne primero las conexiones matemáticas entre los modelos estudiados: qué distribución o estructura intentan aproximar, qué objetivo empírico calculan y qué fuentes de variación permanecen. Después presenta un paquete reproducible mínimo y discute cómo registrar artefactos, versiones y resultados sin confundir una semilla fija con replicación estadística.

Los capítulos finales se ocupan de la escritura y la exposición oral. Una conclusión técnica debe distinguir resultados observados, interpretación y alcance; una figura debe permitir reconstruir la comparación que presenta; y una defensa debe hacer visibles tanto las decisiones tomadas como las afirmaciones que los datos no permiten sostener.

Reproducibilidad: que otra persona pueda reconstruir el resultado




Figura 25: Reproducibilidad: datos, código, entorno y parámetros alimentan una corrida que produce métricas, artefactos y un manifiesto verificable.

La figura muestra esa trazabilidad como un flujo: datos, código, entorno y parámetros producen una corrida; la corrida genera métricas y artefactos; un manifiesto registra cómo volver a encontrarlos y verificarlos.

Síntesis conceptual: redes, estrategia y no supervisado

Pregunta aplicada

Una pregunta del parcial puede comenzar con logits, pasar por una tabla de validación y terminar con un slice que falla. ¿Cómo se organiza una respuesta sin mezclar esos objetos?

Alcance

Este capítulo prepara el Parcial 2 e integra tres bloques:

- redes neuronales desde primeros principios;
- estrategia ML y diagnóstico;
- aprendizaje no supervisado.

El examen evalúa cálculos, implementación y lectura de resultados. Recordar el nombre de una técnica no reemplaza ninguno de esos tres componentes.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. conectar forward/backward de redes con diagnóstico de entrenamiento;
2. explicar cómo métrica, baseline y partición sostienen una comparación;
3. interpretar PCA, K-Means o recomendación como descripciones estructurales;
4. responder preguntas integradoras sin depender de memoria aislada;
5. escribir una recomendación con resultado, lectura, siguiente comprobación y límite.

Mapa probabilístico de síntesis

Todo método del curso puede ubicarse en cuatro niveles:

Nivel	Pregunta	Ejemplo
población	¿qué cantidad define P ?	$\mathbb{E}[Y \mid X = x]$, $P(Y = k \mid X = x)$, Σ

Nivel	Pregunta	Ejemplo
muestra	¿qué observaciones se realizaron?	$D_m \sim P^m$ o muestra dependiente
objetivo empírico	¿qué promedio o geometría se calcula?	MSE, CE, distorsión, covarianza empírica
algoritmo	¿cómo se obtiene una solución?	<code>lstsq</code> , <code>backprop</code> , Adam, SVD, K-Means

Confundir niveles produce errores típicos: tratar una probabilidad estimada como verdadera, una métrica como riesgo conocido, una componente empírica como dirección poblacional fija o una semilla reproducible como estabilidad estadística.

Principio de riesgo empírico. Regresión, clasificación y redes minimizan promedios de pérdidas sobre una muestra. Esa operación es una aproximación al riesgo poblacional solo bajo supuestos sobre muestreo, dependencia y comparabilidad con el uso. La corrección del algoritmo no demuestra esos supuestos.

Mapa de contenidos

Bloque	Pregunta central	Qué debe aparecer
Redes	¿Cómo se calculan predicciones y gradientes?	dimensiones, forward, pérdida y actualización
Estrategia ML	¿Cómo comparo modelos sin usar test para escoger?	baseline, partición, métrica, validación y análisis de errores
No supervisado	¿Qué estructura encontré sin etiqueta?	varianza, reconstrucción, separación, estabilidad e interpretación

Redes neuronales

Forward propagation. Para una capa densa:

$$Z^{[\ell]} = A^{[\ell-1]}W^{[\ell]} + b^{[\ell]}, \quad A^{[\ell]} = g(Z^{[\ell]}).$$

Las dimensiones son parte del razonamiento. Si $A^{[\ell-1]} \in \mathbb{R}^{m \times d}$ y $W^{[\ell]} \in \mathbb{R}^{d \times h}$, entonces $Z^{[\ell]} \in \mathbb{R}^{m \times h}$.

Softmax y entropía cruzada

Para clasificación multiclase, softmax convierte logits en probabilidades:

$$\text{softmax}(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}.$$

La implementación estable resta el máximo por fila antes de exponenciar. Esto no cambia las probabilidades, pero evita overflow.

Diagnóstico de modelos

Una comparación evaluable requiere:

1. baseline explícito;
2. métrica alineada con el costo de error;
3. particiones sin leakage;
4. validación o estimación de variabilidad;
5. análisis de errores;
6. conclusión con el alcance de los resultados disponibles.

Un puntaje alto no basta si no sabemos contra qué baseline compite, qué variabilidad tiene y dónde falla.

No supervisado

En PCA se decide cuántos componentes retener usando varias señales:

- varianza explicada acumulada;
- error de reconstrucción;
- interpretabilidad;
- utilidad para la tarea posterior.

En K-Means se evita elegir k solo por inercia porque inercia disminuye al aumentar k . Silhouette ayuda, pero también tiene sesgos geométricos: favorece grupos compactos y separados.

Forma del Parcial 2

Parte	Tipo	Propósito
Notebook autograded, 70 %	implementación y resultados numéricos	verificar funciones y cálculos
Preguntas estructuradas, 20 %	fórmulas, selección, respuestas numéricas	comprobar conceptos con respuesta cerrada

Parte	Tipo	Propósito
Explicación breve, 10 %	rúbrica 0/1/2 escalada a 10	leer un resultado y acotar su uso

Regla de preparación

Una respuesta breve puede seguir esta estructura:

`resultado -> lectura -> siguiente comprobación -> límite`

Cómo leer una pregunta integradora

Una pregunta integradora suele mezclar cálculo, implementación y decisión. Antes de responder, separa cuatro capas:

Capa	Pregunta que debes responder
Objeto matemático	¿qué función, matriz, métrica o pérdida aparece?
Procedimiento	¿qué algoritmo o transformación se aplica?
Resultado	¿qué número, curva, tabla o slice sostiene la afirmación?
Alcance	¿qué comprobación sigue y qué no puede afirmarse todavía?

Por ejemplo, si una pregunta combina PCA y clasificación, no basta con decir que PCA “mejora” el modelo. Debes decir si PCA se ajustó dentro del pipeline, cuánta varianza conserva, cómo cambia la métrica de validación y qué interpretación no puede hacerse de los componentes. Esta lectura evita respuestas largas pero desordenadas.

Ejemplo resuelto: softmax estable en síntesis

Supón que una red produce logits:

$$z = (1000, 1001, 1002).$$

Calcular e^{1002} directamente puede producir overflow. Restamos el máximo:

$$z - \max(z) = (-2, -1, 0).$$

Entonces:

$$\text{softmax}(z) = \frac{(e^{-2}, e^{-1}, 1)}{e^{-2} + e^{-1} + 1}.$$

Como $e^{-2} \approx 0.135$ y $e^{-1} \approx 0.368$, la suma es aproximadamente 1.503. Por tanto:

$$\text{softmax}(z) \approx (0.090, 0.245, 0.665).$$

La respuesta integradora debe decir dos cosas: la resta del máximo no cambia las probabilidades y evita un problema numérico. Si la clase correcta es la tercera, la pérdida de esa observación sería $-\log(0.665) \approx 0.408$.

Ejemplo resuelto: estructura no supervisada dentro de una respuesta

Supón que PCA muestra separación visual entre dos grupos y K-Means produce dos clusters con silhouette razonable. Son dos resúmenes de la misma geometría, no dos pruebas independientes. Pueden sugerir estructura, pero no prueban que los grupos correspondan a clases útiles para una decisión supervisada.

Una respuesta integradora adecuada sería:

Resultado: PCA y K-Means resumen la nube en dos grupos geométricos.
Lectura: puede haber estructura de baja dimensión, pero no hay etiqueta ni costo de error.
Comprobación: tratar los clusters como hipótesis exploratoria y compararlos con variables de d
Límite: no afirmar que los clusters son segmentos reales ni que predicen una decisión.

La síntesis del curso exige separar un resultado exploratorio de una evaluación predictiva. Un método no supervisado puede abrir una pregunta; no siempre puede cerrarla.

Ejemplo resuelto: respuesta integradora

Caso: una red mejora accuracy global, pero el análisis por slice muestra caída fuerte en datos recientes.

Respuesta posible:

Resultado: la accuracy global mejora, pero el slice reciente cae.
Lectura: el patrón es compatible con data mismatch temporal.
Comprobación: validar con partición temporal, revisar variables y medir el cambio por periodo.
Límite: no recomendar despliegue si el uso real se parece al slice reciente.

La clave es no quedarse en “mejoró la métrica”.

Caso longitudinal: respuesta integradora

Retoma `clasificacion_binaria_sintetica.csv`. Una respuesta integradora no debe decir solo “el modelo regularizado ganó”. Debe conectar varias capas del análisis:

Pieza	Resultado o registro esperado
modelo	logística regularizada o baseline comparable
validación	media y variabilidad de F1/recall
error analysis	desempeño por <code>slice</code>
reproducibilidad	semilla, partición, pipeline y manifest
comunicación	recomendación y límite

Una respuesta de parcial aceptable sería:

```
El modelo regularizado mejora el baseline en F1 medio, pero el recall cae en el slice reciente. El diagnóstico probable es mismatch temporal o cambio de distribución. Recomendaría usarlo solo como baseline interno y construir una validación temporal antes de despliegue.
```

Esta respuesta integra métrica, validación, diagnóstico y alcance.

Verificaciones seleccionadas

1. Una mejora global no basta si el slice relevante para producción empeora.
2. PCA o K-Means pueden apoyar exploración, pero no sustituyen una métrica supervisada cuando la decisión depende de etiquetas.
3. La secuencia **resultado** -> **lectura** -> **comprobación** -> **límite** obliga a nombrar qué se observó y cómo se podría refutar la explicación propuesta.

Ejemplo resuelto: matriz de decisión integradora

Supón dos modelos:

Resultado	Modelo A	Modelo B
F1 global	0.83	0.85
F1 slice reciente	0.62	0.51
desviación CV	0.03	0.09
manifest completo	sí	no

Aunque B tiene mayor F1 global, A es el candidato más prudente si el slice reciente representa el uso futuro: su caída es menor y su validación es más estable. El manifest faltante de B impide auditar esa corrida, pero no demuestra que B prediga peor; es un problema de trazabilidad que debe corregirse antes de comparar de nuevo.

Mini-rúbrica para una respuesta integradora

Una respuesta de parcial puede calificarse de forma consistente con cuatro criterios 0/1/2.

Criterio	0	1	2
resultado	no cita resultados	cita un resultado aislado	conecta métrica global, slice y variabilidad
diagnóstico	no explica causa probable	nombra una causa sin sostenerla	relaciona patrón observado con causa plausible
acción	propone algo genérico	propone una acción parcial	propone acción proporcional y verificable
límite	no declara límite	límite vago	límite específico sobre uso, datos o despliegue

Esta rúbrica también guía el estudio. Antes del parcial, el estudiante debe practicar respuestas que no sean listas de conceptos, sino argumentos breves con resultados identificables. Para el profesor, la ventaja es que la parte manual se concentra en juicio técnico observable, mientras los cálculos, formas y métricas pueden quedar autocalificados.

Un error común es responder solo con el nombre del método: “usaría regularización” o “miraría PCA”. Eso rara vez basta. La respuesta debe decir qué resultado activa esa propuesta y qué esperaría observar después. Si la acción propuesta no produce una verificación posterior, todavía no es una decisión técnica cerrada. El objetivo es mostrar criterio técnico, no solo vocabulario aislado.

Para explorar más

- **Extensión matemática:** construye un mapa de dependencias entre pérdida, métrica, regularización, validación y decisión.
- **Extensión computacional:** rehace un experimento anterior desde cero y verifica si produce las mismas métricas dentro de tolerancias razonables.
- **Conexión con proyecto:** escribe qué comprobación mínima usarías para estudiar si tu resultado depende de una partición afortunada.

Revisión del capítulo

Este capítulo reúne los conceptos necesarios para responder preguntas integradoras. Una buena respuesta no enumera fórmulas: conecta modelo, métrica, validación, resultados y alcance.

El Parcial 2 exige reconocer cuándo una mejora global es insuficiente, cuándo un slice crítico cambia la recomendación y cuándo una técnica no supervisada solo permite una conclusión exploratoria. También exige cálculos básicos estables, como softmax con resta del máximo.

La estructura de respuesta esperada es resultado -> lectura -> comprobación -> límite. Permite calificar con claridad y evita que una explicación plausible se presente como hecho demostrado.

Términos clave

- **Respuesta integradora:** explicación que conecta modelo, métrica, resultado y límite.
- **Data mismatch temporal:** diferencia entre datos antiguos y recientes que afecta generalización.
- **Síntesis conceptual:** capacidad de relacionar contenidos de varios módulos en un argumento.
- **Alcance proporcional:** conclusión ajustada a la partición, métrica y datos disponibles.

Ejercicios

Preguntas conceptuales

1. Explique por qué una mejora global no basta si un slice crítico empeora.
2. ¿Qué diferencia hay entre diagnosticar overfitting y diagnosticar data mismatch?

Problemas cuantitativos

3. Compare dos modelos con métricas globales similares y desempeño distinto por slice; elija uno y justifique.
4. Calcule softmax estable para logits (1000, 1001, 1002) usando resta del máximo.

Práctica computacional

5. Escriba una función que evalúe una métrica global y la misma métrica por slice.
6. Cree una tabla resumen para preparar una respuesta de parcial: baseline, métrica, error principal y acción.

Interpretación y pensamiento crítico

7. Escriba una respuesta de 120 palabras con estructura resultado -> lectura -> comprobación -> límite.

Proyecto de cierre

8. Tome un resultado real o simulado de su proyecto y conviértalo en una respuesta oral de dos minutos para Parcial 2.

Reproducibilidad y tracking

Pregunta aplicada

Si otra persona recibe nuestros resultados, ¿puede reconstruir qué datos, código, parámetros y decisiones produjeron la conclusión?

Qué significa reproducir

Reproducibilidad: capacidad de volver a ejecutar el análisis con los mismos datos, código, entorno y parámetros para obtener resultados iguales o numéricamente equivalentes bajo una tolerancia declarada.

Esta propiedad permite comparar corridas y depurar errores. No demuestra que el modelo sea correcto ni que el resultado se replique con otra muestra.

Reproducibilidad: que otra persona pueda reconstruir el resultado




Figura 26: Reproducibilidad: datos, código, entorno y parámetros alimentan una corrida que produce métricas, artefactos y un manifiesto verificable.

Lectura de la figura. Una corrida reproducible no se identifica solo por el resultado final. Necesita registrar datos, código, entorno, parámetros, métricas y artefactos para reconstruir la corrida.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. listar los componentes mínimos de un proyecto reproducible;
2. explicar qué controla una semilla y qué no controla;
3. construir un `manifest.json` útil;
4. registrar parámetros, métricas y artefactos;
5. usar hashes para detectar cambios en archivos.

Reproducibilidad computacional y replicación estadística

Conviene separar dos preguntas:

1. **Reproducibilidad computacional:** con los mismos bytes, código y entorno, ¿se reconstruye el mismo resultado?
2. **Replicación estadística:** con otra muestra del proceso de interés, ¿la conclusión se mantiene dentro de una variación razonable?

La primera condiciona en el dataset observado. La segunda considera $D'_m \sim P^m$ y estudia la distribución de $T(D'_m)$, donde T puede ser un coeficiente, una métrica o una recomendación.

Una semilla fija selecciona una realización de generadores pseudoaleatorios. Debe registrarse, pero no reduce $\text{Var}_{D_m}(T(D_m))$ ni corrige cambio de distribución.

Un manifest completo registra la semilla y también el protocolo estadístico: unidad de muestreo, partición, repeticiones, intervalos o dispersión y distribución de uso pretendida.

El paquete mínimo reproducible

Elemento	Pregunta que responde
README.md	¿Qué hace el proyecto y cómo se corre?
requirements.txt o environment.yml	¿Qué entorno necesita?
src/ o funciones claras	¿Dónde vive la lógica reutilizable?
notebooks/	¿Dónde está la exploración documentada?
data/README.md	¿Qué datos se usaron y qué restricciones tienen?
reports/	¿Cuál es la conclusión final?
artifacts/	¿Qué modelos, métricas o figuras se generaron?
manifest.json	¿Qué entorno, parámetros, métricas y hashes identifican la corrida?

Semillas

La semilla controla generadores pseudoaleatorios:

```
RANDOM_STATE = 42
```

Pero una semilla no garantiza reproducibilidad total si cambian dependencias, hardware, versiones o datos. Algunas operaciones paralelas también pueden ser no deterministas. Por eso se registra junto con el entorno y los artefactos.

Manifest de experimento

Un manifest es un resumen estructurado:

```
{
  "schema_version": 1,
  "run_id": "logreg-c01-s2105",
  "code": {"commit": "4d92a1f"},
  "environment": {
    "python": "3.13.5",
    "packages": {"numpy": "2.3.1", "scikit-learn": "1.7.1"}
  },
  "inputs": {"datos.csv": "6f7d...a12c"},
  "params": {
    "model": "LogisticRegression",
    "C": 1.0,
    "seed": 2105,
    "split": {"train": 0.6, "dev": 0.2, "test": 0.2}
  },
  "metrics": {"dev_f1": 0.81},
  "artifacts": {"metricas.csv": "c2a8...90bf"}
}
```

Los hashes se muestran abreviados solo para lectura; el archivo real conserva los 64 caracteres hexadecimales de SHA-256. La pregunta que responde el manifest es: “¿qué corrida produjo este número?”.

Ejemplo resuelto: manifest mínimo

Un manifest suficientemente útil para un baseline podría ser:

```
{
  "schema_version": 1,
  "run_id": "baseline-logreg-s2105",
  "environment": {
    "python": "3.13.5",
    "packages": {"scikit-learn": "1.7.1"}
  },
  "params": {
    "model": "LogisticRegression",
    "C": 1.0,
    "seed": 2105,
    "split": "60/20/20 estratificado"
  },
  "metrics": {"dev_f1": 0.81},
  "artifacts": {"metricas.csv": "c2a8...90bf"}
}
```

No es necesario que sea largo. Debe distinguir la partición de cada métrica y permitir localizar sus salidas. `test_f1` se agrega cuando el protocolo queda cerrado y se ejecuta la evaluación final.

Ejemplo resuelto: resultado no reproducible

Supón que un equipo reporta `test_f1 = 0.84`, pero al ejecutar el notebook desde cero aparece `test_f1 = 0.77`. La primera hipótesis no debe ser mala fe; debe ser falta de trazabilidad. Revisa en orden:

1. si la partición usa la misma semilla;
2. si el pipeline aprende transformaciones solo en entrenamiento;
3. si el dataset tiene el mismo hash;
4. si las versiones de librerías cambiaron;
5. si el reporte copió una métrica de una corrida anterior.

Un resultado no reproducible no se corrige con memoria. Se reconstruye la secuencia de entradas y transformaciones hasta localizar por qué cambió la métrica.

Ejemplo resuelto: auditar un manifest

Supón que el manifest registra:

```
{
  "run_id": "ridge_v3",
  "environment": {"python": "3.13.5", "packages": {"numpy": "2.3.1"}},
  "params": {"model": "Ridge", "alpha": 10.0, "seed": 2105},
  "metrics": {"dev_rmse": 12.4},
```

```
"artifacts": {"predictions.csv": "abc123..."}
}
```

Dos semanas después, el archivo `predictions.csv` existe, pero su hash calculado es `sha256:def987`.

La conclusión correcta no es “el modelo está mal”. La conclusión correcta es:

1. el artefacto actual no coincide con el artefacto registrado;
2. la métrica `dev_rmse=12.4` ya no queda respaldada por ese archivo;
3. hay que volver a ejecutar la evaluación o recuperar el artefacto original;
4. cualquier reporte que use esa corrida debe marcarse como no verificado hasta resolver la discrepancia.

Un hash no evalúa calidad estadística. Evalúa identidad del archivo.

Tracking de experimentos

Herramientas como MLflow organizan experimentos en corridas con parámetros, métricas y artefactos. En este curso no se exige un servidor MLflow; el patrón conceptual sí se exige:

Concepto	En el curso
experimento	carpeta o manifest
run	una corrida con semilla y parámetros
params	hiperparámetros, semilla y protocolo de partición
metrics	resultados numéricos
artifacts	modelo, figuras, reporte, predicciones

Persistencia de modelos

Para proyectos con `scikit-learn`, una práctica común es guardar pipelines completos:

```
from joblib import dump

dump(pipeline, "artifacts/model.joblib")
```

Nunca cargues archivos `pickle` o `joblib` de fuentes no confiables. La persistencia basada en `pickle` puede ejecutar código durante la carga. Para producción o intercambio abierto, considera formatos más seguros o flujos de confianza explícita.

Hash de artefactos

Un hash SHA-256 permite detectar si un archivo cambió:

```
import hashlib

def sha256_file(path):
    h = hashlib.sha256()
    with open(path, "rb") as f:
        for chunk in iter(lambda: f.read(8192), b''):
            h.update(chunk)
    return h.hexdigest()
```

Checklist de reproducibilidad

1. ¿Está la semilla definida en un lugar visible?
2. ¿La partición de datos es reproducible?
3. ¿El preprocesamiento está dentro de un pipeline?
4. ¿El entorno está documentado?
5. ¿Las métricas finales se pueden recalcular?
6. ¿Los artefactos tienen nombre, versión o hash?
7. ¿El reporte distingue resultados, interpretación y recomendación?

Punto de control

Si alguien abre tu proyecto dos semanas después, debería poder responder:

1. ¿qué datos se usaron?;
2. ¿con qué entorno se ejecutó?;
3. ¿qué modelo produjo la métrica reportada?;
4. ¿qué archivos sostienen los resultados y cuáles son auxiliares?;
5. ¿qué decisión se tomó a partir de la corrida?

Caso longitudinal: manifest del clasificador

Para `clasificacion_binaria_sintetica.csv`, un manifest mínimo debería registrar:

Campo	Ejemplo
dataset	<code>clasificacion_binaria_sintetica.csv</code>
hash o versión	SHA-256 del archivo publicado
target	<code>target</code>
slices auditados	<code>base, reciente</code>
partición	semilla y proporciones

Campo	Ejemplo
pipeline	escalamiento dentro del pipeline y modelo
métrica primaria	F1 o recall
artefactos	tabla de métricas, matriz de confusión, error por slice

El manifest no garantiza que el modelo sea bueno. Permite reconstruir qué corrida produjo los archivos registrados. Esa diferencia es central para una defensa técnica.

Verificaciones seleccionadas

1. Un notebook ejecutable sin semilla puede ser reproducible en estructura, pero no necesariamente en resultados numéricos.
2. Si el dataset cambia y no cambia el manifest, ya no sabes qué archivo sostiene la conclusión.
3. Una tabla de métricas sin partición asociada no permite reconstruir la evaluación.

Ejemplo resuelto: manifest mínimo en JSON

Un manifest pequeño puede verse así:

```
{
  "schema_version": 1,
  "environment": {
    "python": "3.13.5",
    "packages": {"pandas": "2.3.1", "scikit-learn": "1.7.1"}
  },
  "params": {
    "dataset": "clasificacion_binaria_sintetica.csv",
    "target": "target",
    "seed": 2105,
    "split": "60/20/20 estratificado",
    "metric_primary": "f1"
  },
  "metrics": {"dev_f1": 0.81},
  "artifacts": {
    "metrics.csv": "c2a8...90bf",
    "slice_report.csv": "151f...2d8e"
  }
}
```

Este archivo no sustituye el reporte, pero permite auditar qué corrida produjo qué resultado. Si cambian datos, métrica o partición, el manifest debe cambiar.

Qué debe poder volver a ejecutarse

Un paquete reproducible no exige que todo el curso se ejecute en segundos, pero sí que exista una ruta verificable. Como mínimo, otra persona debe poder ejecutar un script o notebook que cargue datos permitidos, reconstruya particiones, entrene o cargue el modelo declarado, calcule métricas principales y regenere la tabla final. Si el entrenamiento completo es costoso, se debe incluir una versión reducida o un modo de evaluación que cargue artefactos ya generados y verifique sus métricas.

La trazabilidad se rompe cuando una figura se pega manualmente, una métrica se copia sin archivo de origen o una tabla final no se puede regenerar. En ese caso, la discusión técnica puede ser buena, pero el resultado no es auditable. El manifest debe apuntar a los archivos que sostienen cada afirmación importante.

Para explorar más

- **Extensión matemática:** identifica qué cantidades numéricas deben quedar fijas para comparar dos corridas de entrenamiento.
- **Extensión computacional:** crea un manifest mínimo con datos, commit, semilla, entorno, métricas y hash de salida.
- **Conexión con proyecto:** define qué archivos entregados permitirían auditar tu resultado sin abrir tu notebook manualmente.

Revisión del capítulo

Reproducibilidad significa que otra persona puede reconstruir el resultado desde datos, código, entorno, parámetros y artefactos. Una semilla ayuda, pero no basta si cambian datos, librerías, hardware o pasos manuales.

El manifest registra qué corrida produjo qué métricas y qué artefactos. Los hashes detectan cambios en archivos, pero no prueban que el contenido sea correcto. El tracking de experimentos ordena comparaciones y evita depender de memoria o nombres informales.

Un paquete reproducible debe permitir auditar el resultado final. Eso implica separar archivos de entrada, scripts, outputs, métricas, modelos y reporte, y declarar qué archivo sostiene cada afirmación cuantitativa.

Términos clave

- **Reproducibilidad:** capacidad de reconstruir resultados desde datos, código, entorno y parámetros.
- **Manifest:** archivo que registra configuración, rutas, semillas, métricas y artefactos.
- **Run:** corrida individual de un experimento.
- **Artefacto:** salida guardada, como modelo, figura, reporte, predicciones o tabla.
- **Hash:** huella de un archivo usada para detectar cambios.

- **Persistencia:** guardado de un modelo o pipeline para reutilizarlo.

Ejercicios

Preguntas conceptuales

1. ¿Por qué una semilla fija no garantiza reproducibilidad completa?
2. ¿Qué diferencia hay entre código que corre y un resultado reproducible?

Problemas cuantitativos

3. Diseñe una tabla mínima con tres runs, dos hiperparámetros y dos métricas.
4. Explique qué detecta y qué no detecta un hash SHA-256.

Práctica computacional

5. Cree un `manifest.json` mínimo para un experimento.
6. Calcule el hash SHA-256 de un archivo de resultados.

Interpretación y pensamiento crítico

7. ¿Qué riesgos tiene cargar modelos `pickle` o `joblib` de fuentes no confiables?
8. Si no puede reproducir una métrica final, ¿qué partes del proyecto revisaría primero?

Proyecto de cierre

9. Prepare un paquete mínimo reproducible para su proyecto: manifest, entorno, script de evaluación, tabla de métricas y lista de artefactos.

Comunicación técnica

Pregunta aplicada

¿Cómo convertimos experimentos, métricas y errores en una recomendación técnica que una audiencia pueda evaluar y cuestionar?

Tesis de un reporte

Un reporte final no debe ser una bitácora de todo lo que se intentó. Debe defender una conclusión.



Figura 27: Comunicación técnica: un reporte organiza tesis, resultados, diagnóstico, recomendación y límites para que una audiencia pueda auditarla.

Lectura de la figura. La tesis técnica aparece primero, pero no vive sola: debe estar sostenida por resultados, una lectura y límites. Si una afirmación no puede conectarse con una tabla, figura, cálculo o archivo, debe suavizarse o eliminarse.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. escribir una tesis técnica breve;
2. seleccionar figuras que respondan preguntas específicas;
3. distinguir resultado, interpretación y recomendación;
4. evitar lenguaje desproporcionado;
5. preparar una respuesta oral precisa.

Comunicar una cantidad aleatoria

Una métrica, coeficiente o componente estimada depende de la muestra. Un reporte matemáticamente proporcionado identifica:

estimando + estimador + estimación + incertidumbre + alcance.

Ejemplo:

En el test temporal de 2025, el MAE fue 4.8 unidades. Un bootstrap por mes dio percentiles 2.5 y 97.5 de 4.1 y 5.7. El intervalo describe remuestreo de meses observados; no cubre un cambio de política posterior.

No toda cifra necesita un intervalo formal, pero toda cifra usada para recomendar debe declarar tamaño efectivo, unidad de muestreo y fuente principal de incertidumbre. **media ± desviación entre folds** no se llamará intervalo de confianza.

Tesis técnica: frase que resume la recomendación, el resultado principal y la limitación más importante.

Ejemplo:

El modelo regularizado mejora el baseline en F1 y mantiene estabilidad en validación cruzada, pero requiere revisar falsos negativos en el subgrupo de mayor riesgo antes de una recomendación operativa.

Estructura recomendada

Sección	Pregunta
Resumen ejecutivo	¿Qué se recomienda y con qué cautela?
Problema y datos	¿Qué pregunta se modeló y qué datos la soportan?
Método	¿Qué pipeline se usó y por qué?
Validación	¿Qué comparación numérica respalda la recomendación?
Error analysis	¿Dónde falla y qué patrón importa?
Reproducibilidad	¿Cómo se vuelve a ejecutar o audita?

Sección	Pregunta
Limitaciones	¿Qué no puede concluirse?
Siguiente paso	¿Qué experimento o acción sigue?

Figuras útiles

Una figura debe cumplir una función. No se incluye porque “se ve bien”.

Figura	Uso
curva de aprendizaje	diagnosticar underfitting/overfitting
matriz de confusión	identificar tipos de error
tabla de métricas con baseline	comparar modelos
slices de error	encontrar fallas por subgrupo
PCA 2D	explorar estructura, no probar causalidad
perfil de clusters	interpretar segmentos

Lenguaje de alcance

Evita:

- “el modelo es bueno”;
- “la gráfica demuestra”;
- “el accuracy es alto”;
- “se recomienda implementar”.

Prefiere:

- “mejora el baseline por...”;
- “en validación se observa...”;
- “el resultado es estable/inestable porque...”;
- “se recomienda el siguiente experimento antes de...”.

Ejemplo resuelto: de bitácora a argumento

Una bitácora dice:

Probamos regresión logística, random forest y varias variables. La mejor métrica fue la del modelo regularizado. También hicimos gráficas y revisamos errores.

Un argumento técnico dice:

La regresión logística regularizada se elige porque mejora el baseline en F1 medio y mantiene menor variabilidad que el modelo más complejo. El análisis por slice muestra caída en observaciones recientes; por eso la recomendación se limita a usarlo como baseline interno y priorizar validación temporal.

La diferencia no es estilo literario. La bitácora enumera acciones; el argumento conecta criterio, resultado, diagnóstico y límite. Un lector puede auditar el segundo texto porque sabe qué tabla buscar y qué afirmación verificar.

Ejemplo resuelto: mejorar una conclusión

Conclusión débil:

El modelo es bueno porque tiene accuracy alta.

Conclusión revisada:

El modelo mejora el baseline de F1 en validación cruzada y mantiene desempeño similar en test. Sin embargo, el recall cae en el slice de observaciones recientes; por eso se recomienda usarlo solo como baseline interno mientras se revisa data mismatch temporal.

La segunda versión nombra comparación, partición, error y límite de uso.

Ejemplo resuelto: mejora absoluta y relativa

Supón que el baseline tiene F1 de 0.60 y el modelo final tiene F1 de 0.72.

La mejora absoluta es:

$$0.72 - 0.60 = 0.12.$$

La mejora relativa respecto al baseline es:

$$\frac{0.72 - 0.60}{0.60} = 0.20 = 20\%.$$

Una frase precisa sería:

El modelo mejora el baseline en 0.12 puntos de F1; al dividir esa diferencia por el F1 del baseline se obtiene 20 %. Ambos valores provienen de la misma partición de validación y deben leerse junto con los conteos de error.

La mejora relativa puede sonar más grande que la absoluta. Además, un aumento relativo de 20 % en F1 no significa que el costo de errores se haya reducido 20 %. El reporte muestra ambas cantidades solo si ayudan a interpretar el caso.

Respuesta oral de 45 segundos

Una respuesta oral de defensa debe caber en 45 segundos:

```
Elegimos [método] porque [criterio].  
El resultado principal fue [métrica + partición].  
El mayor error aparece en [slice o caso].  
La limitación más importante es [límite].  
Por eso recomendamos [acción proporcional].
```

Caso longitudinal: conclusión del clasificador

Con `clasificacion_binaria_sintetica.csv`, una conclusión débil sería:

El modelo final tiene buen F1 y se recomienda usarlo.

Una conclusión revisada sería:

El modelo regularizado mejora el baseline en F1 medio de validación, pero el recall del slice **reciente** es menor que el del slice **base**. Por tanto, el modelo puede usarse como baseline interno para priorizar revisión, pero no como sistema automático final hasta construir una validación temporal y auditar variables que cambian entre slices.

La segunda versión tiene tesis, resultado, diagnóstico, recomendación y límite. También deja claro qué experimento falta.

Verificaciones seleccionadas

1. Una mejora relativa de 20 % puede sonar grande; siempre debe leerse junto con la mejora absoluta y el baseline.
2. Una figura funcional debe responder una pregunta: comparación, error, curva, slice o trazabilidad.
3. Si una conclusión no declara límite, probablemente exagera el alcance del resultado.

Ejemplo resuelto: tabla de soporte de afirmaciones

Antes de entregar un reporte, cruza cada afirmación fuerte contra un soporte identificable:

Afirmación	Soporte necesario	Estado
supera el baseline	tabla baseline vs modelo	verificable
mantiene desempeño en la muestra de test	métrica, tamaño y protocolo de test	incompleto si no hay test
funciona para casos recientes	métrica por <code>slice</code>	falso si el slice cae

Afirmación	Soporte necesario	Estado
la corrida es reproducible	manifest, entorno y hashes	verificable

Una afirmación sin soporte debe cambiar de tono. Por ejemplo, “generaliza bien” puede convertirse en “la media de F1 fue estable entre los cinco folds; falta la evaluación final en test”. Incluso un test final estima desempeño sobre una muestra concreta, no garantiza todos los datos futuros.

Plantilla de resultados

Una sección de resultados puede tener esta forma:

```
Baseline. [regla simple] obtiene [métrica] en [partición].
Modelo. [modelo elegido] obtiene [métrica media ± desviación] bajo [validación].
Error principal. El peor patrón aparece en [slice/tipo de error].
Recomendación. Con estos resultados se propone [acción proporcional].
Límite. No se puede afirmar [conclusión excesiva] porque [razón].
```

Esta plantilla evita dos extremos: una bitácora larga sin tesis y una conclusión fuerte sin soporte. Si una línea no puede llenarse con una tabla, figura, cálculo o archivo, el reporte todavía no está listo.

De resultado a recomendación

La recomendación final debe tener un verbo de acción. “El modelo alcanza 0.84 de F1” es un resultado; “usar el modelo como filtro preliminar con revisión humana en casos de baja confianza” es una recomendación. Entre ambos debe aparecer el razonamiento: baseline superado, error principal, costo de fallo y límite de uso. En ciencia de datos aplicada, una métrica sin acción suele quedarse corta.

“Baja confianza” solo tiene sentido si el puntaje tiene una interpretación adecuada y se revisó calibración. Una probabilidad logística o softmax no queda calibrada por el solo hecho de estar entre cero y uno.

También importa el tono. Si el resultado viene de validación interna, la recomendación debe decirlo. Si el test final es pequeño, debe aparecer el tamaño. Si un slice falla, no se debe esconder detrás del promedio global. La escritura calidad de la escritura no consiste en sonar segura; consiste en precisar qué permiten sostener los datos disponibles.

Una buena prueba de lectura es subrayar cada afirmación del reporte y preguntar: ¿qué tabla, figura, cálculo o archivo la sostiene? Si no hay respuesta, la frase debe debilitarse, eliminarse o convertirse en trabajo futuro. Esta disciplina hace que el texto sea más corto, pero más fuerte y auditable. Además, ayuda a distinguir entre una conclusión lista para entrega y una idea que aún necesita validación adicional.

Para explorar más

- **Extensión matemática:** convierte una mejora de métrica en mejora absoluta, relativa y límite de interpretación.
- **Extensión computacional:** genera una tabla final reproducible que combine baseline, modelo elegido, métrica principal, variabilidad y nota de validación.
- **Conexión con proyecto:** prepara una conclusión de 45 segundos que incluya recomendación, resultado principal, error, limitación y siguiente paso.

Revisión del capítulo

La comunicación técnica transforma resultados en una conclusión verificable. Una tesis de reporte debe decir qué problema se abordó, qué se obtuvo, qué se recomienda y bajo qué límites.

Las figuras funcionales responden preguntas concretas: desempeño contra baseline, errores por slice, curva de validación o estructura de datos. Una figura decorativa puede distraer; una figura funcional reduce ambigüedad.

El lenguaje debe ser proporcional. En lugar de afirmar que un modelo “es bueno”, el reporte debe explicar contra qué baseline mejora, con qué métrica, en qué datos, dónde falla y qué acción se recomienda.

Términos clave

- **Tesis del reporte:** afirmación central vinculada a resultados identificables.
- **Resumen ejecutivo:** síntesis de recomendación, resultado y límite para lector no técnico.
- **Figura funcional:** visualización incluida porque responde una pregunta técnica.
- **Limitación:** frontera explícita de lo que no se puede concluir.
- **Acción proporcional:** recomendación ajustada al alcance de los resultados.

Ejercicios

Preguntas conceptuales

1. ¿Por qué “el modelo es bueno” no es una conclusión técnica suficiente?
2. ¿Qué diferencia hay entre una figura decorativa y una figura funcional?

Problemas cuantitativos

3. Reduzca una tabla con cinco métricas a las dos más relevantes para una decisión de alto costo.
4. Compare un modelo contra baseline y escriba la mejora absoluta y relativa de la métrica principal.

Práctica computacional

5. Cree una tabla final de resultados con baseline, modelo elegido, métrica, media y desviación entre folds, y nota de validación. No llame intervalo a **media $\pm$ desviación**.
6. Genere una figura de error analysis con título, eje claro y caption interpretativo.

Interpretación y pensamiento crítico

7. Reescriba una conclusión exagerada para que incluya resultado, límite y siguiente paso.

Proyecto de cierre

8. Escriba el resumen ejecutivo de su proyecto en 180 palabras: problema, método, resultado principal, error, limitación y recomendación.

Entrega final y defensa

Pregunta aplicada

¿Qué debe entregar un equipo para que su proyecto pueda leerse, ejecutarse, auditarse y defenderse sin depender de una explicación informal?

Paquete final

El paquete final debe permitir tres acciones:

1. leer la conclusión;
2. ejecutar o auditar el flujo principal;
3. evaluar la contribución individual.

Objetivos del capítulo

Al terminar este capítulo deberías poder:

1. organizar un repositorio de proyecto con resultados auditables;
2. preparar una entrega que se pueda leer y ejecutar;
3. explicar tu contribución individual;
4. responder preguntas sobre métrica, validación, leakage y limitaciones;
5. distinguir presentación grupal de defensa individual.

Defensa del fundamento probabilístico

La defensa individual debe poder responder, con notación y datos del proyecto:

1. ¿cuál es la población o distribución de uso P_{uso} ?
2. ¿qué mecanismo produjo la muestra y qué dependencias existen?
3. ¿qué objeto poblacional aproxima el modelo?
4. ¿qué riesgo o métrica empírica se calculó y sobre qué partición?
5. ¿qué variación tiene la cifra principal y cómo se estimó?
6. ¿qué cambio de distribución invalidaría la recomendación?

Una respuesta que solo describe una función de biblioteca no demuestra comprensión matemática del proyecto.

Estructura del repositorio de proyecto

```
proyecto-final/  
  README.md  
  requirements.txt  
  data/  
    README.md  
  notebooks/  
    01_exploracion.ipynb  
    02_modelado.ipynb  
    03_reporte_final.ipynb  
  src/  
    features.py  
    evaluation.py  
  reports/  
    reporte_final.pdf  
  artifacts/  
    metrics.json  
    manifest.json
```

No todos los proyectos tendrán exactamente la misma estructura, pero sí deben separar datos, código, resultados y reporte.

Criterio de paquete ejecutable

Un proyecto no está listo porque “corre en mi computador”. Está listo cuando otra persona puede reconstruir el resultado principal con instrucciones mínimas. El README debe responder:

Pregunta	Archivo o respuesta esperada
¿qué problema estudia?	pregunta aplicada y alcance
¿qué datos usa?	fuentes, licencia, columnas y restricciones
¿cómo se ejecuta?	comandos o notebooks en orden
¿qué resultado debe aparecer?	métrica, tabla o figura esperada
¿qué no se publica?	datos privados, credenciales o archivos sensibles

Si el notebook final depende de rutas locales, celdas ejecutadas fuera de orden o archivos no incluidos, la defensa se vuelve una explicación informal. La entrega debe eliminar esa fragilidad antes de la entrega.

Ejemplo resuelto: contribución individual

Respuesta vaga:

Ayudé con el modelo.

Respuesta verificable:

Implementé la partición train/dev/test, construí el baseline logístico y comparé F1/recall contra el modelo regularizado. También preparé la tabla de errores por slice de edad y documenté el riesgo de falsos negativos.

La segunda respuesta permite verificar autoría y comprensión.

Peso del proyecto en el curso

El proyecto completo representa 40 % de la nota:

Componente	Peso del curso	Momento
Hitos y checkpoints	15 %	durante el semestre
Reporte y repositorio final	15 %	entrega de Semana 16
Defensa individual	10 %	jornadas de defensa

Los hitos usan formularios y plantillas breves. La tabla siguiente califica el reporte y el repositorio sobre 100 puntos y luego se multiplica por 0.15.

Rúbrica del reporte y repositorio

Criterio	Peso sugerido
Pregunta, datos y alcance	15 %
Fundamento matemático y algoritmo	20 %
Validación, métricas y error analysis	25 %
Reproducibilidad y organización	15 %
Comunicación visual y escrita	15 %
Limitaciones, ética y decisión	10 %

Ejemplo resuelto: cálculo de nota ponderada

Supón que un proyecto recibe:

Criterio	Puntaje	Peso
Pregunta, datos y alcance	12/15	15 %
Fundamento matemático y algoritmo	16/20	20 %
Validación, métricas y error analysis	20/25	25 %
Reproducibilidad y organización	13/15	15 %

Criterio	Puntaje	Peso
Comunicación visual y escrita	12/15	15 %
Limitaciones, ética y decisión	8/10	10 %

Como los pesos suman 100 puntos y los denominadores coinciden con esos pesos, la nota total es:

$$12 + 16 + 20 + 13 + 12 + 8 = 81.$$

El porcentaje del componente es $81/100 = 81\%$, que aporta

$$0.81(15) = 12.15$$

puntos a la nota del curso. La tabla muestra en qué criterio se perdieron los 2.85 puntos restantes del componente.

Defensa oral individual

La defensa no repite la presentación. Verifica autoría, comprensión y criterio.



Figura 28: Defensa oral: la respuesta individual conecta pregunta, respuesta breve, archivo verificable y límite específico con una rúbrica 0/1/2.

Lectura de la figura. Una defensa fuerte no empieza con “yo hice varias cosas”; empieza con una respuesta breve, la conecta con un archivo o resultado y declara un límite. Esa estructura permite evaluar rápido sin convertir la defensa en una conversación improvisada.

Preguntas típicas:

1. ¿Cuál fue tu contribución técnica concreta?
2. ¿Por qué esa métrica es la correcta?
3. ¿Dónde falla el modelo?
4. ¿Qué parte del pipeline podría producir leakage?
5. ¿Qué cambiaría si tuvieras dos semanas más?
6. ¿Qué conclusión no puedes afirmar con estos datos?

Rúbrica de defensa 0/1/2

Criterio	0	1	2
Autoría	no identifica contribución	contribución vaga	contribución concreta y verificable
Matemática	errores conceptuales	idea parcial	explicación correcta y conectada
Validación	no justifica métrica	justifica parcialmente	conecta métrica, baseline y error
Reproducibilidad	no localiza la corrida	menciona archivos aislados	explica entorno, semilla, manifest y artefacto
Limitaciones	no reconoce límites	límite genérico	límite específico y relevante

Cada criterio aporta 0, 1 o 2 puntos. Los cinco criterios suman directamente los 10 puntos porcentuales de la defensa en la nota del curso.

Caso longitudinal: defensa del clasificador

Para defender el caso `clasificacion_binaria_sintetica.csv`, prepara una tabla de archivos antes de hablar:

Pregunta posible	Archivo o resultado que debes abrir
¿por qué esa métrica?	costo de falsos positivos/falsos negativos y baseline
¿dónde falla?	matriz de confusión y tabla por <code>slice</code>
¿hay leakage?	pipeline y partición
¿qué hiciste tú?	commit, notebook, función o tabla verificable
¿qué no puedes afirmar?	límite sobre el <code>slice reciente</code>

Una defensa de 45 segundos:

Mi contribución fue construir el pipeline de evaluación y la tabla por slice. El modelo regularizado mejora el baseline en F1, pero el recall cae en el slice reciente. Por eso no recomiendo despliegue; recomiendo usarlo como baseline y crear una validación temporal antes de tomar decisiones.

Verificaciones seleccionadas

1. “Ayudé con el modelo” no prueba autoría; “implementé la partición y la tabla por slice en el archivo X” sí es verificable.
2. Una defensa fuerte puede reconocer que el resultado no basta para despliegue.
3. La rúbrica 0/1/2 funciona cuando la respuesta tiene un soporte observable y no depende de impresiones.

Ejemplo resuelto: pregunta difícil

Pregunta:

Si tu modelo tiene mejor F1, ¿por qué no recomiendas desplugarlo?

Respuesta precisa:

Porque la mejora global no se mantiene en el slice reciente. La tabla por slice muestra una caída de recall, y ese slice se parece más al uso esperado. Recomendando mantener el modelo como baseline interno y construir una validación temporal antes de despliegue.

La respuesta obtiene puntaje alto porque no niega la mejora; la ubica dentro de su límite y propone una acción técnica.

Checklist individual antes de entrar a defensa

Cada estudiante debe poder abrir un soporte concreto para estas preguntas:

Pregunta	Soporte mínimo
¿qué hiciste tú?	archivo, función, notebook, tabla o commit
¿qué fórmula o métrica usaste?	definición y razón aplicada
¿qué baseline superaste?	tabla comparativa
¿dónde falla el modelo?	matriz de confusión, residuos o slice
¿cómo evitas leakage?	partición y pipeline
¿qué no puedes concluir?	limitación específica

Si una respuesta depende de “eso lo hizo mi compañero”, la defensa individual no está lista. La colaboración es válida, pero cada persona debe defender una parte técnica concreta del proyecto.

Carga docente mínima

Para grupos grandes:

- revisar el reporte con rúbrica estructurada;
- usar checklist de reproducibilidad antes de leer detalles;
- evaluar defensa individual con 5 criterios 0/1/2;
- pedir soporte de contribución en una tabla;
- muestrear notebooks solo cuando haya inconsistencia.

Contribución individual y trazabilidad

La defensa individual debe apoyarse en archivos concretos. Una respuesta fuerte no dice solamente “yo hice el modelo”; señala el archivo, la función, el commit, la tabla o la figura que prueba la contribución. Esta trazabilidad evita dos problemas frecuentes: estudiantes que entienden el proyecto pero no pueden mostrar su aporte, y estudiantes que presentan artefactos sin poder defender las decisiones técnicas.

Una forma simple de prepararse es construir una tabla con tres columnas: pregunta posible, archivo que abriría y respuesta de 30 segundos. Por ejemplo, si la pregunta es “¿cómo evitaron leakage?”, el soporte puede ser el pipeline de preprocesamiento y la partición; la respuesta debe explicar qué pasos se ajustaron solo con entrenamiento y cuáles se aplicaron después a validación o test. Esta preparación hace la defensa más justa y reduce tiempo de evaluación.

Para explorar más

- **Extensión matemática:** anticipa una pregunta sobre pérdida, métrica o validación y prepara una respuesta con una fórmula o cálculo simple.
- **Extensión computacional:** ejecuta el proyecto en un entorno limpio y registra cualquier dependencia faltante antes de la defensa.
- **Conexión con proyecto:** arma una tabla de preguntas difíciles con archivo fuente y respuesta breve.

Revisión del capítulo

La entrega final debe ser auditable. El repositorio, el reporte, los artefactos y la defensa deben permitir reconstruir qué se hizo, quién lo hizo, qué resultado se obtuvo y qué conclusión se puede sostener.

La defensa individual no repite la presentación grupal. Su función es verificar criterio técnico: contribución concreta, elección de métrica, prevención de leakage, lectura de errores, limitaciones y siguiente experimento razonable.

La carga docente se reduce cuando los soportes están estructurados. Una rúbrica 0/1/2 funciona si cada criterio se puede observar rápidamente en archivos, tablas, respuestas orales o artefactos reproducibles.

Términos clave

- **Paquete final:** conjunto de reporte, código, datos permitidos y artefactos.
- **Defensa oral:** instancia para verificar autoría, comprensión y criterio.
- **Contribución individual:** trabajo técnico concreto que puede ser explicado y verificado.
- **Rúbrica:** criterio explícito para evaluar con consistencia.
- **Carga docente mínima:** diseño de evaluación que concentra revisión manual donde aporta juicio.

Ejercicios

Preguntas conceptuales

1. ¿Por qué una defensa oral no debe repetir simplemente la presentación?
2. ¿Qué archivo o resultado distingue una contribución concreta de una afirmación vaga?

Problemas cuantitativos

3. Con la rúbrica propuesta, calcule la nota de un proyecto que obtiene 12/15, 16/20, 20/25, 13/15, 12/15 y 8/10.
4. Si una defensa usa cinco criterios 0/1/2, diseñe una conversión transparente a porcentaje.

Práctica computacional

5. Cree una estructura de carpetas final para su proyecto y liste qué archivo prueba cada resultado importante.
6. Prepare una tabla de contribuciones individuales con tarea, soporte y responsable.

Interpretación y pensamiento crítico

7. Escriba una respuesta precisa a: “¿Qué cambiaría si tuviera dos semanas más?”

Proyecto de cierre

8. Arme un checklist final de entrega con 12 ítems verificables antes de subir el proyecto.

Ejercicios integradores: reproducibilidad y defensa

Esta sección sirve como ensayo final del curso. Cada ejercicio conecta matemática, implementación y comunicación. La respuesta no termina en el cálculo: debe decir qué permite concluir y qué falta comprobar.

Resultados de práctica

Al terminar este banco deberías poder:

1. estabilizar cálculos numéricos básicos;
2. transformar métricas en diagnóstico y acción;
3. usar PCA y reconstrucción como herramientas verificables;
4. diseñar un manifest reproducible;
5. defender límites antes de recomendar uso real.

Mapa del banco

Ejercicio	Qué comprueba
1	estabilidad numérica en softmax
2	diagnóstico con baseline, CV, test y slice crítico
3	PCA, scores y reconstrucción
4	manifest y trazabilidad de experimento
5	defensa técnica con límites explícitos

Criterio de calidad

Una respuesta final de curso debe:

1. usar una fórmula o procedimiento correcto;
2. señalar el resultado observado;
3. traducirlo en una lectura técnica;
4. proponer una acción proporcional;
5. declarar un límite.

Columna probabilística del cierre

P1. Cuatro niveles. Para una red de clasificación, identifique distribución poblacional, muestra, riesgo empírico y algoritmo. Repita para PCA y K-Means.

P2. Dos reproducibilidades. Dé un ejemplo donde una corrida sea perfectamente reproducible, pero la conclusión cambie mucho con otra muestra.

P3. Semilla. Explique qué variables aleatorias controla `random_state=2105` en su pipeline y cuáles fuentes de incertidumbre permanecen.

P4. Manifest estadístico. Diseñe campos JSON para registrar población de uso, unidad independiente, partición, repeticiones y resumen de incertidumbre.

P5. Comunicación. Reescriba “el modelo tiene F1 de 0.87” como una afirmación que identifique partición, tamaño efectivo, procedimiento fijado, incertidumbre y límite de transporte.

P6. Defensa. Prepare una respuesta de 90 segundos que conecte un resultado de su proyecto con P_{uso} , $\hat{R}$, fuente de variación y siguiente comprobación.

Ejercicio 1: Softmax estable

Sea

$$Z = \begin{bmatrix} 1000 & 1001 & 1002 \end{bmatrix}.$$

1. Explica por qué una implementación directa puede fallar.
2. Calcula softmax después de restar el máximo.
3. Verifica que las probabilidades suman 1.

Ejercicio 2: Diagnóstico

Un modelo tiene:

- baseline F1 = 0.62;
- modelo F1 CV = 0.78, desviación entre folds 0.09;
- test F1 = 0.70;
- slice crítico de test F1 = 0.48 en 40 casos.

Escribe una recomendación en cuatro partes:

```
resultado -> lectura -> comprobación -> límite
```

Ejercicio 3: PCA y reconstrucción

Tienes una matriz centrada X_c y su SVD $X_c = U\Sigma V^\top$.

1. Escribe la fórmula de los scores con k componentes.
2. Escribe la reconstrucción aproximada.
3. Explica por qué el error de reconstrucción no aumenta al aumentar k .

Ejercicio 4: Reproducibilidad

Diseña un `manifest.json` mínimo para un experimento de clasificación. Debe incluir:

- semilla;
- entorno y versiones;
- protocolo de partición;
- modelo;
- hiperparámetros;
- métrica principal con nombre de partición;
- hash de artefactos;
- commit o versión del código.

Ejercicio 5: Defensa

Responde en 120 palabras:

¿Qué resultados y comprobaciones necesitarías antes de recomendar el uso de un modelo?

Respuestas seleccionadas

Ejercicio 1. La implementación directa puede fallar porque e^{1002} excede el rango numérico usual. Al restar el máximo, se calcula softmax sobre $(-2, -1, 0)$. Las probabilidades son proporcionales a $(e^{-2}, e^{-1}, 1)$ y se normalizan dividiendo por $e^{-2} + e^{-1} + 1$. La suma final es 1 por construcción.

Ejercicio 2. Una respuesta posible sería: “Resultado: el modelo supera el baseline, pero varía entre folds, baja en test y obtiene F1 0.48 en 40 casos del slice crítico. Lectura: el resultado es inestable y puede haber una falla en ese subgrupo. Comprobación: revisar sus conteos de error y repetir la medición en otro periodo; no volver a escoger el modelo con test. Límite: no recomendar uso si el slice representa casos de alto costo.”

Ejercicio 3. Los scores con k componentes son $Z = X_c V_k$. La reconstrucción aproximada es $\hat{X}_k = Z V_k^\top$. Al aumentar k , el subespacio disponible contiene al anterior, así que la mejor reconstrucción no puede empeorar.

Ejercicio 4. El manifest debe registrar `environment`, `params`, `metrics` y `artifacts`. En `params` se incluyen semilla y partición; cada métrica nombra su conjunto, y cada artefacto conserva el SHA-256 completo. Un hash identifica los bytes del archivo, no certifica que el análisis sea correcto.

Ejercicio 5. La revisión mínima incluye baseline, partición independiente, métrica alineada con el costo, análisis por slices con tamaños y conteos, matriz de errores, revisión de leakage, estabilidad ante cambios de datos y límites. Una métrica global aislada no justifica una recomendación de uso.

Herramientas probabilísticas y estadísticas

Los capítulos anteriores introducen ideas probabilísticas en el momento en que aparecen en un problema: la esperanza condicional al estudiar regresión, el riesgo al definir una pérdida, el modelo Bernoulli en clasificación, la variabilidad muestral al validar y la covarianza poblacional al estudiar PCA. Esta parte reúne esas ideas en una exposición sistemática que puede utilizarse como referencia.

El primer capítulo formaliza espacios de probabilidad, variables aleatorias, distribuciones, momentos y muestras. El segundo desarrolla condicionamiento, estimación, riesgo esperado, incertidumbre de métricas, remuestreo y cambio de distribución. Ambos incluyen ejemplos y ejercicios que permiten estudiar los temas con mayor profundidad que la requerida en su primera aparición.

La lectura puede hacerse de dos formas. Quien necesite revisar una definición puede consultar directamente la sección correspondiente; quien quiera consolidar la teoría probabilística puede leer los dos capítulos en orden. En ninguno de los dos casos esta parte sustituye la formulación concreta de los modelos: su función es explicar con más detalle los objetos que el resto del libro utiliza.

Variables aleatorias, distribuciones y muestras

Referencia matemática sobre variación y muestreo

En los capítulos de modelos, una observación nueva se representó mediante variables aleatorias, la calidad de una regla se definió como una esperanza y la estabilidad de un procedimiento se estudió imaginando otras muestras. Este capítulo reúne y formaliza el lenguaje que sostiene esas construcciones.

Comenzaremos por los resultados y eventos de un experimento aleatorio, definiremos variables aleatorias y distribuciones, estudiaremos esperanzas y covarianzas, y finalmente distinguiremos una muestra aleatoria de la realización concreta que aparece en una tabla. La exposición puede leerse de manera continua o utilizarse para consultar una definición cuando vuelva a aparecer en regresión, validación, redes neuronales o PCA.

Al terminar el capítulo, el lector podrá:

1. interpretar un espacio de probabilidad y sus eventos;
2. distinguir variable aleatoria, realización y valor registrado;
3. describir distribuciones mediante masa, densidad o función de distribución;
4. calcular esperanza, varianza, covarianza y correlación;
5. interpretar distribuciones conjuntas, marginales e independencia;
6. formular una muestra aleatoria y declarar cuándo el supuesto iid es razonable;
7. distinguir distribución poblacional y distribución empírica;
8. explicar, bajo condiciones explícitas, por qué un promedio muestral puede aproximar una esperanza.

Las conexiones principales con el recorrido del libro son:

Objeto de este capítulo	Primera aparición en el desarrollo
par aleatorio, muestra y esperanza condicional	regresión lineal
esperanza y varianza de una pérdida	regresión y optimización
distribución Bernoulli	regresión logística
distribución categórica	redes neuronales
covarianza poblacional y empírica	PCA
distribución muestral	regularización, métricas y validación

La tabla no fija prerequisites. Señala las preguntas que motivaron cada objeto antes de que este capítulo lo estudie en forma general.

La incertidumbre antes de observar

Supongamos que se selecciona una unidad de una población y se registra una característica. Antes de observarla hay varios resultados posibles; después de observarla aparece un valor concreto. Un modelo probabilístico describe la primera situación.

Hay al menos dos orígenes habituales para esta incertidumbre:

- **aleatoriedad del diseño:** el procedimiento de muestreo o asignación utiliza un mecanismo aleatorio conocido;
- **variación del proceso:** las unidades futuras, mediciones repetidas o resultados experimentales no son idénticos y se representan mediante una distribución.

En una población finita puede existir una lista fija de valores y ser aleatoria únicamente la selección de unidades. En otros problemas se idealiza una secuencia de observaciones futuras como realizaciones de un mismo proceso. Las dos interpretaciones conducen a cálculos probabilísticos, pero sus supuestos y su alcance no son idénticos.

Ejemplo 1: dos fuentes de aleatoriedad. Si se eligen al azar 100 estudiantes de un registro institucional fijo, la aleatoriedad procede del diseño de muestreo. Si se estudia el tiempo de espera de las próximas 100 solicitudes de un servicio, los casos aún no existen y la distribución representa variación del proceso futuro.

Espacios de probabilidad y eventos

Un modelo probabilístico comienza con una terna

$$(\Omega, \mathcal{F}, \mathbb{P}).$$

Sus componentes son:

- Ω , el **espacio muestral**, que contiene los resultados elementales posibles;
- $\mathcal{F}$, una colección de subconjuntos de Ω llamados **eventos**;
- $\mathbb{P}$, una función que asigna probabilidad a cada evento.

La colección $\mathcal{F}$ contiene a Ω , es cerrada bajo complementos y bajo uniones numerables. Estas condiciones garantizan que las operaciones usuales con eventos produzcan otros eventos a los que puede asignarse probabilidad.

La función $\mathbb{P}$ satisface tres propiedades:

1. $\mathbb{P}(A) \geq 0$ para todo $A \in \mathcal{F}$;
2. $\mathbb{P}(\Omega) = 1$;
3. si $A_1, A_2, \dots$ son eventos disjuntos, entonces

$$\mathbb{P}\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} \mathbb{P}(A_j).$$

De estas propiedades se deducen identidades conocidas, por ejemplo

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

y

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Ejemplos de espacios muestrales

Al lanzar dos veces una moneda podemos usar

$$\Omega = \{CC, CS, SC, SS\},$$

donde C y S representan cara y sello. El evento “obtener exactamente una cara” es $\{CS, SC\}$.

Para el tiempo de espera de una solicitud podríamos usar

$$\Omega = [0, \infty).$$

En espacios continuos no es posible asignar una probabilidad positiva a cada punto manteniendo suma total uno. Las probabilidades se asignan a intervalos u otros conjuntos mediante una distribución.

El espacio muestral no tiene una única descripción obligatoria. Debe ser lo suficientemente detallado para definir las variables y eventos de interés. En un estudio clínico, ω podría contener toda la trayectoria de una persona, aunque el análisis utilice solo algunas mediciones de esa trayectoria.

Variables aleatorias y realizaciones

Variable aleatoria. Una variable aleatoria real es una función medible

$$Y : \Omega \longrightarrow \mathbb{R}.$$

La medibilidad garantiza que conjuntos como $\{\omega : Y(\omega) \leq t\}$ sean eventos y, por tanto, tengan probabilidad definida.

En este libro trabajaremos principalmente con variables discretas y con variables continuas usuales. No necesitaremos verificar la medibilidad en cada ejemplo, pero la condición explica por qué una variable aleatoria no es simplemente “un número que cambia”. Es una función fija aplicada a un resultado ω que todavía no se conoce.

Si ocurre ω_i , observamos la **realización**

$$y_i = Y(\omega_i).$$

Por convención, usaremos mayúsculas para variables aleatorias y minúsculas para sus realizaciones. Una columna $(y_1, \dots, y_m)$ contiene valores ya observados; Y representa el resultado antes de observar una unidad nueva.

Una variable aleatoria también puede tomar valores en otros espacios. Una clase de cultivar puede pertenecer al conjunto $\{0, 1, 2\}$; una imagen puede representarse en un espacio de arreglos; un vector de características toma valores en $\mathbb{R}^d$. Para un vector aleatorio escribimos

$$X = (X_1, \dots, X_d) : \Omega \longrightarrow \mathbb{R}^d.$$

En aprendizaje supervisado, el par

$$Z = (X, Y)$$

representa las entradas y la salida de una unidad antes de observarla. Una fila registrada es una realización $z_i = (x_i, y_i)$.

Indicadores

Para un evento A definimos su variable indicadora como

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

Las variables indicadoras conectan eventos y variables aleatorias. Un resultado binario puede expresarse como $Y = \mathbf{1}_A$, y la proporción de veces que ocurre A en una muestra será un promedio de indicadores.

La distribución de una variable aleatoria

La **distribución** o **ley** de Y asigna a cada conjunto de valores la probabilidad de que Y pertenezca a él:

$$P_Y(B) = \mathbb{P}(Y \in B).$$

La distribución resume todo lo que el modelo probabilístico afirma sobre Y . Dos variables definidas en espacios muestrales distintos pueden tener la misma distribución.

Función de distribución acumulada

La función

$$F_Y(t) = \mathbb{P}(Y \leq t), \quad t \in \mathbb{R},$$

se llama **función de distribución acumulada**. Toda variable aleatoria real tiene una. Es no decreciente, continua por la derecha y satisface

$$\lim_{t \rightarrow -\infty} F_Y(t) = 0, \quad \lim_{t \rightarrow \infty} F_Y(t) = 1.$$

La función F_Y determina por completo la distribución. Por ejemplo,

$$\mathbb{P}(a < Y \leq b) = F_Y(b) - F_Y(a).$$

Variables discretas

Si Y toma valores en un conjunto finito o numerable, su función de masa es

$$p_Y(y) = \mathbb{P}(Y = y).$$

Debe satisfacer $p_Y(y) \geq 0$ y

$$\sum_y p_Y(y) = 1.$$

Para cualquier conjunto B ,

$$\mathbb{P}(Y \in B) = \sum_{y \in B} p_Y(y).$$

Ejemplo 2: variable Bernoulli. Si $Y \in \{0, 1\}$ y $\mathbb{P}(Y = 1) = p$, entonces Y tiene distribución Bernoulli con parámetro p , lo que escribimos $Y \sim \text{Bernoulli}(p)$. Su función de masa es

$$p_Y(y) = p^y(1-p)^{1-y}, \quad y \in \{0, 1\}.$$

Variables continuas

Una variable continua puede describirse mediante una densidad f_Y tal que

$$f_Y(y) \geq 0, \quad \int_{-\infty}^{\infty} f_Y(y) dy = 1,$$

y

$$\mathbb{P}(a < Y \leq b) = \int_a^b f_Y(y) dy.$$

Una densidad no es una probabilidad puntual. Puede tomar valores mayores que uno y, para una variable continua,

$$\mathbb{P}(Y = y) = 0$$

para todo valor individual y . Las probabilidades corresponden a áreas bajo la densidad.

No toda distribución es puramente discreta o posee densidad. La función de distribución acumulada permite tratar también distribuciones mixtas, aunque en los ejemplos iniciales nos concentraremos en los dos casos usuales.

Esperanza y transformaciones

La esperanza resume el promedio de una variable respecto a su distribución.

Si Y es discreta y la suma converge absolutamente,

$$\mathbb{E}[Y] = \sum_y y p_Y(y).$$

Si Y tiene densidad y $\int |y| f_Y(y) dy < \infty$,

$$\mathbb{E}[Y] = \int_{-\infty}^{\infty} y f_Y(y) dy.$$

Más generalmente, para una función g integrable,

$$\mathbb{E}[g(Y)] = \int g(y) dP_Y(y).$$

Esta última notación cubre variables discretas, continuas y mixtas. Es importante porque las pérdidas de un modelo, los indicadores de acierto y las transformaciones de variables son funciones de variables aleatorias.

Propiedades básicas

Si las esperanzas existen y $a, b \in \mathbb{R}$, entonces

$$\mathbb{E}[aY + b] = a\mathbb{E}[Y] + b.$$

Para variables $Y_1, \dots, Y_k$,

$$\mathbb{E}\left[\sum_{j=1}^k a_j Y_j\right] = \sum_{j=1}^k a_j \mathbb{E}[Y_j].$$

La linealidad no requiere independencia. En cambio, en general

$$\mathbb{E}[g(Y)] \neq g(\mathbb{E}[Y]).$$

Por ejemplo, $\mathbb{E}[Y^2]$ no suele ser igual a $(\mathbb{E}[Y])^2$.

Para una indicadora,

$$\mathbb{E}[\mathbf{1}_A] = 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(A^c) = \mathbb{P}(A).$$

Esta identidad muestra que una probabilidad puede expresarse como una esperanza. La accuracy poblacional de una regla de clasificación será la esperanza del indicador de acierto.

Ejemplo 3: esperanza de una Bernoulli. Si $Y \sim \text{Bernoulli}(p)$,

$$\mathbb{E}[Y] = 0(1 - p) + 1p = p.$$

Por eso el promedio de observaciones binarias es una proporción y puede utilizarse para aproximar la probabilidad p bajo un modelo de muestreo apropiado.

Varianza y desviación estándar

Si Y tiene segundo momento finito, su varianza es

$$\text{Var}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^2].$$

Al desarrollar el cuadrado se obtiene la identidad

$$\text{Var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2.$$

La varianza mide dispersión cuadrática alrededor de la media y se expresa en unidades al cuadrado. La desviación estándar

$$\text{sd}(Y) = \sqrt{\text{Var}(Y)}$$

conserva las unidades de Y .

Para $a, b \in \mathbb{R}$,

$$\text{Var}(aY + b) = a^2 \text{Var}(Y).$$

Sumar una constante desplaza la distribución sin cambiar su dispersión; cambiar la escala por a multiplica la desviación estándar por $|a|$.

En una variable Bernoulli,

$$\text{Var}(Y) = p(1 - p).$$

La variación es cero cuando p es 0 o 1 y alcanza su máximo en $p = 1/2$.

Media y varianza no describen toda la distribución

Dos distribuciones pueden tener la misma media y varianza y diferir en asimetría, colas o número de modos. Por esta razón los resúmenes numéricos deben acompañarse de información sobre la forma de la distribución y el contexto del problema.

Ejemplo 4: misma media, formas distintas. Una variable que toma -1 y 1 con igual probabilidad tiene media 0 y varianza 1. Una variable normal estándar también tiene media 0 y varianza 1, pero admite infinitos valores y posee colas continuas.

Algunas distribuciones de referencia

Las distribuciones no se eligen solo porque una gráfica “se parezca”. Cada familia representa un tipo de resultado y establece supuestos sobre su variación.

Distribución	Soporte	Parámetros	Uso típico
Bernoulli	$\{0, 1\}$	p	un resultado binario
categorica	$\{1, \dots, K\}$	$p_1, \dots, p_K$	una clase entre K opciones
binomial	$\{0, \dots, n\}$	n, p	número de éxitos en n ensayos Bernoulli independientes
uniforme continua	$[a, b]$	a, b	igual densidad en un intervalo
normal	$\mathbb{R}$	μ, σ^2	modelo simétrico continuo y aproximaciones de sumas

Distribución categórica

Si Y toma una de K clases con probabilidades $p_1, \dots, p_K$, donde $p_k \geq 0$ y $\sum_k p_k = 1$, escribimos

$$\mathbb{P}(Y = k) = p_k.$$

Una codificación útil es el vector *one-hot* $E_Y \in \mathbb{R}^K$, cuya coordenada k vale uno si $Y = k$ y cero en otro caso. Entonces

$$\mathbb{E}[E_Y] = (p_1, \dots, p_K)^\top.$$

Distribución binomial

Sean $Y_1, \dots, Y_n$ variables Bernoulli independientes con el mismo parámetro p . El conteo

$$S_n = \sum_{i=1}^n Y_i$$

tiene distribución binomial. Para $k = 0, \dots, n$,

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

Además,

$$\mathbb{E}[S_n] = np, \quad \text{Var}(S_n) = np(1-p).$$

La independencia es parte del modelo. Un conteo de respuestas de personas que pertenecen a los mismos hogares puede presentar más variación que la prevista por una binomial simple.

Distribución normal

Una variable $Y \sim \mathcal{N}(\mu, \sigma^2)$ tiene densidad

$$f_Y(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right).$$

Su media es μ y su varianza es σ^2 . La normal es importante tanto como modelo de variación aproximadamente simétrica como por su papel en aproximaciones de distribuciones de promedios. No debe suponerse normalidad únicamente por conveniencia; colas pesadas, asimetría, límites físicos o mezclas de poblaciones pueden hacerla inadecuada.

Distribuciones conjuntas y marginales

Para estudiar relaciones entre variables necesitamos su distribución conjunta. El par (X, Y) tiene distribución

$$P_{X,Y}(A \times B) = \mathbb{P}(X \in A, Y \in B).$$

Las distribuciones individuales se obtienen ignorando la otra variable y se llaman **marginales**:

$$P_X(A) = P_{X,Y}(A \times \mathcal{Y}), \quad P_Y(B) = P_{X,Y}(\mathcal{X} \times B).$$

Conocer solo las marginales no determina la relación entre X y Y . Dos pares pueden compartir las mismas distribuciones marginales y tener asociaciones muy distintas.

Ejemplo 5: marginales iguales, relación distinta. Sea X Bernoulli con parámetro $1/2$. Si $Y = X$, ambas marginales son Bernoulli($1/2$) y las variables coinciden. Si $Y = 1 - X$, las marginales siguen siendo las mismas, pero una variable determina el valor opuesto de la otra.

Independencia

Independencia. Las variables aleatorias X y Y son independientes si, para todos los conjuntos medibles A y B ,

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B).$$

En el caso discreto esto equivale a

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

para todos los valores. Si existe densidad conjunta, la factorización correspondiente es

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

casi en todas partes.

Si X y Y son independientes y las esperanzas existen, entonces

$$\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$$

para funciones integrables g y h . La afirmación inversa no vale en general: que un producto particular factorice no demuestra independencia.

Covarianza y correlación

Para variables con segundos momentos finitos, la covarianza es

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

También puede escribirse como

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Una covarianza positiva indica que valores por encima de sus medias tienden a aparecer juntos en sentido lineal; una negativa indica variación en direcciones opuestas. Su magnitud depende de las unidades.

Si ambas desviaciones estándar son positivas, la correlación es

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\text{sd}(X) \text{sd}(Y)}.$$

La correlación pertenece a $[-1, 1]$ y no cambia al multiplicar cada variable por una constante positiva. Mide asociación lineal, no dependencia general ni efecto causal.

La independencia implica covarianza cero cuando existen segundos momentos. La converso es falsa.

Ejemplo 6: incorrelación sin independencia. Sea X uniforme en $[-1, 1]$ y $Y = X^2$. Por simetría, $\mathbb{E}[X] = 0$ y $\mathbb{E}[X^3] = 0$, así que $\text{Cov}(X, Y) = 0$. Sin embargo, Y queda completamente determinado por X ; las variables no son independientes.

Matriz de covarianza

Para un vector aleatorio $X \in \mathbb{R}^d$ con segundo momento finito, definimos

$$\mu = \mathbb{E}[X], \quad \Sigma = \text{Cov}(X) = \mathbb{E}[(X - \mu)(X - \mu)^\top].$$

La entrada (j, k) es $\text{Cov}(X_j, X_k)$. La matriz Σ es simétrica y semidefinida positiva. En efecto, para cualquier $v \in \mathbb{R}^d$,

$$v^\top \Sigma v = \mathbb{E}[(v^\top (X - \mu))^2] = \text{Var}(v^\top X) \geq 0.$$

Esta identidad explica el significado geométrico de la covarianza: $v^\top \Sigma v$ es la variación de X en la dirección v . La matriz reaparecerá en escalamiento, propagación de varianza y análisis de componentes principales.

Muestras aleatorias

Sea Z una variable aleatoria con distribución P . Una muestra aleatoria de tamaño m se representará como la tupla ordenada

$$D_m = (Z_1, \dots, Z_m).$$

Antes de observarla, D_m es un vector aleatorio. Después de observar los datos, obtenemos la realización

$$d_m = (z_1, \dots, z_m).$$

En aprendizaje supervisado, $Z_i = (X_i, Y_i)$ y

$$D_m = ((X_1, Y_1), \dots, (X_m, Y_m)).$$

Esta notación evita identificar la muestra aleatoria con el archivo concreto. Un algoritmo aplicado a D_m produce una salida aleatoria; el mismo algoritmo aplicado a d_m produce el valor observado en nuestro computador.

El supuesto iid

Una idealización frecuente es

$$Z_1, \dots, Z_m \stackrel{\text{iid}}{\sim} P.$$

La notación contiene dos supuestos:

1. **idéntica distribución:** cada Z_i tiene la misma ley P ;
2. **independencia:** conocer unas observaciones no cambia la distribución de las demás.

El formato rectangular de una tabla no implica ninguno de los dos. El supuesto puede fallar cuando:

- una persona aparece en varias filas;
- observaciones cercanas en tiempo o espacio se influyen;
- unidades pertenecen a hospitales, colegios o regiones con características compartidas;
- el procedimiento de recolección cambia entre periodos;
- la probabilidad de inclusión depende de variables relacionadas con el resultado.

La pregunta correcta no es simplemente “¿los datos son iid?”, sino “¿qué unidad podría considerarse aproximadamente independiente y respecto a qué distribución?”. En datos agrupados, el grupo puede ser la unidad independiente; en series de tiempo, el orden es parte del objeto y no debe destruirse con una permutación arbitraria.

Muestreo con y sin reemplazo

Si se seleccionan unidades con reemplazo de una población finita, las selecciones son independientes y tienen la misma distribución. Sin reemplazo, las unidades seleccionadas son dependientes: observar una unidad modifica lo que queda disponible. Cuando la población es muy grande frente a la muestra, el modelo iid puede ser una aproximación razonable; cuando la fracción muestreada es importante, la dependencia debe incorporarse.

El caso de las subzonas

Las 32 filas de Bogotá no son 32 viviendas iid. Son subzonas agregadas y no se ha establecido aquí un diseño aleatorio de selección. Pueden existir dependencias espaciales y diferencias sistemáticas de cobertura. Podemos describir la tabla y utilizarla para aprender un procedimiento, pero una afirmación sobre una población más amplia necesita supuestos que la fuente por sí sola no proporciona.

Distribución empírica

Dada una realización $d_m = (z_1, \dots, z_m)$, la distribución empírica es

$$\hat{P}_m = \frac{1}{m} \sum_{i=1}^m \delta_{z_i},$$

donde δ_{z_i} asigna masa uno al valor observado z_i . La distribución empírica asigna peso $1/m$ a cada registro.

Para cualquier función g definida sobre los registros,

$$\int g(z) d\hat{P}_m(z) = \frac{1}{m} \sum_{i=1}^m g(z_i).$$

Esta identidad conecta integrales respecto a una distribución con promedios calculables. Un histograma, una tabla de frecuencias y muchos resúmenes numéricos son descripciones de $\hat{P}_m$.

La distribución empírica no es “la distribución verdadera”. Si repitiéramos el muestreo, cambiarían sus puntos de masa y sus resúmenes. La diferencia entre $\hat{P}_m$ y P es una fuente central de incertidumbre.

Función de distribución empírica

Para observaciones reales $y_1, \dots, y_m$, la función de distribución empírica es

$$\hat{F}_m(t) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}\{y_i \leq t\}.$$

Para cada t , $\hat{F}_m(t)$ es la proporción de observaciones menores o iguales que t . A diferencia de un histograma, no depende de escoger intervalos.

Resúmenes muestrales

La media observada es

$$\bar{y}_m = \frac{1}{m} \sum_{i=1}^m y_i.$$

Antes de observar la muestra, la cantidad correspondiente es

$$\bar{Y}_m = \frac{1}{m} \sum_{i=1}^m Y_i,$$

que es una variable aleatoria. Mayúsculas y minúsculas distinguen el estadístico antes del muestreo de su valor calculado.

La varianza descriptiva con denominador m es

$$\hat{v}_m = \frac{1}{m} \sum_{i=1}^m (y_i - \bar{y}_m)^2.$$

También se usa

$$s_m^2 = \frac{1}{m-1} \sum_{i=1}^m (y_i - \bar{y}_m)^2.$$

Bajo muestreo iid con varianza finita, s_m^2 es un estimador insesgado de $\text{Var}(Y)$. El denominador m corresponde al segundo momento central de la distribución empírica. Ninguna fórmula es universalmente “la varianza” sin indicar qué objeto se resume y con qué propósito.

Para vectores $x_i \in \mathbb{R}^d$, la media y la covarianza empíricas con denominador m son

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \quad \hat{\Sigma}_m = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^\top.$$

Estadísticos y distribuciones muestrales

Estadístico. Un estadístico es una función de la muestra que no depende de cantidades poblacionales desconocidas:

$$T_m = T(D_m).$$

Como D_m es aleatoria, T_m también lo es. Su distribución bajo repetición del muestreo se llama **distribución muestral**. Después de observar d_m , obtenemos el valor $t_m = T(d_m)$.

La media, una proporción, una covarianza empírica, un coeficiente ajustado y una métrica calculada son estadísticos. No tienen la misma distribución muestral ni la misma sensibilidad a observaciones

extremas. El capítulo siguiente estudiará cuándo un estadístico sirve para estimar una cantidad poblacional y cómo describir su incertidumbre.

Por qué se estabilizan los promedios

Supongamos que $Y_1, \dots, Y_m$ son iid, con

$$\mathbb{E}[Y_i] = \mu, \quad \text{Var}(Y_i) = \sigma^2 < \infty.$$

Por linealidad,

$$\mathbb{E}[\bar{Y}_m] = \mu.$$

La independencia hace que las covarianzas entre observaciones distintas sean cero, de modo que

$$\text{Var}(\bar{Y}_m) = \text{Var}\left(\frac{1}{m} \sum_{i=1}^m Y_i\right) = \frac{1}{m^2} \sum_{i=1}^m \text{Var}(Y_i) = \frac{\sigma^2}{m}.$$

La desviación estándar del promedio decrece como $1/\sqrt{m}$. Duplicar el tamaño de muestra no divide la variación por dos; para reducir a la mitad la desviación estándar se necesita multiplicar el tamaño por cuatro, bajo estos supuestos.

La desigualdad de Chebyshev da, para todo $\varepsilon > 0$,

$$\mathbb{P}(|\bar{Y}_m - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{m\varepsilon^2}.$$

El lado derecho tiende a cero cuando m crece. Esto conduce a la forma de la ley de los grandes números que utilizaremos:

Ley de los grandes números. Si $Y_1, Y_2, \dots$ son iid y tienen esperanza finita, entonces

$$\bar{Y}_m \xrightarrow{\mathbb{P}} \mathbb{E}[Y].$$

La notación significa que, para todo $\varepsilon > 0$,

$$\mathbb{P}(|\bar{Y}_m - \mathbb{E}[Y]| > \varepsilon) \rightarrow 0.$$

La ley justifica aproximar una esperanza mediante un promedio bajo condiciones de muestreo apropiadas. No corrige sesgo de selección, dependencia, mediciones defectuosas ni cambio de población. Una muestra enorme obtenida del marco equivocado puede producir un promedio muy estable de una cantidad que no responde a la pregunta original.

Un experimento de simulación

El siguiente código genera muchas muestras Bernoulli con $p = 0.3$ y observa sus promedios:

```
import numpy as np

rng = np.random.default_rng(2105)
p = 0.3
repeticiones = 5000

for m in [20, 100, 500]:
    muestras = rng.binomial(1, p, size=(repeticiones, m))
    medias = muestras.mean(axis=1)
    print(
        m,
        medias.mean(),
        medias.std(ddof=1),
        np.sqrt(p * (1 - p) / m),
    )
```

El promedio de las medias simuladas se acerca a p . Su desviación estándar se aproxima a $\sqrt{p(1-p)/m}$ y disminuye al aumentar m . La simulación ilustra el resultado; no lo sustituye ni demuestra que un dataset real sea iid.

Qué aporta y qué no aporta el modelo probabilístico

La probabilidad permite distinguir tres niveles:

Nivel	Objeto	Ejemplo
proceso o población	$P, \mathbb{E}[Y], \text{Cov}(X)$	cantidades definidas antes de observar la muestra
muestra aleatoria	$D_m = (Z_1, \dots, Z_m)$	posibles conjuntos de datos
realización observada	$d_m = (z_1, \dots, z_m)$	tabla concreta disponible

El paso de P a D_m exige un mecanismo de muestreo o una idealización del proceso. El paso de D_m a d_m corresponde a la realización observada. Los cálculos se hacen con d_m , pero las conclusiones sobre otras observaciones se formulan respecto a P .

El modelo probabilístico no crea representatividad. Si la población, el marco o la unidad fueron mal definidos, escribir $Z_i \stackrel{\text{iid}}{\sim} P$ solo oculta el problema bajo una notación compacta. La formalización es útil precisamente porque obliga a declarar qué distribución y qué mecanismo se están suponiendo.

Síntesis

Un espacio de probabilidad describe resultados posibles y eventos. Una variable aleatoria transforma esos resultados en valores de interés; una realización es el valor concreto que aparece después de observar. La distribución de una variable puede representarse mediante su función acumulada y, según el caso, mediante una función de masa o una densidad.

La esperanza, la varianza y la covarianza son propiedades de una distribución. La independencia describe una factorización de la distribución conjunta y es más fuerte que tener covarianza cero. Para vectores aleatorios, la matriz de covarianza resume la variación lineal en todas las direcciones.

Una muestra aleatoria D_m debe distinguirse de su realización d_m . Bajo un modelo iid, los promedios muestrales se estabilizan alrededor de sus esperanzas, pero esta conclusión depende de independencia, distribución común y momentos apropiados. La distribución empírica resume los datos observados; no reemplaza sin supuestos la distribución poblacional.

Términos clave

- **Espacio muestral:** conjunto de resultados elementales posibles.
- **Evento:** subconjunto medible del espacio muestral.
- **Variable aleatoria:** función medible de un resultado a un espacio de valores.
- **Realización:** valor observado de una variable aleatoria.
- **Distribución:** ley probabilística inducida por una variable aleatoria.
- **Función de masa:** probabilidades puntuales de una variable discreta.
- **Densidad:** función cuya integral sobre un conjunto da su probabilidad.
- **Esperanza:** promedio de una variable respecto a su distribución.
- **Varianza:** dispersión cuadrática respecto a la esperanza.
- **Covarianza:** medida de variación lineal conjunta.
- **Independencia:** factorización de probabilidades conjuntas en marginales.
- **Muestra aleatoria:** colección de variables antes de observar sus realizaciones.
- **Distribución empírica:** ley que asigna peso uniforme a los valores observados.
- **Estadístico:** función de una muestra aleatoria.
- **Distribución muestral:** distribución de un estadístico bajo repetición del muestreo.

Ejercicios

Comprensión conceptual

1. Distinga resultado elemental, evento, variable aleatoria y realización mediante el experimento de lanzar dos dados.
2. Explique por qué una columna observada no es una variable aleatoria. Use la notación Y y $(y_1, \dots, y_m)$ en su respuesta.
3. ¿Puede una densidad tomar un valor mayor que uno? Construya un ejemplo uniforme y explique por qué no contradice los axiomas de probabilidad.

4. Dé dos pares de variables con las mismas distribuciones marginales y distinta distribución conjunta.
5. Explique por qué independencia implica covarianza cero bajo momentos finitos, pero covarianza cero no implica independencia.
6. Distinga muestra aleatoria D_m y realización d_m . ¿Cuál de las dos recibe un algoritmo cuando se ejecuta en el computador?
7. Dé un ejemplo donde las filas tengan la misma distribución marginal pero no sean independientes, y otro donde sean independientes pero no tengan la misma distribución.
8. Explique qué significa que un promedio converja en probabilidad. Evite la frase “eventualmente es igual”.

Problemas cuantitativos

9. Una variable Y toma valores $-1, 0, 2$ con probabilidades $0.2, 0.5, 0.3$. Calcule $\mathbb{E}[Y]$, $\mathbb{E}[Y^2]$ y $\text{Var}(Y)$.
10. Si $Y \sim \text{Bernoulli}(0.2)$, calcule su esperanza, varianza y desviación estándar.
11. Sean $Y_1, \dots, Y_{50}$ Bernoulli independientes con $p = 0.2$. Calcule la esperanza y la varianza del número total de éxitos, y la esperanza y varianza de la proporción de éxitos.
12. Para $y = (2, 4, 4, 10)$, calcule la media, la varianza descriptiva con denominador m y la varianza con denominador $m - 1$.
13. Una variable tiene media 10 y varianza 9. Defina $W = 100Y + 5$. Calcule $\mathbb{E}[W]$, $\text{Var}(W)$ y $\text{sd}(W)$.
14. Sean X y Y variables con varianzas 4 y 9 y covarianza 3. Calcule $\text{Var}(2X - Y)$.
15. Una matriz de covarianza es

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 9 \end{bmatrix}.$$

Calcule la varianza de $X_1 + X_2$ y la correlación entre X_1 y X_2 .

16. Use la desigualdad de Chebyshev para acotar $\mathbb{P}(|\bar{Y}_m - \mu| \geq 0.5)$ cuando $\sigma^2 = 4$ y $m = 100$. ¿Qué tamaño garantiza mediante esta cota un valor no mayor que 0.01?

Práctica computacional

17. Simule 1000 muestras normales de tamaños 10, 50 y 500. Compare la desviación observada de las medias con $\sigma/\sqrt{m}$.
18. Simule una variable X uniforme en $[-1, 1]$ y $Y = X^2$. Calcule correlación y produzca un diagrama de dispersión. Explique por qué la correlación no resume la dependencia.
19. Implemente una función de distribución empírica $\hat{F}_m(t)$ y compárela con una implementación de biblioteca para diez valores de t .
20. Genere dos variables Bernoulli con marginales 1/2: primero haga $Y = X$ y luego genere Y de manera independiente. Compare tablas conjuntas y marginales.
21. Para `load_wine`, calcule media y covarianza empíricas de las variables numéricas. Verifique numéricamente que los autovalores de la covarianza no sean negativos salvo tolerancia de redondeo.
22. Simule datos agrupados con un efecto común por grupo. Compare la variación de la media entre repeticiones con la que se obtendría si todas las filas fueran independientes.

Interpretación y formulación

23. Una encuesta en línea obtiene un millón de respuestas voluntarias. Explique por qué la ley de los grandes números no basta para concluir que el promedio representa a toda la población.
24. En una serie diaria, la medición de hoy está correlacionada con la de ayer. Explique qué parte del supuesto iid falla y qué información se perdería al permutar las fechas.
25. Para un conjunto de datos de su interés, proponga una variable aleatoria Z , su espacio de valores, una población o proceso P y una interpretación de D_m . Declare por qué las observaciones podrían no ser iid.
26. En el caso de Bogotá, indique qué significado tendría tratar las 32 subzonas como una muestra de una distribución. Liste los supuestos que necesitaría y la información que todavía no está disponible.

Respuestas seleccionadas

3. Sí. Una uniforme en $[0, 1/2]$ tiene densidad 2 dentro del intervalo. La probabilidad total es el área $2(1/2) = 1$; la altura de una densidad no es una probabilidad puntual.

9.

$$\mathbb{E}[Y] = -1(0.2) + 0(0.5) + 2(0.3) = 0.4,$$

$$\mathbb{E}[Y^2] = 1(0.2) + 0 + 4(0.3) = 1.4,$$

y $\text{Var}(Y) = 1.4 - 0.4^2 = 1.24$.

11. Para $S = \sum_{i=1}^{50} Y_i$, $\mathbb{E}[S] = 10$ y $\text{Var}(S) = 8$. Para $\bar{Y} = S/50$, la esperanza es 0.2 y la varianza es $0.2(0.8)/50 = 0.0032$.

12. La media es 5. La suma de desviaciones cuadradas es 36. Por tanto, la varianza con denominador 4 es 9 y la varianza con denominador 3 es 12.

14.

$$\text{Var}(2X - Y) = 4 \text{Var}(X) + \text{Var}(Y) - 4 \text{Cov}(X, Y) = 16 + 9 - 12 = 13.$$

15. Con $v = (1, 1)^\top$, $\text{Var}(X_1 + X_2) = v^\top \Sigma v = 17$. La correlación es $2/(2 \cdot 3) = 1/3$.

16. La cota es $4/(100 \cdot 0.5^2) = 0.16$. Para que sea a lo sumo 0.01 se requiere $4/(m \cdot 0.25) \leq 0.01$, es decir, $m \geq 1600$.

23. La ley describe estabilización alrededor de la esperanza de la distribución que generó la muestra. Si la participación voluntaria selecciona un grupo distinto de la población objetivo, una muestra grande estabiliza el promedio de ese grupo y no elimina el sesgo de cobertura o selección.

Condicionamiento, estimación, riesgo e incertidumbre

Referencia matemática sobre aprendizaje a partir de muestras

La regresión, la clasificación y la evaluación de modelos han planteado una misma dificultad de varias formas: la cantidad de interés pertenece a una distribución, pero el cálculo disponible utiliza una muestra particular. La media condicional, la probabilidad de una clase, el desempeño esperado de una regla y la variación de una métrica son ejemplos de esa diferencia entre objeto poblacional y evidencia observada.

Este capítulo estudia ese vínculo de manera sistemática. El condicionamiento describe cómo cambia una distribución cuando se conocen las entradas. La teoría de estimación distingue la cantidad poblacional, el procedimiento que la aproxima y el valor obtenido. El riesgo esperado establece el objetivo de una regla de predicción, y la incertidumbre cuantifica cuánto puede variar la evidencia empírica utilizada para evaluarla. Las secciones amplían desarrollos que aparecen en los capítulos de regresión, regularización, clasificación y estrategia de modelado.

Al terminar el capítulo, el lector podrá:

1. calcular e interpretar probabilidades y distribuciones condicionales;
2. utilizar esperanza condicional y sus propiedades fundamentales;
3. explicar por qué la media condicional y la probabilidad condicional son objetivos naturales de regresión y clasificación;
4. distinguir estimando, estimador, estimación y distribución muestral;
5. analizar sesgo, varianza, error cuadrático medio y consistencia;
6. separar riesgo esperado y riesgo empírico;
7. explicar los papeles de entrenamiento, validación y prueba;
8. estimar el error estándar de una media de pérdidas e interpretar un intervalo;
9. decidir qué debe remuestrearse en un bootstrap;
10. reconocer cuándo un cambio de distribución limita la evaluación.

Los conceptos se conectan con los modelos de la siguiente manera:

Objeto de este capítulo	Problema que lo hace necesario
esperanza condicional	predecir una respuesta numérica bajo pérdida cuadrática
probabilidad condicional	modelar una clase y separar probabilidad de decisión
estimador y distribución muestral	describir cómo cambia un ajuste con la muestra

Objeto de este capítulo	Problema que lo hace necesario
riesgo esperado y empírico	distinguir objetivo poblacional y función calculable
sesgo y varianza	estudiar complejidad y regularización
error estándar y bootstrap	cuantificar variación en métricas y comparaciones
cambio de distribución	evaluar si los datos representan el contexto de uso

Esta organización permite volver a la teoría desde un problema ya conocido y, al mismo tiempo, comparar bajo una notación común ideas que aparecieron en capítulos diferentes.

Probabilidad condicional

La información modifica las probabilidades relevantes. Si A y B son eventos con $\mathbb{P}(B) > 0$, la probabilidad condicional de A dado B es

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

El numerador conserva los resultados en los que ocurren ambos eventos; el denominador renormaliza la probabilidad dentro del conjunto B .

Ejemplo 1: una tabla de contingencia. En una muestra de 200 solicitudes, 50 corresponden al grupo B y 20 de esas 50 presentan el resultado A . Las proporciones empíricas son

$$\hat{P}(B) = \frac{50}{200}, \quad \hat{P}(A \cap B) = \frac{20}{200},$$

de modo que

$$\hat{P}(A | B) = \frac{20/200}{50/200} = 0.4.$$

El denominador de la proporción condicional es 50, no 200.

De la definición se obtiene la regla del producto:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B)\mathbb{P}(B).$$

Si $B_1, \dots, B_K$ forman una partición de Ω , entonces la ley de probabilidad total establece

$$\mathbb{P}(A) = \sum_{k=1}^K \mathbb{P}(A | B_k)\mathbb{P}(B_k).$$

Esta identidad separa la frecuencia del resultado dentro de cada grupo de la frecuencia con la que aparecen los grupos.

Fórmula de Bayes

Siempre que $\mathbb{P}(A) > 0$ y $\mathbb{P}(B) > 0$,

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A | B)\mathbb{P}(B)}{\mathbb{P}(A)}.$$

Con una partición $B_1, \dots, B_K$,

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(A | B_j)\mathbb{P}(B_j)}{\sum_{k=1}^K \mathbb{P}(A | B_k)\mathbb{P}(B_k)}.$$

La fórmula muestra por qué una tasa de acierto condicional no basta para interpretar una prueba: también importa la prevalencia previa de cada grupo.

Ejemplo 2: una prueba y una condición poco frecuente. Suponga que una condición afecta al 1 % de una población, una prueba es positiva en el 95 % de quienes tienen la condición y en el 5 % de quienes no la tienen. Entonces

$$\mathbb{P}(C | +) = \frac{0.95(0.01)}{0.95(0.01) + 0.05(0.99)} \approx 0.161.$$

Un resultado positivo no implica una probabilidad posterior de 95 %. La diferencia proviene de intercambiar $\mathbb{P}(+ | C)$ con $\mathbb{P}(C | +)$ y de ignorar la prevalencia.

Independencia vista mediante condicionamiento

Si A y B son independientes y $\mathbb{P}(B) > 0$, entonces

$$\mathbb{P}(A | B) = \mathbb{P}(A).$$

Observar B no modifica la probabilidad de A . Esta igualdad es equivalente a $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ cuando las probabilidades necesarias son positivas.

Distribuciones condicionales

Para variables discretas X y Y , la función de masa condicional es

$$p_{Y|X}(y | x) = \mathbb{P}(Y = y | X = x) = \frac{p_{X,Y}(x, y)}{p_X(x)},$$

si $p_X(x) > 0$. Para cada valor fijo de x ,

$$\sum_y p_{Y|X}(y | x) = 1.$$

Si (X, Y) posee densidad conjunta y $f_X(x) > 0$, una densidad condicional puede definirse como

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

Cuando X es continua, normalmente $\mathbb{P}(X = x) = 0$. Por ello la distribución de Y dado $X = x$ no se obtiene dividiendo por esa probabilidad puntual. La fórmula de densidades, o más generalmente una distribución condicional regular, proporciona el objeto adecuado. En los modelos de este libro asumiremos que existe una versión condicional bien definida para los valores relevantes de x .

La distribución conjunta puede reconstruirse a partir de una marginal y una condicional. En el caso de densidades,

$$f_{X,Y}(x, y) = f_{Y|X}(y | x)f_X(x).$$

Este factor permite separar cómo aparecen las entradas de cómo se distribuye la salida entre unidades con entradas semejantes.

Esperanza condicional

La esperanza condicional de Y dado X es una variable aleatoria que depende de X . Se denota por

$$\mathbb{E}[Y | X].$$

En condiciones usuales puede escribirse como una función $\mu(X)$, donde

$$\mu(x) = \mathbb{E}[Y | X = x].$$

Para variables discretas,

$$\mu(x) = \sum_y y p_{Y|X}(y | x).$$

Si existe una densidad condicional,

$$\mu(x) = \int y f_{Y|X}(y | x) dy.$$

La función μ se denomina **función de regresión poblacional**. No tiene que ser lineal. Una regresión lineal aproxima esta función dentro de una familia lineal; una red neuronal utiliza una familia más flexible.

Propiedades fundamentales

Si $g(X)$ es integrable, entonces

$$\mathbb{E}[g(X)Y | X] = g(X)\mathbb{E}[Y | X].$$

La ley de la esperanza total afirma

$$\mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[Y].$$

Es decir, promediar primero dentro de cada valor de X y luego sobre la distribución de X recupera la media marginal.

Cuando Y tiene segundo momento finito, la varianza total se descompone como

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

El primer término es la variación promedio que permanece entre unidades con el mismo X . El segundo es la variación de las medias condicionales entre distintos valores de X . Esta identidad separa variación no explicada por X de variación asociada a cambios en X , sin convertir la asociación en una afirmación causal.

Ejemplo 3: media por grupos. Si X indica dos grupos con probabilidades 0.6 y 0.4, y las medias condicionales de Y son 10 y 15, entonces

$$\mathbb{E}[Y] = 0.6(10) + 0.4(15) = 12.$$

Conocer solo la media marginal 12 no revela las diferencias entre grupos.

Objetivos poblacionales en aprendizaje supervisado

El condicionamiento permite identificar qué cantidad intenta aproximar un modelo.

Pérdida cuadrática y media condicional

Sean Y y $g(X)$ variables con segundo momento finito. Para un valor de X , se puede escribir

$$Y - g(X) = (Y - \mathbb{E}[Y | X]) + (\mathbb{E}[Y | X] - g(X)).$$

Al elevar al cuadrado y condicionar en X , el término cruzado tiene esperanza cero porque

$$\mathbb{E}[Y - \mathbb{E}[Y | X] | X] = 0.$$

Por tanto,

$$\mathbb{E}[(Y - g(X))^2 | X] = \text{Var}(Y | X) + (\mathbb{E}[Y | X] - g(X))^2.$$

El primer término no depende de g y el segundo es no negativo. En consecuencia,

$$g^*(x) = \mathbb{E}[Y | X = x]$$

minimiza el riesgo cuadrático entre todas las funciones admisibles. Si restringimos g a una familia, por ejemplo funciones lineales, el mejor elemento de esa familia no tiene por qué coincidir con la media condicional verdadera.

Clasificación binaria y probabilidad condicional

Si $Y \in \{0, 1\}$, definimos

$$\eta(x) = \mathbb{P}(Y = 1 | X = x).$$

Para una predicción probabilística $q \in (0, 1)$, la pérdida logarítmica es

$$\ell(q, y) = -y \log q - (1 - y) \log(1 - q).$$

El riesgo condicional es

$$L_x(q) = -\eta(x) \log q - (1 - \eta(x)) \log(1 - q).$$

Cuando $0 < \eta(x) < 1$, su derivada y segunda derivada son

$$L'_x(q) = -\frac{\eta(x)}{q} + \frac{1 - \eta(x)}{1 - q},$$

$$L''_x(q) = \frac{\eta(x)}{q^2} + \frac{1 - \eta(x)}{(1 - q)^2} > 0.$$

La única solución de $L'_x(q) = 0$ es $q = \eta(x)$ y es el mínimo. Si se extiende la pérdida a $q \in [0, 1]$ con la convención usual $0 \log 0 = 0$, entonces para $\eta(x) = 0$ o 1 el mínimo se alcanza en el borde correspondiente.

Un modelo logístico produce

$$\hat{p}_\theta(x) = \sigma(x^\top \theta).$$

Esta es una probabilidad estimada. Solo bajo supuestos de especificación y ajuste adecuados puede identificarse con $\eta(x)$. Incluso una probabilidad estimada que ordena bien los casos puede estar mal calibrada.

De probabilidad a decisión

Una probabilidad no determina por sí sola una clase. Si el costo de un falso negativo es c_{FN} y el de un falso positivo es c_{FP} , una regla idealizada con costos constantes predice la clase positiva cuando

$$\eta(x) > \frac{c_{\text{FP}}}{c_{\text{FP}} + c_{\text{FN}}}.$$

En la práctica usamos $\hat{p}(x)$ y elegimos el umbral con datos de validación, no con el conjunto reservado para la estimación final. El umbral depende del uso, los costos, la prevalencia y la calibración; 0.5 no es una ley universal.

Ruido, residual y error de medición

Si definimos

$$\mu(X) = \mathbb{E}[Y \mid X], \quad \varepsilon = Y - \mu(X),$$

entonces, por construcción,

$$\mathbb{E}[\varepsilon \mid X] = 0.$$

La igualdad no afirma que ε sea independiente de X ni que tenga varianza constante. Tampoco implica una distribución normal.

Cuando se propone un modelo $f_\theta(X)$ y se escribe

$$Y = f_\theta(X) + \varepsilon,$$

la condición $\mathbb{E}[\varepsilon \mid X] = 0$ es un supuesto de especificación. Se cumple automáticamente solo si $f_\theta(X) = \mu(X)$.

Conviene distinguir:

Objeto	Definición	Momento en que existe
ruido ε	componente aleatoria no explicada dentro del modelo poblacional	antes de observar
residual r_i error de medición	$y_i - \hat{y}_i$ diferencia entre registro y cantidad que se pretendía medir	después de ajustar y observar durante la medición
error de predicción	pérdida entre predicción y resultado en un caso	después de conocer el resultado

Un residual puede reflejar variación intrínseca, variables omitidas, forma funcional inadecuada, cambio de población o error de medición. Un residual pequeño en los datos de ajuste no demuestra que el modelo represente correctamente el proceso.

Estimandos, estimadores y estimaciones

Estimando. Un estimando es la cantidad poblacional que se desea conocer. Puede ser un número, un vector, una función o una característica de una distribución.

Ejemplos de estimandos son

$$\mu = \mathbb{E}[Y], \quad p = \mathbb{P}(Y = 1), \quad \Sigma = \text{Cov}(X), \quad \mu(x) = \mathbb{E}[Y \mid X = x].$$

En un modelo paramétrico $\{P_\theta : \theta \in \Theta\}$, el parámetro θ es un estimando si representa la característica poblacional que se desea conocer. En modelos predictivos, los coeficientes también pueden ser cantidades internas del procedimiento y no siempre poseen una interpretación poblacional única fuera de la familia elegida.

Estimador. Un estimador es una función de la muestra aleatoria,

$$\hat{\theta}_m = T(D_m),$$

diseñada para aproximar un estimando θ .

Antes de observar la muestra, $\hat{\theta}_m$ es una variable aleatoria. Después de observar d_m , el valor

$$\hat{\theta}_m(d_m)$$

es una **estimación**. El estimador es la regla; la estimación es el resultado numérico de aplicarla.

Nivel	Notación	Ejemplo
estimando	$\mu = \mathbb{E}[Y]$	media poblacional

Nivel	Notación	Ejemplo
estimador	$\bar{Y}_m$	media de una muestra todavía aleatoria
estimación	$\bar{y}_m = 12.4$	valor calculado con la muestra observada
distribución muestral	ley de $\bar{Y}_m$	variación bajo muestras repetidas

Sesgo

El sesgo de $\hat{\theta}_m$ para estimar θ es

$$\text{Bias}(\hat{\theta}_m) = \mathbb{E}[\hat{\theta}_m] - \theta.$$

Un estimador es insesgado si el sesgo es cero. Esta es una propiedad bajo un modelo de muestreo, no una garantía de que la estimación observada sea igual al estimando. Un estimador insesgado puede tener gran variación.

Para una muestra iid con esperanza μ ,

$$\mathbb{E}[\bar{Y}_m] = \frac{1}{m} \sum_{i=1}^m \mathbb{E}[Y_i] = \mu,$$

de modo que la media muestral es insesgada para μ .

Varianza y error cuadrático medio

Para un estimador escalar, su varianza es

$$\text{Var}(\hat{\theta}_m) = \mathbb{E}[(\hat{\theta}_m - \mathbb{E}[\hat{\theta}_m])^2].$$

El error cuadrático medio respecto a θ es

$$\text{MSE}(\hat{\theta}_m) = \mathbb{E}[(\hat{\theta}_m - \theta)^2].$$

Al sumar y restar $\mathbb{E}[\hat{\theta}_m]$ se obtiene

$$\text{MSE}(\hat{\theta}_m) = \text{Var}(\hat{\theta}_m) + \text{Bias}(\hat{\theta}_m)^2.$$

La identidad muestra que un estimador ligeramente sesgado puede tener menor error cuadrático medio si reduce suficientemente la varianza. La regularización explota esta posibilidad: introduce sesgo para estabilizar coeficientes y predicciones.

Consistencia

Una secuencia de estimadores es consistente para θ si

$$\hat{\theta}_m \xrightarrow{\mathbb{P}} \theta$$

cuando $m \rightarrow \infty$. La consistencia es una propiedad asintótica. No indica que una muestra finita sea suficiente ni corrige un estimando mal definido, selección sesgada o cambio de distribución.

Error estándar

La desviación estándar de la distribución muestral,

$$\text{sd}(\hat{\theta}_m),$$

describe cuánto varía el estimador entre muestras. Como normalmente depende de cantidades desconocidas, se aproxima mediante un **error estándar estimado**. Reportar una estimación sin su error estándar puede ocultar que otras muestras producirían valores muy distintos.

Pérdida y riesgo esperado

Sea $f : \mathcal{X} \rightarrow \mathcal{A}$ una regla y $\ell : \mathcal{A} \times \mathcal{Y} \rightarrow [0, \infty)$ una función de pérdida. El riesgo de f bajo una distribución de interés P es

$$R_P(f) = \mathbb{E}_{(X,Y) \sim P}[\ell(f(X), Y)].$$

La pérdida asigna un costo a un caso; el riesgo promedia ese costo sobre la distribución. Cambiar la pérdida cambia el objetivo matemático.

Ejemplos:

Problema	Pérdida por observación
regresión cuadrática	$(y - f(x))^2$
regresión absoluta	$ y - f(x) $
clasificación 0-1	$\mathbf{1}\{f(x) \neq y\}$
clasificación probabilística	$-y \log q(x) - (1 - y) \log(1 - q(x))$

El riesgo se refiere a una distribución específica. Si el uso previsto sigue P_{uso} , el objetivo relevante es

$$R_{\text{uso}}(f) = \mathbb{E}_{P_{\text{uso}}}[\ell(f(X), Y)].$$

Una evaluación histórica solo informa sobre este riesgo si su distribución es comparable con la de uso.

Riesgo empírico

Dada una muestra observada $d_m = ((x_1, y_1), \dots, (x_m, y_m))$, el riesgo empírico es

$$\widehat{R}_m(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(x_i), y_i).$$

Mediante la distribución empírica conjunta,

$$\widehat{P}_m = \frac{1}{m} \sum_{i=1}^m \delta_{(x_i, y_i)},$$

podemos escribir

$$\widehat{R}_m(f) = \int \ell(f(x), y) d\widehat{P}_m(x, y).$$

Esta igualdad es el puente exacto entre una esperanza poblacional y una suma implementable.

Para una función f fija e independiente de una muestra iid, la ley de los grandes números permite que $\widehat{R}_m(f)$ aproxime $R_P(f)$ si la pérdida es integrable. La situación es distinta cuando f fue escogida para minimizar el riesgo sobre la misma muestra: entonces f depende de esos datos y el riesgo de entrenamiento puede ser optimista.

Minimización empírica del riesgo

En una familia $\mathcal{F}$, un estimador por minimización empírica satisface

$$\widehat{f} \in \arg \min_{f \in \mathcal{F}} \widehat{R}_{\text{train}}(f).$$

La solución depende de la muestra. Una familia más flexible puede disminuir la pérdida de entrenamiento y, al mismo tiempo, aumentar la variación del modelo entre muestras. Regularización, validación y control de complejidad buscan equilibrar estos efectos.

Baselines

Un **baseline** es una regla simple y reproducible utilizada como referencia. En regresión, una opción común predice la media de la salida en entrenamiento:

$$f_{\text{base}}(x) = \bar{y}_{\text{train}}.$$

En clasificación, puede predecir la clase más frecuente de entrenamiento o las proporciones de clase. El baseline debe ajustarse con la misma información permitida al modelo. Compararlo en las observaciones reservadas permite preguntar si las entradas aportan algo más que una referencia marginal.

Riesgo del modelo ajustado y riesgo del algoritmo

Después de observar una muestra de entrenamiento d_m , el modelo $\hat{f} = A(d_m)$ tiene riesgo

$$R_P(A(d_m)) = \mathbb{E}_{Z \sim P}[\ell(A(d_m)(X), Y)].$$

Este es el desempeño esperado del modelo concreto que quedó ajustado.

También puede interesar el comportamiento del procedimiento A bajo nuevas muestras de entrenamiento, con el caso nuevo Z independiente de D_m :

$$\mathcal{R}_m(A) = \mathbb{E}_{D_m \sim P^m} [R_P(A(D_m))].$$

El segundo objeto incorpora la variación del ajuste entre muestras. Un conjunto de prueba independiente evalúa principalmente el modelo ajustado condicional a la muestra de entrenamiento observada. Repetir todo el proceso sobre nuevas muestras es necesario para estudiar directamente la variación del algoritmo completo.

Entrenamiento, validación y prueba

Una sola muestra suele desempeñar varios papeles. Para evitar que la misma información ajuste, seleccione y certifique el procedimiento, se distinguen:

Conjunto	Papel
entrenamiento	ajustar parámetros y transformaciones aprendidas
validación	elegir familia, variables, hiperparámetros y umbral
prueba	estimar al final el desempeño del procedimiento ya fijado

La separación no es un ritual. Permite que la evaluación final sea independiente de las decisiones tomadas durante el desarrollo.

Si un procedimiento consulta repetidamente la validación, también puede adaptarse a ella. La métrica de validación debe interpretarse como parte de la selección, no como una estimación final neutral. La validación cruzada y los procedimientos anidados refinan esta idea y se estudiarán en capítulos posteriores.

Qué debe ajustarse dentro de entrenamiento

Toda transformación que aprende de los datos forma parte del algoritmo:

- medias y desviaciones para escalar;
- reglas de imputación;
- categorías observadas;
- selección de variables;
- componentes principales;

- calibración y elección de umbrales.

Estas operaciones se ajustan con entrenamiento y se aplican sin volver a aprender en validación o prueba. Una `Pipeline` ayuda a expresar esta dependencia en código.

El conjunto de prueba se utiliza una vez

Si se modifica el modelo después de consultar prueba, esa muestra participó en la selección. El reporte resultante tiende a favorecer las decisiones que funcionaron accidentalmente bien en esas observaciones. Para recuperar una evaluación final se necesita una nueva muestra independiente o un diseño que modele explícitamente la selección realizada.

Incertidumbre de una métrica

Supongamos que un modelo ya está fijado y se evalúa en observaciones iid que no intervinieron en el ajuste. Definimos las pérdidas

$$L_i = \ell(f(X_i), Y_i), \quad i = 1, \dots, n.$$

La estimación de riesgo es

$$\widehat{R}_n = \bar{L}_n = \frac{1}{n} \sum_{i=1}^n L_i.$$

Si $\text{Var}(L_i) = \sigma_L^2 < \infty$, entonces

$$\text{Var}(\widehat{R}_n) = \frac{\sigma_L^2}{n}.$$

Con la varianza muestral

$$s_L^2 = \frac{1}{n-1} \sum_{i=1}^n (L_i - \bar{L}_n)^2,$$

estimamos el error estándar mediante

$$\widehat{\text{se}}(\widehat{R}_n) = \frac{s_L}{\sqrt{n}}.$$

Esta fórmula trata el modelo como fijo y la muestra de evaluación como la fuente de variación. No incluye automáticamente la variación causada por volver a ajustar el modelo con otra muestra.

Aproximación normal e intervalos

Bajo condiciones del teorema central del límite,

$$\frac{\sqrt{n}(\widehat{R}_n - R_P(f))}{\sigma_L} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1).$$

Esto motiva el intervalo aproximado

$$\widehat{R}_n \pm z_{1-\alpha/2} \widehat{\text{se}}(\widehat{R}_n).$$

Para un nivel aproximado de 95 %, $z_{0.975} \approx 1.96$.

La interpretación frecuentista se refiere al procedimiento: si repitiéramos el muestreo y construyéramos el intervalo de la misma manera, aproximadamente el 95 % de esos intervalos contendría el riesgo fijo bajo las condiciones del método. No significa que, después de calcular los extremos, el parámetro fijo tenga 95 % de probabilidad de estar dentro.

La aproximación puede ser deficiente con muestras pequeñas, pérdidas de cola pesada o proporciones cercanas a 0 o 1. Para accuracy, los L_i son indicadores de error; intervalos binomiales como Wilson suelen comportarse mejor que el intervalo normal elemental cerca de los bordes.

Una cota para pérdidas acotadas

Si $0 \leq L_i \leq 1$, las observaciones son iid y el modelo es fijo e independiente de la muestra de evaluación, la desigualdad de Hoeffding da

$$\mathbb{P}(|\widehat{R}_n - R_P(f)| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

La cota no necesita conocer la varianza, pero puede ser conservadora. Sus condiciones son esenciales: no se aplica directamente al riesgo de entrenamiento del modelo escogido con esos mismos datos.

Comparar dos modelos en los mismos casos

Si dos modelos A y B se evalúan sobre las mismas observaciones, conviene analizar las diferencias emparejadas

$$D_i = L_i^{(A)} - L_i^{(B)}.$$

La diferencia media

$$\overline{D}_n = \frac{1}{n} \sum_{i=1}^n D_i$$

estima la diferencia de riesgos y su error estándar se calcula a partir de la variación de los D_i . Tratar las dos listas de pérdidas como muestras independientes desperdicia la información de que cada par corresponde al mismo caso.

Bootstrap

El bootstrap aproxima una distribución muestral mediante remuestreo de los datos observados. En su versión iid elemental:

1. se parte de $d_n = (z_1, \dots, z_n)$;
2. se generan B muestras de tamaño n con reemplazo desde d_n ;
3. se calcula el estadístico T en cada muestra;
4. se utiliza la distribución de $T^{*(1)}, \dots, T^{*(B)}$ para estimar error estándar, sesgo o cuantiles.

El remuestreo con reemplazo equivale a extraer observaciones de la distribución empírica $\hat{P}_n$. Su validez depende de que $\hat{P}_n$ aproxime el aspecto de P relevante para el estadístico y de condiciones de regularidad que no se cumplen para todos los procedimientos.

¿Qué incertidumbre se quiere medir?

La respuesta determina qué debe repetirse.

Modelo fijo y test variable. Si se quiere medir la variación de una métrica del modelo ya ajustado, se mantienen sus parámetros fijos y se remuestran las unidades independientes de test.

Procedimiento completo. Si se quiere medir la variación causada por obtener otra muestra de entrenamiento, deben repetirse dentro de cada réplica el ajuste, las transformaciones aprendidas y la selección. Remuestrear solo las predicciones de un modelo ya fijado omite esa fuente de variación.

Comparación emparejada. Si se comparan modelos sobre los mismos casos, cada réplica debe remuestrear pares de pérdidas o registros completos, no listas separadas.

Dependencia y unidad de remuestreo

El bootstrap iid supone que las observaciones son aproximadamente intercambiables e independientes. Si hay varias filas por paciente, se remuestran pacientes y se conservan sus filas. Si hay dependencia temporal, puede utilizarse un bootstrap por bloques que preserve fragmentos consecutivos. En datos espaciales o por centros, la unidad de remuestreo debe reflejar la fuente de independencia.

Remuestrear filas individuales cuando la información independiente reside en 20 hospitales no crea una muestra efectiva de miles de hospitales. Produce intervalos demasiado estrechos al ignorar la variación entre centros.

Cambio de distribución

Denotemos por P_S la distribución fuente que produjo los datos históricos y por P_T la distribución objetivo o de uso. Una evaluación tomada de P_S estima directamente riesgo bajo P_S . Su relevancia para P_T depende de qué aspectos se mantienen.

Cambio de covariables

Hay **covariate shift** en el sentido usual cuando

$$P_S(X) \neq P_T(X), \quad P_S(Y | X) = P_T(Y | X).$$

Cambia la frecuencia de las entradas, pero se supone estable la relación condicional de la salida dado X . Bajo condiciones adicionales puede corregirse el riesgo fuente mediante ponderaciones de densidad. La igualdad condicional no se deduce de observar que los histogramas de X cambiaron.

Cambio de prevalencia

Hay **label shift** o cambio de prevalencia bajo el supuesto

$$P_S(Y) \neq P_T(Y), \quad P_S(X | Y) = P_T(X | Y).$$

Cambian las proporciones de clase mientras permanece estable la distribución de entradas dentro de cada clase. Este supuesto es diferente del cambio de covariables.

Cambio conceptual

Hay **concept shift** cuando

$$P_S(Y | X) \neq P_T(Y | X).$$

Una política nueva, un cambio de comportamiento o una intervención en el sistema pueden alterar la relación que el modelo intenta aprender. Reponderar únicamente las entradas no resuelve este cambio.

Cambio de medición

También puede cambiar la representación: otro sensor, una nueva definición de resultado, una codificación diferente o una modificación del protocolo. En ese caso, las variables llamadas X o Y ya no necesariamente representan el mismo objeto. Antes de comparar distribuciones numéricas debe verificarse la invariancia semántica de las mediciones.

Un conjunto de prueba aleatorio tomado de la misma tabla puede estimar variación interna bajo P_S y aun así no representar un cambio temporal, geográfico o institucional. Diseñar la evaluación exige describir la población de uso, no solo reservar un porcentaje de filas.

Ejemplo completo: clasificación de vinos

El conjunto `load_wine` contiene 178 vinos, trece mediciones químicas y tres clases de cultivar. Cada fila representa un vino analizado. Utilizaremos una partición estratificada para comparar una regla de clase mayoritaria con una regresión logística escalada.




Figura 29: Las clases de Wine contienen 59, 71 y 48 observaciones. La clase mayoritaria define una referencia antes de ajustar el modelo.

```
from sklearn.datasets import load_wine
from sklearn.dummy import DummyClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, confusion_matrix
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

wine = load_wine(as_frame=True)
X = wine.data
y = wine.target

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.25,
    random_state=2105,
    stratify=y,
)

baseline = DummyClassifier(strategy="most_frequent")
```

```
baseline.fit(X_train, y_train)
pred_baseline = baseline.predict(X_test)

modelo = make_pipeline(
    StandardScaler(),
    LogisticRegression(max_iter=2000),
)
modelo.fit(X_train, y_train)
pred_modelo = modelo.predict(X_test)
```

La tubería ajusta el escalamiento únicamente con `X_train`. En las 45 observaciones reservadas, el baseline acierta 18 y el modelo acierta 44:

Método	Aciertos	Accuracy
clase mayoritaria	18 de 45	0.400
regresión logística	44 de 45	0.978




Figura 30: La matriz de confusión contiene 44 aciertos en la diagonal y un error: una observación de clase 1 fue predicha como clase 2.

Qué se estimó

La accuracy de test es la media de 45 indicadores de acierto. Estima la probabilidad de acierto del modelo ajustado bajo una distribución comparable con la que produjo test, condicionada a la

muestra de entrenamiento y al procedimiento ya elegido. No estima automáticamente el desempeño en otro laboratorio, región o periodo.

Con 44 aciertos de 45, el intervalo normal elemental es poco apropiado porque la proporción está cerca de uno. Un intervalo de Wilson de 95 % para la probabilidad de acierto es aproximadamente

$$[0.884, 0.996].$$

El intervalo es mucho más amplio de lo que sugiere reportar únicamente 0.978. Aun así, solo incorpora la variación binomial idealizada de las observaciones de test; no incluye volver a seleccionar la partición, ajustar el escalamiento, entrenar el modelo o escoger sus hiperparámetros.

La conclusión compatible con el experimento es:

En la partición fijada por la semilla 2105, la tubería acertó 44 de 45 vinos reservados, frente a 18 de 45 del baseline de clase mayoritaria. El único error confundió una observación de clase 1 con clase 2. La muestra de prueba es pequeña y no evalúa cambios de laboratorio, región o periodo.

Esta redacción identifica unidad, denominador, referencia, error observado y alcance de la distribución evaluada.

Síntesis

La distribución condicional describe cómo se comporta una salida al conocer las entradas. La media condicional minimiza el riesgo cuadrático y la probabilidad condicional minimiza la log-loss binaria. Los modelos intentan aproximar esas cantidades dentro de familias y con muestras finitas; sus salidas no deben identificarse automáticamente con los objetos poblacionales.

Un estimando pertenece a la población o al modelo; un estimador es una función de la muestra; una estimación es el valor obtenido. Sesgo, varianza, error cuadrático medio y consistencia describen propiedades del procedimiento bajo repetición del muestreo. El error estándar cuantifica la variación de un estimador, no el tamaño del error observado en un caso individual.

El riesgo esperado promedia una pérdida bajo una distribución. El riesgo empírico es la suma calculable sobre una muestra. Entrenamiento ajusta, validación selecciona y prueba estima al final. Una métrica de prueba sigue siendo aleatoria y debe acompañarse de su unidad de muestreo, tamaño, incertidumbre y población de referencia. Si la distribución de uso difiere de la fuente, una partición interna puede responder una pregunta distinta de la que motivó el modelo.

Términos clave

- **Probabilidad condicional:** probabilidad restringida y renormalizada por información conocida.
- **Distribución condicional:** ley de una variable dado el valor de otra.
- **Esperanza condicional:** promedio de una variable dentro de la información condicionante.
- **Función de regresión:** $x \mapsto \mathbb{E}[Y \mid X = x]$.

- **Estimando:** cantidad poblacional que se desea conocer.
- **Estimador:** función de una muestra diseñada para aproximar un estimando.
- **Estimación:** valor observado de un estimador.
- **Sesgo:** diferencia entre la esperanza de un estimador y el estimando.
- **Error estándar:** desviación estándar estimada de una distribución muestral.
- **Consistencia:** convergencia en probabilidad del estimador al estimando.
- **Pérdida:** costo asignado a una predicción y su resultado.
- **Riesgo esperado:** esperanza de la pérdida bajo una distribución.
- **Riesgo empírico:** promedio de pérdidas en una muestra observada.
- **Generalización:** mantenimiento de bajo riesgo en la distribución de uso.
- **Bootstrap:** aproximación por remuestreo de una distribución muestral.
- **Cambio de distribución:** diferencia relevante entre distribución fuente y objetivo.

Ejercicios

Comprensión conceptual

1. Distinga $\mathbb{P}(A \mid B)$ de $\mathbb{P}(B \mid A)$ mediante un ejemplo. Explique por qué una no puede sustituirse por la otra.
2. ¿Por qué no se define $\mathbb{P}(Y \in C \mid X = x)$ mediante una división por $\mathbb{P}(X = x)$ cuando X es continua?
3. Explique la ley de la esperanza total con grupos de una población. ¿Qué dos piezas se necesitan para recuperar la media marginal?
4. Distinga $\mathbb{E}[Y \mid X]$, $\mathbb{E}[Y \mid X = x]$ y una predicción $\hat{f}(x)$.
5. Explique por qué la identidad $\mathbb{E}[Y - \mathbb{E}[Y \mid X] \mid X] = 0$ no implica que el ruido sea independiente de X .
6. Distinga estimando, estimador, estimación y distribución muestral mediante la proporción de una clase.
7. ¿Puede preferirse un estimador sesgado a uno insesgado? Responda usando la descomposición del error cuadrático medio.
8. Explique por qué el riesgo de entrenamiento del modelo elegido no se comporta como el promedio de pérdidas de una función fijada antes de observar los datos.
9. Distinga el riesgo del modelo ajustado $R_P(A(d_m))$ del riesgo promedio del algoritmo $\mathcal{R}_m(A)$.
10. Explique por qué un intervalo calculado sobre test no incorpora necesariamente la variación del entrenamiento.

Problemas cuantitativos

11. En una población, $\mathbb{P}(B) = 0.3$, $\mathbb{P}(A | B) = 0.7$ y $\mathbb{P}(A | B^c) = 0.2$. Calcule $\mathbb{P}(A)$ y $\mathbb{P}(B | A)$.
12. Una variable X toma valores 0 y 1 con probabilidades 0.4 y 0.6. Se sabe que $\mathbb{E}[Y | X = 0] = 2$ y $\mathbb{E}[Y | X = 1] = 5$. Calcule $\mathbb{E}[Y]$.
13. Además de los datos del ejercicio 12, suponga que $\text{Var}(Y | X = 0) = 1$ y $\text{Var}(Y | X = 1) = 4$. Use la ley de varianza total para calcular $\text{Var}(Y)$.
14. Para $\eta(x) = 0.8$, calcule la log-loss condicional al predecir $q = 0.8$ y $q = 0.6$. Verifique cuál es menor.
15. Dos estimadores de θ tienen, respectivamente, sesgo 0 y varianza 9, y sesgo 1 y varianza 4. Calcule sus errores cuadráticos medios y compare.
16. Para pérdidas de test $(1, 0, 0, 1, 0, 0, 0, 0, 0)$, calcule el riesgo empírico, la varianza muestral de las pérdidas y el error estándar estimado.
17. Una regresión produce errores absolutos $(1, 2, 1, 4, 2, 3, 1, 2)$. Calcule MAE y su error estándar bajo independencia.
18. Use Hoeffding para encontrar un tamaño n que garantice una cota no mayor que 0.05 para $\mathbb{P}(|\widehat{R}_n - R_P(f)| \geq 0.1)$, bajo las condiciones de la desigualdad.
19. Dos clasificadores tienen pérdidas 0-1 sobre los mismos seis casos: $L^{(A)} = (0, 0, 1, 0, 1, 0)$ y $L^{(B)} = (0, 1, 1, 0, 0, 0)$. Calcule las diferencias emparejadas y su media. ¿Qué información se perdería al comparar solo las dos accuracies?
20. Un clasificador produce 44 aciertos en 45 casos. Calcule el intervalo normal elemental para la proporción y explique por qué puede ser inadecuado. Compare con el intervalo de Wilson reportado en el capítulo.

Práctica computacional

21. Simule una variable binaria Y cuya probabilidad dependa de X . Agrupe X en intervalos y compare proporciones empíricas con la función condicional usada en la simulación.
22. Simule $Y = 2 + 3X + \varepsilon$ con $\mathbb{E}[\varepsilon | X] = 0$ pero varianza condicional creciente. Verifique que el promedio de residuales por intervalos de X se aproxima a cero y que su dispersión no es constante.
23. Simule distribuciones muestrales de la media y la mediana para una distribución con valores extremos. Compare sesgo, varianza y error cuadrático medio.
24. Implemente un bootstrap iid para la mediana. Compare el error estándar bootstrap con la variación observada en muchas muestras simuladas de una distribución conocida.
25. Ajuste un modelo una sola vez y haga bootstrap de su métrica de test. Después repita todo el proceso de ajuste dentro de cada réplica. Explique por qué las dos distribuciones responden preguntas distintas.

26. Con `load_wine`, reproduzca la partición del capítulo y calcule matriz de confusión, accuracy del baseline y accuracy del modelo. Cambie la semilla varias veces para estudiar variación, pero no seleccione la semilla con mejor test.
27. Compare dos modelos sobre los mismos casos usando un bootstrap emparejado de la diferencia de pérdidas. Reporte el intervalo y la unidad remuestreada.

Interpretación y formulación

28. Un equipo ajusta veinte modelos, elige el que obtiene mejor resultado en test y reporta un intervalo calculado sobre ese mismo test. Identifique las dos fuentes de optimismo que el intervalo no representa.
29. Un modelo se entrena con datos de una ciudad y se usa en otra. Describa por separado qué significarían cambio de covariables, cambio de prevalencia, cambio conceptual y cambio de medición.
30. Para un proyecto propio, escriba: estimando, estimador propuesto, unidad independiente, pérdida, distribución de uso, posible cambio de distribución y procedimiento para cuantificar incertidumbre.

Respuestas seleccionadas

11. Por probabilidad total,

$$\mathbb{P}(A) = 0.7(0.3) + 0.2(0.7) = 0.35.$$

Luego,

$$\mathbb{P}(B \mid A) = \frac{0.7(0.3)}{0.35} = 0.6.$$

- 12.

$$\mathbb{E}[Y] = 0.4(2) + 0.6(5) = 3.8.$$

13. La primera parte es $\mathbb{E}[\text{Var}(Y \mid X)] = 0.4(1) + 0.6(4) = 2.8$. La varianza de las medias condicionales es $0.4(2 - 3.8)^2 + 0.6(5 - 3.8)^2 = 2.16$. Por tanto, $\text{Var}(Y) = 4.96$.

14. Para $q = 0.8$,

$$L_x(0.8) = -0.8 \log(0.8) - 0.2 \log(0.2) \approx 0.500.$$

Para $q = 0.6$,

$$L_x(0.6) = -0.8 \log(0.6) - 0.2 \log(0.4) \approx 0.592.$$

La predicción $q = \eta(x) = 0.8$ tiene menor riesgo condicional.

15. Los errores cuadráticos medios son $9 + 0^2 = 9$ y $4 + 1^2 = 5$. El segundo estimador es sesgado, pero tiene menor MSE.

16. El riesgo empírico es 0.2. La suma de desviaciones cuadradas es 1.6, así que $s_L^2 = 1.6/9 \approx 0.178$ y el error estándar es $\sqrt{0.178/10} \approx 0.133$.

18. Se requiere

$$2e^{-2n(0.1)^2} \leq 0.05,$$

por lo que

$$n \geq \frac{\log(40)}{0.02} \approx 184.44.$$

El menor entero que satisface la cota es 185.

19. Las diferencias $L^{(A)} - L^{(B)}$ son $(0, -1, 0, 0, 1, 0)$ y su media es cero. Las accuracies son iguales, pero las pérdidas emparejadas muestran que los modelos fallan en casos diferentes.

28. Test participó en la selección entre veinte modelos, de modo que el mejor resultado contiene optimismo por búsqueda. Además, el intervalo usual condiciona en el modelo ya escogido y no repite el proceso de seleccionar entre veinte alternativas; por tanto, no incorpora esa variación adaptativa.

Herramientas de estudio

Guía de estudio del estudiante

Esta guía explica cómo usar el libro, los notebooks y los laboratorios como un sistema de aprendizaje. No reemplaza el calendario del curso; sirve para tomar buenas decisiones de estudio semana a semana.

Cómo se conectan las páginas del curso

Usa las páginas del curso con funciones distintas:

Página	Cuándo abrirla	Para qué sirve
Portal del curso	al comenzar la semana	ubicar programa, calendario, ruta, materiales, proyecto y configuración
Libro	antes y después de clase	estudiar conceptos, derivaciones, ejemplos, ejercicios y apéndices
Ruta semanal	antes de cada clase	saber qué leer, qué notebook usar y qué entregar
Materiales	al descargar archivos	encontrar slides, notebooks, laboratorios y paquetes por módulo

La regla práctica es: si necesitas saber **qué hacer**, usa el portal y la ruta; si necesitas saber **por qué funciona**, usa el libro; si necesitas **entregar**, usa materiales y conserva el notebook ejecutado con salidas visibles.

Ruta mínima por semana

Cada semana debe dejar un producto pequeño antes de llegar a la evaluación.

Momento	Acción	Producto concreto
Antes de clase	leer la pregunta aplicada, objetivos, mapa de objetivos y definiciones	lista breve de símbolos, dimensiones y dudas

Momento	Acción	Producto concreto
Durante clase	ejecutar el notebook y anotar errores	celda reproducida, output revisado y una pregunta técnica
Después de clase	resolver puntos de control del capítulo	cálculo pequeño o explicación de una métrica
Antes del laboratorio	implementar funciones mínimas	pruebas locales, shapes y comparación con referencia
Después del feedback	corregir interpretación	párrafo con resultado, límite y siguiente paso

Regla práctica. Si solo puedes ejecutar el código pero no puedes explicar qué objeto matemático calcula, todavía no estás listo. Si solo puedes repetir la fórmula pero no puedes probarla con datos, tampoco estás listo.

Cómo leer un capítulo técnico

Lee cada capítulo en tres pasadas.

Pasada	Meta	Qué debes marcar
Primera lectura	ubicar la pregunta aplicada	qué problema se intenta resolver y qué decisión se quiere apoyar
Lectura matemática	seguir objetos y derivaciones	variables, dimensiones, función objetivo, gradiente o métrica
Lectura computacional	conectar con implementación	entradas, salidas, tests, semilla, partición y comparación

No intentes memorizar todo en la primera lectura. El libro está diseñado para que vuelvas a los ejemplos cuando implementes o estudies para evaluación.

El [Mapa de objetivos de aprendizaje](#) te ayuda a convertir la lectura en acciones observables: formular, derivar, implementar, diagnosticar, seleccionar, comunicar o defender. Úsalo antes de estudiar para saber qué deberías poder producir al cerrar el capítulo.

Señales de dominio

Antes de entregar un laboratorio o presentar una defensa, verifica si puedes hacer lo siguiente sin mirar una solución completa:

- definir el objeto matemático principal del tema;
- calcularlo en un caso pequeño;
- implementar una versión mínima en Python;

- comparar el resultado con una biblioteca de referencia sin cambiar el experimento;
- elegir una métrica adecuada;
- explicar una limitación del resultado;
- detectar una fuente posible de leakage, sesgo o sobreajuste;
- escribir una recomendación técnica con resultados y cautela.

Uso de respuestas seleccionadas

Las respuestas seleccionadas están para calibrar tu estudio, no para sustituir tu solución.

Buen uso	Mal uso
comparar después de intentar el ejercicio	leer antes de pensar el problema
detectar errores de dimensión o signo	copiar el razonamiento sin reproducirlo
verificar una métrica o interpretación	usar la respuesta como solución de laboratorio
preparar preguntas para clase	ocultar que no se entiende la derivación

Si una respuesta seleccionada no basta para destrabar una duda, usa el foro, la clase o la atención docente con un contexto mínimo: fórmula, celda, error, shape, métrica o párrafo que no entiendes.

Preparación para parciales

Un parcial de este curso no debe prepararse como una lista de fórmulas aisladas. Usa esta secuencia:

1. escoger un tema;
2. escribir la función objetivo, métrica o factorización central;
3. resolver un ejemplo pequeño a mano;
4. implementar el cálculo en un notebook limpio;
5. interpretar el output en una frase;
6. cambiar un supuesto y predecir qué debería pasar;
7. revisar respuestas seleccionadas o feedback automático;
8. registrar el error más importante encontrado.

La pregunta típica no es “¿recuerdas la fórmula?”, sino “¿qué se optimiza, cómo se calcula, cómo se valida y qué decisión permite o no permite tomar?”.

Preparación para el proyecto

Desde el inicio del proyecto, conserva un registro de:

- fuente del dataset, licencia o permiso de uso y fecha de descarga;
- qué representa cada fila y cada variable importante;
- variable objetivo o decisión aplicada;
- partición de datos y justificación;

- baseline inicial;
- métrica primaria y métricas secundarias;
- riesgos de privacidad, sesgo, leakage o falta de representatividad;
- cambios de código que alteran resultados;
- ayuda externa o uso sustancial de IA.

El proyecto se evalúa por hitos, reproducibilidad, reporte y defensa técnica. Una métrica alta sin trazabilidad no es un resultado fuerte.

Cuando te bloqueas

Antes de pedir ayuda, prepara uno de estos soportes:

Bloqueo	Soporte útil
fórmula	símbolos, dimensiones y paso exacto donde aparece la duda
código	celda mínima, error, shape esperado y shape obtenido
métrica	matriz de confusión, tabla de residuos o curva relevante
interpretación	frase actual, resultado usado y límite que no sabes declarar
proyecto	fuentes de datos, decisión aplicada y riesgo detectado

Pedir ayuda con un ejemplo concreto acelera la retroalimentación y protege tu autoría.

Checklist antes de publicar una entrega

- ¿El notebook corre desde cero?
- ¿Las semillas y particiones están declaradas?
- ¿Las transformaciones se ajustan solo con entrenamiento?
- ¿Las métricas corresponden al tipo de problema?
- ¿Los outputs importantes tienen interpretación?
- ¿La recomendación declara límites?
- ¿El uso de ayuda externa o IA está declarado cuando corresponde?
- ¿El archivo entregado no contiene datos privados innecesarios?

Formatos y descargas

Esta página reúne los formatos públicos del libro y los recursos descargables de la edición vigente. Su propósito es que estudiantes, instructores y revisores puedan encontrar rápidamente la versión web, el PDF, los datos de práctica y los manifiestos de publicación sin depender del portal operativo del curso.

La versión HTML es el formato principal de lectura y accesibilidad. El PDF se publica como respaldo offline y archivo de versión; en esta edición todavía no es un PDF etiquetado.

Lectura principal

Recurso	Enlace	Uso recomendado
Libro web	Inicio del libro	lectura principal, búsqueda, navegación y enlaces internos
PDF del libro	PDF del libro	lectura offline y archivo de versión
Guía de impresión	Guía	criterios para usar el PDF como copia archivable o imprimible
Accesibilidad	Declaración	estado de accesibilidad, evidencia automática y barreras conocidas

Guías de inicio

Recurso	Enlace	Uso recomendado
Guía del estudiante	Estudiar con el libro	rutina semanal, preparación de parciales y proyecto
Guía docente pública	Adopción docente	adopción modular, separación público/privado y evaluación automatizada
Mapa de objetivos	Objetivos por capítulo	resultados observables, evidencia y alineación por capítulo
Mapa de cierres	Cierres de capítulo	términos clave, repaso, práctica y proyecto por capítulo

Recurso	Enlace	Uso recomendado
Casos longitudinales	Casos longitudinales	hilos de regresión, clasificación y estructura no supervisada
Respuestas y solucionarios	Política	respuestas públicas, manual de estudiante y recursos restringidos
Prerrequisitos mínimos	Prerrequisitos matemáticos	álgebra lineal, gradientes, probabilidad mínima y notación NumPy/PyTorch

Datos de práctica

Recurso	Enlace	Uso recomendado
Manifest de datos	Manifest JSON	filas, columnas, hashes, semillas y uso pedagógico
README de datos	README	descripción del paquete de CSV
Regresión generada	CSV regresión	regresión lineal, gradiente y regularización
Clasificación generada	CSV clasificación	logística, umbrales y métricas
Clustering generado	CSV clustering	K-Means y diagnóstico de escala
PCA generado	CSV PCA	PCA, SVD y reconstrucción
Interacciones de recomendación	CSV recomendación	recomendación item-item pequeña

Trazabilidad de publicación

Recurso	Enlace	Qué prueba
Manifiesto de publicación	Manifest JSON	inventario, tamaños y hashes SHA-256
Manifest de objetivos	Manifest JSON	objetivos por capítulo, evidencia y alineación global
Manifest de figuras	Manifest JSON	SVG, PNG, texto alternativo, atribución y primer uso significativo
Sitemap	sitemap.xml	páginas públicas previstas para descubrimiento
Registro de candidato	libro_curso/registros/publicacion/candidato-2026-07-13.md	construcción y bloqueadores editoriales

Recurso	Enlace	Qué prueba
Registro público de errata	registro_errata_publica.html	reportes abiertos, cerrados y cambios editoriales
Referencias y atribuciones	referencias_atribuciones.html	fuentes técnicas, benchmark editorial y cómo citar
Plantillas de respuestas	README	control editorial de respuestas públicas y recursos restringidos

El registro de candidato vive en el repositorio fuente, no en el libro publicado. El manifiesto público es el artefacto correcto para verificar una carpeta renderizada.

Estado de uso

El repositorio incluye un **LICENSE** formal de uso docente restringido. La lectura y el uso dentro del curso están permitidos; redistribución, adaptación pública o uso comercial requieren autorización explícita. Una licencia abierta futura debe declararse explícitamente antes de tratar el libro como OER.

Para citar esta edición:

Galindo, C. (2026). *Matemáticas y Algoritmos en Ciencia de Datos Aplicada: Libro del curso MATE-2105*. Universidad de los Andes. <https://cesarneyit-code.github.io/mate2105/libro/>

Qué no se descarga desde el libro

El libro público no distribuye:

- soluciones oficiales completas;
- pruebas ocultas;
- autograders;
- paquetes Gradescope;
- guías docentes privadas;
- datos de estudiantes o entregas reales.

Estos materiales permanecen fuera de la publicación para proteger evaluación, privacidad y trazabilidad docente.

Datos y recursos reproducibles

Este libro usa datasets pequeños, públicos o generados para práctica, de modo que los ejemplos puedan ejecutarse sin depender de internet durante clase, laboratorio o autograding. La prioridad es que el estudiante pueda concentrarse en el modelo, la validación y la interpretación.

Los datasets de ejemplo no reemplazan un problema aplicado real. Sirven para practicar conceptos bajo condiciones controladas. En el proyecto final, cada equipo debe documentar fuente, licencia, fecha de descarga, variables, restricciones de uso y riesgos de interpretación.

Paquete descargable del libro

El libro publica un paquete de CSV de práctica para que estudiantes e instructores puedan reproducir ejemplos básicos sin conexión a internet y sin depender de material privado del curso.

Estos archivos también funcionan como casos longitudinales. No se introducen solo para practicar una función de código; reaparecen en capítulos distintos para conectar regresión, regularización, validación, análisis por slice, comunicación técnica y defensa. La guía completa está en [Casos longitudinales del libro](#).

Archivo	Filas	Uso pedagógico
regresion_lineal_sintetica.csv	160	regresión lineal, descenso del gradiente y regularización
clasificacion_binaria_sintetica.csv	240	regresión logística, umbrales, métricas y análisis por slice
clusters_sinteticos.csv	240	K-Means, centroides, inercia y diagnóstico de escala
pca_sintetico.csv	180	PCA, SVD, varianza explicada y reconstrucción
recomendacion_interacciones.csv	32	recomendación item-item y evaluación offline pequeña
vivienda_nueva_bogota_subzonas.csv	32	unidad de observación, documentación y regresión con datos agregados reales

El archivo [manifest_datos.json](#) registra columnas, número de filas, tamaño, hash SHA-256, semilla y uso pedagógico de cada CSV. El README del paquete está en [datos/README.md](#).

Cinco CSV fueron generados artificialmente. El archivo de vivienda nueva es una adaptación de datos públicos agregados por subzona. Ninguno permite inferencias sobre viviendas individuales ni decisiones operativas sin validación adicional.

Caso Bogotá: vivienda nueva por subzona

El archivo `vivienda_nueva_bogota_subzonas.csv` conserva 32 filas del conjunto oficial **Caracterización precios vivienda nueva**. Cada fila representa una subzona, no una vivienda. Las columnas publicadas son:

Columna	Lectura usada en el curso
<code>subzona</code>	nombre de la unidad agregada
<code>precio_reportado</code>	campo numérico llamado <code>precios</code> en el recurso original
<code>estrato_promedio</code>	promedio reportado para la subzona
<code>area_promedio</code>	área promedio reportada
<code>alcobas_promedio</code>	promedio de alcobas
<code>banos_promedio</code>	promedio de baños
<code>parqueaderos_promedio</code>	promedio de parqueaderos

La fuente no especifica en el archivo descargado la unidad de `precios`. El curso no la infiere. Esta ausencia limita la interpretación de errores y funciona como un ejemplo de por qué la documentación forma parte del análisis.

Fuente: [Datos Abiertos Bogotá](#), Secretaría Distrital del Hábitat, licencia CC BY 4.0; consulta 2026-07-10.

Datasets incluidos en scikit-learn

`load_wine`. Se usa en el arranque del curso para clasificación multiclase con mediciones químicas de vinos. Tiene 178 observaciones, 13 variables y 3 clases.

Fuente técnica: [scikit-learn: `load\_wine`](#).

`load_diabetes`. Se usa para regresión, Ridge/Lasso y validación. Tiene 442 observaciones, 10 variables y un objetivo numérico.

Fuente técnica: [scikit-learn: `load\_diabetes`](#).

`load_breast_cancer`. Se usa para clasificación binaria, métricas, umbrales y diagnóstico. Tiene 569 observaciones, 30 variables y 2 clases.

Fuente técnica: [scikit-learn: `load\_breast\_cancer`](#).

`load_digits`. Se usa para redes neuronales, PCA y clasificación multiclase. Tiene 1797 imágenes 8x8, 64 variables y 10 clases.

Fuente técnica: [scikit-learn: `load\_digits`](#).

Datos generados para práctica

make_regression. Se usa para regresión lineal, descenso del gradiente, ruido y condicionamiento. Controla número de observaciones, variables, ruido y semilla.

Fuente técnica: [scikit-learn: make_regression](#).

make_blobs. Se usa para K-Means, clustering y separación geométrica. Controla centros, desviación de clusters y semilla.

Fuente técnica: [scikit-learn: make_blobs](#).

make_moons. Se usa para fronteras no lineales y limitaciones de modelos lineales. Controla ruido, número de puntos y semilla.

Fuente técnica: [scikit-learn: make_moons](#).

Regla de reproducibilidad

Todo ejemplo computacional debe registrar:

1. función, fuente o archivo del dataset;
2. versión aproximada de la librería cuando sea relevante;
3. `random_state` o semilla;
4. partición usada: train, dev, validation o test;
5. transformaciones aprendidas solo con entrenamiento;
6. métrica principal;
7. advertencia de interpretación.

Advertencias de interpretación

Los datasets clásicos son útiles porque están limpios, documentados y disponibles localmente. Esa misma limpieza limita su valor como evidencia aplicada.

Un buen resultado en `load_breast_cancer`, `load_diabetes` o `load_digits` no justifica por sí solo una recomendación clínica, económica u operativa. Para una decisión real se requiere validación externa, análisis de sesgos, trazabilidad de datos y revisión de dominio.

Checklist para datasets de proyecto

Antes de aprobar un dataset de proyecto, debe poder responderse:

- ¿cuál es la fuente original?
- ¿qué licencia o permiso de uso tiene?
- ¿cuándo se obtuvo?
- ¿qué representa cada fila?
- ¿cuál es la variable objetivo o decisión?
- ¿qué observaciones no están representadas?

- ¿qué filtrados o transformaciones se hicieron?
- ¿qué riesgos de privacidad, sesgo o leakage existen?
- ¿puede reproducirse la carga de datos desde instrucciones claras?

Casos longitudinales del libro

Este libro usa varios datasets pequeños y reproducibles. Algunos aparecen una sola vez; otros funcionan como **casos longitudinales**: regresan en distintos capítulos para que el estudiante vea cómo una misma decisión técnica cambia cuando se estudia desde regresión, clasificación, validación, diagnóstico, reproducibilidad y comunicación.

Un caso longitudinal no es un proyecto final. Es una línea de continuidad para leer el libro: el mismo dataset permite formular la pregunta, entrenar un baseline, validar, diagnosticar errores y escribir una recomendación.

Caso A: regresión sintética con escala y regularización

Archivo público:

```
datos/regresion_lineal_sintetica.csv
```

Uso principal:

Capítulo	Rol del caso
Capítulo 1	construir matriz de diseño, intercepto, MSE y ecuación normal
Capítulo 2	comparar ecuación normal contra descenso del gradiente
Capítulo 3	revisar escalamiento, regularización y selección por validación
Capítulo 20	registrar semilla, datos, métrica y artefactos
Capítulo 21	convertir una tabla de errores en conclusión técnica

Pregunta guía:

¿Cómo cambia la recomendación cuando pasamos de ajustar una regresión a validar si sus errores son estables y reproducibles?

Evidencia mínima:

- forma de X y de y ;
- baseline de promedio de entrenamiento;
- MSE o MAE en partición independiente;

- comparación OLS/Ridge/Lasso;
- diagnóstico de escala o condicionamiento;
- manifest de corrida.

Caso B: clasificación binaria con slice reciente

Archivo público:

`datos/clasificacion_binaria_sintetica.csv`

Este dataset incluye una columna **slice** con dos valores: **base** y **reciente**. El objetivo no es simular una población real, sino crear una situación controlada para discutir generalización y data mismatch.

Uso principal:

Capítulo	Rol del caso
Capítulo 4	interpretar probabilidades, umbral y matriz de confusión
Capítulo 11	escoger métrica, baseline, train/dev/test y pipeline
Capítulo 12	estimar variabilidad con validación cruzada y curvas
Capítulo 13	comparar desempeño global contra desempeño por slice
Capítulo 19	responder preguntas integradoras de parcial
Capítulo 21	escribir una recomendación proporcional
Capítulo 22	defender una decisión con evidencia y límites

Pregunta guía:

Si el modelo mejora el promedio global pero falla en observaciones recientes, ¿qué recomendación técnica tiene soporte suficiente?

Evidencia mínima:

- proporción de clase por partición;
- baseline de clase mayoritaria o regla simple;
- matriz de confusión;
- precision, recall y F1;
- métrica por **slice**;
- diagnóstico de mismatch;
- decisión y límite.

Caso C: estructura no supervisada

Archivos públicos:

```
datos/pca_sintetico.csv
datos/clusters_sinteticos.csv
datos/recomendacion_interacciones.csv
```

Uso principal:

Capítulo	Rol del caso
Capítulo 15	centrar datos, aplicar SVD/PCA y medir varianza explicada
Capítulo 16	ajustar K-Means y revisar estabilidad geométrica
Capítulo 17	construir matriz usuario-item y discutir cobertura
Capítulo 21	comunicar hallazgos exploratorios sin exagerar

Pregunta guía:

¿Qué tipo de estructura puede sugerirse sin etiquetas y qué conclusión no se puede afirmar sin validación adicional?

Evidencia mínima:

- criterio de centrado o escalamiento;
- varianza explicada o error de reconstrucción;
- inercia, silhouette o estabilidad de clusters;
- cobertura y sesgo de popularidad en recomendación;
- advertencia explícita sobre interpretación causal.

Cómo usar los casos al estudiar

Cuando un capítulo mencione un caso longitudinal, haz tres preguntas:

1. ¿Qué evidencia nueva agrega este capítulo al caso?
2. ¿Qué decisión técnica cambia respecto al capítulo anterior?
3. ¿Qué límite debe mantenerse aunque el resultado numérico mejore?

La meta no es memorizar resultados de estos datasets. La meta es aprender a reconstruir una cadena de evidencia: pregunta, datos, modelo, validación, diagnóstico, comunicación y defensa.

Atlas visual de modelos y decisiones

Este atlas reúne figuras originales del curso. Su función es dar mapas visuales para objetos que luego se formalizan con álgebra, cálculo o código. Cada figura debe leerse como guía conceptual, no como sustituto de la derivación.

Manifiesto editorial

El inventario completo de figuras, archivos fuente, texto alternativo, atribución, derechos de uso y primer uso significativo está publicado en [figuras/manifest_figuras.json](#). Este archivo permite auditar que cada SVG/PNG tenga metadatos mínimos antes de una nueva edición del libro.

Regresión lineal




Figura 31: Geometría de mínimos cuadrados: las predicciones forman una proyección de y sobre el espacio columna de X ; el residual queda perpendicular a ese espacio.

Lectura. Mínimos cuadrados elige $\hat{y} = X\theta$ dentro del espacio de predicciones posibles. En la solución óptima, el residual $r = y - \hat{y}$ es ortogonal a las columnas de X . Esa idea geométrica produce la ecuación normal $X^T r = 0$.

Regularización

Regularización: controlar complejidad sin cambiar la pregunta




Figura 32: Regularización: OLS puede producir coeficientes grandes, Ridge reduce magnitudes y Lasso puede llevar coeficientes exactamente a cero.

Lectura. Regularizar no es castigar el modelo por estética. Es introducir una preferencia cuantitativa por soluciones más estables. La fuerza de la penalización se valida fuera del entrenamiento.

Descenso del gradiente

Descenso del gradiente: trayectoria, escala

Cada actualización usa el gradiente local para reducir la pérdida, pero el tamar




Figura 33: Descenso del gradiente: la trayectoria avanza sobre contornos de pérdida y la tasa de aprendizaje controla si el avance es lento, estable u oscilatorio.

Lectura. El gradiente define una dirección local; la tasa de aprendizaje define cuánto se avanza. La convergencia se diagnostica con pérdida, escala y estabilidad, no solo con el número de iteraciones.

Validación y curvas de aprendizaje




Figura 34: Curvas de aprendizaje: un caso de overfitting mantiene una brecha entre entrenamiento y validación, un caso de underfitting mantiene ambos desempeños bajos, y un caso estable cierra la brecha con más datos.

Lectura. Una curva no es decoración. Debe producir una acción: regularizar, simplificar, aumentar capacidad, recolectar datos, revisar leakage o aceptar un límite por ruido.

Particiones y evaluación



Figura 35: Particiones: train ajusta parámetros, dev selecciona modelos y test estima desempeño final; mezclar esos roles produce evaluaciones optimistas.

Lectura. La partición determina para qué puede usarse cada resultado. Train ajusta, dev selecciona y test estima desempeño final. Si test participa en la selección, deja de cumplir ese último papel.

Regresión logística y umbrales




Figura 36: Regresión logística: la curva sigmoide produce probabilidades; un umbral convierte probabilidades en clases y modifica la matriz de confusión.

Lectura. El modelo produce un puntaje probabilístico; la regla de decisión aparece al escoger τ . Dos modelos con probabilidades similares pueden tener consecuencias distintas si el umbral no corresponde al costo del problema.

Métricas para decidir



Figura 37: Selección de métricas: el costo relativo de falsos positivos y falsos negativos orienta si conviene mirar accuracy, precisión, recall o una métrica F beta.

Lectura. Una métrica es una traducción operativa de una preferencia. Reportar solo accuracy en datos desbalanceados puede esconder el error que más importa.

Error analysis

Error analysis: el promedio no cuenta toda la historia

Un modelo con métrica global aceptable puede fallar en un slice que importa para el uso previsto.




Figura 38: Error analysis por slices: el promedio global puede ocultar un slice crítico con desempeño bajo y exige una recomendación con resultado, lectura, comprobación y límite.

Lectura. El promedio global ayuda a comparar, pero no describe cada grupo. Un slice crítico requiere tamaño, conteos de error, una lectura probable, una comprobación posterior y un límite de interpretación.

Backpropagation




Figura 39: Backpropagation como grafo: el forward calcula X , $Z1$, $A1$, $Z2$, P y J ; el backward propaga dJ hacia $dZ2$, $dW2$, $dA1$, $dZ1$ y $dW1$ usando la cache.

Lectura. Backpropagation no es una fórmula aislada. Es una forma organizada de recorrer el grafo de cómputo en sentido inverso y producir gradientes con las mismas formas que los parámetros.

Optimizadores



Figura 40: Optimizadores: SGD usa el gradiente actual, momentum suaviza direcciones recientes y Adam combina memoria con escala adaptativa por coordenada.

Lectura. Cambiar de optimizador cambia la actualización, no la lógica científica. Deben reportarse semilla, tasa, épocas, arquitectura y métrica de validación.

PCA y SVD




Figura 41: PCA como proyección: datos centrados se factorizan con SVD; los primeros vectores de V definen ejes principales y la matriz Z contiene coordenadas de baja dimensión.

Lectura. PCA requiere centrar datos, elegir cuántas direcciones retener y separar visualización de interpretación. Una proyección útil no prueba causalidad.

K-Means




Figura 42: K-Means alterna dos pasos: asignar cada punto al centroide más cercano y actualizar centroides como promedio de los puntos asignados.

Lectura. K-Means optimiza una geometría. Antes de convertir clusters en segmentos reales, hay que revisar escalamiento, estabilidad, tamaño de grupos e interpretación con variables originales.

Recomendación latente



Lectura: factores latentes explican patrones; la validación decide si recomiendan bien.

Figura 43: Sistemas de recomendación: una matriz usuario-item incompleta se aproxima mediante factores latentes de usuarios e ítems; una calificación faltante se predice con un producto punto.

Lectura. La factorización latente convierte preferencias observadas en coordenadas de baja dimensión. La recomendación final debe evaluarse como decisión: a quién se recomienda, qué se omite y qué sesgo puede amplificarse.

Reproducibilidad

Reproducibilidad: que otra persona pueda reconstruir el resultado




Figura 44: Reproducibilidad: datos, código, entorno y parámetros alimentan una corrida que produce métricas, artefactos y un manifiesto verificable.

Lectura. Un resultado no es reproducible solo porque el notebook existe. El manifest registra entradas, código, entorno, parámetros y salidas con precisión suficiente para repetir la corrida.

Comunicación y defensa



Figura 45: Comunicación técnica: un reporte organiza tesis, resultados, diagnóstico, recomendación y límites para que una audiencia pueda auditarla.

Lectura. La comunicación técnica convierte resultados en una tesis verificable. Cada afirmación fuerte necesita una tabla, figura, cálculo o límite que la sostenga.

Defensa oral: responder con un archivo, no con memoria

La defensa verifica autoría, criterio técnico y límites de la recomendación.



Figura 46: Defensa oral: la respuesta individual conecta pregunta, respuesta breve, archivo verificable y límite específico con una rúbrica 0/1/2.

Lectura. La defensa no premia recitar el reporte. Evalúa autoría, comprensión, capacidad de abrir un archivo concreto y claridad sobre los límites.

Resultados de aprendizaje y alineación

Esta página resume qué debe poder hacer un estudiante al terminar el curso y qué evidencia muestra ese aprendizaje. Su función es que el libro no sea solo una secuencia de temas, sino una ruta evaluable de capacidades.

El detalle operativo por capítulo está en el [Mapa de objetivos de aprendizaje](#). Para auditoría editorial, el inventario machine-readable está en [objetivos/manifest_objetivos_aprendizaje.json](#).

Resultados de aprendizaje globales

Al finalizar MATE-2105, el estudiante debe poder:

1. derivar y analizar algoritmos fundamentales de ciencia de datos desde funciones objetivo, gradientes, restricciones o factorizaciones, incluyendo condiciones, costo computacional y estabilidad numérica;
2. implementar versiones básicas de esos algoritmos con programación vectorizada y verificaciones numéricas pequeñas;
3. comparar implementaciones propias con bibliotecas de referencia sin cambiar la pregunta experimental;
4. diagnosticar modelos usando métricas, curvas, residuos, particiones y análisis de errores;
5. diseñar particiones `train/dev/test` y justificar validación, selección de métricas y criterios de comparación;
6. reconocer problemas aplicados frecuentes: escalamiento, leakage, overfitting, data mismatch, clases desbalanceadas, sesgo y límites de interpretación;
7. construir un proyecto reproducible con datos reales, baseline, modelos, evidencia y recomendaciones técnicas;
8. comunicar y defender decisiones técnicas con evidencia, límites y autoría clara;
9. formular la dimensión probabilística y estadística de un problema, distinguiendo población, muestra, estimador, estimación, riesgo e incertidumbre.

El resultado esperado no es memorizar algoritmos. Es poder explicar qué objeto poblacional se busca, cómo se aproxima con una muestra, qué se optimiza, cómo se calcula, cómo se valida y cuál es el alcance de la conclusión obtenida.

Alineación por parte del libro

Parte	Capacidades dominantes	Evidencia esperada
Fundamentos	proceso generador, muestra, distribución, condicionamiento, riesgo y lectura de datos	diagnóstico probabilístico, pregunta modelable y distinción
Regresión, optimización y clasificación	media condicional, estimación, riesgo, derivación, regularización y modelo Bernoulli	población-muestra-estimador laboratorios y Parcial 1
Redes neuronales	distribuciones condicionales, entropía cruzada, gradientes estocásticos y backpropagation	implementación desde cero y comparación con referencia
Estrategia de ML	métricas como estimadores, incertidumbre, validación y cambio de distribución	selección de modelo con protocolo explícito
No supervisado	covarianza, PCA, distorsión esperada, estabilidad y exposición	reducción de dimensión, segmentación o recomendación justificadas
Reproducibilidad y defensa	replicación estadística, tracking, incertidumbre, reporte y defensa oral	proyecto final reproducible y defensa individual

Alineación con evaluación

Evidencia	Qué verifica	Qué no debe verificar sola
Parciales	formulación probabilística, razonamiento matemático, derivación, diagnóstico y lectura de resultados	memorización de fórmulas aisladas
Laboratorios	estimación, implementación, pruebas, comparación con referencia e interpretación corta	copiar una API sin entender el algoritmo
Notebooks de clase	práctica guiada, predicción, ejecución y discusión de errores	evaluación final de desempeño
Proyecto final	flujo completo con datos reales, reproducibilidad y comunicación	una métrica única sin contexto
Defensa oral	comprensión individual, autoría y límites de la recomendación	presentación memorizada sin evidencia

Criterios de evidencia

Una evidencia de aprendizaje es fuerte cuando contiene:

- **objeto matemático:** variables, dimensiones, función objetivo o métrica;
- **objeto poblacional:** distribución, parámetro, riesgo o cantidad que se busca aprender;
- **aproximación muestral:** muestra, estimador, estimación y mecanismo de observación;
- **procedimiento:** algoritmo, gradiente, factorización o regla de decisión;
- **análisis algorítmico:** condiciones, tipo de solución, costo, estabilidad y criterio de parada;
- **verificación:** prueba pequeña, comparación, baseline o resultado esperado;
- **validación:** partición, métrica, curva, error o análisis de estabilidad;
- **interpretación:** recomendación, límite y riesgo de extrapolación;
- **incertidumbre:** fuente de variación, error estándar, intervalo o análisis de estabilidad apropiado;
- **trazabilidad:** fuente de datos, semilla, entorno, ayuda externa y autoría.

Los casos longitudinales del libro ayudan a practicar esa estructura en más de un capítulo. Un mismo dataset puede producir evidencia de ajuste, validación, diagnóstico, comunicación y defensa; por eso el aprendizaje esperado no es solo resolver una tarea local, sino sostener una decisión técnica a través de varias etapas.

Progresión de autonomía

Momento	Apoyo esperado	Autonomía esperada
Semanas 1-3	plantillas, ejemplos pequeños y tests guiados	entender notación, ejecutar notebooks y explicar outputs
Semanas 4-6	funciones incompletas, rúbricas y comparación con sklearn	implementar, validar y justificar regularización o umbral
Semanas 7-10	derivaciones guiadas y bibliotecas de referencia	leer loops de entrenamiento y diagnosticar entrenamiento
Semanas 11-13	casos aplicados, curvas y análisis de errores	seleccionar métrica, partición y diagnóstico verificable
Semanas 14-16	checklist final y defensa	sostener una recomendación técnica reproducible

Cómo usar esta página

Para estudiar, usa los resultados como lista de control: si no puedes explicar un resultado con un ejemplo pequeño y una interpretación, todavía falta trabajo.

Para enseñar, usa la alineación como restricción de diseño: una actividad semanal debe preparar al menos una evidencia mayor del curso. Si una clase introduce un tema que no se conecta con evidencia, laboratorio, parcial o proyecto, debe revisarse su lugar en la secuencia.

Para revisar el libro, usa esta página como auditoría pedagógica: cada capítulo debe aportar a una capacidad observable, no solo cubrir un tema.

Mapa de objetivos de aprendizaje

Esta página convierte los resultados de aprendizaje en una matriz operativa por capítulo. Su propósito es que cada capítulo tenga una promesa verificable: qué debe poder hacer el estudiante, con qué evidencia se observa y cómo se conecta con la evaluación del curso.

El inventario completo está publicado en [objetivos/manifest_objetivos_aprendizaje.json](#). Ese archivo funciona como contrato editorial: cada capítulo principal debe tener objetivos observables, evidencia primaria y alineación con los resultados globales del curso.

Cómo leer los códigos

Los resultados globales usan códigos RA1 a RA9:

Código	Capacidad observable
RA1	derivar y analizar algoritmos desde objetivos, gradientes, restricciones o factorizaciones, incluyendo condiciones, costo y estabilidad
RA2	implementar algoritmos con programación vectorizada y verificaciones pequeñas
RA3	comparar implementaciones propias con bibliotecas de referencia
RA4	diagnosticar modelos con métricas, curvas, residuos, particiones y errores
RA5	diseñar validación, particiones y criterios de comparación
RA6	reconocer leakage, overfitting, data mismatch, sesgo y límites
RA7	construir un proyecto reproducible con evidencia y recomendación
RA8	comunicar y defender decisiones técnicas con límites y autoría clara
RA9	formular población, muestra, estimador, riesgo e incertidumbre de un problema de aprendizaje

Los objetivos de capítulo usan códigos como C04-02: capítulo 4, objetivo 2.

Cobertura por parte

Parte	Capítulos principales	Énfasis de aprendizaje
Parte I: Datos y preguntas	1	significado de los datos, población, muestra disponible, formulación y representación
Parte II: Regresión, optimización y clasificación	4	media condicional, riesgo, estimación, derivación, regularización y modelo Bernoulli
Parte III: Redes neuronales	4	distribuciones condicionales, entropía cruzada, gradientes estocásticos y backpropagation
Parte IV: Evaluación y estrategia de modelado	3	métricas como estimadores, incertidumbre, validación y cambio de distribución
Parte V: Aprendizaje no supervisado	3	covarianza, distorsión esperada, estabilidad, exposición y estructura latente
Parte VI: Reproducibilidad y comunicación	4	replicación estadística, incertidumbre, reporte, entrega y defensa
Herramientas probabilísticas y estadísticas	2	distribuciones, momentos, muestreo, condicionamiento, estimación, riesgo e incertidumbre

Mapa por capítulo principal

Capítulo	Objetivos observables	Evidencia primaria	Alineación
Observaciones, variables y preguntas	identificar unidad, nivel de agregación, población, marco y muestra; formular preguntas compatibles con los datos; representar una tabla matemáticamente	ficha de datos, Lab diagnóstico, ideas iniciales de proyecto	RA1, RA2, RA5, RA6, RA7, RA8, RA9

Capítulo	Objetivos observables	Evidencia primaria	Alineación
Regresión lineal múltiple	formular modelo poblacional y estimador matricial; derivar ecuación normal; comparar implementación propia con referencia	Lab 1, Parcial 1, baseline de proyecto	RA1, RA2, RA3, RA9
Descenso del gradiente	calcular gradiente de MSE; interpretar gradientes de minibatch; diagnosticar escalamiento y condicionamiento	Lab 1, Parcial 1	RA1, RA2, RA4, RA6, RA9
Regularización y validación	distinguir train/dev/test; descomponer sesgo y varianza; seleccionar complejidad con validación	Lab 2, Parcial 1, checkpoint de proyecto	RA1, RA4, RA5, RA6, RA8, RA9
Regresión logística	formular el modelo Bernoulli; derivar pérdida logística; convertir probabilidades en decisiones; justificar métricas	Lab 2, Parcial 1, baseline de clasificación	RA1, RA2, RA4, RA5, RA6, RA8, RA9
Perceptrón y forward propagation	representar capas; implementar forward pass; interpretar distribución categórica y entropía cruzada	notebook de clase, laboratorio de redes	RA1, RA2, RA8, RA9
Backpropagation	aplicar regla de la cadena; distinguir gradientes poblacional y empírico; verificar gradientes	notebook de clase, laboratorio de redes	RA1, RA2, RA4, RA9
Diagnóstico en redes	leer curvas; separar fuentes de variación; aplicar regularización o early stopping	curvas de entrenamiento, laboratorio de redes	RA4, RA5, RA6, RA8, RA9
Optimizadores y PyTorch	construir loop mínimo; analizar el ruido del gradiente; comparar optimizadores	notebook PyTorch, laboratorio de redes	RA2, RA3, RA4, RA8, RA9

Capítulo	Objetivos observables	Evidencia primaria	Alineación
Métricas, particiones y baseline	diseñar particiones; interpretar métricas como estimadores; cuantificar incertidumbre	checkpoint de proyecto, reporte de baseline	RA4, RA5, RA6, RA7, RA8, RA9
Validación y curvas	estimar riesgo mediante validación; reconocer dependencia entre folds; seleccionar modelo	checkpoint de proyecto, reporte de selección	RA4, RA5, RA6, RA8, RA9
Error analysis y data mismatch	construir riesgos condicionales por slice; diagnosticar cambio de distribución; priorizar acciones	análisis de errores del proyecto, reporte técnico	RA4, RA5, RA6, RA7, RA8, RA9
SVD y PCA	distinguir covarianza poblacional y muestral; calcular scores; evaluar estabilidad	notebook de PCA, ejercicio integrador	RA1, RA2, RA6, RA8, RA9
K-Means y clustering	distinguir distorsión esperada y empírica; separar variación muestral e inicialización; comunicar clusters con cautela	notebook de clustering, ejercicio integrador	RA1, RA2, RA4, RA6, RA8, RA9
Recomendación latente	modelar observación y exposición; evaluar sin leakage; discutir sesgos de recomendación	notebook de recomendación, ejercicio integrador	RA1, RA2, RA4, RA5, RA6, RA8, RA9
Síntesis conceptual	conectar población, muestra, objetivo empírico y algoritmo; resolver preguntas integradoras	Parcial 2, repaso integrador	RA1, RA2, RA4, RA6, RA8, RA9
Reproducibilidad y tracking	registrar manifiesto; distinguir reproducibilidad computacional y replicación estadística	manifest del proyecto, reporte reproducible	RA2, RA6, RA7, RA8, RA9
Comunicación técnica	reportar estimando, estimador, estimación e incertidumbre; seleccionar figuras funcionales	reporte final, presentación final	RA4, RA6, RA7, RA8, RA9

Capítulo	Objetivos observables	Evidencia primaria	Alineación
Entrega y defensa	preparar artefactos verificables; defender muestreo, incertidumbre, alcance y decisiones	defensa oral, entrega final del proyecto	RA4, RA5, RA6, RA7, RA8, RA9
Variables aleatorias, distribuciones y muestras	interpretar variables aleatorias y distribuciones; calcular momentos; formular muestras; explicar distribución empírica y ley de los grandes números	ejercicios probabilísticos y simulaciones	RA1, RA2, RA4, RA5, RA6, RA8, RA9
Condicionamiento, estimación, riesgo e incertidumbre	calcular cantidades condicionales; distinguir estimando y estimador; analizar riesgo y selección; cuantificar incertidumbre	ejercicios, evaluación de baselines y análisis de métricas	RA1, RA4, RA5, RA6, RA8, RA9

Uso para estudiantes

Antes de leer un capítulo, identifica los verbos de la fila correspondiente: formular, derivar, implementar, diagnosticar, seleccionar, comunicar o defender. Después de estudiar, debes poder producir la evidencia indicada sin mirar una solución oficial completa.

Si solo puedes repetir una definición, todavía no has alcanzado el objetivo. Si puedes resolver un caso pequeño, verificarlo con código y explicar el límite de la conclusión, estás cerca del estándar esperado.

Uso para instructores

Esta matriz permite revisar si una clase, notebook, laboratorio o parcial está evaluando la capacidad correcta. Si una actividad no produce evidencia asociada a un objetivo, debe rediseñarse o declararse como práctica no evaluativa.

Para publicar una nueva edición, el manifiesto debe mantenerse sincronizado con:

- capítulos principales;
- laboratorios y parciales;
- checkpoints de proyecto;
- rúbricas públicas;
- recursos restringidos de instructor.

Criterio de mantenimiento

Cada cambio de capítulo debe revisar tres preguntas:

1. ¿Cambió lo que el estudiante debe poder hacer?
2. ¿Cambió la evidencia que prueba ese aprendizaje?
3. ¿Cambió la alineación con evaluación, laboratorio, parcial o proyecto?

Si la respuesta a alguna pregunta es sí, debe actualizarse `objetivos/manifest_objetivos_aprendizaje.json` y ejecutarse:

```
python3 scripts/auditar_objetivos_aprendizaje_libro.py
```

Mapa de cierres de capítulo

Este mapa muestra cómo los capítulos principales del libro incorporan elementos de cierre de capítulo propios de un texto de curso: revisión, términos clave, preguntas de práctica, problemas cuantitativos, pensamiento crítico y conexión con proyecto.

La página no sustituye los ejercicios. Sirve para que estudiantes, instructores y revisores puedan verificar rápidamente que cada capítulo termina con práctica clasificada y evidencia observable.

Rasgos de cierre

Rasgo	Función pedagógica	Evidencia esperada
Revisión del capítulo	synetizar ideas centrales antes de practicar	lista de conceptos, criterios o advertencias
Términos clave	fijar vocabulario técnico	definiciones operativas y notación usada
Preguntas conceptuales	comprobar comprensión sin cálculo largo	explicación breve, contraejemplo o distinción
Problemas cuantitativos	verificar cálculo y derivación	fórmula, sustitución, resultado y sentido
Práctica computacional	conectar algoritmo con código	función, notebook, shape, métrica o salida reproducible
Pensamiento crítico	interpretar evidencia y límites	recomendación proporcional con riesgo declarado
Proyecto de cierre	transferir el tema al proyecto	decisión documentada, artefacto o miniinforme

Los cierres de capítulo son públicos. No contienen pruebas ocultas, soluciones oficiales completas ni lógica de autograding.

Mapa por capítulo principal

Parte	Capítulo	Cierre público	Rasgos incluidos
Datos y preguntas	Observaciones, variables y preguntas	síntesis, términos, ejercicios y respuestas seleccionadas	unidad, medición, población, formulación y representación

Parte	Capítulo	Cierre público	Rasgos incluidos
Regresión	Regresión lineal	revisión, términos, ejercicios y proyecto	conceptual, cuantitativo, computacional, interpretación
Regresión	Descenso del gradiente	revisión, términos, ejercicios y proyecto	derivación, simulación, diagnóstico de convergencia
Regresión	Regularización y validación	revisión, términos, ejercicios y proyecto	validación, leakage, Ridge/Lasso, selección
Regresión	Regresión logística	revisión, términos, ejercicios y proyecto	log-loss, umbral, matriz de confusión, recomendación
Redes	Perceptrón y forward propagation	revisión, términos, ejercicios y proyecto	formas, activaciones, capas, predicción
Redes	Backpropagation	revisión, términos, ejercicios y proyecto	regla de la cadena, gradientes, verificación
Redes	Diagnóstico y regularización en redes	revisión, términos, ejercicios y proyecto	overfitting, dropout, early stopping, curvas
Redes	Optimizadores y PyTorch	revisión, términos, ejercicios y proyecto	loop de entrenamiento, optimizador, reproducibilidad
Estrategia ML	Métricas y particiones	revisión, términos, ejercicios y proyecto	train/dev/test, baseline, costos de error
Estrategia ML	Validación y curvas	revisión, términos, ejercicios y proyecto	learning curves, cross-validation, estabilidad
Estrategia ML	Error analysis y data mismatch	revisión, términos, ejercicios y proyecto	slices, mismatch, diagnóstico, acción
No supervisado	SVD y PCA	revisión, términos, ejercicios y proyecto	centrar, proyectar, reconstruir, explicar varianza
No supervisado	K-Means y clustering	revisión, términos, ejercicios y proyecto	centroides, inercia, escala, estabilidad
No supervisado	Recomendación latente	revisión, términos, ejercicios y proyecto	similitud, ranking, evaluación offline
Cierre	Síntesis conceptual	revisión, términos, ejercicios y proyecto	mapa de decisiones, comparación, límites
Cierre	Reproducibilidad y tracking	revisión, términos, ejercicios y proyecto	manifest, semillas, entorno, trazabilidad
Cierre	Comunicación técnica	revisión, términos, ejercicios y proyecto	reporte, visualización, audiencia, evidencia
Cierre	Entrega y defensa	revisión, términos, ejercicios y proyecto	defensa oral, autoría, límites, cierre

Parte	Capítulo	Cierre público	Rasgos incluidos
Herramientas probabilísticas	Variables aleatorias, distribuciones y muestras	síntesis, términos, ejercicios y respuestas seleccionadas	distribución, esperanza, covarianza, muestra y ley de los grandes números
Herramientas probabilísticas	Condicionamiento, estimación, riesgo e incertidumbre	síntesis, términos, ejercicios y respuestas seleccionadas	condicionamiento, estimadores, riesgo, error estándar y bootstrap

Bancos integradores

Los capítulos de ejercicios integradores funcionan como cierres de parte. No repiten el patrón de un capítulo conceptual; reúnen práctica acumulativa, problemas integradores, autoevaluación y respuestas seleccionadas.

Parte	Banco público	Uso recomendado
Regresión	Ejercicios de regresión	preparación de Parcial 1 y baseline del proyecto
Redes	Ejercicios de redes	verificación de forward, backpropagation y PyTorch
Estrategia ML	Ejercicios de estrategia	selección de métrica, partición y diagnóstico
No supervisado	Ejercicios de no supervisado	PCA, K-Means, recomendación y evaluación
Cierre	Ejercicios de cierre	reproducibilidad, comunicación y defensa final

Relación con respuestas seleccionadas

Las respuestas seleccionadas viven en los apéndices de cada parte y en el apéndice consolidado de formularios. Su propósito es orientar estudio y revisión, no reemplazar soluciones oficiales.

Recurso	Función
Formularios y respuestas seleccionadas	consulta pública consolidada
Apéndices por parte	notación mínima, fórmulas y respuestas seleccionadas
Guía del estudiante	rutina para usar respuestas sin copiar
Guía de adopción docente	separación entre recurso público y solución restringida

Criterio editorial

Un capítulo principal queda listo para uso de curso cuando:

1. declara objetivos observables;
2. contiene al menos un ejemplo resuelto;
3. incluye revisión del capítulo;
4. define términos clave;
5. ofrece ejercicios conceptuales, cuantitativos, computacionales e interpretativos;
6. cierra con una conexión de proyecto;
7. no expone soluciones oficiales completas ni pruebas ocultas;
8. pasa la auditoría de estructura editorial.

La auditoría automática revisa presencia y densidad mínima. La revisión externa real debe juzgar si esos cierres son matemáticamente correctos y pedagógicamente suficientes.

Apéndices de consulta

Glosario y notación

Este apéndice reúne términos y símbolos que se usan repetidamente en el curso. No reemplaza las definiciones de cada capítulo; sirve como referencia rápida.

Términos clave

Término	Significado operativo en el curso
Unidad de observación	Entidad, evento o intervalo representado por un registro.
Unidad de análisis	Entidad sobre la que se formula una conclusión; puede diferir de la unidad de observación.
Variable	Característica con un dominio de valores y una regla de medición o construcción.
Población objetivo	Conjunto de unidades, lugares y periodos sobre el que se desea concluir.
Marco de observación	Conjunto de unidades que el procedimiento de recolección podía identificar o incluir.
Variable aleatoria	Función medible que asigna un valor a cada resultado posible de un experimento aleatorio.
Realización	Valor concreto observado de una variable aleatoria.
Muestra aleatoria	Colección de variables aleatorias antes de observar sus realizaciones.
Distribución empírica	Distribución que asigna el mismo peso a cada observación de una muestra.
Valor esperado	Integral o promedio de una variable respecto a su distribución.
Estimando	Cantidad poblacional que se desea conocer.
Estimador	Función de una muestra aleatoria diseñada para aproximar un estimando.
Estimación	Valor obtenido al aplicar un estimador a la muestra observada.
Distribución muestral	Distribución de un estadístico bajo repetición del mecanismo de muestreo.
Error estándar	Desviación estándar estimada de la distribución muestral de un estimador.
Ruido	Componente aleatoria no explicada dentro de un modelo probabilístico declarado.

Término	Significado operativo en el curso
Matriz de diseño	Matriz X que contiene las variables usadas por el modelo.
Parámetro	Cantidad que identifica un elemento de una familia de modelos o distribuciones.
Predicción	Salida producida por el modelo para una observación o lote de observaciones.
Residual	Diferencia entre valor observado y predicción en regresión.
Pérdida	Costo numérico asignado a una acción o predicción y su resultado.
Pérdida empírica	Promedio de pérdidas calculado sobre datos observados.
Riesgo esperado	Esperanza de una pérdida bajo una distribución especificada.
Métrica	Cantidad usada para evaluar desempeño y tomar decisiones.
Baseline	Modelo o regla simple que sirve como punto mínimo de comparación.
Gradiente	Vector de derivadas parciales que indica dirección local de mayor aumento.
Tasa de aprendizaje	Escala del paso en descenso del gradiente.
Regularización	Penalización o restricción que busca mejorar generalización.
Validación	Evaluación en datos no usados para ajustar parámetros.
Leakage	Uso accidental de información que no estaría disponible al predecir en producción.
Regresión logística	Modelo probabilístico para clasificación binaria.
Probabilidad condicional	Probabilidad calculada dado que se conoce cierta información, como $P(Y = 1 \mid X = x)$.
Umbral	Regla que convierte probabilidad o score en decisión discreta.
Matriz de confusión	Tabla de verdaderos/falsos positivos y negativos.
Precision	Proporción de predicciones positivas que fueron correctas.
Recall	Proporción de positivos reales detectados por el modelo.
F1	Media armónica entre precision y recall.
Forward propagation	Cálculo de predicciones capa por capa en una red neuronal.
Backpropagation	Cálculo eficiente de gradientes en una red usando regla de la cadena.
Cross-validation	Evaluación repetida con particiones de entrenamiento y validación.
Bootstrap	Aproximación de una distribución muestral mediante remuestreo de los datos observados.

Término	Significado operativo en el curso
Cambio de distribución	Diferencia relevante entre la distribución que produjo los datos y la distribución de uso.
PCA	Proyección lineal que conserva la mayor varianza posible en pocas dimensiones.
SVD	Factorización matricial que sustenta PCA y otras aproximaciones de bajo rango.
K-Means	Algoritmo de clustering basado en centroides.
Reproducibilidad	Capacidad de reconstruir resultados a partir de datos, código, entorno y decisiones documentadas.

Notación frecuente

Símbolo	Uso
m, n	Números de observaciones; el símbolo se declara en cada contexto.
p	Número de columnas usadas por el modelo después de codificación.
d	Número de variables originales o dimensión de entrada, según contexto.
X	Vector aleatorio de entradas o matriz de diseño, según se declare en el contexto.
x_i	Vector de variables de la observación i .
y	Vector de valores observados.
y_i	Valor observado de la observación i .
Y	Variable aleatoria objetivo antes de observar un caso.
$D_m = (Z_1, \dots, Z_m)$	Muestra aleatoria de tamaño m .
$d_m = (z_1, \dots, z_m)$	Realización observada de una muestra.
P	Distribución poblacional o de uso especificada.
$\hat{P}_m$	Distribución empírica de una muestra observada.
$\hat{y}$	Vector de predicciones.
$\mathbb{E}[Y]$	Valor esperado de Y .
$P(Y = 1 \mid X = x)$	Probabilidad condicional de clase positiva dado x .
ε	Ruido o componente no explicado en un modelo como $Y = f(X) + \varepsilon$.
θ	Vector de parámetros en modelos lineales.
w, b	Pesos y sesgo de una neurona o capa.
$J(\theta)$	Función de pérdida como función de parámetros.
∇J	Gradiente de la función de pérdida.
λ	Intensidad de regularización.

Símbolo	Uso
α	Tasa de aprendizaje o hiperparámetro, según contexto.
Z	Pre-activación o representación proyectada.
A	Activación de una capa.
$U, \Sigma, V^\top$	Factores de la descomposición SVD.

Convención de formas

Cuando se use código Python, el libro favorece esta convención:

Objeto	Forma típica
X	<code>(n, p)</code>
y	<code>(n,)</code> o <code>(n, 1)</code>
θ	<code>(p,)</code> o <code>(p, 1)</code>
$X @ \theta$	<code>(n,)</code> o <code>(n, 1)</code>
W en una capa densa	<code>(d_in, d_out)</code>
b en una capa densa	<code>(d_out,)</code>

Las formas pueden cambiar por biblioteca o por convención local. Lo importante es declarar la convención antes de derivar o implementar.

Índice temático

Este índice ayuda a encontrar conceptos por problema de estudio, no por orden semanal. Úsalo cuando necesites repasar una idea antes de un laboratorio, ubicar una derivación, comparar modelos o preparar una defensa técnica.

Cómo usar este índice

- Si estás empezando un tema, lee primero el capítulo indicado como entrada.
- Si estás resolviendo un ejercicio, revisa también el apéndice o banco integrador asociado.
- Si estás trabajando en proyecto, busca la columna de decisión técnica: allí se indica qué evidencia debes poder defender.

Modelación y representación

Tema	Entrada recomendada	Conexión de proyecto
Observaciones, variables y matriz de datos	Observaciones, variables y preguntas	definir qué representa una fila y qué conclusión se quiere formular
Variable aleatoria y realización	Capítulo 1; referencia formal	distinguir proceso aleatorio, objetivo futuro y valores observados
Distribución y distribución empírica	Capítulo 1; referencia formal	describir variación poblacional y muestral sin confundirlas
Condicionamiento, ruido y residual	Capítulo 1; referencia formal	formular el objetivo condicional y distinguir fuentes de error
Pérdida empírica y riesgo esperado	Capítulo 1; referencia formal	explicar por qué la evaluación muestral tiene alcance limitado
Matriz de diseño e intercepto	Capítulo 1	documentar columnas, transformaciones y forma final de X
Parámetros, predicciones y residuales	Capítulo 1	interpretar qué aprende el modelo y qué errores quedan
Features e interacciones	Capítulo 3	justificar transformaciones sin introducir leakage
Baselines	Capítulo 1 y Capítulo 11	comparar contra una regla simple en la misma muestra de evaluación

Tema	Entrada recomendada	Conexión de proyecto
Casos longitudinales	Casos longitudinales	seguir el mismo dataset a través de modelo, validación, diagnóstico y comunicación

Álgebra lineal y optimización

Tema	Entrada recomendada	Conexión de proyecto
Prerrequisitos matemáticos mínimos	Apéndice de prerrequisitos	repasar formas, gradientes, probabilidad mínima y notación antes de resolver ejercicios
Producto matricial y formas	Capítulo 1	detectar errores antes de entrenar
Norma cuadrática y MSE	Capítulo 1	explicar qué error numérico se minimiza
Ecuación normal	Capítulo 1	comparar solución cerrada contra implementación de biblioteca
Gradiente de MSE	Capítulo 2	justificar la actualización iterativa
Escalamiento y condicionamiento	Capítulo 2	decidir cuándo una variable necesita transformación
SVD y bajo rango	Capítulo 15	explicar qué estructura se conserva al reducir dimensión

Regresión, regularización y clasificación

Tema	Entrada recomendada	Conexión de proyecto
Regresión lineal múltiple	Capítulo 1	construir un baseline de regresión verificable
Descenso del gradiente	Capítulo 2	diagnosticar convergencia y tasa de aprendizaje
Overfitting y complejidad	Capítulo 3	elegir complejidad usando validación, no test
Ridge y Lasso	Capítulo 3	controlar varianza y seleccionar hiperparámetros
Regresión logística	Capítulo 4	convertir scores en probabilidades interpretables
Probabilidad condicional	Capítulo 4 y referencia formal	interpretar $P(Y = 1 \mid X = x)$ antes de escoger umbral

Tema	Entrada recomendada	Conexión de proyecto
Umbrales de decisión	Capítulo 4	ajustar decisión al costo relativo de errores
Ejercicios integradores de regresión	Capítulo 5	practicar derivación, código e interpretación conjunta

Validación, métricas y diagnóstico

Tema	Entrada recomendada	Conexión de proyecto
Train, dev, validation y test	Capítulo 3 y Capítulo 11	separar ajuste, selección y estimación final
Leakage	Capítulo 11	impedir que el pipeline vea información de validación o test
Matriz de confusión	Capítulo 4	explicar tipos de error
Precision, recall y F1	Capítulo 4 y Capítulo 11	escoger métrica primaria según costo
Curvas de aprendizaje	Capítulo 12	distinguir sesgo, varianza y límite por datos
Error analysis por slice	Capítulo 13	encontrar fallas que el promedio oculta
Data mismatch	Capítulo 13	decidir si un modelo puede salir del contexto de entrenamiento

Redes neuronales

Tema	Entrada recomendada	Conexión de proyecto
Perceptrón y capas densas	Capítulo 6	decidir si hace falta no linealidad
Forward propagation	Capítulo 6	revisar formas de entradas, pesos, activaciones y logits
Backpropagation	Capítulo 7	verificar gradientes y cache
Diagnóstico de entrenamiento	Capítulo 8	interpretar curvas train/dev
Regularización en redes	Capítulo 8	decidir entre menor capacidad, L2, dropout o más datos
Optimizadores y PyTorch	Capítulo 9	reportar configuración reproducible de entrenamiento

Aprendizaje no supervisado y recomendación

Tema	Entrada recomendada	Conexión de proyecto
PCA	Capítulo 15	reducir dimensión sin afirmar causalidad
Varianza explicada	Capítulo 15	justificar cuántos componentes conservar
K-Means	Capítulo 16	describir clusters antes de convertirlos en decisiones
Inercia y silueta	Capítulo 16	evaluar estructura sin absolutizar una métrica
Recomendación item-item	Capítulo 17	explicar similitud, cobertura y sesgo de popularidad
Ejercicios integradores no supervisados	Capítulo 18	practicar PCA, clustering y recomendación con límites

Reproducibilidad y comunicación

Tema	Entrada recomendada	Conexión de proyecto
Síntesis conceptual	Capítulo 19	conectar pérdidas, métricas, validación y decisión
Manifest de experimento	Capítulo 20	registrar datos, código, entorno, parámetros y artefactos
Trazabilidad de datos	Capítulo 20	permitir auditoría de resultados
Reporte técnico	Capítulo 21	separar evidencia, interpretación y recomendación
Defensa oral	Capítulo 22	responder preguntas difíciles con evidencia concreta
Paquete final	Capítulo 22 y Capítulo 23	entregar reporte, código, datos permitidos y evidencia reproducible

Recursos de consulta rápida

Necesidad	Recurso
Definiciones y símbolos	Glosario y notación
Prerrequisitos de lectura	Prerrequisitos matemáticos mínimos
Algoritmos, datasets y funciones	Índice de algoritmos, datasets y funciones
Respuestas seleccionadas	Formularios y respuestas seleccionadas
Datos descargables	Datos y recursos reproducibles
Accesibilidad y barreras conocidas	Accesibilidad
Errata y correcciones	Errata, revisión y control de calidad

Criterio de mantenimiento

Este índice debe actualizarse cuando:

- se agregue un capítulo;
- cambie el nombre de un capítulo;
- se mueva una derivación central;
- se agregue una métrica, algoritmo o dataset público;
- se modifique la estructura de apéndices;
- una revisión externa pida mejorar navegabilidad o trazabilidad.

Un índice temático no reemplaza la lectura lineal. Sirve para estudiar de forma estratégica y para conectar conceptos que aparecen en partes distintas del curso.

Índice de algoritmos, datasets y funciones

Este apéndice funciona como una tabla de referencia rápida. No enseña los conceptos desde cero; indica dónde aparecen, qué función o clase suele usarse y qué debe revisar el estudiante antes de confiar en un resultado.

Cómo usar este apéndice

Usa este índice cuando encuentres una función, clase o algoritmo en un notebook y necesites ubicar su primer uso conceptual. La columna de revisión necesaria indica qué debe comprobarse antes de convertir un output en evidencia.

El primer uso fuerte no siempre coincide con la primera mención. Se registra el punto donde el libro espera que puedas explicar el objeto matemático, ejecutar o leer una implementación y conectar el resultado con una decisión.

Mapa por primer uso

Capítulo	Objetos técnicos introducidos	Uso posterior
Observaciones, variables y preguntas	unidad de observación, diccionario de datos, matriz de diseño, familia y algoritmo	definición y representación matemática del problema
Capítulo 1	par aleatorio, media condicional, riesgo, matriz de diseño, MSE, ecuación normal, <code>np.linalg.lstsq</code>	regresión, comparación con bibliotecas y baselines
Capítulo 2	descenso del gradiente, <code>np.linalg.cond</code> , historial de pérdida	optimización, escala y diagnóstico de convergencia
Capítulo 3	features polinomiales, Ridge, Lasso, validación	selección de modelo, regularización y prevención de leakage
Capítulo 4	sigmoide estable, log-loss, matriz de confusión, umbral	clasificación binaria y métricas de decisión
Capítulo 6	capas densas, activaciones, softmax estable	redes neuronales y clasificación multiclase
Capítulo 7	regla de la cadena, cache, gradientes vectorizados	entrenamiento de redes y verificación numérica

Capítulo	Objetos técnicos introducidos	Uso posterior
Capítulo 9	<code>nn.Module</code> , <code>loss.backward</code> , <code>optimizer.step</code>	loops de entrenamiento reproducibles
Capítulo 11	particiones, <code>Pipeline</code> , métricas y prevención de leakage	evaluación y selección de modelos
Capítulo 12	curvas de aprendizaje, curvas de validación, <code>GridSearchCV</code>	diagnóstico de sesgo/varianza e hiperparámetros
Capítulo 15	centrado, SVD, PCA, varianza explicada	reducción de dimensión e interpretación cautelosa
Referencia: variables, distribuciones y muestras	espacio de probabilidad, distribuciones, momentos, muestra, <code>np.mean</code> , <code>np.var</code> , <code>np.random.default_rng</code>	consulta y profundización probabilística
Referencia: condicionamiento, estimación y riesgo	Bayes, estimadores, bootstrap y cambio de distribución	consulta y profundización estadística
Capítulo 16	<code>KMeans</code> , inercia, silhouette, escalamiento	clustering, segmentación y estabilidad
Capítulo 17	similitud coseno, ranking y cobertura	recomendación y evaluación offline
Capítulo 20	manifest de experimento, semillas, entorno	trazabilidad y reconstrucción de resultados

Referencia de API por capítulo

Primer uso	API o patrón	Qué aprende o calcula	Riesgo principal
Estimación y riesgo	<code>train_test_split</code>	separa observaciones	mezclar selección y test
Estimación y riesgo	<code>DummyClassifier</code>	baseline de clasificación	compararlo con otra partición
Estimación y riesgo	<code>make_pipeline</code>	encadena transformación y modelo	olvidar qué paso aprende parámetros
Distribuciones y muestras	<code>np.mean</code> , <code>np.var</code>	resumen de distribución empírica	confundir resumen muestral con garantía futura
Distribuciones y muestras	<code>np.random.default_rng</code>	simulación reproducible	interpretar simulación como dato real
Cap. 1	<code>np.column_stack</code> , <code>np.hstack</code>	construye matriz de diseño	duplicar intercepto
Cap. 1	<code>np.linalg.solve</code>	resuelve sistema lineal	usar matriz mal condicionada
Cap. 2	historial de pérdida	registra convergencia	no revisar escala de gradiente

Primer uso	API o patrón	Qué aprende o calcula	Riesgo principal
Cap. 3	<code>Ridge</code> , <code>Lasso</code>	ajusta regularización	escoger hiperparámetro con test
Cap. 4	<code>np.clip</code> , <code>np.log</code>	estabiliza log-loss	ocultar probabilidades extremas sin revisar
Cap. 6	<code>softmax</code> estable	convierte logits en probabilidades	overflow y ejes incorrectos
Cap. 9	<code>loss.backward()</code>	calcula gradientes	acumular gradientes sin limpiar
Cap. 11	<code>Pipeline</code>	evita leakage en transformaciones	ajustar pasos fuera del pipeline
Cap. 12	<code>GridSearchCV</code>	selecciona hiperparámetros	buscar sobre pipeline incompleto
Cap. 15	<code>np.linalg.svd</code>	factoriza matriz centrada	olvidar centrar antes
Cap. 16	<code>KMeans</code>	ajusta centroides	no escalar o no fijar semilla
Cap. 17	<code>cosine_similarity</code>	mide similitud angular	ignorar datos faltantes y popularidad

Algoritmos principales

Algoritmo o método	Primer uso fuerte	Implementación o referencia	Revisión necesaria
Regresión lineal	Capítulo 1	ecuación normal, <code>np.linalg.solve</code>	dimensiones, intercepto, MSE y residual
Descenso del gradiente	Capítulo 2	actualización vectorizada en NumPy	escala de variables, pérdida y convergencia
Regresión polinomial	Capítulo 3	matriz de features y validación	overfitting, grado y partición
Ridge	Capítulo 3	ecuación normal regularizada, <code>Ridge</code>	no penalizar intercepto y validar <code>lambda</code>
Lasso	Capítulo 3	<code>Lasso</code>	<code>sparsity</code> , escalamiento y validación
Regresión logística	Capítulo 4	sigmoide, log-loss, <code>LogisticRegression</code>	umbral, calibración y matriz de confusión
Perceptrón/logística multicapa	Capítulo 6	forward propagation	formas de matrices y activaciones
Backpropagation	Capítulo 7	regla de la cadena vectorizada	gradientes, cache y prueba numérica

Algoritmo o método	Primer uso fuerte	Implementación o referencia	Revisión necesaria
Momentum/Adam	Capítulo 9	loop NumPy o PyTorch	learning rate, estabilidad y validación
PCA	Capítulo 15	centrado y <code>np.linalg.svd</code>	varianza explicada e interpretación
K-Means	Capítulo 16	KMeans	escalamiento, inercia, silhouette y estabilidad
Recomendación item-item	Capítulo 17	similitud coseno	sesgo de popularidad y cobertura

Datasets y generadores

Recurso	Uso en el curso	Advertencia
<code>regresion_lineal_sintetica.csv</code>	caso longitudinal de regresión, gradiente, regularización y comunicación	sintético; no representa una población real
<code>clasificacion_binaria_sintetica.csv</code>	caso longitudinal de clasificación, métricas, validación, error analysis y defensa	el slice reciente ilustra mismatch de forma controlada
<code>pca_sintetico.csv</code>	PCA/SVD, varianza explicada y reconstrucción	estructura latente generada; no afirmar causalidad
<code>clusters_sinteticos.csv</code>	K-Means, inercia, silhouette y estabilidad	clusters compactos por construcción
<code>recomendacion_interacciones.csv</code>	recomendación item-item y cobertura	datos ficticios; no inferir preferencias reales
<code>load_wine</code>	arranque, clasificación multiclase y pipeline básico	dataset limpio; no prueba despliegue real
<code>load_diabetes</code>	regresión, Ridge/Lasso y validación	objetivo clínico simplificado; requiere cautela aplicada
<code>load_breast_cancer</code>	clasificación binaria, métricas y umbrales	no usar como recomendación clínica real
<code>load_digits</code>	redes, PCA y clasificación multiclase	imágenes pequeñas 8x8; no representa visión moderna
<code>make_regression</code>	regresión generada y gradiente	útil para revisar código, no para concluir aplicación
<code>make_blobs</code>	clustering sintético	favorece clusters compactos
<code>make_moons</code>	fronteras no lineales	muestra límites geométricos de modelos lineales

Funciones NumPy frecuentes

Función	Uso típico	Riesgo frecuente
<code>np.asarray</code>	convertir entradas a arreglo numérico	ocultar copias o formas inesperadas
<code>np.ones</code> , <code>np.hstack</code> , <code>np.column_stack</code>	construir matriz de diseño	duplicar intercepto
<code>@</code>	producto matricial	confundir producto elemento a elemento
<code>np.mean</code> , <code>np.sum</code> <code>np.linalg.solve</code>	pérdidas, métricas y gradientes resolver sistemas lineales	olvidar eje o factor $1/m$ usar matrices mal condicionadas
<code>np.linalg.cond</code>	diagnosticar condicionamiento	calcularlo después de leakage o escalamiento incorrecto
<code>np.linalg.svd</code> <code>np.exp</code> , <code>np.log</code> , <code>np.clip</code> <code>np.random.default_rng</code>	PCA y bajo rango sigmoide y log-loss reproducibilidad	olvidar centrar datos overflow o logaritmo de cero no fijar semilla o mezclar generadores

Herramientas scikit-learn frecuentes

Objeto	Uso típico	Revisión necesaria
<code>train_test_split</code>	separar entrenamiento, validación o test	estratificación y semilla
<code>StandardScaler</code>	escalar variables numéricas	ajustar solo con entrenamiento
<code>Pipeline</code> o <code>make_pipeline</code>	evitar leakage en transformaciones	ordenar pasos y revisar qué se aprende
<code>DummyClassifier</code>	baseline de clasificación	comparar antes de celebrar métricas
<code>LinearRegression</code>	referencia de regresión	misma matriz y mismo intercepto
<code>Ridge</code> , <code>Lasso</code>	regularización	escala, alpha y selección por validación
<code>LogisticRegression</code>	clasificación lineal	umbral, regularización y clases
<code>KMeans</code>	clustering por centroides	n_init , semilla y escalamiento
<code>silhouette_score</code>	evaluar separación de clusters	no absolutizar en geometrías no convexas
<code>cosine_similarity</code>	recomendación y similitud	normalización y datos faltantes

Métricas y diagnósticos

Métrica o diagnóstico	Dónde aparece	Pregunta que responde
MSE/MAE	regresión	¿qué tan grande es el error numérico?
matriz de confusión	clasificación	¿qué tipos de error se cometen?
precision	clasificación	¿cuántas predicciones positivas son correctas?
recall	clasificación	¿cuántos positivos reales se detectan?
F1	clasificación	¿cómo balancear precision y recall?
ROC-AUC	clasificación	¿cómo ordena scores el modelo?
learning curve	estrategia ML	¿hay sesgo, varianza o límite por datos?
validation curve	estrategia ML	¿cómo cambia el desempeño con un hiperparámetro?
inertia	K-Means	¿qué tan compactos son los clusters?
silhouette	clustering	¿qué tan separados están los clusters?
varianza explicada	PCA	¿cuánta estructura conserva la proyección?

PyTorch mínimo del curso

Elemento	Uso	Error frecuente
<code>torch.Tensor</code>	datos y parámetros en tensores	mezclar tipos o dispositivos sin control
<code>nn.Module</code>	definir modelo entrenable	esconder formas de entrada/salida
<code>loss_fn</code>	calcular pérdida	usar pérdida incompatible con logits o probabilidades
<code>loss.backward()</code>	calcular gradientes	olvidar limpiar gradientes antes
<code>optimizer.zero_grad()</code>	reiniciar acumulación de gradientes	acumular gradientes sin querer
<code>optimizer.step()</code>	actualizar parámetros	actualizar sin revisar escala de pérdida

Regla de lectura rápida

Cuando encuentres una función o clase en un notebook, pregunta:

1. ¿qué objeto matemático representa?
2. ¿qué aprende con `fit` o durante entrenamiento?
3. ¿qué datos puede ver sin producir leakage?
4. ¿qué métrica verifica que funciona?
5. ¿qué decisión se justifica y cuál no?

Una biblioteca estable reduce trabajo mecánico, no reduce responsabilidad técnica. El estudiante sigue siendo responsable de la pregunta, la partición, la métrica, el diagnóstico y la interpretación.

Taxonomía de ejercicios y banco de preguntas

Este apéndice organiza los ejercicios del libro por tipo de evidencia. No es un banco privado de parciales ni una colección de soluciones. Su función es ayudar a estudiantes e instructores a reconocer qué habilidad se está practicando y qué cuenta como una respuesta completa.

Propósito

Los ejercicios del libro siguen una progresión:

1. entender vocabulario y objetos;
2. calcular cantidades pequeñas;
3. implementar procedimientos reproducibles;
4. interpretar resultados con límites;
5. conectar evidencia con una decisión técnica.

Una pregunta bien construida no solo pide “obtener un número”. También debe dejar claro qué evidencia permite confiar en ese número y qué conclusión no se puede afirmar.

Tipos de ejercicio

Tipo	Pregunta que responde	Evidencia mínima
Conceptual	¿qué significa este objeto o supuesto?	explicación breve con vocabulario correcto
Cuantitativo	¿puedes calcularlo en un caso pequeño?	cálculo, fórmula, forma o métrica verificable
Computacional	¿puedes implementarlo sin romper la lógica?	función, notebook o salida reproducible
Interpretativo	¿qué decisión se justifica con la evidencia?	recomendación proporcional con limitación
Proyecto	¿cómo se aplica al caso propio?	decisión documentada, artefacto o miniinforme

Niveles cognitivos

El curso usa cinco niveles operativos de dificultad.

	Nivel	Acción observable	Ejemplo de verbo
	1	reconocer o definir	identificar, nombrar, distinguir
	2	calcular o verificar	calcular, derivar, comprobar, estimar
	3	implementar o reproducir	programar, ejecutar, comparar, graficar
	4	diagnosticar o evaluar	justificar, seleccionar, detectar, criticar
	5	diseñar o defender	proponer, integrar, defender, comunicar

Un buen capítulo debe ofrecer ejercicios en varios niveles. Un parcial o laboratorio puede concentrarse en algunos niveles, pero debe declarar qué evidencia espera.

Evidencia esperada

Evidencia	Debe incluir	No basta con
Cálculo matemático	fórmula, sustitución, resultado y unidad o interpretación	solo resultado final
Derivación	hipótesis, pasos algebraicos y forma final	saltar de fórmula inicial a final
Código	función ejecutable, shapes esperados y caso de prueba	celda que funciona solo para un dataset
Métrica	definición, valor, partición usada y baseline	reportar accuracy aislada
Diagnóstico	patrón observado, posible causa y acción siguiente	decir “overfitting” sin evidencia
Recomendación	decisión, métrica, límite y riesgo	afirmar que el modelo “es bueno”

Banco público por módulo

Este banco resume familias de preguntas públicas. Los ejercicios concretos están en cada capítulo; esta tabla ayuda a calibrar estudio y evaluación.

Módulo	Familia de preguntas	Nivel típico	Capítulos
Datos y preguntas	identificar observación, variable, población, medición y alcance de una pregunta	1-4	Observaciones y variables
Regresión	formular media condicional y riesgo, construir matriz de diseño, derivar MSE y resolver ecuación normal	2-4	Capítulos 1-2
Regularización	comparar Ridge/Lasso, validar hiperparámetro y detectar leakage	3-4	Capítulo 3
Clasificación	calcular matriz de confusión, precisión, recall, F1 y umbral	2-4	Capítulo 4
Redes	verificar formas, forward, backward, gradientes y entrenamiento	2-4	Capítulos 6-9
Estrategia ML	diseñar particiones, curvas, error analysis y diagnóstico por slice	3-5	Capítulos 11-13
No supervisado	centrar datos, aplicar PCA, ejecutar K-Means e interpretar clusters	2-4	Capítulos 15-17
Reproducibilidad	construir manifest, trazabilidad, reporte y defensa técnica	3-5	Capítulos 20-22
Herramientas probabilísticas	formalizar distribuciones, muestreo, estimación, riesgo e incertidumbre	2-5	Distribuciones y muestras y estimación y riesgo

Criterios de calibración

Una pregunta es demasiado fácil si puede responderse copiando una definición sin aplicarla. Es demasiado difícil si requiere información no enseñada, datos no disponibles o criterios ocultos.

Criterio	Pregunta de control
Alineación	¿la pregunta mide un objetivo del capítulo?
Verificabilidad	¿hay una respuesta, cálculo o criterio observable?
Independencia	¿puede resolverse sin material privado?
Transferencia	¿obliga a usar la idea en un caso nuevo?
Interpretación	¿pide límites, riesgo o decisión cuando corresponde?
Automatización	¿qué parte puede calificarse con pruebas o reglas claras?

Uso para estudiantes

Antes de entregar un laboratorio o preparar un parcial, identifica qué tipo de pregunta estás resolviendo:

- si es conceptual, prioriza definiciones y contraejemplos;
- si es cuantitativa, revisa formas, fórmulas y unidades;
- si es computacional, prueba con casos pequeños antes del dataset final;
- si es interpretativa, compara contra baseline y declara límites;
- si es de proyecto, conecta la respuesta con la decisión aplicada.

Uso para instructores

Al diseñar o revisar ejercicios, mantener esta mezcla mínima:

Evaluación	Mezcla recomendada
Quiz corto	conceptual y cuantitativo
Laboratorio	computacional, cuantitativo e interpretativo
Parcial autograded	cuantitativo, computacional y diagnóstico estructurado
Proyecto	interpretativo, reproducible y defensa de decisión

La calificación manual debe reservarse para interpretación, decisión y comunicación. Shapes, métricas, outputs numéricos y funciones pequeñas deben preferirse para autocalificación cuando sea razonable.

Señales de mala pregunta

Una pregunta debe revisarse si:

- premia memorizar una frase sin usarla;
- no indica qué partición de datos usar;
- mezcla entrenamiento y test;
- pide una recomendación sin baseline;
- usa una métrica sin explicar el costo de error;
- requiere una solución oficial o autograder privado;
- tiene ambigüedad matemática que cambia la respuesta;
- no permite distinguir error de código de error conceptual.

Mantenimiento y revisión

Esta taxonomía debe actualizarse cuando:

- cambie la política de evaluación;
- se agreguen laboratorios o parciales;
- se cambie el peso de interpretación manual;
- una revisión externa detecte desalineación entre objetivos y ejercicios;
- un autograder muestre hardcoding o patrones de error no previstos.

Prerrequisitos matemáticos mínimos

Este apéndice resume el lenguaje matemático que el libro usa de forma recurrente. Presupone los cursos indicados de álgebra lineal y cálculo, pero no un curso formal previo de probabilidad. Su propósito es ofrecer una referencia rápida para leer capítulos, notebooks y ejercicios sin perder la forma de los objetos; la teoría probabilística se desarrolla dentro del texto y se reúne en los capítulos de herramientas.

Cómo usar este apéndice

Úsalo cuando aparezca una duda de notación antes de resolver un ejercicio:

1. identifica el objeto: escalar, vector, matriz, función o variable aleatoria;
2. revisa la forma esperada;
3. conecta la fórmula con la operación de NumPy o PyTorch;
4. vuelve al capítulo y verifica si la interpretación tiene sentido.

La pregunta central no es “¿recuerdo la fórmula?”, sino “¿sé qué objeto calcula, con qué forma, sobre qué datos y para qué decisión?”.

Álgebra lineal mínima

Objeto	Notación	Forma típica	Lectura
vector de variables	x	p o $p \times 1$	una observación con p entradas
matriz de diseño	X	$n \times p$	n observaciones y p variables
parámetros	θ o w	p o $p \times 1$	pesos que convierten entradas en predicción
predicción	$\hat{y} = X\theta$	n	una salida por observación
residual	$r = y - \hat{y}$	n	error observado
matriz de pesos	$W^{[\ell]}$	$d_{\ell-1} \times d_{\ell}$	conecta capas de una red

Producto matricial:

$$(X\theta)_i = \sum_{j=1}^p X_{ij}\theta_j.$$

En NumPy:

```
y_hat = X @ theta
```

Chequeo básico:

Operación	Requisito
<code>X @ theta</code>	columnas de <code>X</code> = largo de <code>theta</code>
<code>X.T @ residual</code>	largo de <code>residual</code> = filas de <code>X</code>
<code>A @ W + b</code>	columnas de <code>A</code> = filas de <code>W</code> ; <code>b</code> broadcast por columnas

Normas, distancias y pérdida cuadrática

La norma euclidiana de un vector es:

$$\|r\|_2 = \sqrt{\sum_i r_i^2}.$$

El MSE usa errores cuadrados:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

En regresión, minimizar MSE equivale a buscar predicciones cercanas a y en promedio cuadrático. En optimización usamos a menudo:

$$J(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2,$$

porque el factor $1/2$ simplifica el gradiente.

Cálculo y gradientes mínimos

Una derivada mide sensibilidad local. Un gradiente reúne derivadas parciales:

$$\nabla J(\theta) = \begin{bmatrix} \frac{\partial J}{\partial \theta_1} \\ \vdots \\ \frac{\partial J}{\partial \theta_p} \end{bmatrix}.$$

Regla práctica del curso:

Si quieres	Usas
reducir una pérdida	moverte en dirección $-\nabla J$
detectar convergencia	norma del gradiente, cambio de pérdida o cambio de parámetros
entrenar una red	regla de la cadena organizada como backpropagation

Para MSE:

$$J(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2, \quad \nabla J(\theta) = \frac{1}{n} X^\top (X\theta - y).$$

Notación probabilística de primera aparición

Antes de observar un caso, Y representa una cantidad incierta. Después de observarlo, y_i es una realización.

Idea	Lectura operativa
distribución empírica	lo que se observa en el dataset disponible
valor esperado	promedio ideal bajo un proceso de generación
ruido	variación que el modelo no explica con las variables disponibles
probabilidad condicional	$P(Y = 1 \mid X = x)$: probabilidad dada una entrada
pérdida empírica	error promedio observado en un conjunto finito
riesgo esperado	error promedio ideal en casos futuros

Estas nociones aparecen primero dentro de modelos concretos. Los capítulos de herramientas probabilísticas precisan después sus definiciones, propiedades y condiciones de uso.

Notación NumPy y PyTorch

Matemática	NumPy	PyTorch	Cuidado
$X\theta$	<code>X @ theta</code>	<code>X @ theta</code> o <code>model(X)</code>	revisar formas
media	<code>np.mean(x)</code>	<code>torch.mean(x)</code>	eje correcto
exponencial	<code>np.exp(z)</code>	<code>torch.exp(z)</code>	overflow
logaritmo	<code>np.log(p)</code>	<code>torch.log(p)</code>	evitar <code>log(0)</code>
gradiente	cálculo manual	<code>loss.backward()</code>	limpiar gradientes
actualización	<code>theta -= alpha * grad</code>	<code>optimizer.step()</code>	no olvidar <code>zero_grad()</code>

PyTorch acumula gradientes por defecto. Por eso el loop mínimo contiene:

```
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

Checklist de formas

Antes de ejecutar un notebook, verifica:

- ¿cada fila representa una observación?
- ¿la variable objetivo tiene una entrada por observación?
- ¿la matriz de diseño incluye o no intercepto?
- ¿los pesos tienen una dimensión compatible con las entradas?
- ¿la pérdida produce un escalar?
- ¿la métrica se calcula sobre la partición correcta?
- ¿las transformaciones se ajustan solo con entrenamiento?

Ejemplo resuelto: gradiente de MSE en una línea

Sea:

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 3 \end{bmatrix}, \quad \theta = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

El residual es:

$$X\theta - y = \begin{bmatrix} -1 \\ -3 \end{bmatrix}.$$

Como $n = 2$,

$$\nabla J(\theta) = \frac{1}{2} X^\top (X\theta - y) = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ -3 \end{bmatrix} = \begin{bmatrix} -2 \\ -1.5 \end{bmatrix}.$$

La actualización con $\alpha = 0.1$ sería:

$$\theta_{\text{nuevo}} = \theta - \alpha \nabla J(\theta) = \begin{bmatrix} 0.2 \\ 0.15 \end{bmatrix}.$$

Respuestas rápidas de autoverificación

1. Si X tiene forma 100×8 y θ tiene largo 8, entonces $X\theta$ tiene largo 100.
2. Si una red produce logits de forma 64×10 , softmax se aplica por fila para obtener una distribución por observación.
3. Si `loss.backward()` se llama dos veces sin `zero_grad()`, los gradientes se acumulan.
4. Si `test` se usa para escoger hiperparámetros, `test` deja de ser estimación final.

Formularios y respuestas seleccionadas

Los apéndices reúnen fórmulas, criterios operativos, patrones de código y respuestas seleccionadas de cada bloque. No reemplazan el estudio de los capítulos: sirven como referencia rápida y como verificación después de resolver ejercicios.

Las respuestas seleccionadas son deliberadamente parciales. El objetivo es orientar, no convertir el libro en un solucionario completo. Las soluciones oficiales de laboratorios, parciales y pruebas ocultas pertenecen al paquete restringido de instructor.

Cómo usar esta parte

1. Intenta resolver primero el ejercicio sin mirar la respuesta.
2. Revisa la fórmula o checklist correspondiente.
3. Compara tu resultado con la respuesta seleccionada cuando exista.
4. Si tu respuesta difiere, identifica si el error es de forma, fórmula, cálculo, código o interpretación.
5. Vuelve al capítulo si no puedes explicar por qué la respuesta es correcta.

Mapa de apéndices

Apéndice	Uso principal
Módulo 1	Regresión, gradiente, regularización, logística y Parcial 1.
Módulo 2	Redes densas, backpropagation, diagnóstico y lectura de PyTorch.
Módulo 3	Métricas, particiones, validación, leakage y análisis de errores.
Módulo 4	PCA/SVD, K-Means, recomendación y límites de interpretación.
Módulo 5	Parcial 2, reproducibilidad, reporte técnico y defensa final.

Política de respuestas

Las respuestas públicas cubren una muestra representativa: algunas verifican cálculo, otras verifican razonamiento y otras muestran el nivel esperado de una explicación técnica breve. Los proyectos de cierre no tienen solución única; por eso se evalúan con criterios, evidencia y límites explícitos.

La política completa de separación entre respuestas públicas, manual de estudiante y recursos restringidos está en [Respuestas, solucionarios y recursos restringidos](#).

Apéndice Módulo 1: formulario y respuestas seleccionadas

Resumen de fórmulas, chequeos y verificación

Cómo usar este apéndice

Este apéndice resume las fórmulas y chequeos del primer bloque matemático del curso: regresión, optimización, regularización y clasificación binaria. Úsalo para verificar derivaciones, notebooks y preparación del Parcial 1.

No memorices fórmulas aisladas. Para cada objeto, verifica forma, significado, hipótesis y el lugar que ocupa en el pipeline de modelación.

Notación mínima

Símbolo	Significado
$X \in \mathbb{R}^{n \times p}$	matriz de diseño
$y \in \mathbb{R}^n$	variable respuesta o etiqueta binaria
$\theta \in \mathbb{R}^p$	vector de parámetros
$\hat{y}$	predicción de regresión
$\hat{p}$	probabilidad predicha en clasificación binaria
λ	intensidad de regularización
τ	umbral de clasificación
TP, TN, FP, FN	conteos de matriz de confusión

Formulario mínimo

Regresión lineal

Predicción:

$$\hat{y} = X\theta.$$

Residual:

$$r = y - X\theta.$$

MSE:

$$\text{MSE}(\theta) = \frac{1}{n} \|X\theta - y\|_2^2.$$

Pérdida escalada:

$$J(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2.$$

Gradiente:

$$\nabla J(\theta) = \frac{1}{n} X^\top (X\theta - y).$$

Ecuación normal:

$$X^\top X\theta = X^\top y.$$

Solución si $X^\top X$ es invertible:

$$\theta^* = (X^\top X)^{-1} X^\top y.$$

Descenso del gradiente

Actualización:

$$\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla J(\theta^{(t)}).$$

Para MSE:

$$\theta^{(t+1)} = \theta^{(t)} - \alpha \frac{1}{n} X^\top (X\theta^{(t)} - y).$$

Estandarización:

$$z_j = \frac{x_j - \mu_j}{s_j}.$$

Ridge

Objetivo:

$$J_{\text{ridge}}(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2 + \frac{\lambda}{2} \|\theta_{1:p}\|_2^2.$$

Gradiente:

$$\nabla J_{\text{ridge}}(\theta) = \frac{1}{n} X^\top (X\theta - y) + \lambda \tilde{\theta}.$$

Solución sin penalizar intercepto:

$$\theta^* = (X^\top X + n\lambda D)^{-1} X^\top y,$$

donde $D_{00}=0$ y $D_{jj}=1$ para $j>0$.

Lasso

Objetivo:

$$J_{\text{lasso}}(\theta) = \frac{1}{2n} \|X\theta - y\|_2^2 + \lambda \|\theta_{1:p}\|_1.$$

Regresión logística

Sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Probabilidad:

$$\hat{p} = \sigma(X\theta).$$

Log-loss:

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Gradiente:

$$\nabla J(\theta) = \frac{1}{n} X^\top (\hat{p} - y).$$

Clasificación por umbral:

$$\hat{y}_i = 1\{\hat{p}_i \geq \tau\}.$$

Métricas

Accuracy:

$$\frac{TP + TN}{TP + TN + FP + FN}.$$

Precision:

$$\frac{TP}{TP + FP}.$$

Recall:

$$\frac{TP}{TP + FN}.$$

F1:

$$2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}.$$

Patrones de código

```
def add_intercept(X):  
    X = np.asarray(X, dtype=float)  
    return np.hstack([np.ones((X.shape[0], 1)), X])
```

```
def mse_loss(X, y, theta):  
    residual = X @ theta - y  
    return np.mean(residual ** 2)
```

```
def mse_gradient(X, y, theta):  
    return (X.T @ (X @ theta - y)) / X.shape[0]
```

```
def ridge_closed_form(X, y, lam):  
    p = X.shape[1]  
    D = np.eye(p)  
    D[0, 0] = 0  
    return np.linalg.solve(X.T @ X + X.shape[0] * lam * D, X.T @ y)
```

```
def sigmoid(z):
    z = np.asarray(z, dtype=float)
    out = np.empty_like(z)
    pos = z >= 0
    out[pos] = 1 / (1 + np.exp(-z[pos]))
    exp_z = np.exp(z[~pos])
    out[~pos] = exp_z / (1 + exp_z)
    return out
```

Checklist antes de entregar

- El notebook corre desde cero.
- Las funciones no dependen de variables globales ocultas.
- Las formas de matrices y vectores son consistentes.
- El preprocesamiento se ajusta solo con entrenamiento.
- Hay baseline.
- Hay métrica adecuada.
- Hay interpretación breve.
- La conclusión menciona al menos una limitación.

Respuestas seleccionadas

Estas respuestas no reemplazan el desarrollo. Sirven para verificar dirección.

Capítulo 1

Ejercicio 1.1. Si X tiene forma $(120, 4)$, entonces `theta` debe tener forma $(4,)$ o $(4, 1)$ para que `X @ theta` produzca 120 predicciones.

Ejercicio 1.2. La columna de unos convierte el intercepto en un coeficiente más: `theta_0 * 1`.

Ejercicio 1.6. Para

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, y = \begin{bmatrix} 2 \\ 2 \\ 5 \end{bmatrix},$$

se obtiene:

$$X^{\top} X = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \quad X^{\top} y = \begin{bmatrix} 9 \\ 12 \end{bmatrix}.$$

Capítulo 2

Ejercicio 2.2. Usamos $\theta - \alpha \cdot \text{grad}$ porque el gradiente apunta hacia mayor aumento de la pérdida.

Ejercicio 2.4. Escalar ayuda porque reduce diferencias extremas de curvatura entre direcciones. El descenso hace pasos más directos y estables.

Ejercicio 2.8. Una curva que sube y baja violentamente sugiere una tasa de aprendizaje demasiado grande o un problema de escala.

Capítulo 3

Ejercicio 3.2. No se escoge λ con prueba porque entonces prueba deja de ser una evaluación final independiente.

Ejercicio 3.8. Para $\theta=(3,4,-1)$, sin intercepto:

$$\|\theta_{1:p}\|_2^2 = 4^2 + (-1)^2 = 17, \quad \|\theta_{1:p}\|_1 = 4 + 1 = 5.$$

Ejercicio 3.16. Preferiría $\lambda=0.1$ si la meta es generalizar: aumenta el error de entrenamiento, pero reduce mucho el error de validación.

Capítulo 4

Ejercicio 4.6.

$$\sigma(0) = 0.5, \quad \sigma(2) \approx 0.881, \quad \sigma(-2) \approx 0.119.$$

Ejercicio 4.7. Si TP=40, FP=10, TN=80, FN=20:

$$\text{accuracy} = 0.80, \quad \text{precision} = 0.80, \quad \text{recall} = 0.667.$$

F1 es aproximadamente 0.727.

Ejercicio 4.16. Accuracy alta y recall bajo puede indicar clases desbalanceadas: el modelo acierta muchos negativos, pero falla positivos.

Tema	Ejercicios recomendados
------	-------------------------

Guía de estudio para el Parcial 1

Prioriza estos ejercicios si tienes poco tiempo:

Tema	Ejercicios recomendados
Regresión lineal	Cap. 1: 6, 7, 10, 14
Gradiente	Cap. 2: 6, 9, 13, 14
Validación	Cap. 3: 2, 6, 10, 16
Regularización	Cap. 3: 7, 8, 11, 13
Logística	Cap. 4: 6, 7, 11, 12
Umbrales	Cap. 4: 14, 15, 16

Para cerrar, escribe una página de resumen con:

1. una fórmula que todavía te cuesta;
2. un error común que ya sabes evitar;
3. una métrica que usarías en tu proyecto;
4. una pregunta concreta para clase o monitoría.

Apéndice Módulo 2: formulario y respuestas seleccionadas

Cómo usar este apéndice

Este apéndice es una referencia para el Módulo 2. Úsalo después de intentar los ejercicios del capítulo o antes de revisar un notebook de redes. La meta no es memorizar símbolos, sino poder auditar cada objeto: forma, significado, operación que lo produjo y riesgo de implementación.

En redes neuronales, una respuesta puede tener código correcto y aun así estar mal argumentada si no explica formas, pérdida, diagnóstico o decisión de entrenamiento.

Notación mínima

Símbolo	Significado
$X \in \mathbb{R}^{n \times p}$	matriz de entrada: n observaciones, p variables
$Y \in \mathbb{R}^{n \times k}$	etiquetas one-hot para k clases
$W^{[\ell]}, b^{[\ell]}$	pesos y sesgos de la capa ℓ
$Z^{[\ell]}$	preactivación de la capa ℓ
$A^{[\ell]}$	activación de la capa ℓ
$\hat{P}$	probabilidades predichas por softmax
J	pérdida promedio

Fórmulas clave de forward

Forward

$$Z^{[1]} = XW^{[1]} + b^{[1]}$$

$$A^{[1]} = \text{ReLU}(Z^{[1]})$$

$$Z^{[2]} = A^{[1]}W^{[2]} + b^{[2]}$$

$$\hat{P} = \text{softmax}(Z^{[2]})$$

Si $X \in \mathbb{R}^{n \times p}$, una capa oculta con h neuronas y k clases usa las formas:

Objeto	Forma
$W^{[1]}$	$p \times h$
$b^{[1]}$	$h \text{ o } 1 \times h$
$Z^{[1]}, A^{[1]}$	$n \times h$
$W^{[2]}$	$h \times k$
$b^{[2]}$	$k \text{ o } 1 \times k$
$Z^{[2]}, \hat{P}, Y$	$n \times k$

Softmax

$$\text{softmax}(z)_j = \frac{e^{z_j}}{\sum_{\ell=1}^k e^{z_\ell}}$$

Versión estable:

$$\text{softmax}(z)_j = \frac{e^{z_j - \max(z)}}{\sum_{\ell=1}^k e^{z_\ell - \max(z)}}.$$

Cross-entropy

$$J = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^k Y_{ij} \log(\hat{P}_{ij})$$

Fórmulas clave de backward

$$dZ^{[2]} = \frac{1}{n}(\hat{P} - Y)$$

$$dW^{[2]} = (A^{[1]})^\top dZ^{[2]}, \quad db^{[2]} = \sum_i dZ_i^{[2]}$$

$$dA^{[1]} = dZ^{[2]}(W^{[2]})^\top$$

$$dZ^{[1]} = dA^{[1]} \odot \mathbf{1}\{Z^{[1]} > 0\}$$

$$dW^{[1]} = X^\top dZ^{[1]}, \quad db^{[1]} = \sum_i dZ_i^{[1]}$$

Diagnóstico de entrenamiento

Evidencia	Diagnóstico probable	Acción inicial
Train mejora y validation empeora	overfitting	early stopping, L2, dropout, menor capacidad
Train y validation son malos	underfitting o mala señal	revisar features, arquitectura, learning rate
La pérdida oscila o explota	learning rate alto o escala inestable	bajar learning rate, revisar inicialización
Probabilidades casi uniformes	entrenamiento insuficiente o logits pequeños	revisar inicialización, gradientes y épocas
Gradientes con forma correcta pero norma cero	saturación o camino bloqueado	revisar activación, inicialización y datos

Patrones de código

```
def softmax_stable(Z):  
    Z = np.asarray(Z, dtype=float)  
    shifted = Z - np.max(Z, axis=1, keepdims=True)  
    exp_scores = np.exp(shifted)  
    return exp_scores / exp_scores.sum(axis=1, keepdims=True)
```

```
def cross_entropy(P, y):  
    eps = 1e-12  
    P = np.clip(P, eps, 1 - eps)  
    return -np.mean(np.log(P[np.arange(len(y)), y]))
```

```
def relu_backward(dA, Z):  
    return dA * (Z > 0)
```

Checklist antes de entregar

- Cada matriz tiene la forma esperada.
- Softmax se aplica por fila.
- La pérdida usa probabilidades recortadas o softmax estable.
- dZ_2 tiene la misma forma que Y .
- Cada gradiente tiene la misma forma que el parámetro que actualiza.
- Los gradientes se dividen por n exactamente una vez.
- El diagnóstico usa curva de entrenamiento y validación.
- La comparación con PyTorch usa misma partición, semilla y métrica.

Respuestas seleccionadas

Estas respuestas verifican dirección. No sustituyen el desarrollo completo ni las pruebas del laboratorio.

Verificaciones de ejemplos resueltos

Softmax estable. Para $z = (2, 1, 0)$, restar el máximo produce $(0, -1, -2)$. La distribución aproximada es $(0.665, 0.245, 0.090)$. La pérdida de una observación se calcula con la probabilidad de la clase correcta, no con la probabilidad más alta en abstracto.

Diferencia finita. Para $J(w) = (w - 3)^2$, $w = 2$ y $\varepsilon = 0.01$, la diferencia central da -2 , igual a la derivada exacta $2(w - 3)$.

Regularización L2. Si $\|W\|_F^2 = 14$ y $\lambda = 0.1$, la penalización $\frac{\lambda}{2}\|W\|_F^2$ vale 0.7. El gradiente suma λW al gradiente de datos.

Momentum. Con $\theta_0 = 5$, $\alpha = 0.1$, $\beta = 0.9$, $v_0 = 0$, $g_1 = 4$ y $g_2 = 2$, se obtiene $v_1 = 0.4$, $\theta_1 = 4.96$, $v_2 = 0.56$ y $\theta_2 = 4.904$.

Capítulo 1

Ejercicio 1.1. Sin activaciones no lineales, una composición de transformaciones lineales sigue siendo una transformación lineal. Por ejemplo:

$$(XW_1)W_2 = X(W_1W_2).$$

La red puede reescribirse como un solo modelo lineal.

Ejercicio 1.3. Si X tiene forma $(250, 20)$ y la capa oculta tiene 12 neuronas, entonces $W1$ debe tener forma $(20, 12)$, $b1$ forma $(12,)$ o $(1, 12)$, y $Z1$ forma $(250, 12)$.

Ejercicio 1.4. Para 5 clases y batch de 32, logits, probabilidades softmax y matriz one-hot tienen forma $(32, 5)$.

Capítulo 2

Ejercicio 2.1. Backpropagation necesita valores guardados del forward porque las derivadas locales dependen de objetos intermedios: por ejemplo, ReLU necesita conocer dónde $Z^{[1]} > 0$, y $dW^{[2]}$ necesita $A^{[1]}$.

Ejercicio 2.2. ReLU vale z cuando $z > 0$ y vale 0 cuando $z \leq 0$. Por tanto, su derivada es 1 en la región positiva y 0 en la región no positiva. En código, $(Z1 > 0)$ actúa como máscara.

Ejercicio 2.4. Si $A^{[1]} \in \mathbb{R}^{80 \times 16}$ y $dZ^{[2]} \in \mathbb{R}^{80 \times 4}$, entonces

$$dW^{[2]} = (A^{[1]})^\top dZ^{[2]} \in \mathbb{R}^{16 \times 4}, \quad db^{[2]} \in \mathbb{R}^4.$$

Capítulo 3

Ejercicio 3.1. Train accuracy 99 % y validation accuracy 70 % sugiere overfitting. El modelo aprendió patrones específicos del entrenamiento que no generalizan. Antes de reportarlo como mejora habría que revisar regularización, capacidad, partición de datos y análisis de errores.

Ejercicio 3.4. Para $w = (2, -1, 0.5)$ y $\lambda = 0.1$,

$$\lambda \sum_j w_j^2 = 0.1(4 + 1 + 0.25) = 0.525.$$

Ejercicio 3.8. Si una métrica global mejora pero un subconjunto crítico empeora, no basta con reportar la mejora. El siguiente paso es aislar el slice, verificar tamaño y costo del error, y proponer una acción antes de usar el modelo.

Capítulo 4

Ejercicio 4.2. PyTorch acumula gradientes porque permite sumar contribuciones de varias pérdidas o batches antes de actualizar. En entrenamiento estándar se llama `zero_grad()` para que el batch actual no se mezcle con gradientes del batch anterior.

Ejercicio 4.3. Con 1024 observaciones y batch size 64, una época tiene $1024/64 = 16$ batches.

Ejercicio 4.4. Si se entrenan 20 épocas con 16 batches por época, `optimizer.step()` se ejecuta $20 \times 16 = 320$ veces.

Ejercicios integradores

Bloque A. Para auditar dimensiones, no empieces por el código. Escribe primero las formas esperadas de X , $W^{[1]}$, $b^{[1]}$, $Z^{[1]}$, $A^{[1]}$, $W^{[2]}$, $b^{[2]}$ y $\hat{P}$. Luego compara cada objeto del notebook contra esa tabla.

Bloque C. Una buena respuesta de diagnóstico tiene tres partes: resultado observado, causa probable y comprobación. Ejemplo: “validation loss sube después de la época 15 mientras train loss sigue bajando; esto sugiere overfitting; probaría early stopping y mayor regularización”.

Apéndice Módulo 3: formulario y respuestas seleccionadas

Cómo usar este apéndice

Este apéndice resume las reglas que evitan conclusiones engañosas en machine learning aplicado: métrica mal escogida, particiones contaminadas, validación mal interpretada y análisis de error insuficiente. Úsalo como checklist antes de comparar modelos o escribir una recomendación técnica.

Una métrica no es una conclusión. La conclusión aparece cuando conectas métrica, baseline, partición, error principal, costo de error y límite de uso.

Notación mínima

Símbolo	Significado
TP, TN, FP, FN	conteos de la matriz de confusión
s_k	métrica obtenida en el fold k
$\bar{s}$	media de validación cruzada
σ_s	variabilidad entre folds
dev	conjunto de validación para elegir modelos
test	conjunto final para estimar desempeño una vez
slice	subconjunto relevante para análisis de error

Métricas de clasificación binaria

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{recall} = \frac{TP}{TP + FN}$$

$$F1 = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

Validación cruzada

$$\bar{s} = \frac{1}{K} \sum_{k=1}^K s_k, \quad \sigma_s = \sqrt{\frac{1}{K-1} \sum_{k=1}^K (s_k - \bar{s})^2}.$$

Reporta media y variabilidad. Si dos modelos tienen medias similares, la variabilidad puede cambiar la decisión.

Reglas operativas

1. El test se toca una vez.
2. La métrica principal se decide antes de comparar modelos.
3. Las transformaciones se ajustan dentro de cada fold o partición de entrenamiento.
4. Todo modelo se compara contra baseline.
5. Un promedio no reemplaza análisis de slices.

Checklist de evaluación

- La métrica principal está alineada con el costo de error.
- Hay baseline trivial o operativo.
- La partición respeta tiempo, grupos o estratificación cuando aplica.
- El preprocesamiento está dentro de un **Pipeline**.
- La validación no usa test para elegir hiperparámetros.
- El reporte incluye variabilidad o intervalo cuando sea razonable.
- Hay análisis de al menos un slice crítico.
- La recomendación incluye un límite explícito.

Patrones de decisión

Situación	Señal	Decisión prudente
Clase positiva rara	accuracy alta con recall bajo	usar recall, F1, PR-AUC o costo explícito
Métricas train muy superiores a dev	brecha alta	diagnosticar overfitting o leakage
Dev estable y test cae	fuentes/población distinta	investigar data mismatch
Mejor media pero alta variabilidad	folds inconsistentes	preferir modelo más estable si el riesgo importa
Slice crítico empeora	promedio oculta daño	no recomendar despliegue sin mitigación

Patrones de código

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

pipe = Pipeline([
    ("scale", StandardScaler()),
    ("model", LogisticRegression(max_iter=1000))
])
```

```
def metric_by_group(df, group_col, y_col, yhat_col, metric_fn):
    rows = []
    for group, part in df.groupby(group_col):
        rows.append({
            "group": group,
            "n": len(part),
            "score": metric_fn(part[y_col], part[yhat_col])
        })
    return pd.DataFrame(rows)
```

Respuestas seleccionadas

Verificaciones de ejemplos resueltos

Costo de errores. Con umbral A, $FP = 40$, $FN = 15$, costo de FP igual a 1 y costo de FN igual a 10, el costo es $40 + 150 = 190$. Con umbral B, el costo es $10 + 250 = 260$. Si el falso negativo es mucho más costoso, A puede ser preferible aunque tenga menor precisión.

Partición estratificada. Si hay 2000 observaciones y 8% de positivos, hay 160 positivos. En una división 60/20/20 se esperan 96 positivos en train, 32 en dev y 32 en test. Esta cuenta solo verifica proporción de clase; no valida tiempo, grupos ni duplicados.

Learning curve. Si F1 de validación sube de 0.63 a 0.86 al aumentar datos y la brecha train-validación baja de 0.35 a 0.04, el patrón sugiere que más datos podría ayudar a reducir varianza. No es una señal para aumentar complejidad como primera acción.

Data mismatch. Si train y dev tienen cerca de 20% de positivos, pero test tiene 8% y recall cae de 0.82 a 0.55, antes de ajustar hiperparámetros hay que auditar fuente, periodo, población y construcción del split.

Brecha por slice. Si el F1 global es 0.81 y en fuente C es 0.57, la brecha es $0.81 - 0.57 = 0.24$. La recomendación debe explicar resultado, lectura, comprobación y límite; no basta reportar el promedio global.

Capítulo 1

Ejercicio 1.1. En fraude, preferir recall es razonable cuando perder un fraude es mucho más costoso que revisar falsos positivos. Preferir precision es razonable cuando cada alerta tiene alto costo operativo o afecta injustamente a usuarios legítimos.

Ejercicio 1.4. Con 2000 observaciones y clase positiva de 8 %, hay 160 positivos. En una partición 60/20/20 estratificada se esperan aproximadamente 96 positivos en train, 32 en dev y 32 en test.

Ejercicio 1.7. Imputar la media usando todo el dataset antes de partir es leakage porque la media incorpora información de validación/test. La media debe aprenderse solo con entrenamiento, idealmente dentro de un **Pipeline**.

Capítulo 2

Ejercicio 2.1. Train F1 0.99 y validation F1 0.70 sugiere overfitting. Acciones razonables: aumentar regularización, simplificar el modelo, revisar leakage, recolectar más datos o cambiar features.

Ejercicio 2.2. La desviación estándar de CV importa porque una media alta con mucha variabilidad puede indicar que el modelo depende demasiado de la partición. Si la aplicación exige estabilidad, un modelo con media apenas menor pero menor variabilidad puede ser preferible.

Ejercicio 2.4. Si se evalúan 4 valores de **C**, 3 valores de **penalty** y 5 folds, se entrenan $4 \times 3 \times 5 = 60$ ajustes.

Capítulo 3

Ejercicio 3.2. Un F1 global puede ocultar una falla grave si el modelo funciona bien en grupos numerosos y mal en un grupo pequeño pero importante. Por eso se reportan métricas por slice.

Ejercicio 3.3. Si una tabla por slice muestra F1 global 0.81 y un slice con F1 0.57, la brecha es 0.24. Si ese slice corresponde a una fuente, grupo o periodo relevante para producción, debe tratarse como riesgo técnico aunque el promedio global parezca aceptable.

Ejercicio 3.4. Si dev tiene 30 % de clase positiva y test 12 %, antes de ajustar hiperparámetros sospecharía data mismatch, cambio temporal, sesgo de muestreo o partición no representativa.

Ejercicio 3.7. Data mismatch puede sospecharse si el desempeño en dev es estable pero cae mucho en test, especialmente si test proviene de otra fuente, periodo o población.

Ejercicios integradores

Bloque A. Una respuesta completa sobre métricas debe nombrar el costo del error. Por ejemplo, no basta decir “F1 es mejor”; hay que explicar si el problema castiga más falsos positivos, falsos negativos o ambos.

Bloque D. La estructura mínima de recomendación técnica es: resultado observado, lectura probable, comprobación concreta y límite. Si falta una de esas cuatro partes, la recomendación es difícil de auditar.

Apéndice Módulo 4: formulario y respuestas seleccionadas

Cómo usar este apéndice

Este apéndice reúne fórmulas y criterios para aprendizaje no supervisado. En este módulo, el cálculo correcto no basta: también debes decir qué conclusión permite el método y qué conclusión sería una sobreinterpretación.

En aprendizaje no supervisado no hay una etiqueta que confirme automáticamente que la estructura encontrada es útil. La respuesta debe combinar cálculo, visualización, estabilidad, interpretación y límite aplicado.

Notación mínima

Símbolo	Significado
$X \in \mathbb{R}^{n \times p}$	matriz de datos
X_c	matriz centrada por columnas
$U\Sigma V^\top$	descomposición SVD
V_k	primeros k vectores derechos
$Z = X_c V_k$	scores o coordenadas PCA
μ_j	centroide del cluster j
c_i	asignación de cluster de la observación i
R	matriz usuario-ítem

SVD

$$X = U\Sigma V^\top$$

Si $X \in \mathbb{R}^{n \times p}$ y $r = \text{rank}(X)$, entonces:

Objeto	Forma
U reducida	$n \times r$
Σ reducida	$r \times r$
V reducida	$p \times r$
V_k	$p \times k$
$Z = X_c V_k$	$n \times k$

PCA

$$X_c = X - \bar{X}$$

$$Z = X_c V_k$$

$$\hat{X} = Z V_k^\top + \bar{X}$$

Varianza explicada por el componente j :

$$\frac{\sigma_j^2}{\sum_\ell \sigma_\ell^2}.$$

Varianza explicada acumulada con k componentes:

$$\frac{\sum_{j=1}^k \sigma_j^2}{\sum_\ell \sigma_\ell^2}.$$

K-Means

$$\min_{\mu, c} \sum_{i=1}^n \|x_i - \mu_{c_i}\|_2^2$$

Silhouette

$$s = \frac{b - a}{\max(a, b)}$$

Cosine similarity

$$\cos(x, y) = \frac{x^\top y}{\|x\| \|y\|}$$

Checklist de interpretación

- Los datos se centraron o escalaron según el método.
- La forma de la proyección PCA es consistente.
- La elección de k tiene un criterio: varianza, reconstrucción, curva o uso.
- K-Means se ejecutó con variables comparables en escala.
- Inertia no se interpreta como métrica absoluta de calidad.
- Silhouette se usa como señal, no como verdad final.
- Los clusters se describen con variables originales.
- El recomendador declara cold start, popularidad o sesgo cuando aplica.

Patrones de código

```
def pca_scores_from_svd(X, k):
    X = np.asarray(X, dtype=float)
    mean = X.mean(axis=0, keepdims=True)
    Xc = X - mean
    U, S, Vt = np.linalg.svd(Xc, full_matrices=False)
    Z = Xc @ Vt[:k].T
    return Z, Vt[:k], mean, S
```

```
def cosine_similarity_matrix(A):
    A = np.asarray(A, dtype=float)
    norms = np.linalg.norm(A, axis=1, keepdims=True)
    norms = np.maximum(norms, 1e-12)
    A_norm = A / norms
    return A_norm @ A_norm.T
```

Respuestas seleccionadas

Capítulo 1

Ejercicio 1.1. PCA centra porque busca direcciones de variación alrededor de la media. Sin centrar, el primer componente puede capturar desplazamiento de la nube respecto al origen, no estructura de variabilidad.

Ejercicio 1.3. Si X tiene forma (500, 64) y usamos $k=2$, la proyección PCA tiene forma (500, 2).

Ejercicio 1.4. Que los primeros 10 componentes expliquen 85 % de la varianza significa que, en el subespacio de 10 dimensiones, se conserva 85 % de la variabilidad cuadrática medida por PCA. No significa que esos componentes expliquen causalmente el fenómeno.

Verificación de proyección. Para

$$X = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \quad \bar{X} = (1, 1),$$

se obtiene:

$$X_c = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}.$$

Con $v_1 = (1, -1)^\top / \sqrt{2}$, los scores son $(\sqrt{2}, -\sqrt{2})^\top$. La reconstrucción con ese único componente recupera exactamente X_c , porque la matriz centrada tiene rango 1.

Capítulo 2

Ejercicio 2.1. Inertia baja al aumentar k porque cada punto puede quedar más cerca de algún centroide. En el extremo $k = n$, cada punto puede ser su propio centroide y la inertia llega a cero.

Ejercicio 2.2. K-Means debe usar escalamiento cuando las variables tienen unidades distintas porque la distancia euclídea queda dominada por variables con mayor escala numérica.

Ejercicio 2.4. Si un cluster contiene 90 % de las observaciones, revisaría escalamiento, elección de k , inicializaciones, variables dominantes y si la estructura real quizá no es aproximadamente esférica.

Verificación de K-Means. Para puntos 1, 2, 8, 10 y centroides iniciales $\mu_1 = 1$, $\mu_2 = 10$, las asignaciones son $\{1, 2\}$ y $\{8, 10\}$. La inertia inicial es

$$0^2 + 1^2 + 2^2 + 0^2 = 5.$$

Los centroides actualizados son 1.5 y 9. Con ellos, la inertia baja a

$$0.5^2 + 0.5^2 + 1^2 + 1^2 = 2.5.$$

Esto verifica el objetivo geométrico, no la calidad aplicada de la segmentación.

Capítulo 3

Ejercicio 3.1. La similitud coseno puede ser útil cuando algunos ítems son más populares porque compara dirección de interacción, no solo magnitud. Aun así, no elimina por completo el sesgo de popularidad.

Ejercicio 3.2. El problema de usuario nuevo se conoce como cold start: sin historial, no hay vector de preferencias suficiente para comparar o inferir gustos.

Ejercicio 3.8. Para detectar si un recomendador amplifica popularidad, compararía la popularidad media de los ítems recomendados contra la popularidad del catálogo y contra un baseline simple de popularidad.

Verificación item-item. Si

$$A = (1, 1, 0, 0), \quad B = (1, 1, 0, 1), \quad C = (0, 1, 1, 0), \quad D = (0, 0, 1, 1),$$

entonces:

$$\cos(A, B) = \frac{2}{\sqrt{2}\sqrt{3}} \approx 0.816, \quad \cos(A, C) = 0.5, \quad \cos(A, D) = 0.$$

Por similitud con A , el primer candidato es B . Si B ya fue visto por el usuario, el siguiente candidato entre estos ítems sería C .

Ejercicios integradores

Bloque A. Si dos componentes explican poca varianza pero separan grupos en un gráfico, puedes afirmar que la proyección muestra una separación visual en esos datos. No puedes afirmar causalidad ni que la separación aparezca en otra muestra sin una comprobación adicional.

Bloque B. Una buena descripción de cluster debe volver a las variables originales. Nombrar clusters solo por la posición en el gráfico suele producir etiquetas frágiles.

Bloque C. Una recomendación item-item mínima debe excluir ítems ya vistos y declarar qué ocurre con usuarios o ítems sin historial.

Apéndice Módulo 5: formulario y respuestas seleccionadas

Cómo usar este apéndice

Este apéndice sirve para cerrar el curso: preparar el Parcial 2, revisar reproducibilidad, escribir el reporte final y defender una decisión técnica. La pregunta central ya no es solo “¿cuál fórmula uso?”, sino “¿qué resultado puedo explicar y qué límite debo declarar?”.

Una defensa precisa no exagera. Presenta un resultado identificable, una lectura proporcional, una comprobación concreta y límites claros.

Notación mínima

Símbolo	Significado
$\hat{p}_{i,y_i}$	probabilidad asignada a la clase correcta
$\bar{s}, \sigma_s$	media y variabilidad de validación
Z_k	representación PCA con k componentes
$\hat{X}$	reconstrucción aproximada
a_i, b_i	distancia intra-cluster y vecino más cercano en silhouette
manifest	archivo que registra datos, parámetros, métricas y artefactos

Fórmulas clave

Softmax

$$\text{softmax}(z)_j = \frac{e^{z_j - \max(z)}}{\sum_{k=1}^K e^{z_k - \max(z)}}.$$

Entropía cruzada multiclase

$$L = -\frac{1}{n} \sum_{i=1}^n \log(\hat{p}_{i,y_i}).$$

Score CV

$$\bar{s} = \frac{1}{K} \sum_{k=1}^K s_k, \quad \sigma_s = \sqrt{\frac{1}{K} \sum_{k=1}^K (s_k - \bar{s})^2}.$$

PCA desde SVD

$$X_c = U \Sigma V^\top, \quad Z_k = X_c V_k, \quad \hat{X} = Z_k V_k^\top + \mu.$$

Silhouette

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}.$$

Hash SHA-256

Un hash no prueba que un resultado sea correcto. Prueba que el archivo no cambió respecto a la versión registrada.

Checklist de paquete reproducible

- Hay una instrucción clara para ejecutar el flujo principal.
- Datos, scripts y resultados tienen rutas documentadas.
- La semilla y las particiones están registradas.
- El entorno está especificado con **requirements**, **environment** o equivalente.
- El preprocesamiento final está dentro del pipeline o descrito paso a paso.
- Las métricas finales se pueden recalcular.
- Los artefactos importantes tienen versión, nombre estable o hash.
- La conclusión distingue resultado, interpretación y recomendación.

Estructura mínima de manifest

```
{  
  "schema_version": 1,  
  "run_id": "baseline-logreg-s2105",  
  "environment": {  
    "python": "3.13.5",  
    "packages": {"scikit-learn": "1.7.1"}  
  },  
}
```

```

"params": {
  "model": "logistic_regression",
  "C": 1.0,
  "seed": 2105,
  "split": "60/20/20 estratificado"
},
"metrics": {"dev_f1": 0.72, "dev_recall": 0.68},
"artifacts": {"metrics.csv": "c2a8...90bf"}
}

```

Lenguaje de defensa

Frase débil	Versión precisa
“El modelo es bueno.”	“El modelo supera el baseline en F1, pero falla en un slice crítico.”
“PCA demuestra grupos.”	“La proyección PCA sugiere separación visual; falta validación adicional.”
“El experimento es reproducible.”	“El experimento tiene semilla, entorno, manifest y script de evaluación.”
“Recomendamos usarlo.”	“Recomendamos una prueba limitada bajo estas restricciones.”

Respuestas seleccionadas

Verificaciones de ejemplos resueltos

Softmax estable. Para logits (1000, 1001, 1002), restar el máximo produce $(-2, -1, 0)$. La distribución queda aproximadamente (0.090, 0.245, 0.665). La resta evita overflow y no cambia softmax.

Manifest. Si el manifest registra `sha256:abc123` y el archivo actual tiene `sha256:def987`, el artefacto no coincide con la corrida registrada. La métrica asociada debe considerarse no verificada hasta volver a ejecutar o recuperar el archivo correcto.

Mejora relativa. Si F1 pasa de 0.60 a 0.72, la mejora absoluta es 0.12 y la relativa es $0.12/0.60 = 20\%$.

Rúbrica ponderada. Con puntajes 12, 16, 20, 13, 12, 8 sobre pesos que suman 100, la nota final es 81 %.

Síntesis para Parcial 2

Capítulo 1, ejercicio 1. Una mejora global no basta si un slice crítico empeora porque la métrica agregada puede ocultar daño concentrado. La respuesta debe revisar tamaño del slice, conteos, costo del error, estabilidad de la medición y acción de mitigación.

Capítulo 1, ejercicio 4. Para logits (1000, 1001, 1002), resta el máximo: $(-2, -1, 0)$. Softmax queda proporcional a $(e^{-2}, e^{-1}, 1)$, es decir aproximadamente (0.090, 0.245, 0.665).

Reproducibilidad

Capítulo 2, ejercicio 1. Una semilla fija no garantiza reproducibilidad completa porque pueden cambiar librerías, hardware, orden de datos, implementaciones paralelas o archivos de entrada.

Capítulo 2, ejercicio 4. Un hash SHA-256 detecta si un archivo cambió respecto a la versión registrada. No dice si el contenido es correcto, ético o suficiente para la decisión.

Capítulo 2, ejercicio 8. Si no se puede reproducir una métrica final, revisa primero partición, versión de datos, pipeline de preprocesamiento, semilla, parámetros del modelo y script de evaluación.

Comunicación técnica

Capítulo 3, ejercicio 1. “El modelo es bueno” no es suficiente porque no dice contra qué baseline, con qué métrica, en qué partición, bajo qué costo de error ni con qué limitaciones.

Capítulo 3, ejercicio 4. Si el baseline tiene F1 0.60 y el modelo final F1 0.72, la mejora absoluta es 0.12 puntos de F1 y la mejora relativa es $(0.72 - 0.60)/0.60 = 20\%$.

Capítulo 3, ejercicio 7. Una conclusión exagerada debe reescribirse con cuatro partes: resultado, límite, acción y condición de uso. Por ejemplo: “El modelo mejora F1 frente al baseline, pero su recall cae en clientes nuevos; recomendamos analizar ese slice antes de una prueba controlada”.

Entrega y defensa

Capítulo 4, ejercicio 3. Con puntajes 12/15, 16/20, 20/25, 13/15, 12/15 y 8/10, el total es 81/100.

Capítulo 4, ejercicio 4. Si una defensa usa cinco criterios 0/1/2, el puntaje máximo es 10. Una conversión transparente a porcentaje es $\text{porcentaje} = 10 \times \text{puntaje}$.

Capítulo 4, ejercicio 7. Una respuesta precisa a “¿qué cambiaría con dos semanas más?” debe nombrar una acción priorizada y una razón: “ampliaría análisis del slice con peor recall porque ahí está el riesgo operativo principal”.

Ejercicios integradores

Ejercicio 1. Restar el máximo evita overflow porque reemplaza exponenciales enormes por valores en una escala estable. La operación no cambia softmax porque multiplica numerador y denominador por la misma constante.

Ejercicio 2. Una respuesta sólida: el modelo mejora el baseline, pero tiene variabilidad alta, cae en test y falla en un slice crítico. La acción prudente es diagnosticar ese slice y ajustar datos, features o umbral antes de recomendar uso operativo.

Ejercicio 3. Con más componentes, el subespacio de reconstrucción contiene al anterior. Por eso la mejor aproximación con $k + 1$ componentes no puede tener mayor error que con k .

Ejercicio 4. Un manifest válido incluye parámetros, métricas, rutas de artefactos, hashes y una decisión. Su valor principal es auditar qué corrida produjo una conclusión.

Ejercicio 5. Una defensa final fuerte debe declarar al menos un límite: datos insuficientes, slice inestable, métrica parcial, supuestos de despliegue o riesgo de cambio de distribución.

Información editorial y publicación

Información editorial

Audiencia

Este libro está escrito para estudiantes de pregrado que cursan **MATE-2105 Matemáticas y Algoritmos en Ciencia de Datos Aplicada**. También puede servir como texto de apoyo para cursos que conecten álgebra lineal, cálculo, optimización, programación científica y aprendizaje automático aplicado.

El texto asume disposición para leer matemáticas y programar en Python, pero no asume experiencia previa avanzada en machine learning.

Prerrequisitos recomendados

Para aprovechar el libro conviene tener familiaridad básica con:

- vectores, matrices y productos matriciales;
- funciones, derivadas y gradientes;
- estadística descriptiva introductoria y nociones básicas de incertidumbre;
- programación básica en Python;
- lectura de tablas y gráficos.

Cuando un capítulo necesita una herramienta específica, la introduce en contexto y la conecta con implementación. El libro no exige un curso formal previo de probabilidad. Las variables aleatorias, las esperanzas, los riesgos y las distribuciones condicionales aparecen a medida que los modelos plantean la necesidad de utilizarlos. La parte **Herramientas probabilísticas y estadísticas** reúne después esas nociones en una exposición formal que puede consultarse en paralelo o estudiarse de manera continua.

Alcance

El libro se concentra en el razonamiento matemático-algorítmico detrás de modelos usados en ciencia de datos aplicada:

- regresión y optimización;
- regularización y validación;
- clasificación y métricas;
- redes neuronales;
- estrategia de machine learning;
- reducción de dimensión y clustering;

- reproducibilidad y comunicación técnica.

No busca ser una enciclopedia de ciencia de datos. Su propósito es formar criterio: qué se calcula, por qué se calcula, cómo se valida y con qué límites se recomienda una decisión.

Formato recomendado

La versión web es el formato principal porque mantiene navegación, búsqueda, enlaces y lectura móvil. El portal del curso publica la versión vigente en:

<https://cesarneyit-code.github.io/mate2105/libro/>

La versión PDF se genera desde Quarto junto con la edición web. Antes de publicarla como material final de impresión, deben revisarse figuras, tablas, fórmulas largas y saltos de página.

Cada publicación web incluye además un `manifest-publicacion.json` con inventario de archivos, tamaños y hashes SHA-256 de los artefactos públicos del libro. Ese archivo permite auditar que una copia publicada corresponde a una construcción concreta.

Cómo citar

Referencia sugerida:

Galindo, C. (2026). *Matemáticas y Algoritmos en Ciencia de Datos Aplicada: Libro del curso MATE-2105*. Universidad de los Andes.

<https://cesarneyit-code.github.io/mate2105/libro/>

Accesibilidad

La edición web debe revisarse con estos criterios mínimos:

- navegación por teclado en páginas principales;
- contraste suficiente en texto, enlaces y cajas pedagógicas;
- tablas legibles en pantallas pequeñas;
- fórmulas renderizadas correctamente;
- texto alternativo o descripción para figuras no decorativas;
- enlaces descriptivos y funcionales.

Si una figura o tabla no puede leerse en móvil, debe rediseñarse antes de considerarse lista para publicación.

La declaración pública completa está en la página **Accesibilidad**, que separa objetivo, evidencia automática, revisión manual requerida, barreras conocidas y plantillas de remediación.

Errata y mejoras

Este libro es una edición viva del curso. Los errores matemáticos, problemas de código, enlaces rotos o sugerencias de mejora deben registrarse como tareas de revisión en el repositorio docente antes de publicar una nueva versión.

Cada corrección importante debe indicar:

- capítulo o sección afectada;
- problema encontrado;
- corrección propuesta;
- impacto sobre notebooks, laboratorios o evaluaciones;
- fecha de revisión.

Separación de materiales

El libro público no contiene:

- soluciones oficiales completas;
- pruebas ocultas;
- autograders;
- paquetes Gradescope;
- guías docentes privadas;
- criterios internos de calificación.

Esa separación protege la integridad académica y permite que el libro funcione como texto de estudio.

Accesibilidad

Esta página declara el estado de accesibilidad del libro y el proceso de mejora continua. La versión web es el formato principal de lectura porque permite navegación, búsqueda, enlaces, ajuste de tamaño de texto y auditorías HTML. El PDF se conserva como formato offline y archivo de versión, pero no reemplaza la versión web como opción accesible principal.

Objetivo de accesibilidad

El objetivo editorial es que la versión web del libro sea usable con:

- navegación por teclado;
- lectores de pantalla modernos;
- zoom del navegador;
- lectura en pantallas pequeñas;
- texto alternativo o descripción equivalente para figuras no decorativas;
- tablas con encabezados;
- enlaces descriptivos;
- bloques de código legibles y desplazables;
- contraste suficiente en texto, enlaces y recursos pedagógicos.

La meta técnica de esta edición es avanzar hacia criterios compatibles con WCAG 2.2 AA para la versión web. Las pruebas automáticas ayudan a detectar problemas, pero no prueban por sí solas conformidad completa.

Alcance evaluado

La revisión actual cubre:

Elemento	Estado
páginas HTML del libro	verificadas con auditoría estática
páginas representativas	verificadas con axe
figuras nuevas	tienen texto alternativo o descripción equivalente
tablas	se auditan encabezados <code><th></code> en HTML
enlaces	se auditan textos accesibles básicos
bloques de código	reciben foco de teclado mediante ajuste HTML
PDF	texto extraíble, tamaño carta y metadatos verificados

Elemento	Estado
PDF etiquetado	no disponible; existe decisión formal de usar HTML como formato accesible principal

Evidencia automática

Antes de publicar, deben pasar estas verificaciones:

```
python3 scripts/auditar_accesibilidad_libro.py sitio_curso/_site/libro
bash scripts/auditar_axe_libro.sh http://127.0.0.1:8765/libro
python3 scripts/auditar_pdf_libro.py sitio_curso/_site/libro/Matemáticas-y-Algoritmos-en-Ciencia
```

La auditoría estática revisa mínimos estructurales: idioma, título, encabezado principal, texto alternativo, enlaces con texto, tablas con encabezados e ids duplicados. Axe revisa una muestra representativa de páginas renderizadas.

Revisión manual requerida

Una edición publicable fuera del curso requiere además revisión manual. Como mínimo, debe probarse:

1. navegación por teclado desde portada hasta capítulos y apéndices;
2. orden de foco en menús, búsqueda, enlaces y bloques de código;
3. lectura con lector de pantalla en portada, página editorial, capítulo con matemática, capítulo con figuras, tabla de datos y apéndice;
4. comprensión de figuras mediante alt text o texto cercano;
5. lectura de fórmulas en el navegador usado por estudiantes;
6. zoom al 200 % sin pérdida de contenido esencial;
7. lectura móvil de tablas y bloques de código;
8. contraste de cajas pedagógicas y enlaces;
9. descarga de CSV y PDF mediante enlaces claros.

El paquete preparado para ejecutar esta revisión está registrado en `libro_curso/registros/accesibilidad/paquete-07-07.md`. Ese documento define páginas mínimas, pruebas, evidencia esperada y plantillas de trabajo; no sustituye la ejecución manual.

Matemática, código y figuras

La accesibilidad de un libro matemático exige revisar tres zonas de riesgo.

Zona	Riesgo	Criterio
Fórmulas	lectura ambigua con tecnologías asistivas	acompañar fórmulas centrales con explicación textual
Figuras	pérdida de información si la imagen no se ve	incluir alt text o lectura de figura cercana
Código	líneas largas o bloques no navegables	permitir desplazamiento, copia y foco de teclado

Las figuras complejas deben tener una **Lectura de la figura** en el capítulo o un texto alternativo suficientemente descriptivo.

Barreras conocidas

Barrera	Estado	Acción
PDF no etiquetado	conocido y decidido para esta edición	mantener HTML como formato accesible principal; no presentar PDF como equivalente accesible
revisión manual con lector de pantalla	pendiente	completar checklist antes de edición publicable final
revisión manual de teclado completa	pendiente	completar checklist antes de edición publicable final
fórmulas complejas en PDF	pendiente de revisión visual/manual	revisar capítulos matemáticos antes de impresión

Reporte de barreras

Si un estudiante, instructor o revisor encuentra una barrera de accesibilidad, el reporte debe incluir:

- página o archivo afectado;
- descripción de lo que ocurrió;
- navegador y sistema operativo;
- tecnología asistiva usada, si aplica;
- captura o ejemplo mínimo, si es posible;
- impacto sobre lectura, navegación, descarga o comprensión.

Las barreras se registran como errata de accesibilidad y se priorizan por impacto pedagógico.

Plantillas de revisión

Las plantillas operativas están publicadas con el libro:

- [checklist_teclado.md](#)
- [checklist_lector_pantalla.md](#)
- [reporte_barrera_accesibilidad.md](#)
- [registro_remediacion_accesibilidad.md](#)

La decisión editorial sobre PDF no etiquetado queda registrada en `libro_curso/registros/pdf/decision_accesibilidad_07-07.md`. Ese registro declara que el HTML es el formato accesible principal y que el PDF se publica como respaldo offline y archivo de versión.

Criterio de cierre

Una barrera de accesibilidad queda cerrada cuando:

1. la causa está identificada;
2. la corrección está aplicada en la fuente;
3. el libro se renderiza de nuevo;
4. la auditoría automática relevante pasa;
5. la persona revisora confirma la mejora cuando el problema era manual;
6. la corrección queda registrada en el historial editorial o en errata.

Equipo, revisión y reconocimientos

Esta página documenta quién produce, revisa y mantiene el libro. En una versión publicable, esta información no es decorativa: permite al lector identificar responsabilidades, estado de revisión y límites de la edición.

Autoría y responsabilidad editorial

Rol	Responsable	Alcance
Autor del curso y del libro	César Galindo	diseño curricular, selección de contenidos, redacción matemática, notebooks y evaluación
Edición técnica	César Galindo	consistencia de notación, código, ejemplos, figuras y referencias internas
Edición pedagógica	César Galindo	secuencia de aprendizaje, ejercicios, respuestas seleccionadas y conexión con laboratorios
Mantenimiento de publicación	César Galindo	render Quarto, portal, PDF, auditorías y control de versiones

Esta es una edición de trabajo. Cuando el libro tenga revisión externa o apoyo institucional formal, esta página debe registrar nombres, afiliaciones, fecha de revisión y alcance de cada contribución.

Estado de revisión

El libro tiene tres niveles de revisión:

1. **Revisión estructural.** Verifica que cada capítulo tenga objetivos, ejemplos, revisión, términos clave, ejercicios y proyecto de cierre.
2. **Revisión técnica.** Verifica fórmulas, dimensiones, código, resultados numéricos y coherencia con notebooks o laboratorios.
3. **Revisión editorial.** Verifica legibilidad, figuras, accesibilidad, enlaces, PDF y separación entre materiales públicos y privados.

Nivel	Estado actual	Evidencia
estructura de capítulos	automatizada	<code>scripts/auditar_estructura_editorial_1</code>
publicación pública	automatizada	<code>scripts/auditar_publicacion.py</code> y verificación del portal
accesibilidad estática	automatizada	<code>scripts/auditar_accesibilidad_libro.py</code>
accesibilidad con navegador	muestra representativa	<code>scripts/auditar_axe_libro.sh</code>
preparación OpenStax-like	automatizada para curso	<code>scripts/auditar_preparacion_openstax_1</code>
revisión matemática externa	pendiente	requiere lector técnico externo
revisión pedagógica externa	pendiente	requiere instructor o par académico externo

La página **Matriz de preparación editorial** detalla el estado por parte y por capítulo para distinguir uso en curso, publicación web y publicación abierta. La página **Protocolo de revisión externa** define el procedimiento y las rúbricas que deben usarse antes de declarar una edición publicable final. Ese protocolo incluye plantillas de carta, checklist, dictamen, rúbrica y registro de correcciones para que la revisión sea trazable. La página **Registro público de errata** mantiene el estado visible de reportes, correcciones cerradas y cambios editoriales de la edición vigente.

Cómo reportar una corrección

Una corrección útil debe incluir:

- capítulo o sección;
- descripción precisa del problema;
- tipo de problema: matemático, código, redacción, enlace, figura, evaluación o accesibilidad;
- propuesta de corrección, si existe;
- evidencia mínima: cálculo, captura, error de ejecución o enlace roto.

Las correcciones que afecten laboratorios, parciales o autograders deben revisarse también en el repositorio docente privado antes de publicar una nueva versión.

Reconocimientos

Este libro se construye como material vivo del curso MATE-2105. Su forma combina texto matemático, notebooks, laboratorios autocalificados, proyecto aplicado y portal de curso. Las mejoras futuras deben reconocer explícitamente a revisores, asistentes docentes, estudiantes o colegas que aporten correcciones sustantivas.

Criterio para versión publicable

Antes de declarar una edición como publicable fuera del curso, deben cumplirse estos requisitos:

- licencia formal definida en el repositorio;

- revisión matemática externa de capítulos centrales;
- revisión pedagógica externa de secuencia, ejercicios y evaluación;
- dictamen externo trazable y correcciones obligatorias cerradas;
- registro de errata abierto o canal institucional equivalente;
- portada, cita sugerida, accesibilidad y recursos complementarios visibles;
- separación verificada entre libro público y materiales privados de evaluación.

Protocolo de revisión externa

Este protocolo define cómo debe revisarse el libro antes de declararlo una edición publicable fuera del curso. Su objetivo es convertir la revisión externa en evidencia verificable, no en una aprobación informal.

Propósito de la revisión

La revisión externa debe responder cuatro preguntas:

1. ¿Las derivaciones matemáticas son correctas y usan notación consistente?
2. ¿Los ejemplos, ejercicios y respuestas seleccionadas apoyan el aprendizaje?
3. ¿La secuencia del libro prepara las evaluaciones y el proyecto del curso?
4. ¿El texto puede publicarse sin exponer material privado ni inducir decisiones técnicas exageradas?

Una revisión externa no reemplaza las auditorías automáticas. Las complementa: las auditorías detectan estructura, enlaces, accesibilidad básica y material sensible; el revisor externo juzga corrección matemática, claridad pedagógica y criterio disciplinar.

Roles de revisión

Rol	Perfil sugerido	Alcance
Revisor matemático	profesor o investigador con experiencia en álgebra lineal, optimización, estadística o aprendizaje automático	derivaciones, notación, resultados, ejemplos y ejercicios cuantitativos
Revisor pedagógico	docente de curso STEM o ciencia de datos aplicada	secuencia, objetivos, carga, evaluación, retroalimentación y autonomía
Revisor computacional	persona con experiencia en Python científico y reproducibilidad	código, notebooks, dependencias, datasets y comparación con librerías
Revisor de accesibilidad	persona con experiencia en accesibilidad web o materiales educativos	navegación, texto alternativo, tablas, contraste, PDF y lector de pantalla

Una misma persona puede cubrir más de un rol si declara su alcance explícitamente.

Evidencia que recibe el revisor

Antes de revisar, el revisor debe tener acceso a:

- libro web vigente;
- PDF vigente;
- fuente Quarto de capítulos públicos;
- matriz de preparación editorial;
- resultados de aprendizaje y alineación;
- página de referencias y atribuciones;
- reporte de auditoría editorial;
- reporte de publicación sin material sensible;
- evidencia de render y link check;
- indicación clara de qué materiales son privados y no se revisan públicamente.

Plantillas de revisión

El paquete operativo para revisión externa está disponible en:

Plantilla	Uso
Carta de solicitud Checklist del paquete	invitar a un revisor y declarar alcance esperado confirmar que el revisor recibe los materiales correctos
Formulario de dictamen Rúbrica de revisión	registrar aprobación, correcciones y trazabilidad evaluar criterios matemáticos, pedagógicos, computacionales y de accesibilidad
Registro de correcciones	cerrar correcciones obligatorias y recomendadas

Estas plantillas deben completarse solo con revisiones reales. No son evidencia de revisión por sí mismas; son el formato para producir esa evidencia.

El paquete preparado para enviar a revisores externos está registrado en `libro_curso/registros/revision_externa/07-07.md`. Ese documento organiza rutas, alcance y evidencia disponible, pero no cuenta como revisión completada.

Rúbrica matemática

Criterio	Aceptable	Requiere corrección
Notación	símbolos, dimensiones y convenciones son consistentes	un símbolo cambia de significado sin aviso
Derivaciones	los pasos principales son correctos y suficientes para el nivel	falta un paso que cambia el resultado o confunde gradientes

Criterio	Aceptable	Requiere corrección
Ejemplos	los cálculos pueden reproducirse y coinciden con el texto	resultados numéricos no coinciden o no se justifican
Ejercicios	practican conceptos centrales con dificultad razonable	preguntan algo no preparado o demasiado ambiguo
Interpretación	las conclusiones declaran límites	se sugieren decisiones no justificadas por la evidencia

Rúbrica pedagógica

Criterio	Aceptable	Requiere corrección
Objetivos	son observables y se conectan con evidencias	son vagos o no se evalúan
Secuencia	los capítulos avanzan de apoyo guiado a autonomía	aparecen saltos conceptuales sin transición
Actividades	ejercicios y proyectos preparan laboratorios y parciales	la práctica no se alinea con evaluación
Carga	la cantidad de lectura y práctica es viable por semana	una semana concentra demasiada demanda nueva
Retroalimentación	respuestas seleccionadas orientan sin ser solucionario	faltan verificaciones públicas donde se necesitan

Rúbrica computacional

Criterio	Aceptable	Requiere corrección
Reproducibilidad	ejemplos declaran datos, semilla y dependencia relevante	un resultado depende de estado oculto
Código	funciones y shapes son claros	código no ejecuta o no coincide con la fórmula
Comparación con referencia	se compara sin cambiar el experimento	se comparan modelos con datos, métricas o particiones distintas
Datasets	fuentes y límites están documentados	se usa un dataset sin advertencia de interpretación
Leakage	transformaciones se aprenden solo en entrenamiento	se filtra información de validación o test

Dictamen de revisión

Cada revisión externa debe cerrar con un dictamen breve:

Revisor:
Afiliación:
Rol de revisión:
Fecha:
Versión revisada:
Alcance:
Dictamen: aprobar / aprobar con correcciones menores / revisar de nuevo
Correcciones obligatorias:
Correcciones recomendadas:
Evidencia revisada:

Registro de revisiones externas

Fecha	Revisor	Rol	Alcance	Dictamen	Estado
pendiente	pendiente	pendiente	pendiente	pendiente	pendiente

Este registro debe actualizarse solo con revisiones reales. No se deben inventar revisores, afiliaciones ni aprobaciones.

Criterio de cierre

La revisión externa se considera cerrada cuando:

1. existe dictamen firmado o trazable;
2. las correcciones obligatorias están registradas;
3. las correcciones aplicadas tienen evidencia de render y validación;
4. las correcciones rechazadas tienen justificación editorial;
5. la matriz de preparación editorial refleja el nuevo estado.

Hasta que esto ocurra, el libro puede estar listo para el curso, pero no debe declararse como edición publicable final.

Matriz de preparación editorial

Esta matriz resume el estado de preparación del libro como texto de curso y como posible publicación abierta. Su función es separar tres cosas que a menudo se confunden: material listo para usar en clase, material verificado por auditorías automáticas y material revisado externamente.

Niveles de preparación

Nivel	Estado actual	Evidencia	Pendiente
Estructura editorial	verificada	capítulos con objetivos, ejemplos, revisión, términos clave, ejercicios y proyecto	mantener auditoría al editar
Técnica matemática	revisión interna	derivaciones, ejemplos, código y respuestas seleccionadas	revisión externa de capítulos centrales
Diseño pedagógico	revisión interna	secuencia por módulos, laboratorios, notebooks y proyecto	revisión externa de alineación
Publicación web	verificada	render Quarto, link check, auditoría de material sensible y LICENSE formal de uso docente restringido	evaluación-aprendizaje decidir si una edición futura será abierta
PDF e impresión	verificado técnicamente, pendiente de prueba de impresión	auditoría PDF, guía de impresión y plantillas de revisión	revisión visual completa antes de impresión pública
Accesibilidad	verificación automática y declaración pública	auditoría estática, axe en páginas representativas y página de accesibilidad	revisión manual con teclado y lector de pantalla
Preparación OpenStax-like	verificada para curso, pendiente para edición final	<code>scripts/auditar_preparacion_openstax_libro.py</code>	cuando existan revisión externa, registros manuales y decisión de PDF accesible

En esta edición, **listo para curso** no significa todavía **publicación abierta final**. El libro puede usarse como texto del curso mientras conserva pendientes editoriales explícitos para una versión publicable.

Matriz por partes

Parte	Alcance	Estado para el curso	Revisión pendiente
I. Fundamentos	datos, espacio de probabilidad, estimadores, condicionamiento y riesgo	base matemática transversal del curso	revisión externa de precisión y secuencia pedagógica
II. Regresión, optimización y clasificación	mínimos cuadrados, gradiente, regularización, logística y métricas	núcleo fuerte y verificable	revisión externa de derivaciones y ejercicios
III. Redes neuronales	perceptrón, backpropagation, diagnóstico y PyTorch	reforzado con derivaciones, ejemplos, verificaciones y caso <code>load_digits</code>	revisión externa de backpropagation y criterios de entrenamiento
IV. Estrategia de ML	métricas, validación, curvas y análisis de errores	reforzado con figuras, casos por slice y verificaciones seleccionadas	revisión pedagógica de decisiones aplicadas
V. No supervisado	PCA/SVD, K-Means y recomendación latente	reforzado con derivaciones, ejemplos calculados y datasets longitudinales	revisar si una edición futura requiere más ejercicios avanzados
VI. Reproducibilidad y defensa	síntesis, tracking, comunicación y defensa final	reforzado con plantillas, casos longitudinales, comunicación y defensa	revisión de rúbricas y defensa oral

Matriz por capítulo principal

Capítulo	Tema	Estado editorial	Siguiente revisión
0A	observaciones, variables y preguntas	desarrollo completo de significado, medición, población y representación	revisión externa de ejemplos y secuencia

Capítulo	Tema	Estado editorial	Siguiente revisión
0B	variables aleatorias, distribuciones y muestras	fundamento probabilístico completo	revisión matemática externa de precisión y ejercicios
0C	condicionamiento, estimación, riesgo e incertidumbre	fundamento estadístico completo	revisión matemática externa de inferencia y remuestreo
1	regresión lineal múltiple	fuerte	revisión externa de notación y ejercicios
2	descenso del gradiente	fuerte	revisión externa de gradiente y convergencia
3	validación y regularización	fuerte	revisión de ejemplos y casos de leakage
4	regresión logística	fuerte	revisión de umbrales y métricas
5	ejercicios integradores de regresión	banco estructurado	calibración de dificultad
6	perceptrón y propagación hacia adelante	reforzado	revisión de formas y ejemplo <code>load_digits</code>
7	backpropagation	reforzado	revisión técnica externa de derivación softmax-log-loss
8	diagnóstico y regularización en redes	reforzado	revisión de criterios de diagnóstico y parada
9	optimizadores y PyTorch	reforzado	revisar dependencia entre teoría, Adam y API
10	ejercicios integradores de redes	banco estructurado	calibración de dificultad
11	métricas y particiones	reforzado	revisar ejemplos por costo de error y partición
12	validación y curvas	reforzado	revisar interpretación de curvas y estabilidad
13	análisis de errores y data mismatch	reforzado	revisar slices, sesgos y acciones correctivas
14	ejercicios integradores de estrategia	banco estructurado	calibración de decisiones
15	SVD y PCA	reforzado	revisión externa de álgebra lineal

Capítulo	Tema	Estado editorial	Siguiente revisión
16	K-Means y clustering	reforzado	revisión de limitaciones y diagnóstico
17	recomendación latente	reforzado	revisión de supuestos y evaluación
18	ejercicios integradores no supervisado	banco estructurado	calibración de dificultad
19	síntesis conceptual	reforzado	revisión de preparación para parcial
20	reproducibilidad y tracking	reforzado	revisión de manifest y trazabilidad
21	comunicación técnica	reforzado	revisión de rúbricas comunicativas
22	entrega y defensa	reforzado	revisión de defensa oral
23	ejercicios integradores de cierre	banco estructurado	calibración final

Evidencia mínima por nueva edición

Antes de publicar una nueva edición, el registro editorial debe incluir:

- fecha de construcción;
- resumen de cambios;
- auditoría de estructura;
- auditoría de material sensible;
- verificación de enlaces;
- revisión de accesibilidad estática;
- pasada axe sobre páginas representativas;
- declaración de accesibilidad actualizada;
- checklist manual de teclado y lector de pantalla cuando aplique;
- revisión de navegabilidad transversal: glosario, índice temático e índice de algoritmos;
- revisión de la taxonomía de ejercicios frente a capítulos, laboratorios y bancos integradores;
- auditoría de preparación OpenStax-like en modo curso;
- registro público de errata actualizado;
- revisión visual del PDF;
- dictamen de revisión externa;
- checklist y formulario de revisión externa completados;
- auditoría de preparación OpenStax-like en modo `--final`;
- estado de correcciones obligatorias;
- decisión de licencia;
- registro de decisión de licencia completado;

- estado de revisión externa;
- checklist de impresión o registro de prueba cuando el PDF se distribuya como versión imprimible.

Señales de riesgo editorial

Un capítulo debe volver a revisión si ocurre cualquiera de estos casos:

- cambia una derivación central;
- cambia un dataset, métrica o semilla de ejemplo;
- se modifica un laboratorio o parcial asociado;
- se agrega una figura sin texto alternativo;
- se cambia una respuesta seleccionada;
- se cambia la taxonomía, dificultad o propósito de un banco de ejercicios;
- se detecta desborde visual en PDF;
- se publica por error material privado de evaluación.

Características pedagógicas

Este libro está diseñado como texto de curso, no como una colección de apuntes. La estructura editorial busca que cada capítulo pueda leerse de forma independiente, pero también como parte de una secuencia de formación matemática y computacional.

Estructura recurrente

Cada capítulo debe tender hacia la siguiente organización:

1. **Pregunta aplicada.** Sitúa el problema antes del formalismo.
2. **Objetivos de aprendizaje.** Declara lo que el estudiante debería poder hacer al terminar.
3. **Marco matemático.** Define objetos, dimensiones, supuestos y notación.
4. **Deducción.** Conecta el problema con la fórmula o actualización central.
5. **Algoritmo.** Declara entradas, salidas, inicialización, pasos y parada.
6. **Análisis.** Distingue garantías, costo, estabilidad y limitaciones.
7. **Implementación.** Traduce el algoritmo a código reproducible.
8. **Validación.** Conecta pérdida, métrica, partición e incertidumbre.
9. **Ejemplo trabajado.** Muestra un caso pequeño que pueda verificarse a mano o con pocas líneas de código.
10. **Para explorar más.** Propone una extensión matemática, una extensión computacional y una conexión con proyecto.
11. **Ejercicios.** Separa práctica conceptual, cuantitativa, computacional e interpretativa.
12. **Respuestas seleccionadas.** Da retroalimentación sin reemplazar el trabajo del estudiante.

La Parte I fija el significado de las observaciones, las variables y las preguntas. A partir de la Parte II, los conceptos probabilísticos aparecen dentro de los problemas que los requieren: la media condicional en regresión, el estimador aleatorio al comparar muestras, el modelo Bernoulli en clasificación y la covarianza poblacional en PCA. Una parte de referencia los organiza después en una exposición sistemática.

Varios capítulos vuelven sobre casos longitudinales. La intención es que el estudiante no vea regresión, regularización, validación, análisis de errores, comunicación y defensa como episodios aislados. Un mismo dataset puede reaparecer con una pregunta nueva: primero para ajustar un modelo, después para seleccionar una métrica, luego para diagnosticar slices y finalmente para comunicar una recomendación proporcional.

Criterio editorial. Un capítulo debe permitir tres lecturas: una rápida para ubicar el tema, una lenta para seguir derivaciones y una de práctica para resolver ejercicios.

Figuras guía

El libro debe usar figuras cuando aclaran una decisión o proceso. Las figuras no reemplazan la derivación matemática; sirven como mapa para que el estudiante ubique qué papel cumple cada objeto.




Figura 47: Ciclo de modelación aplicada del curso: pregunta aplicada, modelo matemático, algoritmo, código, validación y retorno a la pregunta.




Figura 48: Flujo de validación: los datos se separan en train, dev y test; train ajusta parámetros, dev selecciona el modelo y test se usa una sola vez para reporte final.

Tipos de recursos

El libro usa una familia de recursos recurrentes.

Recurso	Uso esperado
Definición	Fijar vocabulario técnico y notación.
Proposición	Registrar un resultado matemático que se usa después.
Ejemplo resuelto	Mostrar una aplicación completa, con cálculo o código.

Recurso	Uso esperado
Criterio	Dar una regla de decisión o diagnóstico.
Nota	Advertir sobre errores frecuentes o sutilezas.
Para explorar más	Extender el capítulo con una tarea matemática, una computacional y una de proyecto.
Ejercicio	Proponer práctica verificable.
Proyecto	Conectar el capítulo con una decisión técnica más amplia.
Caso longitudinal	Mantener continuidad entre capítulos mediante un dataset o decisión que reaparece.
Índice temático	Ayudar a estudiar por concepto, modelo, métrica o decisión, no solo por semana.
Taxonomía de ejercicios	Calibrar tipo de pregunta, nivel cognitivo y evidencia esperada.

Estándar de ejercicios

Los ejercicios del libro deben cubrir cuatro niveles.

Nivel	Evidencia de aprendizaje
Conceptual	El estudiante explica el significado de un objeto, supuesto o métrica.
Cuantitativo	El estudiante calcula una cantidad, gradiente, métrica o dimensión.
Computacional	El estudiante implementa o verifica un procedimiento.
Interpretativo	El estudiante defiende una decisión técnica con evidencia y límites.

La página [Taxonomía de ejercicios y banco de preguntas](#) convierte estos niveles en criterios de diseño, estudio y revisión. Esa página es pública porque orienta la práctica; no contiene pruebas ocultas ni soluciones oficiales completas.

La página [Mapa de cierres de capítulo](#) muestra cómo cada capítulo principal incorpora revisión, términos clave, preguntas conceptuales, problemas cuantitativos, práctica computacional, pensamiento crítico y proyecto de cierre.

Relación con evaluación

El libro prepara para laboratorios y parciales, pero no contiene pruebas ocultas ni soluciones oficiales completas. La separación es intencional:

- el libro desarrolla conocimiento;

- el portal organiza entregas;
- los notebooks entrenan implementación;
- los laboratorios y parciales verifican desempeño.

Estándar de revisión

Antes de publicar una versión del libro, cada capítulo debe revisarse con esta lista mínima:

- objetivos claros y evaluables;
- notación consistente;
- al menos un ejemplo resuelto;
- derivación guiada cuando el capítulo introduce una función objetivo, gradiente, factorización o regla de decisión;
- análisis del algoritmo cuando corresponda: condiciones, tipo de solución, costo dominante, criterio de parada y estabilidad numérica;
- respuestas o verificaciones seleccionadas visibles al final del capítulo;
- sección de exploración adicional conectada con matemática, código y proyecto;
- ejercicios suficientes y clasificados;
- una conexión explícita con validación o decisión técnica;
- conexión con un caso longitudinal cuando el tema se beneficie de continuidad;
- ausencia de dependencias privadas;
- enlaces funcionales;
- lectura legible en móvil y escritorio.

Recursos para estudiantes e instructores

Este libro se publica como texto de estudio. El curso completo incluye además portal, notebooks, laboratorios, rúbricas y guías docentes. Esta página separa qué recursos son públicos, cuáles son de uso del estudiante y cuáles deben permanecer restringidos para proteger la integridad académica.

Recursos públicos para estudiantes

Libro web y PDF. Texto principal del curso: definiciones, derivaciones, ejemplos, figuras, ejercicios, respuestas seleccionadas y apéndices.

Datasets públicos. CSV de práctica descargables y manifest de datos con hashes para practicar regresión, clasificación, clustering, PCA y recomendación sin depender de internet.

Casos longitudinales. Hilos de datos que reaparecen en varios capítulos para conectar modelo, validación, diagnóstico, comunicación y defensa.

Portal del curso. Calendario, ruta semanal, enlaces a materiales, proyecto y configuración técnica. El portal organiza el trabajo; el libro organiza las ideas.

Notebooks de clase. Documentos ejecutables para practicar implementación, validar fórmulas y conectar teoría con código. Deben poder ejecutarse sin exponer soluciones oficiales de evaluaciones.

Laboratorios publicados. Enunciados, notebooks de estudiante, datos permitidos, criterios de entrega y rúbricas públicas. Las pruebas ocultas no se publican.

Respuestas seleccionadas. Retroalimentación parcial para ejercicios del libro. Su función es calibrar el estudio, no reemplazar soluciones completas.

Política de integridad académica y uso de IA. Reglas públicas sobre ayuda permitida, declaración de uso sustancial, defensa oral y límites de colaboración.

Guías públicas de inicio

El libro incluye dos guías de uso que deben permanecer públicas:

Guía	Audiencia	Propósito
Guía de estudio del estudiante	estudiantes	convertir lectura, notebook, laboratorio y proyecto en una rutina semanal verificable

Guía	Audiencia	Propósito
Guía pública de adopción docente	instructores y revisores	explicar adopción, separación público/privado, evaluación automatizada y controles de publicación
Mapa de objetivos de aprendizaje	estudiantes, instructores y revisores	ubicar objetivos observables, evidencia primaria y alineación con resultados globales
Mapa de cierres de capítulo	estudiantes, instructores y revisores	localizar términos clave, repaso, problemas, pensamiento crítico y proyecto de cierre
Casos longitudinales	estudiantes, instructores y revisores	seguir datasets públicos a través de varias decisiones técnicas
Respuestas y solucionarios	estudiantes, instructores y revisores	separar respuestas públicas, manual de estudiante y recursos restringidos
Prerrequisitos matemáticos mínimos	estudiantes	repasar formas, gradientes, probabilidad mínima y notación de código

Estas guías no contienen soluciones oficiales, pruebas ocultas ni instrucciones internas de calificación. Su función es transparentar el método de trabajo.

Recursos restringidos para instructores

Los recursos restringidos no deben publicarse en el libro ni en el portal público.

Recurso	Motivo de restricción
soluciones oficiales completas	preservan el valor formativo de ejercicios y evaluaciones
pruebas ocultas de autograding paquetes Gradescope/Otter guías docentes de clase	evitan hardcoding y filtración de criterios contienen lógica de calificación automática incluyen tiempos, decisiones de conducción y notas internas
rúbricas internas detalladas	apoyan consistencia docente sin revelar casos límite
bancos de parcial no liberados	mantienen integridad de evaluación

Una versión pública del curso nunca debe contener autograders, soluciones oficiales completas, zips de Gradescope ni notebooks con respuestas incrustadas. Antes de publicar, debe correrse la auditoría de material sensible del repositorio.

Cómo estudiar con los recursos

La secuencia recomendada para cada tema es:

1. leer la pregunta aplicada y los objetivos del capítulo;
2. revisar definiciones, proposiciones y figuras;
3. reproducir al menos un ejemplo resuelto;
4. ejecutar el notebook de clase;
5. resolver ejercicios conceptuales y cuantitativos;
6. implementar las funciones pequeñas del laboratorio;
7. escribir una interpretación corta con evidencia y límites;
8. comparar solo después con respuestas seleccionadas o feedback automático.

Criterio de dominio. Un estudiante domina un tema cuando puede explicar el objeto matemático, calcularlo en un caso pequeño, implementarlo en Python, validarlo con una métrica apropiada y decir qué decisión sí o no se justifica.

Cómo usar los recursos como instructor

El instructor puede usar el libro como base estable y el portal como capa operativa. Una preparación semanal mínima debería revisar:

Recurso	Pregunta docente
capítulo del libro	¿qué concepto central debe quedar claro?
notebook de clase	¿qué implementación se hará en vivo?
laboratorio	¿qué evidencia autocalifica el sistema?
rúbrica pública	¿qué debe saber el estudiante antes de entregar?
guía docente privada	¿qué errores frecuentes conviene anticipar?
reporte de autograding	¿qué casos requieren revisión humana?

Flujo de publicación

Antes de publicar una nueva versión:

1. renderizar libro y portal;
2. ejecutar verificación de enlaces del sitio público;
3. ejecutar auditoría de material sensible;
4. ejecutar auditoría estática de accesibilidad;
5. ejecutar axe sobre páginas representativas;
6. revisar visualmente portada, índice, figuras, tablas y páginas nuevas;
7. registrar cambios importantes en la auditoría editorial.

Política de respuestas

El libro puede incluir respuestas seleccionadas si cumplen estas reglas:

- explican el razonamiento central;
- no sustituyen una solución completa de laboratorio o parcial;
- no revelan pruebas ocultas;
- no publican código final de evaluaciones autograded;
- ayudan al estudiante a detectar errores de concepto, dimensión o interpretación.

Las soluciones completas pueden existir en materiales docentes privados, pero no deben sincronizarse con el portal público ni con el libro publicado.

La página [Respuestas, solucionarios y recursos restringidos](#) formaliza esta separación y enlaza plantillas públicas para controlar la liberación de respuestas.

Guía pública de adopción docente

Esta guía ayuda a usar el libro en un curso real y a separar los recursos de clase de los materiales de calificación. Está pensada para instructores, monitores y revisores que necesitan preparar sesiones y sostener una evaluación con baja carga manual.

Para dictar MATE-2105 semana a semana, use también el panel docente compartible, cuya URL se distribuye directamente a quienes preparan o sustituyen una clase. No aparece en la navegación del estudiante. Conecta esta guía con la ruta semanal, el libro, las diapositivas, notebooks, libretos, entregas y fechas del curso.

Sistema de sincronización del curso

La adopción del curso debe mantener tres capas sincronizadas:

Capa	Función	Riesgo si se desactualiza
Portal	operación del curso, enlaces, programa, calendario y entregas	el estudiante no sabe qué hacer ni qué entregar
Libro	explicación conceptual, matemática y ejercicios	el estudiante estudia sin estructura o con notación inconsistente
Panel docente compartible	preparación, libreto, conducción y cierre de clase	el profesor dicta sin verificar recursos, hitos o evaluación

Antes de dictar una semana, el profesor debe confirmar que las tres capas dicen lo mismo sobre tema, fecha, lectura, notebook, entrega e hito de proyecto.

Rutina mínima del profesor

Momento	Acción
7 días antes	revisar calendario, ruta semanal y programa
48 horas antes	abrir capítulo, slides, notebook y laboratorio público
antes de entrar a clase	definir pregunta aplicada, derivación central y cierre técnico
durante clase	derivar, implementar, validar e interpretar

Momento	Acción
después de clase	publicar recordatorio y registrar bloqueos frecuentes
antes de calificar	correr autograding y revisar solo casos que requieren juicio

Usos posibles del libro

Uso	Qué adoptar	Qué ajustar
Curso completo MATE-2105	todas las partes, portal, notebooks, labs y proyecto	fechas, plataforma de entrega y datasets de proyecto
Módulo de regresión aplicada	Parte II y apéndice de regresión	profundidad de derivaciones y número de laboratorios
Módulo de redes	Parte III y notebooks asociados	librería, hardware y alcance de entrenamiento
Módulo de estrategia ML	Parte IV y proyecto aplicado	dominio, métricas y criterios de decisión
Taller de reproducibilidad	Parte VI, manifiestos y guías de publicación	herramientas institucionales y política de datos

El libro permite una lectura modular, pero la secuencia completa fue diseñada para pasar de apoyo guiado a autonomía: derivar, implementar, validar, comunicar y defender.

Diseño semanal recomendado

Bloque	Tiempo sugerido	Producto
Activación	10-15 min	pregunta aplicada y error común
Desarrollo matemático	35-45 min	objeto, derivación o criterio de decisión
Implementación guiada	40-60 min	notebook con funciones y verificaciones
Discusión de validación	20-30 min	métrica, partición, curva o diagnóstico
Cierre	10-15 min	checklist de laboratorio o proyecto

Para una clase más corta, conserve pregunta aplicada, derivación mínima, notebook y cierre. Para una clase larga, agregue comparación con librería, diagnóstico de errores y discusión de límites.

Separación entre recursos públicos y privados

Público	Restringido
libro web y PDF	soluciones oficiales completas
datasets públicos y manifest	pruebas ocultas de autograding
notebooks de clase sin soluciones finales	zips Gradescope/Otter
enunciados y rúbricas públicas	bancos de parcial no liberados
respuestas seleccionadas	guías docentes con decisiones internas
panel y libretos docentes	reportes individuales de estudiantes

Esta separación es parte del diseño pedagógico. El estudiante debe tener criterios de éxito claros, pero no la lógica completa de evaluación.

Evaluación con baja carga manual

La calificación manual debe concentrarse en interpretación, decisiones técnicas y casos dudosos marcados por el autograder.

Evidencia	Autocalificable	Revisión humana mínima
funciones numéricas	shapes, valores, tolerancias y pruebas ocultas	patrones sospechosos o hardcoding
notebooks	ejecución limpia, outputs y métricas	interpretación corta
parciales notebook	implementación y resultados	justificación de fórmula o decisión
proyecto	checklist, manifest, métricas y reproducibilidad	defensa, límites y autoría

Principio operativo. Automatice código, resultados y consistencia. Revise manualmente solo aquello que requiere juicio: interpretación, decisión, ética, comunicación y autoría.

Alineación mínima antes de dictar

Antes de abrir una semana, confirme:

- el capítulo asociado está publicado;
- el objetivo observable de la semana aparece en el mapa de objetivos;
- el notebook de clase corre desde cero;
- el laboratorio no expone soluciones ni pruebas ocultas;
- la rúbrica pública coincide con lo que se autocalifica;
- los datasets no requieren internet para evaluación;
- las dependencias están en la guía de configuración;
- hay una pregunta de cierre conectada con proyecto o parcial.

Adaptación a otro contexto

Si el libro se usa fuera de MATE-2105, documente estos cambios:

Decisión	Debe quedar explícito
alcance de capítulos	partes asignadas y partes omitidas
calendario	semanas, fechas y entregas
evaluación	pesos, plataformas y reglas de colaboración
datasets	fuentes, licencia, fecha y restricciones
software	entorno, versiones y fallback local
accesibilidad	formato principal y canal de reporte
licencia	permisos de uso, redistribución y adaptación

No declare una adaptación como edición abierta si la licencia vigente no lo permite. En esta edición, el repositorio tiene una licencia formal de uso docente restringido.

Revisión de calidad antes de publicar

Use esta secuencia como control mínimo:

1. renderizar libro y portal;
2. ejecutar auditoría de estructura editorial;
3. ejecutar auditoría de objetivos de aprendizaje;
4. ejecutar auditoría de datasets;
5. ejecutar verificación del sitio público;
6. ejecutar auditoría de material sensible;
7. ejecutar auditoría de accesibilidad HTML y axe;
8. revisar visualmente portada, descargas, capítulos modificados y apéndices;
9. generar o verificar manifiesto de publicación;
10. registrar bloqueadores editoriales;
11. no cerrar revisión externa ni accesibilidad manual sin evidencia humana real.

Señales de una adopción saludable

Una adopción del libro funciona cuando:

- los estudiantes saben qué producir antes de cada evaluación;
- los notebooks no son solo demostraciones, sino práctica verificable;
- las rúbricas públicas explican criterios sin revelar tests ocultos;
- el proyecto avanza por checkpoints con evidencia;
- las decisiones técnicas se discuten con límites;
- el instructor revisa pocos casos a mano y con mejor evidencia;
- la versión publicada puede reconstruirse y auditarse.

Referencias y atribuciones

Esta página centraliza las fuentes técnicas, referencias editoriales y atribuciones del libro. No reemplaza las referencias locales de cada capítulo; funciona como registro de trazabilidad para estudiantes, instructores y revisores.

Referencia editorial

El benchmark editorial usado para esta edición es:

- OpenStax. *Principles of Data Science*. Página del libro: <https://openstax.org/details/books/principles-data-science>.
- OpenStax. Prefacio de *Principles of Data Science*: <https://openstax.org/books/principles-data-science/pages/preface>.
- OpenStax. Elementos de cierre de capítulo: términos clave, revisión de capítulo y problemas cuantitativos.
- OpenStax. Separación entre Answer Key, Student Solution Manual e Instructor Solution Manual descrita en el prefacio.

Esta referencia se usa como estándar de formato: front matter, recursos, accesibilidad, errata, atribución, separación estudiante-instructor y cierres de capítulo. No se usa como fuente de contenido matemático para copiar.

Referencias matemáticas y algorítmicas

Estas referencias son útiles para revisión técnica y profundización:

- Blitzstein, J. K., & Hwang, J. (2019). *Introduction to Probability*. Chapman and Hall/CRC.
- Casella, G., & Berger, R. L. (2002). *Statistical Inference*. Duxbury.
- Wasserman, L. (2004). *All of Statistics*. Springer.
- Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman and Hall/CRC.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Trefethen, L. N., & Bau, D. (1997). *Numerical Linear Algebra*. SIAM.
- Strang, G. (2016). *Introduction to Linear Algebra*. Wellesley-Cambridge Press.

Documentación técnica

El curso usa documentación oficial como referencia para implementación:

- NumPy documentation: <https://numpy.org/doc/stable/>.
- pandas documentation: <https://pandas.pydata.org/docs/>.
- scikit-learn user guide and API: <https://scikit-learn.org/stable/>.
- scikit-learn toy datasets: https://scikit-learn.org/stable/datasets/toy_dataset.html.
- Matplotlib documentation: <https://matplotlib.org/stable/index.html>.
- seaborn documentation: <https://seaborn.pydata.org/>.
- PyTorch documentation: <https://docs.pytorch.org/docs/stable/index.html>.
- Project Jupyter documentation: <https://docs.jupyter.org/>.
- Quarto books documentation: <https://quarto.org/docs/books/>.

Evaluación automatizada

Las referencias técnicas para autograding y publicación de evaluaciones son:

- Otter-Grader documentation: <https://otter-grader.readthedocs.io/en/latest/>.
- Gradescope autograder documentation: <https://gradescope-autograders.readthedocs.io/en/latest/>.

Los autograders, pruebas ocultas y paquetes de evaluación son recursos restringidos. Esta página referencia las plataformas, no publica material privado de evaluación.

Datasets y generadores

El libro incluye un paquete público de CSV de práctica generados por `scripts/generar_datasets_libro.py` y documentados en `datos/manifest_datos.json`. Estos archivos son originales del curso y se usan para práctica reproducible.

Además, algunos ejemplos y laboratorios pueden usar datasets de `scikit-learn` o generadores de datos controlados con semilla fija:

- `load_wine`: clasificación multiclase en el módulo de arranque.
- `load_diabetes`: regresión y regularización.
- `load_breast_cancer`: clasificación binaria, métricas y umbrales.
- `load_digits`: redes neuronales, PCA y clasificación multiclase.
- `make_regression`: regresión generada y descenso del gradiente.
- `make_blobs`: clustering y geometría de grupos.
- `make_moons`: fronteras no lineales y límites de modelos lineales.

El caso de vivienda nueva por subzona adapta el conjunto [Caracterización precios vivienda nueva](#), publicado por la Secretaría Distrital del Hábitat de Bogotá con licencia CC BY 4.0. La adaptación y sus limitaciones están registradas en `datos/manifest_datos.json`.

La página **Datos y recursos reproducibles** describe el uso pedagógico y las advertencias de interpretación de estos recursos.

Figuras

Las figuras del atlas visual y de las aperturas de parte son originales del curso MATE-2105. Fueron creadas para explicar objetos matemáticos y decisiones técnicas del libro. El inventario auditable está publicado en [figuras/manifest_figuras.json](#) e incluye, para cada figura, archivo SVG, archivo PNG, caption, texto alternativo, autoría, estado de derechos, primer uso significativo y propósito pedagógico.

Cada figura debe conservar:

- título o caption;
- texto alternativo o descripción equivalente;
- archivo fuente o versión editable cuando exista;
- indicación de autoría del curso si se reutiliza fuera del contexto original.

Si una edición futura incorpora imágenes, tablas, datasets o textos de terceros, debe registrar fuente, autor, licencia, enlace original y modificaciones realizadas.

Cómo citar este libro

Galindo, C. (2026). *Matemáticas y Algoritmos en Ciencia de Datos Aplicada: Libro del curso MATE-2105*. Universidad de los Andes.

<https://cesarneyit-code.github.io/mate2105/libro/>

El repositorio incluye `CITATION.cff` para herramientas compatibles con GitHub y gestores bibliográficos.

Integridad académica y uso de IA

El libro está diseñado para estudiar, practicar y preparar evaluaciones. Esa apertura requiere una regla clara: el estudiante puede recibir ayuda, pero debe poder explicar, modificar y defender lo que entrega.

Principio central

Puedes usar apoyo técnico, bibliográfico o computacional, incluido apoyo de IA generativa, siempre que mantengas responsabilidad sobre cada línea relevante de código, cada cálculo, cada métrica y cada conclusión que presentes.

En este curso, aprender no significa producir una respuesta que pase una prueba. Significa construir criterio técnico verificable.

Uso permitido

Está permitido usar recursos externos o IA para:

- aclarar mensajes de error;
- repasar definiciones, fórmulas o derivaciones;
- proponer pruebas pequeñas para una función;
- mejorar redacción, visualización o estructura de un reporte;
- comparar una implementación con documentación oficial;
- generar preguntas de estudio;
- preparar una defensa oral mediante preguntas de práctica.

El uso permitido siempre exige verificación: ejecutar código, revisar dimensiones, comprobar métricas y contrastar conclusiones con evidencia.

Uso que requiere declaración

Debe declararse de forma breve cualquier uso sustancial de IA o apoyo externo cuando influya en una entrega evaluada. Una declaración suficiente puede tener este formato:

Usé IA para: depurar la función de pérdida y mejorar la redacción de la conclusión.

Verifiqué el resultado mediante: pruebas del laboratorio, comparación con `sklearn` y revisión de métricas.

No es necesario declarar correcciones menores de ortografía, autocompletado trivial o consulta puntual de documentación.

Uso no permitido

No está permitido:

- entregar código que no puedes explicar;
- copiar una solución completa de laboratorio, parcial o proyecto;
- pedir a una herramienta que fabrique interpretaciones sin verificarlas;
- inventar fuentes, métricas, resultados o limitaciones;
- publicar, solicitar o compartir pruebas ocultas, autograders o soluciones oficiales;
- ocultar colaboración sustancial en una entrega individual;
- usar IA para evadir una defensa oral individual.

Evidencia de trabajo propio

Una entrega verificable debe dejar registro de:

Evidencia	Pregunta que debe responder
código ejecutable	¿puede reproducirse el resultado?
pruebas o checks	¿cómo se sabe que la implementación calcula lo esperado?
comparación razonable	¿hay baseline, referencia o cálculo manual pequeño?
interpretación	¿qué decisión se justifica y con qué límite?
trazabilidad	¿de dónde vienen datos, fórmulas, fuentes o ayudas externas?

Defensa oral

La defensa oral existe para verificar comprensión individual. Un estudiante debe poder explicar:

- qué representan los datos;
- qué modelo o algoritmo se usó;
- qué función objetivo, pérdida o métrica se optimizó;
- qué errores aparecen y cómo se diagnosticaron;
- qué límites tiene la recomendación;
- qué parte del trabajo fue propia y qué apoyo externo recibió.

Si una respuesta, notebook o conclusión no puede defenderse sin consultar la herramienta que la produjo, todavía no cumple el estándar académico del curso.

Regla práctica antes de entregar

Antes de entregar, responde:

Si el profesor me pide explicar esta línea, esta fórmula, esta métrica o esta conclusión en una defensa oral, ¿puedo hacerlo con mis propias palabras?

Si la respuesta es no, la entrega debe revisarse antes de enviarse.

Respuestas, solucionarios y recursos restringidos

Esta página declara qué tipo de respuestas puede publicar el libro y qué debe permanecer fuera de la publicación. El objetivo es dar retroalimentación útil al estudiante sin debilitar laboratorios, parciales, proyectos ni defensas orales.

Principio editorial

El libro puede publicar respuestas seleccionadas, fórmulas, verificaciones y criterios de interpretación. No debe publicar soluciones oficiales completas de evaluaciones, pruebas ocultas ni lógica de calificación.

Regla de separación. Lo público ayuda a estudiar y verificar dirección. Lo restringido permite calificar, comparar entregas y preservar integridad académica.

Tipos de recurso

Recurso	Audiencia	Estado	Contenido permitido
Respuestas seleccionadas del libro	estudiantes	público	resultado breve, pista, criterio o verificación parcial
Formularios y notación	estudiantes	público	fórmulas, formas, métricas y convenciones
Manual de estudio del estudiante	estudiantes	público	guía de uso de respuestas, rutina y preparación
Rúbricas públicas	estudiantes	público	criterios de evaluación sin pruebas ocultas
Guía de adopción docente	instructores y revisores	público	diseño de curso, separación de recursos y validaciones
Manual de instructor	equipo docente verificado	restringido	desarrollos completos, casos límite y criterios internos

Recurso	Audiencia	Estado	Contenido permitido
Paquetes de calificación	equipo docente verificado	restringido	pruebas, tolerancias, reportes y lógica de evaluación
Bancos no liberados	equipo docente verificado	restringido	variantes de parcial, quiz o defensa

Qué puede aparecer en respuestas públicas

Una respuesta pública es aceptable si cumple al menos una función formativa:

- verificar el signo, dimensión, fórmula o métrica esperada;
- mostrar el nivel de detalle de una interpretación breve;
- señalar un error frecuente;
- conectar un resultado con una limitación;
- dar una pista suficiente para corregir sin revelar todo el desarrollo.

Qué no debe publicarse

El libro y el portal público no deben incluir:

- desarrollo completo de laboratorios evaluados;
- código final de evaluaciones;
- pruebas ocultas, tolerancias o casos límite privados;
- respuestas completas de parciales no liberados;
- soluciones únicas para proyectos abiertos;
- reportes individuales de estudiantes;
- instrucciones internas para decidir casos dudosos de calificación.

Política por tipo de pregunta

Tipo de pregunta	Respuesta pública adecuada	Recurso restringido adecuado
Conceptual	definición breve o distinción clave	ejemplos de respuestas completas y distractores
Cuantitativa	valor final, fórmula o paso crítico	desarrollo algebraico completo y variantes
Computacional	shape, output esperado o test visible mínimo	pruebas ocultas y casos límite
Interpretativa	estructura evidencia-límite-decisión	rúbrica detallada y ejemplos calibrados
Proyecto	checklist, criterio y ejemplo abstracto	retroalimentación individual y notas de defensa

Respuestas de proyectos

Los proyectos no tienen solución oficial única. Una buena respuesta depende de datos, contexto, métrica, costo de error, limitaciones y defensa técnica. Por eso el libro puede publicar:

- estructura de reporte;
- rúbricas;
- ejemplos abstractos;
- checklists de reproducibilidad;
- criterios de defensa.

No debe publicar una solución modelo que los equipos puedan convertir en plantilla mecánica para evitar la toma de decisiones.

Proceso para liberar una respuesta

Antes de pasar una respuesta de restringida a pública, revisar:

1. ¿ayuda a aprender sin reemplazar el ejercicio?
2. ¿evita revelar pruebas, tolerancias o casos límite privados?
3. ¿no corresponde a una evaluación activa?
4. ¿declara límites cuando hay interpretación?
5. ¿puede mantenerse si cambia el autograder o la rúbrica?
6. ¿respeto privacidad y autoría?
7. ¿está enlazada desde el capítulo, apéndice o guía adecuada?

Plantillas de control

El libro publica plantillas para mantener la separación:

Plantilla	Uso
plantillas/solucionarios/manual_estudiante	respuestas en curso público con pistas y verificaciones parciales
plantillas/solucionarios/manual_instructores	restringido en curso restringido sin mezclarlo con la publicación
plantillas/solucionarios/registro_liberacion	decisiones de si una respuesta puede pasar a pública

Estas plantillas son públicas porque describen proceso editorial, no contenido de evaluación.

Criterio de auditoría

Una edición publicable debe poder demostrar que:

- el apéndice de respuestas seleccionadas existe y está enlazado;
- la política de respuestas está publicada;
- los recursos restringidos no aparecen en el sitio público;
- el auditor de publicación no detecta material sensible;
- la guía de estudiante explica cómo usar respuestas sin copiar;
- la guía de adopción docente explica la separación público/restringido.

Errata, revisión y control de calidad

Un libro de curso debe poder corregirse sin perder trazabilidad. Esta página define cómo registrar errores, cómo priorizarlos y qué evidencia se requiere para cerrar una corrección.

Qué cuenta como errata

Debe registrarse como errata cualquier problema que pueda afectar aprendizaje, evaluación, reproducibilidad o confianza editorial:

- fórmula incorrecta o ambigua;
- derivación incompleta;
- ejemplo con resultado numérico inconsistente;
- código que no ejecuta o no coincide con el texto;
- figura sin explicación suficiente;
- tabla rota en HTML o PDF;
- enlace roto;
- instrucción de evaluación confusa;
- material privado publicado por error.

Severidad

Severidad	Criterio	Acción
Alta	afecta una fórmula, resultado, evaluación o integridad académica	corregir antes de publicar
Media	confunde una explicación, ejemplo o ejercicio	corregir en la siguiente revisión
Baja	estilo, ortografía o formato menor	agrupar en una pasada editorial

Flujo de corrección

1. registrar capítulo, sección y descripción del problema;
2. clasificar severidad;
3. proponer corrección mínima;
4. revisar impacto en notebooks, laboratorios, rúbricas o autograders;

5. aplicar cambio en fuente, no solo en HTML generado;
6. renderizar y validar;
7. registrar evidencia de cierre.

Plantillas de errata

El paquete operativo de errata está disponible en:

Plantilla	Uso
Reporte de errata	reportar problema con ubicación, evidencia y corrección sugerida
Registro público de errata	mantener historial público de cambios aceptados o cerrados
Cierre de corrección	documentar evidencia después de corregir
Clasificación de severidad	decidir prioridad, evidencia mínima y manejo privado

Estas plantillas se publican para transparencia editorial. Los reportes que incluyan soluciones oficiales, pruebas ocultas o lógica de autograding deben moverse al espacio docente privado.

Evidencia de cierre

Una errata se considera cerrada solo si existe evidencia verificable:

- archivo fuente corregido;
- render actualizado del libro;
- prueba o auditoría relevante aprobada;
- revisión visual cuando el problema era de formato;
- nota breve del impacto sobre materiales asociados.

Registro público

La página [Registro público de errata](#) muestra el estado vigente de reportes abiertos, errata cerrada y cambios editoriales de la edición. Aunque no haya errata confirmada, el registro debe existir para que el lector sepa dónde consultar correcciones futuras.

Separación de errata pública y docente

La errata pública puede mencionar problemas de texto, código público o enlaces. La errata docente privada debe manejar por separado cualquier asunto que revele:

- soluciones oficiales;
- pruebas ocultas;
- bancos de parcial;
- criterios internos de calificación;
- casos límite del autograder.

Si una corrección involucra material privado, primero se retira del sitio público y luego se revisa el historial de publicación. La integridad académica tiene prioridad sobre la estética editorial.

Registro público de errata

Esta página mantiene el estado público de errata y correcciones del libro. Su propósito es que estudiantes, instructores y revisores puedan distinguir entre problemas confirmados, correcciones cerradas y cambios editoriales de una nueva edición.

Estado actual

Campo	Estado
Edición	Edición de trabajo 2026-20
Fecha de actualización	2026-07-13
Errata confirmada abierta	0
Errata confirmada cerrada	0
Correcciones editoriales registradas	2
Material privado afectado	no

Que no haya errata confirmada no significa que el libro esté libre de errores. Significa que, al momento de esta edición, no hay reportes públicos aceptados y pendientes de corrección.

Estados de un reporte

Estado	Significado
recibido	el reporte llegó, pero todavía no fue triageado
en revisión	el problema se está verificando
aceptado	el problema fue confirmado y requiere corrección
corregido	la corrección fue aplicada en la fuente
cerrado	la corrección fue renderizada, validada y documentada
no reproducible	no se pudo confirmar con la evidencia disponible
privado	el reporte toca soluciones, autograders o evaluación y se mueve al repositorio docente

Errata abierta

ID	Fecha	Ubicación	Severidad	Estado	Nota
—	—	—	—	sin errata abierta	—

Errata cerrada

ID	Fecha	Ubicación	Tipo	Evidencia de cierre
—	—	—	—	sin errata cerrada registrada

Cambios editoriales de edición

Estos cambios no son necesariamente errores. Se registran porque afectan la forma pública del libro.

Fecha	Alcance	Tipo	Evidencia
2026-07-13	Recorrido matemático del libro	reorganización editorial de probabilidad y estadística: primera aparición dentro de los modelos y capítulos posteriores de consulta sistemática	render HTML/PDF, auditorías matemáticas y editoriales, revisión visual y verificación del portal
2026-07-07	Libro completo	consolidación editorial de edición de trabajo: front matter, accesibilidad, errata, datasets, índices, figuras, auditorías y publicación	render del libro, auditoría editorial, auditoría PDF, manifest y verificación del portal

Criterio de publicación de errata

Un reporte se publica en esta página cuando:

1. afecta contenido público del libro;
2. no revela soluciones oficiales, pruebas ocultas ni lógica de autograding;
3. tiene ubicación verificable;
4. fue clasificado por severidad;
5. existe una decisión editorial: aceptar, cerrar, rechazar o mover a privado.

Reportes privados

Los reportes que mencionen evaluaciones, soluciones completas, pruebas ocultas, rúbricas internas, bancos de parcial o paquetes de autograding no se publican aquí. Deben manejarse en el repositorio docente privado y, si hubo exposición accidental, también debe revisarse el historial de publicación.

Cómo reportar

Para reportar una errata pública, usar la plantilla:

- [reporte_errata.md](#)

Para cerrar una corrección, usar:

- [cierre_correccion.md](#)

Para decidir severidad, usar:

- [clasificacion_severidad.md](#)

Criterio de cierre

Una errata pública queda cerrada cuando:

- el archivo fuente fue corregido;
- el libro fue renderizado nuevamente;
- la auditoría relevante pasó;
- el manifest publicado fue regenerado;
- la corrección no expuso material privado;
- el registro público fue actualizado.

Edición, versión y publicación

Esta página funciona como ficha editorial de la edición vigente. Su propósito es que el lector, el estudiante y el instructor sepan qué versión están usando, qué estado tiene el material y qué revisiones deben cumplirse antes de publicarlo como texto estable.

Ficha de edición

Campo	Valor
Título	<i>Matemáticas y Algoritmos en Ciencia de Datos Aplicada</i>
Curso	MATE-2105
Autor	César Galindo
Edición	Edición de trabajo 2026-20
Fecha de construcción	2026-07-13
Formatos	libro web, PDF, datasets públicos, guía de impresión, manifiesto de publicación y capítulos fuente Quarto
Sitio público previsto	https://cesarneyit-code.github.io/mate2105/libro/
Estado	versión docente en revisión editorial

Criterio de versión estable

Una versión puede considerarse estable cuando cumple estas condiciones:

1. todos los capítulos principales tienen objetivos, ejemplos resueltos, revisión, términos clave, ejercicios y proyecto de cierre;
2. los apéndices tienen notación mínima, fórmulas y respuestas seleccionadas;
3. las figuras tienen texto alternativo o explicación equivalente;
4. el PDF no tiene tablas, fórmulas o títulos visualmente rotos;
5. el portal no contiene soluciones oficiales completas ni autograders privados;
6. la auditoría PDF verifica metadatos, tamaño carta, texto extraíble y ausencia de JavaScript o encriptación;
7. las auditorías de estructura, enlaces, publicación y accesibilidad pasan;
8. el manifiesto de publicación existe y registra hashes de artefactos primarios;
9. el paquete de datasets públicos tiene manifest y auditoría de hashes;

10. la declaración de accesibilidad está publicada y distingue evidencia automática, revisión manual pendiente y barreras conocidas;
11. el registro público de errata está publicado y actualizado para la edición;
12. la licencia y el estado de uso están documentados explícitamente;
13. el estado de impresión del PDF está documentado cuando se distribuya como versión archivable o imprimible.
14. cada página HTML incluye un pie editorial con cita sugerida, estado de uso y enlaces a licencia, accesibilidad, errata y atribuciones.

Canales de publicación

El libro debe publicarse en dos niveles:

Canal	Función	Ritmo de cambio
libro web	lectura principal, búsqueda y navegación	puede actualizarse durante el semestre
PDF	lectura offline y archivo de versión	debe actualizarse solo después de revisión visual
datasets públicos	práctica reproducible y descargas del libro	se regeneran con semilla fija antes de publicación
accesibilidad	declaración pública, pruebas y remediación	se actualiza con cada barrera o auditoría
errata pública	reportes abiertos, cerrados y cambios editoriales	se actualiza con cada corrección aceptada
guía de impresión	revisión de PDF archivable e imprimible	se completa antes de impresión pública
formatos y descargas	entrada pública a HTML, PDF, datasets y manifiestos	debe actualizarse con cada cambio de artefactos
metadatos bibliográficos	citation tags, Dublin Core, Open Graph y JSON-LD	deben coincidir con título, autor, fecha, URL y estado de uso
capturas visuales	evidencia de portada, páginas editoriales, descargas, capítulos y apéndices	se regeneran con cada candidato de publicación
manifiesto	inventario, tamaños y hashes de publicación	se regenera con cada render público
portal del curso	calendario, materiales y entregas	cambia por cohorte
repositorio fuente	historial, edición y auditoría	cambia con cada mejora aprobada

El portal organiza la secuencia semanal. El libro desarrolla los contenidos y construye sus relaciones matemáticas. Una publicación publicable mantiene esa separación incluso cuando ambos viven en el mismo sitio.

Checklist de publicación

Antes de publicar una nueva edición:

- renderizar libro y portal desde cero;
- verificar enlaces del sitio público;
- auditar material sensible;
- auditar estructura editorial;
- auditar PDF generado;
- auditar accesibilidad estática;
- correr **axe** sobre páginas representativas;
- revisar y actualizar la declaración de accesibilidad;
- revisar y actualizar el registro público de errata;
- revisar visualmente portada, índice, capítulos modificados, tablas y figuras;
- completar checklist de impresión si el PDF se usará como copia archivable o imprimible;
- confirmar que PDF, HTML y descargas corresponden a la misma versión;
- revisar que la página de formatos y descargas apunte a los artefactos vigentes;
- verificar metadatos bibliográficos en HTML;
- generar capturas visuales representativas en escritorio y móvil;
- generar y revisar **manifest-publicacion.json**;
- registrar cambios editoriales relevantes;
- confirmar que licencia, cita sugerida y política de errata están visibles.
- verificar que el pie editorial persistente aparezca en páginas representativas del libro.

Registro de edición

Fecha	Cambio editorial	Evidencia esperada
2026-07-13	Reorganización del recorrido probabilístico: los conceptos aparecen dentro de los modelos y se reúnen después en dos capítulos de consulta; revisión de regresión, clasificación, métricas, partes e índices	render HTML/PDF, auditorías de estructura, profundidad, voz, accesibilidad y privacidad, y revisión visual en escritorio, móvil y PDF
2026-07-07	Consolidación de estructura tipo libro, front matter, auditorías, figuras, ejemplos resueltos, apéndices, guía de impresión y registro público de errata	render del libro, auditoría editorial y validación del portal

Registros de candidato

Cada construcción que se quiera tratar como candidato de publicación debe tener un registro interno en `libro_curso/registros/publicacion/`. Ese registro no reemplaza el manifiesto de publicación: el manifiesto prueba qué archivos fueron publicados; el registro editorial explica qué evidencia se revisó, qué estado se declara y qué bloqueadores quedan abiertos.

Para esta edición, el registro vigente es:

```
libro_curso/registros/publicacion/candidato_2026-07-13.md
```

Paquete de publicación

Esta página define qué se entrega cuando el libro se publica como versión web del curso. El objetivo es que cada edición pueda auditarse con artefactos identificables, checksums y comandos de validación, no solo con una carpeta HTML.

Artefactos públicos

Cada publicación debe incluir, como mínimo:

Artefacto	Ruta esperada	Propósito
Libro web	<code>index.html</code> y capítulos HTML	lectura principal, búsqueda y navegación
PDF	<code>Matemáticas-y-Algoritmos-en-Ciencia-de-Datos-Aplicada.pdf</code>	lectura offline y archivo de versión
Manifiesto	<code>manifest-publicacion.json</code>	inventario de archivos, tamaños y hashes
Sitemap	<code>sitemap.xml</code>	descubrimiento por buscadores
Recursos visuales	<code>figuras/</code> , <code>figuras/manifest_figuras.json</code> , <code>portada.svg</code> , <code>portada.png</code>	figuras, portada, atribuciones y assets del libro
Datasets públicos	<code>datos/*.csv</code> y <code>datos/manifest_datos.json</code>	práctica reproducible y descargas del libro
Estilos	<code>styles.css</code>	formato pedagógico y ajustes de accesibilidad
Apéndices de consulta	<code>apendices/</code>	glosario, índice temático, algoritmos y respuestas seleccionadas
Taxonomía de ejercicios	<code>apendices/taxonomia-ejercicios.html</code>	tipos de pregunta, niveles cognitivos y banco público por módulo
Guías de inicio	<code>guia_estudiante.html</code> y <code>guia_adopcion_docente.html</code>	rutina de estudio, adopción docente y separación público/privado
Mapa de objetivos de aprendizaje	<code>mapa_objetivos_aprendizaje.html</code> y <code>objetivos/manifest_objetivos_aprendizaje.json</code>	objetivos observables, evidencia y alineación por capítulo

Artefacto	Ruta esperada	Propósito
Mapa de cierres de capítulo	<code>mapa_cierres_capitulo.html</code>	revisión, términos clave, práctica y proyecto por capítulo
Política de respuestas y solucionarios	<code>solucionarios_respuestas.html</code> y <code>plantillas/solucionarios/</code>	separación entre respuestas públicas y recursos restringidos
Guía de impresión	<code>guia_impresion.html</code>	criterios para PDF archivable e impresión controlada
Plantillas de impresión	<code>plantillas/impresion/</code>	checklist visual y registro de prueba de impresión
Declaración de accesibilidad	<code>accesibilidad.html</code>	estado de accesibilidad, barreras conocidas y proceso de remediación
Plantillas de accesibilidad	<code>plantillas/accesibilidad/</code>	revisión de teclado, lector de pantalla y reporte de barreras
Formatos y descargas	<code>formatos_descargas.html</code>	acceso directo a HTML, PDF, datasets, manifiestos y estado de uso
Metadatos bibliográficos	<code><head></code> de páginas HTML	citation tags, Dublin Core, Open Graph y JSON-LD Schema.org
Registro público de errata	<code>registro_errata_publica.html</code>	estado de reportes, correcciones y cambios editoriales
Pie editorial persistente	todas las páginas HTML del libro	cita sugerida, estado de uso, licencia, accesibilidad, errata y atribuciones

El manifiesto no reemplaza la revisión editorial. Sirve para probar que una carpeta publicada corresponde a una construcción concreta y para detectar cambios accidentales en archivos públicos.

Manifiesto de publicación

El archivo público [manifest-publicacion.json](#) se genera después de renderizar el sitio. Contiene:

- fecha de generación;
- título y URL pública prevista;
- lista de artefactos primarios;
- inventario de archivos públicos del libro;
- tamaño en bytes;
- hash SHA-256;
- comandos recomendados de validación.

El manifiesto excluye librerías vendorizadas de Quarto en `site_libs/`, porque su contenido depende de la herramienta de render y no del manuscrito del libro. Sí incluye páginas HTML, figuras, datasets públicos, PDF, sitemap, estilos y archivos de búsqueda.

El archivo [figuras/manifest_figuras.json](#) registra las figuras originales con SVG, PNG, texto alternativo, atribución, estado de derechos, primer uso significativo y propósito pedagógico.

El archivo [objetivos/manifest_objetivos_aprendizaje.json](#) registra los objetivos observables de los capítulos principales, la evidencia esperada y la alineación con resultados globales.

Comandos de construcción

Desde la raíz del repositorio:

```
bash sitio_curso/scripts/sync_libro.sh
```

Para preparar una carpeta pública separada:

```
bash scripts/preparar_repo_publico.sh
```

Ambos flujos generan el manifiesto del libro publicado.

Comandos de validación

Antes de publicar, deben pasar:

```
python3 scripts/generar_datasets_libro.py
python3 scripts/auditar_datasets_libro.py
python3 scripts/auditar_figuras_libro.py --published-root sitio_curso/_site/libro
python3 scripts/auditar_objetivos_aprendizaje_libro.py --published-root sitio_curso/_site/libro
python3 scripts/auditar_estructura_editorial_libro.py
python3 scripts/auditar_profundidad_matematica_libro.py
python3 scripts/auditar_columna_probabilistica.py
python3 scripts/auditar_voz_autoral.py
python3 scripts/auditar_pdf_libro.py sitio_curso/_site/libro/Matemáticas-y-Algoritmos-en-Ciencias
python3 scripts/auditar_manifest_publicacion_libro.py sitio_curso/_site/libro
python3 scripts/auditar_publicacion.py sitio_curso/_site
python3 scripts/verificar_sitio_publico.py sitio_curso/_site
python3 scripts/auditar_accesibilidad_libro.py sitio_curso/_site/libro
python3 scripts/generar_capturas_visuales_libro.py
python3 scripts/auditar_preparacion_openstax_libro.py
bash scripts/auditar_axe_libro.sh http://127.0.0.1:8765/libro
```

Además, el PDF debe revisarse visualmente en portada, índice, capítulos modificados, tablas, figuras, fórmulas largas y páginas de apéndices. Si la edición se va a imprimir, también debe completarse la guía de impresión y PDF del libro.

Para una edición publicable fuera del curso, también deben completarse las plantillas manuales de accesibilidad para teclado y lector de pantalla. Los paquetes de trabajo preparados para esas revisiones

están en `libro_curso/registros/revision_externa/paquete_revision_externa_2026-07-07.md` y `libro_curso/registros/accesibilidad/paquete_revision_manual_2026-07-07.md`. El cierre final se verifica con:

```
python3 scripts/auditar_preparacion_openstax_libro.py --final
```

Criterio de aceptación

Una publicación del libro se considera aceptable para el curso cuando:

1. el sitio renderizado contiene HTML, PDF y manifiesto;
2. el manifiesto registra hashes de los artefactos primarios;
3. el paquete de datasets públicos pasa auditoría de filas, columnas y hashes;
4. no hay enlaces internos rotos;
5. no hay material sensible en el sitio público;
6. las auditorías de estructura, profundidad matemática, columna probabilística y voz autoral pasan;
7. la auditoría PDF pasa y declara explícitamente el estado de etiquetado;
8. la auditoría HTML de accesibilidad pasa;
9. **axe** no reporta violaciones en el muestreo vigente;
10. la versión PDF se revisó visualmente.
11. la declaración de accesibilidad está publicada y no promete más de lo que la evidencia puede probar.
12. el registro público de errata está actualizado para la edición.
13. si el PDF se presenta como versión imprimible, existe checklist de impresión o registro de prueba asociado.
14. la taxonomía pública de ejercicios está sincronizada con los capítulos, laboratorios y bancos integradores vigentes.
15. el pie editorial persistente aparece en páginas representativas del libro.
16. la página de formatos y descargas enlaza los artefactos públicos vigentes.
17. existe un registro de capturas visuales representativas para escritorio y móvil.
18. la portada HTML incluye metadatos bibliográficos machine-readable.
19. las figuras publicadas tienen manifiesto auditable con atribución, texto alternativo, formatos SVG/PNG y primer uso significativo.
20. los capítulos principales tienen objetivos observables auditables, evidencia primaria y alineación con resultados globales.

Para una edición publicable fuera del curso, además se requiere revisión externa registrada y revisión manual de accesibilidad. La decisión explícita sobre accesibilidad del PDF ya está registrada: HTML es el formato accesible principal y el PDF es respaldo offline/archivo de versión. Para una edición abierta tipo OER, también debe documentarse una licencia abierta que reemplace o complemente el LICENSE restringido vigente.

Guía de impresión y PDF

Esta página define el estándar mínimo para tratar el PDF como una edición archivable e imprimible del libro. La versión web sigue siendo el formato principal de lectura y accesibilidad; el PDF funciona como respaldo estable, lectura offline y fuente para impresión controlada.

Relación entre web, PDF e impresión

Formato	Uso principal	Criterio editorial
Web	lectura principal, búsqueda, enlaces, actualización y accesibilidad	debe ser la versión más actual y navegable
PDF	lectura offline, archivo de versión y distribución cerrada	debe corresponder al mismo contenido renderizado del libro web
Impresión	lectura prolongada, archivo físico o copia institucional	requiere revisión visual adicional antes de ordenar copias

El PDF no reemplaza la revisión de accesibilidad de la versión web. Mientras el PDF no sea etiquetado, la publicación debe declarar que la versión HTML es la opción accesible principal.

Especificación de PDF

La edición vigente usa estos parámetros de construcción:

- tamaño de página: carta;
- márgenes: 1 pulgada;
- tabla de contenido hasta nivel de subsección;
- enlaces en color;
- código con ajuste de línea;
- figuras con captions;
- metadatos de título y autor;
- texto extraíble;
- sin JavaScript;
- sin encriptación.

La auditoría técnica se ejecuta con:

```
python3 scripts/auditar_pdf_libro.py sitio_curso/_site/libro/Matemáticas-y-Algoritmos-en-Cienc.
```

Para generar evidencia visual HTML representativa:

```
python3 scripts/generar_capturas_visuales_libro.py
```

Revisión visual obligatoria

Antes de usar el PDF como versión de referencia, revisar una muestra que cubra:

1. portada;
2. índice;
3. información editorial;
4. páginas con tablas anchas;
5. páginas con fórmulas largas;
6. páginas con bloques de código;
7. páginas con figuras;
8. ejercicios integradores;
9. apéndices;
10. páginas finales.

La revisión debe confirmar:

- que no hay títulos aislados al final de página;
- que las tablas no se salen del área imprimible;
- que las fórmulas largas no quedan cortadas;
- que los bloques de código mantienen legibilidad;
- que las figuras no pierden su caption;
- que las referencias internas no aparecen como enlaces rotos;
- que el contraste es suficiente en impresión a color y en escala de grises;
- que el número total de páginas coincide con el registro de edición.

Prueba de impresión

Para una edición pública fuera del curso, la prueba de impresión debe hacerse antes de anunciar el PDF como versión final. La prueba mínima consiste en:

- imprimir portada, índice, una parte introductoria, un capítulo matemático, un capítulo con código, un capítulo con figuras y un apéndice;
- revisar lectura en escala de grises;
- confirmar que los enlaces visibles no son indispensables para entender el contenido impreso;
- verificar que tablas y fórmulas conservan alineación;
- registrar cualquier corrección en el flujo de errata.

Plantillas de revisión

Las plantillas operativas están publicadas con el libro:

- [checklist_revision_impresion.md](#)
- [registro_prueba_impresion.md](#)

Estado de impresión de esta edición

Elemento	Estado	Evidencia
PDF generado	verificado automáticamente	auditoría PDF
tamaño carta	verificado automáticamente	pdfinfo y auditoría PDF
texto extraíble	verificado automáticamente	extracción de texto
JavaScript/encryptación	verificado automáticamente	auditoría PDF
PDF etiquetado	no disponible en la edición vigente	decisión formal: HTML es el formato accesible principal
capturas HTML representativas	verificado automáticamente	scripts/generar_capturas_visuales_libro
revisión visual completa	pendiente para impresión pública	checklist de impresión
prueba física o simulada	pendiente para impresión pública	registro de prueba

Criterio de aceptación para impresión

Una edición puede enviarse a impresión controlada cuando:

1. el libro web, el PDF y el manifiesto provienen del mismo render;
2. la auditoría PDF pasa sin errores;
3. la revisión visual obligatoria está registrada;
4. las páginas impresas de muestra son legibles en color y escala de grises;
5. las correcciones obligatorias de maquetación están cerradas;
6. la edición, licencia y cita sugerida están visibles;
7. el estado de accesibilidad del PDF se declara explícitamente.

La decisión vigente está registrada en **libro_curso/registros/pdf/decision_accesibilidad_pdf_2026-07-07.md**: el PDF se usa como respaldo offline y archivo de versión; el HTML es el formato accesible principal.

Licencia y uso del material

Estado de licencia

Este libro es material docente del curso **MATE-2105 Matemáticas y Algoritmos en Ciencia de Datos Aplicada**.

El repositorio incluye un archivo **LICENSE** formal de uso docente restringido. Esa licencia permite lectura, estudio, revisión y uso dentro del curso, pero no es una licencia abierta ni una licencia Creative Commons. La redistribución, adaptación pública o uso comercial requiere autorización explícita del autor.

Esta página separa el estado legal del material de su uso pedagógico. La intención futura puede ser publicar una versión abierta, pero esa decisión debe quedar documentada de manera explícita en el repositorio y reemplazar o complementar el **LICENSE** vigente.

La página **Decisión de licencia abierta** compara opciones de licencia y define el procedimiento para migrar de uso docente restringido a licencia abierta sin confundir intención editorial con permiso legal vigente.

Uso permitido en el curso

Los estudiantes pueden:

- leer el libro en línea;
- descargar materiales públicos del portal;
- citar secciones del libro en sus reportes de curso;
- usar fragmentos de código educativo dentro de sus notebooks de clase y laboratorios, con atribución cuando corresponda.

Uso no permitido sin autorización

No está permitido, salvo autorización explícita:

- redistribuir el libro completo como producto propio;
- vender copias o adaptaciones;
- remover autoría o contexto institucional;
- publicar soluciones oficiales, pruebas ocultas o autograders;
- mezclar este texto con materiales externos de licencia incompatible.

Cita sugerida

Galindo, C. (2026). *Matemáticas y Algoritmos en Ciencia de Datos Aplicada: Libro del curso MATE-2105*. Universidad de los Andes.

<https://cesarneyit-code.github.io/mate2105/libro/>

Materiales de terceros

Si una versión futura incorpora imágenes, datasets o textos de terceros, cada recurso debe incluir:

- fuente;
- autor o entidad responsable;
- licencia;
- enlace original;
- modificaciones realizadas, si aplica;
- texto alternativo cuando el recurso sea visual.

Integridad académica

El libro público no contiene soluciones oficiales completas ni pruebas privadas. Esa separación permite estudiar con transparencia sin debilitar laboratorios, parciales o autograders.

La política operativa de autoría, colaboración y uso de IA se documenta en la página **Integridad académica y uso de IA** de este mismo libro.

Decisión de licencia abierta

Esta página documenta cómo debe tomarse una eventual decisión de licencia abierta para el libro. No reemplaza el archivo LICENSE del repositorio. En la edición vigente, ese archivo declara una licencia formal de **uso docente restringido**; por tanto, el libro no es todavía un recurso educativo abierto en sentido estricto.

Por qué esta decisión importa

Un libro publicable debe decir con claridad qué puede hacer el lector con el material:

- leerlo;
- compartirlo;
- adaptarlo;
- traducirlo;
- imprimirlo;
- usar fragmentos en clase;
- reutilizar código;
- reutilizar figuras;
- usarlo con fines comerciales o no comerciales.

OpenStax declara explícitamente que *Principles of Data Science* usa una licencia Creative Commons BY-NC-SA 4.0 para el contenido del libro. Ese es un referente editorial útil, pero no obliga a este curso a elegir la misma licencia.

Opciones razonables

Opción	Qué permite	Ventaja	Cuidado
Uso restringido del curso	lectura y uso dentro de MATE-2105	protege evaluaciones y futuras versiones	no es una licencia abierta
CC BY 4.0	reutilización amplia con atribución	máxima circulación académica	permite uso comercial y adaptaciones permisivas
CC BY-SA 4.0	reutilización con atribución y misma licencia	mantiene adaptaciones abiertas	puede limitar compatibilidad con algunos materiales
CC BY-NC 4.0	reutilización no comercial con atribución	reduce uso comercial no autorizado	“no comercial” puede ser ambiguo

Opción	Qué permite	Ventaja	Cuidado
CC BY-NC-SA 4.0	reutilización no comercial, atribución y misma licencia	cercano al modelo OpenStax revisado	limita uso comercial y exige compartir adaptaciones bajo la misma licencia

La decisión de licencia debe cubrir el libro, las figuras, el código educativo y los materiales descargables. No debe cubrir soluciones oficiales, pruebas ocultas, autograders ni guías docentes privadas.

Separación por tipo de material

La licencia no tiene que ser idéntica para todos los artefactos.

Artefacto	Decisión recomendada antes de publicar
texto del libro	uso docente restringido vigente; escoger licencia abierta solo si se quiere OER
figuras originales	alinear con la licencia del texto o declarar atribución propia
fragmentos de código	declarar si siguen la licencia del libro o una licencia de software
notebooks públicos	declarar si son material docente abierto o solo del curso
datasets externos	conservar licencia y términos de la fuente original
autograders y pruebas ocultas	mantener privados y fuera de la licencia pública
soluciones oficiales	mantener privadas o publicar solo respuestas seleccionadas

Criterios de decisión

Antes de reemplazar o complementar el LICENSE restringido vigente con una licencia abierta, resolver estas preguntas:

1. ¿Se quiere permitir adaptación por otros profesores?
2. ¿Se quiere permitir uso comercial?
3. ¿Las adaptaciones deben conservar la misma licencia?
4. ¿Las figuras y el texto tendrán la misma licencia?
5. ¿Los notebooks públicos seguirán la licencia del libro?
6. ¿Hay material institucional que requiera aprobación previa?
7. ¿Hay recursos de terceros incompatibles con la licencia deseada?
8. ¿Cómo se separan libro público y materiales privados de evaluación?

Registro de decisión pendiente

Elemento	Estado	Evidencia requerida
licencia del texto	uso docente restringido	archivo LICENSE
licencia abierta del texto	pendiente	decisión explícita de Creative Commons u otra licencia abierta
licencia de figuras originales	alineada al uso docente restringido salvo indicación contraria	nota en referencias/atribuciones
licencia de código educativo	uso docente restringido salvo indicación contraria	archivo LICENSE y README
tratamiento de notebooks públicos	pendiente de normalización por módulo	política en portal o README
exclusión de autograders	definida	política de recursos restringidos
revisión de terceros	pendiente	tabla de atribuciones completa

Procedimiento de cierre

Para cerrar la decisión de licencia:

1. elegir licencia abierta o mantener uso restringido de forma explícita;
2. reemplazar o complementar **LICENSE** si se adopta una licencia abierta;
3. actualizar `licencia_uso.qmd`, `README.md`, `CITATION.cff` y el portal;
4. revisar atribuciones de figuras, datasets y fragmentos de código;
5. confirmar que materiales privados no quedan incluidos;
6. renderizar libro y portal;
7. ejecutar auditorías de publicación;
8. registrar la decisión en la matriz editorial.

La plantilla fuente para documentar esta decisión está en [registro_decision_licencia.md](#).