

MATE-2105: Módulo 0

Datos y fundamentos probabilísticos

César Galindo

2026-07-12

Tabla de contenidos

Módulo 0: Datos y preguntas	6
Propósito del módulo	7
Resultados de aprendizaje del módulo	8
Artefactos del módulo	9
Ruta del estudiante	9
Materiales docentes	9
Flujo recomendado	11
Entrega de la semana	12
Observaciones, variables y preguntas	13
Unidades de observación y niveles de análisis	14
Variables, valores y mediciones	15
El diccionario de datos	17
Población, marco de observación y muestra	18
De una pregunta amplia a una pregunta precisa	19
Familias de tareas	20
De la tabla a la notación matemática	21
Modelo, algoritmo y resultado ajustado	23
Disponibilidad temporal y filtración de información	25
Calidad de datos como propiedad de la pregunta	26
Análisis completo del caso de Bogotá	26
Una ficha mínima para iniciar un análisis	27
Síntesis	28
Problemas integrados	28
Respuestas seleccionadas	30
Variables aleatorias, distribuciones y muestras	31
Antes y después de observar	31
La distribución	32
Esperanza y variación	33
Distribuciones conjuntas, independencia y covarianza	34
De la población a una muestra	35
Distribución empírica y estadísticos	35
Por qué se estabiliza un promedio	36
Síntesis	37
Problemas integrados	37

Respuestas seleccionadas	38
Condicionamiento, estimación y riesgo	40
Lo que cambia al conocer las entradas	40
De la cantidad poblacional al valor calculado	43
Pérdida, riesgo y aprendizaje a partir de una muestra	44
Regreso a las subzonas de Bogotá	47
Síntesis	47
Problemas integrados	47
Respuestas seleccionadas	48
Guía de orientación de la Semana 1	50
Cómo usar esta guía	51
La promesa del curso	52
El contrato intelectual del curso	53
Qué esperamos de ti	54
Lenguaje mínimo de la semana	55
Dataset	55
Variable de entrada y variable objetivo	55
Modelo	55
Pérdida	56
Métrica	56
Baseline	56
Train/test	56
Primer ejemplo: clasificar vinos	57
Un primer fragmento de código	58
Cómo se verá una semana típica	60
Proyecto final desde la primera semana	61
Entrega de la semana	62
Cierre	63
Configuración del entorno de trabajo	64
Objetivo	65
Versión de Python	66
Opción recomendada: entorno semestral	67
Alternativa ligera para la Semana 1	68

Verificación esperada	69
Cómo abrir el laboratorio	70
Si algo falla	71
Fallback temporal	72
Errores frecuentes	73
ModuleNotFoundError	73
El notebook abre pero no ejecuta	73
python no existe	73
Instalación muy lenta	73
Laboratorio diagnóstico 1	74
Objetivo	75
Entrega	76
Parte 0: preparación	77
Parte 1: población, muestra y riesgo	78
Pregunta probabilística	79
Parte 2: cargar e inspeccionar datos	80
Pregunta de interpretación 1	80
Parte 3: partición de datos	81
Pregunta de interpretación 2	81
Parte 4: baseline	82
Pregunta de interpretación 3	82
Parte 5: modelo de referencia	83
Parte 6: errores	84
Pregunta de interpretación 4	84
Parte 7: accuracy como estimación y conclusión técnica	85
Parte 8: dos ideas iniciales de proyecto	86
Idea 1	86
Idea 2	86
Checklist antes de entregar	87
Guía inicial del proyecto final	88
Proposito del proyecto	89

Qué cuenta como buen proyecto	90
Preguntas para elegir tema	91
Tipos de proyecto permitidos	92
Predicción o regresión	92
Clasificación	92
No supervisado	92
Criterios de dataset	94
Hitos del proyecto	95
Producto final	96
Defensa oral individual	97
Entrega inicial de Semana 1	98
Ejemplos de transformación	99
Política preliminar de uso de IA	100
Principio general	101
Usos permitidos	102
Usos no permitidos	103
Declaración de uso	104
Responsabilidad	105
Defensa oral	106
Uso recomendado	107
Criterio práctico	108

Módulo 0: Datos y preguntas

Propósito del módulo

Este módulo abre el curso MATE-2105: Matemáticas y Algoritmos en Ciencia de Datos Aplicada.

La primera semana no es una sesión administrativa. Es el primer ensayo del modo de trabajo del curso: partir de una pregunta aplicada, mirar datos reales, construir un primer modelo, medirlo, diagnosticarlo y explicar qué decisión técnica se puede defender.

El módulo tiene cuatro propósitos:

1. Entender la identidad del curso.
2. Establecer el ciclo de trabajo: pregunta, datos, modelo, diagnóstico y decisión.
3. Configurar el entorno mínimo de trabajo.
4. Ejecutar un primer laboratorio diagnóstico con datos reales.

Resultados de aprendizaje del módulo

Al finalizar el módulo, el estudiante debe poder:

1. Explicar la diferencia entre aprender herramientas, aprender teoría y hacer ciencia de datos aplicada.
2. Identificar las partes de un problema de aprendizaje supervisado: datos, variables, objetivo, modelo, pérdida y métrica.
3. Distinguir datos observados, variable aleatoria, ruido y desempeño futuro.
4. Cargar un dataset real pequeño y describir su estructura básica.
5. Separar datos de entrenamiento y prueba.
6. Construir un baseline simple y compararlo con un modelo de referencia.
7. Interpretar una métrica inicial sin sobreprometer el resultado.
8. Entender como el proyecto final se conectara con las técnicas del semestre.

Artefactos del módulo

El módulo tiene materiales para estudiantes y materiales docentes. Si eres estudiante, no necesitas abrir todos los archivos.

Ruta del estudiante

Momento	Qué hacer	Artefacto	Tiempo sugerido
Antes de la clase 1	Leer observaciones, variables y preguntas	<code>capitulo00_libro_estudiantes.qmd</code>	60-75 min
Antes de la clase 2	Leer variables aleatorias, distribuciones y muestras	<code>capitulo00b_incertidumbre_datos.qmd</code>	60-75 min
Antes de la Semana 2	Leer el puente entre condicionamiento, estimación y riesgo	<code>capitulo00c_estimacion_misgo_incertidumbre.qmd</code>	60-75 min
Antes de clase	Revisar la orientación del curso	<code>texto_estudiantes.qmd</code>	15-20 min
Antes o durante clase	Configurar entorno o identificar bloqueo técnico	<code>recursos/configuracion_entorno.qmd</code>	20-40 min
Durante clase	Seguir el live coding del profesor	<code>notebooks/semana01_live_coding.ipynb</code>	en clase
Durante/después de clase	Completar la entrega diagnóstica	<code>laboratorios/semana01_lab.ipynb</code>	60-90 min
Después de clase	Proponer ideas iniciales de proyecto	<code>recursos/guia_proyecto.qmd</code>	20-30 min
Permanente	Consultar reglas de uso de IA	<code>recursos/politica_ia.qmd</code>	10 min

Materiales docentes

Artefacto	Uso
<code>slides/semana01_presentacion.qmd</code>	Presentación de clase
<code>docente/semana01_guion_clase.md</code>	Guion minuto a minuto para el profesor

Artefacto	Uso
docente/semana01_notas_docente.md	Notas pedagogicas y técnicas para conducir la semana
docente/checklist_modulo00.md	Lista operativa antes, durante y después de clase
laboratorios/semana01_rubrica.md	Rúbrica del laboratorio

Flujo recomendado

Antes de clase:

- Leer el capítulo tipo libro.
- Revisar la guía de orientación.
- Intentar configurar el entorno.
- Si el entorno falla, registrar el error y traerlo a clase.

Durante clase:

- Discutir la promesa del curso.
- Construir el mapa conceptual de ciencia de datos aplicada.
- Ejecutar el notebook de live coding.
- Empezar el laboratorio.

Después de clase:

- Terminar el laboratorio diagnóstico.
- Revisar la guía de proyecto.
- Proponer dos posibles temas o datasets de interés.

Entrega de la semana

La entrega de la Semana 1 es diagnóstica. Debes entregar:

1. El laboratorio `semana01_lab.ipynb` ejecutado o, si hubo bloqueo técnico, el mismo archivo con una descripción precisa del error.
2. Las respuestas de interpretación dentro del notebook.
3. La conclusión técnica final.
4. Dos ideas iniciales de proyecto.

Formato recomendado del archivo:

```
apellido_nombre_semana01_lab.ipynb
```

La prioridad de esta entrega es identificar temprano el nivel de preparación, los problemas de entorno y la capacidad inicial de interpretar resultados.

Observaciones, variables y preguntas

Cómo definir los objetos de un problema con datos

La Secretaría Distrital del Hábitat publica una caracterización de precios de vivienda nueva en Bogotá. Para los ejemplos de este libro se congeló un subconjunto de 32 subzonas y siete columnas. Cinco filas tienen la forma siguiente.

subzona	precio reportado	estrato prom.	área prom.
Rosales	16.365	5.922	177.316
Chicó	13.939	5.905	128.044
Bosque Medina	10.751	4.699	151.226
Multicentro	10.365	5.647	94.071
Centro	9.504	3.195	63.383

subzona	alcobas prom.	baños prom.	parqueaderos prom.
Rosales	2.673	3.776	2.981
Chicó	2.225	3.105	2.152
Bosque Medina	2.533	3.037	2.467
Multicentro	2.086	2.625	1.786
Centro	1.744	1.799	0.988

La tabla puede leerse de varias maneras equivocadas. Una fila no representa una vivienda, sino una subzona. Las columnas numéricas son promedios o indicadores de esa subzona, no mediciones individuales. Además, el archivo fuente llama **precios** a una de las columnas, pero no documenta su unidad en el recurso descargado. Por esta razón usamos el nombre **precio_reportado** y no afirmamos que la cifra esté expresada en pesos, millones de pesos o precio por metro cuadrado.



Figura 1: Las 32 filas representan subzonas de Bogotá y no viviendas individuales. El eje horizontal usa el campo de precio reportado, cuya unidad no está documentada en el archivo fuente.

La figura permite comparar el orden y la dispersión del indicador dentro de las 32 filas. No permite valorar una vivienda particular ni completar una unidad de medida ausente. Esta diferencia entre lo que muestran los datos y lo que quisiéramos saber será recurrente a lo largo del libro.

Unidades de observación y niveles de análisis

Unidad de observación. La unidad de observación es la entidad, evento o intervalo representado por un registro. Puede ser una persona, una transacción, una imagen, una subzona, un paciente en una visita o el resultado de un experimento.

La descripción de la unidad debe incluir más que un sustantivo. También interesa el periodo de registro, el lugar, los criterios de inclusión y el procedimiento que produjo la fila. “Paciente” y “visita de un paciente” definen unidades distintas. Si una misma persona aparece en cinco visitas, las cinco filas no constituyen cinco personas independientes.

La **unidad de análisis** es la entidad sobre la cual se formula la conclusión. Con frecuencia coincide con la unidad de observación, pero no siempre. Una tabla puede registrar transacciones y utilizarse para estudiar comercios; puede registrar estudiantes y utilizarse para comparar colegios; puede registrar subzonas y pretender describir viviendas. Cuando las unidades no coinciden, es necesario especificar cómo se agregan los registros y qué información se pierde.

Ejemplo 1: registros hospitalarios. Un archivo contiene una fila por consulta. La pregunta “¿qué consultas terminarán en hospitalización?” tiene la consulta como unidad de observación y de análisis. La pregunta “¿qué pacientes tendrán al menos una hospitalización durante el año?” exige

agrupar consultas por paciente y fijar un intervalo temporal. Usar cada consulta como si fuera un paciente alteraría el denominador y podría colocar consultas de una misma persona en conjuntos distintos.

Identificadores y repetición

Un identificador permite reconocer la unidad registrada. No siempre es una variable útil para predecir. Un número de documento puede ser indispensable para detectar duplicados y, al mismo tiempo, ser inadecuado como entrada de un modelo.

Conviene distinguir:

- **identificador de registro**, que diferencia filas;
- **identificador de unidad**, que permite reconocer observaciones repetidas de la misma entidad;
- **identificador de grupo**, que señala hospital, colegio, región o dispositivo;
- **marca temporal**, que sitúa la observación y permite reconstruir el orden.

Estas columnas determinan dependencias que no se ven en una matriz numérica. Más adelante condicionarán la manera de construir muestras de entrenamiento y evaluación.

Agregación y falacia ecológica

En la tabla de Bogotá, `area_promedio` es un resumen de subzona. Una relación entre `area_promedio` y `precio_reportado` describe asociaciones entre subzonas. No se deduce de ella la relación correspondiente entre viviendas dentro de cada subzona.

Inferir un comportamiento individual a partir de datos agregados se conoce como **falacia ecológica**. El problema no se resuelve aumentando el número de subzonas: la información individual fue reemplazada por resúmenes. Tampoco puede recuperarse la variación interna de cada grupo a partir de un promedio aislado.

Ejemplo 2: dos subzonas con el mismo promedio. En una subzona, las áreas de dos viviendas pueden ser 80 y 120 metros cuadrados; en otra, 99 y 101. Ambas tienen promedio 100, pero su variación interna es diferente. Una tabla que conserva solo el promedio no permite distinguirlas.

Variables, valores y mediciones

Variable. Una variable es una característica que puede tomar distintos valores en las unidades consideradas. Su definición incluye un dominio de valores posibles y una regla, explícita o implícita, para asignar un valor a cada unidad.

Una columna es la representación computacional de los valores registrados para una variable. Variable y columna no son sinónimos perfectos. Una variable puede requerir varias columnas, como una fecha separada en año, mes y día; una columna puede ser un identificador técnico sin interpretación sustantiva; y una variable no observada directamente puede construirse a partir de otras mediciones.

Dominio y tipo de variable

El dominio describe qué valores admite una variable. Algunas categorías útiles son:

Tipo conceptual	Ejemplo	Operaciones con sentido
binaria	hospitalización: sí/no	proporción, comparación de categorías
categorica nominal	localidad	igualdad, conteos, frecuencias
categorica ordinal	nivel bajo/medio/alto	orden y comparaciones ordinales
conteo	número de visitas	suma, diferencia, razón bajo condiciones
continua	área construida	diferencias, promedios, transformaciones
temporal	fecha de venta	orden, duración, estacionalidad
texto, imagen o señal	descripción, radiografía, audio	representación específica del objeto

El tipo almacenado por un programa no decide el tipo conceptual. Un código postal puede aparecer como entero y seguir siendo categórico; convertirlo a `float` no hace razonable promediarlo. De forma inversa, un número guardado como texto puede representar una medición continua que necesita limpieza.

Escala y unidad

La unidad determina la interpretación de diferencias y proporciones. Una longitud en metros y la misma longitud en centímetros contienen la misma información, pero producen coeficientes numéricos diferentes. Una temperatura en grados Celsius admite diferencias con sentido, aunque la razón “20 es el doble de 10” no tenga la interpretación física usual de una escala con cero absoluto.

Por ello, antes de calcular conviene registrar:

1. definición de la variable;
2. unidad y escala;
3. instante o periodo al que se refiere;
4. instrumento o fuente;
5. transformaciones aplicadas;
6. códigos especiales y valores faltantes.

Medición y construcción

No toda variable es observada de manera directa. “Ingreso mensual” puede proceder de una declaración, un registro tributario o una imputación. “Satisfacción” puede ser la respuesta a una escala. “Riesgo” puede ser un índice construido a partir de varias columnas. Cada procedimiento define un objeto diferente, aunque los nombres se parezcan.

Procedimiento de medición. Es la regla mediante la cual una propiedad de una unidad se transforma en un valor registrado. Incluye instrumento, protocolo, momento, resolución, redondeo y tratamiento de casos no observables.

El error de medición es la diferencia entre el valor registrado y la cantidad que se pretendía medir. No es lo mismo que un residual de un modelo, que se calcula después de comparar una observación con una predicción. La distinción se retomará al estudiar modelos probabilísticos.

Datos faltantes

Un valor faltante no es necesariamente cero y tampoco constituye una categoría ordinaria. Puede faltar porque la medición no aplica, porque no se realizó, porque el participante no respondió o porque el sistema perdió el registro. Esas causas pueden contener información.

Antes de imputar o eliminar filas deben responderse al menos tres preguntas:

- ¿qué significa la ausencia en esta variable?;
- ¿puede conocerse la causa con las demás columnas?;
- ¿cambia la frecuencia de ausencia entre grupos, periodos o valores del resultado?

La teoría estadística de los mecanismos de ausencia requiere supuestos adicionales. En esta etapa basta con no ocultar la ausencia bajo una transformación automática.

El diccionario de datos

Un diccionario de datos conserva el significado que se pierde al convertir una tabla en un arreglo. Para cada columna debería indicar, cuando corresponda:

Campo	Pregunta que debe responder
nombre	¿cómo se identifica en el archivo?
descripción	¿qué propiedad representa?
dominio	¿qué valores son admisibles?
unidad	¿en qué escala se expresa?
procedencia	¿qué sistema o instrumento la produjo?
disponibilidad	¿en qué momento se conoce?
transformación	¿es original, agregada o derivada?
faltantes	¿qué códigos y causas de ausencia existen?

Para el subconjunto de Bogotá puede escribirse un diccionario parcial:

variable	papel	interpretación disponible	limitación principal
subzona	identificador	nombre de la subzona	no identifica viviendas
precio_reportado	posible salida	indicador llamado precios en la fuente	unidad no documentada

variable	papel	interpretación disponible	limitación principal
estrato_promedio	entrada	promedio reportado por subzona	oculta variación interna
area_promedio	entrada	área promedio reportada	tipo de área no documentado aquí
alcobas_promedio	entrada	promedio de alcobas	no es conteo de una vivienda
banos_promedio	entrada	promedio de baños	no es conteo de una vivienda
parqueaderos_promedio	entrada	promedio de parqueaderos	no es conteo de una vivienda

Este diccionario no completa información ausente. Su valor consiste precisamente en separar lo conocido de lo supuesto.

Población, marco de observación y muestra

Una tabla contiene unidades observadas. Para interpretar una conclusión también debemos precisar el conjunto más amplio al que se refiere.

Población objetivo. Es el conjunto de unidades, lugares y periodos sobre los que se desea formular una conclusión.

Marco de observación. Es el conjunto de unidades que el procedimiento de recolección podía identificar o incluir. Puede ser más pequeño o diferente de la población objetivo.

Muestra observada. Es el conjunto de unidades del marco que finalmente aparece en los datos después de aplicar criterios de inclusión, respuesta, disponibilidad y limpieza.

Estas tres colecciones pueden diferir. Si la población objetivo son todos los hogares de una ciudad y el marco contiene solo hogares con conexión fija a internet, ningún tamaño de muestra dentro de ese marco incluye a quienes quedaron fuera. El problema es de cobertura, no de precisión numérica.

La relación puede resumirse así:

población objetivo → marco de observación → muestra registrada → tabla analizada.

Cada flecha corresponde a un mecanismo: cobertura, selección, respuesta, medición o procesamiento. Una conclusión sobre la población requiere que esos mecanismos sean compatibles con la comparación que se pretende realizar.

Un censo también tiene alcance limitado

Observar todas las unidades de un marco en un instante elimina el error asociado a seleccionar solo algunas de ellas, pero no resuelve otros problemas. El marco puede excluir unidades, las mediciones pueden contener errores y la población futura puede cambiar. Un “censo” de transacciones de 2025 sigue siendo una muestra de los periodos posibles si la pregunta se refiere a 2026.

¿Qué población corresponde al caso de Bogotá?

La respuesta depende de la pregunta. Podríamos interesarnos por las 32 subzonas en el periodo documentado, por todas las subzonas de Bogotá, por proyectos de vivienda nueva o por viviendas particulares. La tabla no convierte automáticamente una de estas opciones en población objetivo. Además, no conocemos aquí el mecanismo de selección de las 32 subzonas ni la unidad del indicador. Por ello, el caso sirve para estudiar asociaciones entre los resúmenes disponibles, no para valorar viviendas individuales ni para describir sin reservas toda la ciudad.

El capítulo siguiente representará muestras y poblaciones mediante distribuciones de probabilidad. Esa formalización no reemplaza la descripción del marco: primero debe quedar claro de qué proceso podría ser muestra la tabla.

De una pregunta amplia a una pregunta precisa

“Analizar vivienda en Bogotá” expresa un tema, pero no una pregunta matemática. Una pregunta precisa debe indicar qué unidad se estudia, qué cantidad se quiere obtener y a qué población se refiere.

Preguntas descriptivas

Una pregunta descriptiva resume lo observado:

¿Cómo se distribuye `precio_reportado` entre las 32 subzonas del archivo?

La respuesta puede incluir tablas, gráficos, medias o cuantiles. Su alcance inmediato son las filas observadas. Extenderla a otras subzonas o periodos exige un argumento adicional sobre la manera en que se obtuvo la muestra.

Preguntas predictivas

Una pregunta predictiva busca anticipar un resultado que no estará disponible en el momento de aplicar la regla. Conviene especificar cinco elementos:

1. **unidad:** ¿para qué tipo de caso se produce la predicción?;
2. **salida:** ¿qué valor o categoría se quiere anticipar?;
3. **momento:** ¿cuándo se realiza la predicción y para qué horizonte?;
4. **información disponible:** ¿qué variables se conocen en ese instante?;
5. **población de uso:** ¿sobre qué casos se aplicará el procedimiento?

Una formulación compatible con el ejemplo sería:

Para una subzona descrita por los promedios disponibles, estimar el indicador `precio_reportado` y evaluar el procedimiento en subzonas comparables que no participaron en el ajuste.

Esta formulación no promete valorar viviendas ni explicar por qué cambia el indicador.

Preguntas causales

Una pregunta causal se refiere al efecto de una intervención o exposición:

¿Cómo cambiaría el resultado si, manteniendo lo demás apropiadamente comparable, se modificara una condición determinada?

Una asociación útil para predecir no identifica por sí sola ese efecto. Si `estrato_promedio` y `precio_reportado` cambian juntos, un modelo puede aprovechar la asociación sin que una modificación administrativa del estrato produzca el cambio predicho. Para sostener una afirmación causal se necesita definir la intervención, establecer qué comparación la representa y justificar supuestos sobre asignación, confusión y medición.

Una misma tabla admite preguntas diferentes

El conjunto `load_wine` de `scikit-learn` contiene mediciones químicas de vinos y tres clases de cultivar. La misma tabla permite formular, entre otras, estas preguntas:

- describir la distribución de una concentración en la muestra;
- predecir la clase de cultivar a partir de las mediciones;
- estimar una concentración continua usando las demás variables;
- explorar una representación de baja dimensión sin escoger una salida.

La tabla no determina por sí sola la tarea. El papel de una columna depende de la pregunta. Una variable puede ser entrada en un análisis y salida en otro.

Familias de tareas

Una vez definida la pregunta, la forma de la salida orienta la familia de métodos.

Pregunta	Salida matemática	Familia habitual
estimar una cantidad	número real	regresión
asignar una categoría	elemento de un conjunto finito	clasificación
estimar una probabilidad	vector de probabilidades	clasificación probabilística
ordenar alternativas	puntaje u orden	ranking y recomendación
representar estructura sin salida	coordenadas, grupos o factores	aprendizaje no supervisado

Pregunta	Salida matemática	Familia habitual
estimar efecto de una intervención	contraste entre resultados potenciales	inferencia causal

Las fronteras no siempre son absolutas. Una variable ordinal puede tratarse como categoría o como valor ordenado; un conteo puede modelarse mediante regresión con una distribución específica; una probabilidad estimada puede convertirse en una decisión después de fijar costos y umbrales. La elección debe corresponder al significado de la salida, no únicamente al tipo almacenado en el archivo.

De la tabla a la notación matemática

Sea una tabla con n registros y q variables registradas. Denotamos la fila i por

$$z_i = (z_{i1}, \dots, z_{iq}),$$

donde cada coordenada representa una variable registrada. La colección ordenada de registros es

$$d_n = (z_1, \dots, z_n).$$

Usamos aquí letras minúsculas porque los valores ya fueron observados. En el capítulo siguiente introduciremos las variables aleatorias Z_i y reservaremos $D_n = (Z_1, \dots, Z_n)$ para la muestra antes de observarla.

Problemas supervisados

Si una variable cumple el papel de salida, escribimos

$$z_i = (x_i, y_i),$$

donde x_i reúne la información de entrada y y_i es el resultado observado. Una transformación $\phi : \mathcal{X}_{\text{raw}} \rightarrow \mathbb{R}^p$ produce la representación numérica que utilizará el modelo. En los capítulos de regresión, su primera coordenada será uno para incluir el intercepto. Las observaciones se organizan como

$$\mathbf{X} = \begin{bmatrix} \phi(x_1^{\text{raw}})^\top \\ \vdots \\ \phi(x_n^{\text{raw}})^\top \end{bmatrix} \in \mathbb{R}^{n \times p}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}.$$

La fila i de $\mathbf{X}$ y la entrada i de $\mathbf{y}$ deben referirse a la misma unidad. La forma de los arreglos es parte del contrato matemático:

- n es el número de observaciones;

- p es el número de columnas de la matriz de diseño, incluido el intercepto;
- $\phi(x_i^{\text{raw}}) \in \mathbb{R}^p$ describe la representación de una observación;
- y_i pertenece al espacio de salidas, que puede ser $\mathbb{R}$, un conjunto de clases u otro dominio.

Para el caso de Bogotá podríamos seleccionar cinco entradas:

```
features = [
    "estrato_promedio",
    "area_promedio",
    "alcobas_promedio",
    "banos_promedio",
    "parqueaderos_promedio",
]

import numpy as np

X_features = tabla[features].to_numpy()
X = np.column_stack([np.ones(len(tabla)), X_features])
y = tabla["precio_reportado"].to_numpy()

assert X.shape == (32, 6)
assert y.shape == (32,)
```

Tabla original y matriz de diseño

No toda tabla puede introducirse directamente en $\mathbb{R}^{n \times p}$. Las categorías necesitan una codificación; las fechas pueden transformarse en duraciones o componentes estacionales; el texto y las imágenes requieren una representación; los valores faltantes necesitan un tratamiento explícito.

Podemos escribir una transformación de características como

$$\phi : \mathcal{X}_{\text{raw}} \rightarrow \mathbb{R}^p, \quad \phi(x_i^{\text{raw}}) = [1 \quad \phi_1(x_i^{\text{raw}}) \quad \cdots \quad \phi_{p-1}(x_i^{\text{raw}})]^\top.$$

La matriz formada por los vectores $\phi(x_i^{\text{raw}})$ es una **matriz de diseño**. La transformación ϕ puede estar completamente fijada de antemano o contener cantidades aprendidas de los datos, como medias para estandarizar o categorías observadas. En el segundo caso, su ajuste forma parte del procedimiento estadístico y debe realizarse sin consultar observaciones reservadas.



La matriz no conserva toda la información

Al convertir una tabla a **numpy**, los valores y las dimensiones permanecen, pero pueden desaparecer nombres, unidades, identificadores y fechas. La representación numérica debe acompañarse de un diccionario y de las reglas que produjeron cada columna.

Modelo, algoritmo y resultado ajustado

En este libro un **modelo predictivo** es una familia de funciones

$$\mathcal{F} = \{f_\theta : \theta \in \Theta\}, \quad f_\theta : \mathcal{X} \longrightarrow \mathcal{Y}.$$

El vector θ identifica una función dentro de la familia. Por ejemplo, una familia lineal utiliza

$$f_\theta(x) = \phi(x)^\top \theta.$$

La primera coordenada de θ es el intercepto y las restantes son los coeficientes de las características representadas.

Un **algoritmo de ajuste** recibe datos y produce parámetros. Si lo denotamos por A , entonces

$$A(d_{\text{train}}) = \hat{\theta}.$$

La función $f_{\hat{\theta}}$ es el **modelo ajustado**. Para una entrada nueva x produce

$$\hat{y} = f_{\hat{\theta}}(x).$$

Estos objetos no deben confundirse:

Objeto	Ejemplo	Qué lo determina
familia de modelos	funciones lineales	decisión de modelación
parámetro	coeficientes θ	algoritmo y datos de ajuste
hiperparámetro	intensidad de regularización	procedimiento de selección
modelo ajustado	$f_{\hat{\theta}}$	familia, algoritmo y muestra
predicción	$f_{\hat{\theta}}(x)$	modelo ajustado y entrada nueva

Un hiperparámetro controla la familia o el algoritmo, pero no se obtiene en el ajuste ordinario de parámetros. Su elección también utiliza datos y, por tanto, debe incluirse al describir el procedimiento completo.

Ajustar y aplicar son operaciones distintas

Durante el ajuste,

$$d_{\text{train}} \mapsto \hat{\theta}.$$

Durante la aplicación,

$$x_{\text{nuevo}} \mapsto f_{\hat{\theta}}(x_{\text{nuevo}}),$$

con $\hat{\theta}$ ya fijado. Esta distinción permite preguntar qué información estaba disponible en cada momento. Si una variable solo se conoce después del resultado, no puede formar parte de x_{nuevo} en un sistema que intenta anticiparlo.

Un primer experimento computacional

El conjunto `load_wine` de `scikit-learn` contiene 178 análisis químicos y una etiqueta con tres clases. No será uno de los casos conductores del libro; se usa aquí porque está disponible sin conexión y permite observar completo un primer ajuste. Antes de elegir un modelo, los conteos de clase ya definen una regla de comparación.




Figura 2: La clase mayoritaria contiene 71 de las 178 observaciones de Wine y define un baseline de clasificación antes de ajustar un modelo.

La regla que siempre anuncia la clase 1 alcanza $\text{accuracy } 71/178 \approx 0.399$ si se calcula sobre la tabla completa. En una evaluación correcta, la clase mayoritaria se determina solo con los datos de ajuste. Con una partición fijada de 133 observaciones para ajuste y 45 para prueba, un pipeline con

escalamiento y regresión logística acierta 44 casos. La matriz de confusión localiza el error que la cifra 44/45 no muestra.




Figura 3: La matriz de confusión del primer modelo contiene 44 aciertos y un único error: una observación de clase 1 fue predicha como clase 2.

Este experimento separa cuatro objetos: la tabla observada, la regla baseline, el algoritmo que ajusta parámetros y el resultado sobre casos reservados. Todavía no explica por qué funciona la regresión logística ni cuánto variaría la métrica con otra muestra. Esas preguntas requieren la formulación probabilística de los capítulos siguientes.

Disponibilidad temporal y filtración de información

Para cada variable predictora conviene registrar un tiempo de disponibilidad. Si t_0 es el momento de predicción, una entrada válida debe estar disponible en t_0 bajo las condiciones reales de uso.

Filtración de información. Hay filtración, o *data leakage*, cuando el procedimiento utiliza para ajustar, seleccionar o representar un caso información que no estaría disponible en el momento de uso o que pertenece a observaciones reservadas para evaluación.

Ejemplos frecuentes son:

- predecir hospitalización con un código registrado al dar de alta;
- predecir fraude con el resultado de la investigación posterior;
- calcular una media de estandarización con toda la tabla antes de separar datos;

- imputar faltantes utilizando observaciones reservadas;
- permitir que registros de una misma persona aparezcan a ambos lados de una partición que pretende evaluar personas nuevas.

Una transformación determinista fijada de antemano, como elevar una medición al cuadrado, no consulta otras filas. En cambio, una transformación que estima medias, categorías, componentes principales o variables seleccionadas aprende de la muestra y debe tratarse como parte del algoritmo *A*.

Calidad de datos como propiedad de la pregunta

La calidad no es una propiedad absoluta del archivo. Una columna puede ser suficiente para una descripción agregada e insuficiente para una predicción individual. Por eso la revisión debe relacionarse con la pregunta.

Dimensión	Pregunta de revisión
cobertura	¿qué unidades de la población no podían aparecer?
selección	¿por qué unas unidades quedaron incluidas y otras no?
medición	¿qué se midió y con qué precisión?
completitud	¿qué valores faltan y por qué?
unicidad	¿hay duplicados o registros repetidos legítimos?
consistencia	¿las definiciones se mantienen entre fuentes y periodos?
temporalidad	¿cada variable estaba disponible al producir la salida?
granularidad	¿la unidad registrada coincide con la unidad de la pregunta?
trazabilidad	¿puede reconstruirse la transformación desde la fuente?

La revisión establece qué afirmaciones admite un conjunto de datos para la pregunta formulada y cuáles requerirían información diferente.

Análisis completo del caso de Bogotá

Podemos ahora describir el ejemplo sin atribuirle información que no contiene.

Unidad de observación. Una subzona de Bogotá resumida por la fuente.

Nivel de agregación. Cada fila contiene promedios o indicadores de la subzona; no hay registros de viviendas individuales.

Muestra disponible. Un subconjunto congelado de 32 subzonas. El archivo del libro conserva la fuente y las transformaciones en un manifiesto, pero no completa la unidad ausente de `precio_reportado`.

Pregunta descriptiva admisible. Comparar los valores registrados y las asociaciones entre columnas dentro de las 32 subzonas.

Pregunta predictiva posible. Estudiar si los promedios disponibles contienen información para anticipar `precio_reportado` en subzonas comparables, declarando que el tamaño es pequeño y que la población de uso debe justificarse.

Afirmaciones no sustentadas. Valorar una vivienda, interpretar el coeficiente como efecto causal, asignar una unidad al indicador o generalizar automáticamente a todos los proyectos de la ciudad.

El archivo puede inspeccionarse con:

```
import pandas as pd

ruta = "datos/vivienda_nueva_bogota_subzonas.csv"
tabla = pd.read_csv(ruta)

print(tabla.shape)
print(tabla.dtypes)
print(tabla.isna().sum())
print(tabla.head())
```

Estas operaciones verifican forma, tipos computacionales y faltantes. No verifican por sí solas la interpretación. Para ello siguen siendo necesarios la ficha de la fuente, el diccionario de datos y el análisis de la unidad de observación.

Una ficha mínima para iniciar un análisis

Antes de ajustar un modelo resulta útil escribir una ficha breve:

1. **Fuente y versión:** procedencia, fecha de descarga y licencia.
2. **Unidad de observación:** qué representa una fila y cómo se identifica.
3. **Población objetivo:** dónde y cuándo se quiere aplicar la conclusión.
4. **Marco y selección:** qué unidades podían aparecer y cómo fueron incluidas.
5. **Variables:** significado, dominio, unidad y tiempo de disponibilidad.
6. **Pregunta:** descriptiva, predictiva o causal; salida y uso previsto.
7. **Representación:** cómo se transformará la tabla en objetos matemáticos.
8. **Limitaciones iniciales:** información ausente, agregación, medición y posibles dependencias.

Esta ficha no reemplaza el análisis exploratorio. Evita que el análisis comience con objetos mal definidos y ofrece un punto de referencia cuando cambian las decisiones de modelación.

Síntesis

Una fila representa una unidad registrada mediante un procedimiento concreto. La unidad puede diferir de aquella sobre la que se desea concluir, especialmente en datos repetidos o agregados. Una columna representa valores observados de una variable, pero su nombre y su tipo computacional no sustituyen la definición, la unidad ni el mecanismo de medición.

La muestra disponible procede de un marco de observación y este puede diferir de la población objetivo. Cobertura, selección, medición y tiempo determinan el alcance de los datos. Una pregunta descriptiva resume lo observado; una pregunta predictiva anticipa una salida para casos de uso definidos; una pregunta causal compara intervenciones y requiere supuestos adicionales.

La traducción matemática organiza los registros como $d_n = (z_1, \dots, z_n)$ y, en un problema supervisado, como pares (x_i, y_i) . Una familia de modelos $\{f_\theta\}$, un algoritmo de ajuste A y un modelo ajustado $f_{\hat{\theta}}$ son objetos diferentes. Esta separación será esencial cuando la muestra misma se represente como aleatoria y se estudie la variación de los resultados obtenidos a partir de ella.

Problemas integrados

Registros, unidades y poblaciones

Los primeros ocho problemas utilizan distintos sistemas de registro. En cada caso debe identificarse la unidad antes de proponer cálculos o modelos.

1. Un archivo de transporte contiene una fila por validación de tarjeta. Proponga una pregunta cuya unidad de análisis sea la validación y otra cuya unidad sea la persona. ¿Qué identificadores necesitaría para la segunda?
2. Explique por qué 32 promedios de subzona no equivalen a 32 mediciones de viviendas. Construya dos conjuntos de valores individuales con el mismo promedio y distinta variación.
3. Dé un ejemplo en el que el tipo `int` de una columna no corresponda a una variable cuantitativa. Indique qué operaciones carecerían de sentido.
4. Distinga población objetivo, marco de observación y muestra en una encuesta enviada por correo institucional a estudiantes matriculados.
5. Explique por qué un censo de todas las ventas realizadas durante un mes puede seguir siendo insuficiente para una pregunta sobre ventas del año siguiente.
6. Formule sobre un mismo conjunto de datos una pregunta descriptiva, una predictiva y una causal. Identifique qué información adicional exige cada una.
7. ¿Por qué el papel de “variable objetivo” no es una propiedad permanente de una columna?
8. Distinga familia de modelos, algoritmo de ajuste, parámetro, hiperparámetro y predicción mediante un ejemplo de regresión.

De la tabla a una representación

En esta secuencia, además del resultado numérico, debe explicarse qué información conserva la representación y qué interpretación no puede recuperarse de ella.

9. Una tabla contiene 240 pacientes, 12 variables numéricas, 3 variables categóricas y una salida binaria. Si cada variable categórica se codifica con 4 columnas indicadoras, ¿cuál es la dimensión de la matriz de diseño sin contar intercepto? Declare cualquier supuesto necesario.
10. Escriba explícitamente la matriz de características sin intercepto y el vector de respuestas para las observaciones $(x_1, y_1) = ((1, 2), 5)$, $(x_2, y_2) = ((0, 3), 4)$ y $(x_3, y_3) = ((-1, 1), 0)$. Indique las dimensiones.
11. Una tabla registra 800 visitas de 300 pacientes. Explique por qué una partición de filas puede colocar información de un mismo paciente en ajuste y evaluación. Proponga una unidad apropiada para formar los grupos.
12. Para una variable de fecha t , proponga una transformación $\phi(t)$ que represente mes y día de la semana. Indique qué información se conserva y cuál se pierde.
13. Considere $f_\theta(x) = \theta_0 + x^\top \theta_{1:5}$ con $x \in \mathbb{R}^5$. ¿Cuántos parámetros escalares tiene el modelo? ¿Cambia ese número si hay 32 o 3200 observaciones?
14. Una variable se expresa primero en metros y luego en centímetros. Explique cómo cambia su columna y por qué la realidad medida no cambia. Anticipe qué ocurriría con el coeficiente de una regresión lineal que utiliza esa variable.

Auditoría de datos y código

Estas tareas deben resolverse como una auditoría breve: comprobación reproducible, hallazgo e implicación para el análisis.

15. Cargue el CSV de Bogotá. Verifique forma, nombres, tipos y faltantes. Produzca un diccionario de datos en una tabla separada; no complete unidades que la fuente no documenta.
16. Busque duplicados en `subzona`. Explique qué significaría encontrar uno y qué información necesitaría antes de eliminarlo.
17. Escriba una función que reciba una tabla, una lista de predictores y una salida, y verifique que las columnas existen, que la salida no está entre los predictores y que X y y tienen el mismo número de filas.
18. Con `load_wine`, identifique unidad de observación, salida, número de entradas y dominio de cada tipo de variable. Formule dos preguntas distintas que usen la misma tabla.
19. Construya un ejemplo pequeño donde una categoría nueva aparezca después de haber definido una codificación. Explique por qué la transformación debe especificar cómo tratar categorías desconocidas.

Formulación de un estudio

Cada respuesta debe terminar con una conclusión admisible y una afirmación que los datos descritos todavía no permitirían sostener.

20. Un hospital quiere predecir reingreso a 30 días. Para cada una de estas variables, determine si estaría disponible al momento del alta: diagnóstico inicial, medicación de alta, número de llamadas posteriores y código del reingreso. Justifique.
21. Una aplicación recoge datos solo de usuarios que aceptan compartir su ubicación. Describa la población objetivo, el marco observado y una posible diferencia sistemática entre usuarios incluidos y excluidos.
22. Redacte una pregunta predictiva completa para un problema de su interés. Debe indicar unidad, salida, momento, información disponible y población de uso.
23. Para el caso de Bogotá, escriba dos conclusiones admisibles y dos conclusiones que excedan la información disponible. Señale exactamente qué dato o supuesto falta en cada caso.
24. Prepare la ficha mínima de un conjunto de datos que considere para un proyecto. Identifique al menos una limitación de cobertura, una de medición y una de temporalidad.

Respuestas seleccionadas

2. Los conjuntos (80,120) y (99,101) tienen promedio 100, pero el primero presenta mucha mayor dispersión. El promedio no permite reconstruir la distribución interna de una subzona.

4. La población objetivo podría ser todo el estudiantado sobre el que se desea concluir. El marco contiene estudiantes matriculados con correo institucional activo. La muestra observada contiene quienes recibieron y respondieron la encuesta. Cada transición puede excluir unidades diferentes.

9. Bajo el supuesto de cuatro columnas por cada una de las tres variables categóricas, la dimensión es $240 \times (12 + 3 \cdot 4) = 240 \times 24$. Si se elimina una categoría de referencia por variable, la dimensión cambia a 240×21 .

10.

$$\mathbf{X}_{\text{features}} = \begin{bmatrix} 1 & 2 \\ 0 & 3 \\ -1 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 2}, \quad y = \begin{bmatrix} 5 \\ 4 \\ 0 \end{bmatrix} \in \mathbb{R}^3.$$

13. El intercepto aporta un parámetro y $\beta \in \mathbb{R}^5$ aporta cinco; hay seis parámetros escalares. El número no depende del tamaño de muestra, aunque la información disponible para estimarlos sí cambia.

20. El diagnóstico inicial y la medicación de alta pueden estar disponibles al alta si el sistema los registra a tiempo. Las llamadas posteriores y el código de reingreso ocurren después y producirían filtración para una predicción realizada al alta.

Variables aleatorias, distribuciones y muestras

Cómo describir la variación antes y después de observar los datos

El archivo sintético de regresión del libro contiene 160 filas generadas con una semilla fija. En esa población, el promedio de `target` es 4.121. Si elegimos doce filas sin reemplazo, el promedio depende de cuáles hayan sido seleccionadas. Cuatro selecciones posibles producen:

selección	tamaño	promedio de <code>target</code>
1	12	2.916
2	12	4.600
3	12	4.467
4	12	4.065

No hay contradicción entre esos cuatro números. Cada uno resume una muestra distinta de la misma población. Antes de seleccionar las filas no sabemos cuál de esos promedios, ni cuál de muchos otros, obtendremos. Después de observar la muestra aparece un valor concreto.

Esta diferencia entre lo posible antes de observar y lo registrado después es el punto de entrada a la probabilidad. En los capítulos posteriores cambiarán los objetos calculados: en lugar de un promedio tendremos coeficientes, pérdidas o métricas. La fuente de variación será la misma: otra muestra puede producir otro resultado.

Antes y después de observar

Consideremos una unidad escogida de una población y la cantidad `target` que registraríamos. Antes de escogerla representamos esa cantidad mediante una variable aleatoria Y . Después de observar la unidad obtenemos una realización y .

Variable aleatoria y realización. Una variable aleatoria real es una función

$$Y : \Omega \longrightarrow \mathbb{R}$$

que asigna un valor numérico a cada resultado posible. Si ocurre el resultado ω_i , el valor observado es $y_i = Y(\omega_i)$.

La función Y no cambia al repetir el procedimiento; cambia el resultado ω_i al que se aplica. Por convención, las mayúsculas representan variables aleatorias y las minúsculas sus realizaciones. Una

columna $\mathbf{y} = (y_1, \dots, y_n)^\top$ contiene valores observados; Y representa la cantidad antes de observar una unidad nueva.

Si cada unidad tiene varias características, usamos un vector aleatorio

$$\mathbf{X} = (X_1, \dots, X_d) \in \mathbb{R}^d.$$

Una fila de un problema supervisado es una realización

$$\mathbf{z}_i = (x_i, y_i)$$

del par aleatorio $Z = (X, Y)$. La negrita distingue el predictor aleatorio de la matriz de diseño $\mathbf{X}$ que construiremos con varias filas.

Eventos y una formulación probabilística

Un modelo probabilístico se expresa mediante una terna

$$(\Omega, \mathcal{F}, \mathbb{P}).$$

El espacio Ω contiene los resultados posibles; $\mathcal{F}$ contiene los eventos a los que se asignará probabilidad; y $\mathbb{P}$ satisface no negatividad, $\mathbb{P}(\Omega) = 1$ y aditividad numerable sobre eventos disjuntos. Estas condiciones permiten calcular probabilidades de afirmaciones como $Y \leq 4$ o $X_1 > 0$.

No necesitaremos construir $\mathcal{F}$ en cada ejemplo. Su presencia aclara, sin embargo, que la probabilidad pertenece a resultados posibles antes de observarlos. El valor 4.242557 de una fila concreta ya no tiene una probabilidad por estimar: es una realización registrada.

La distribución

La distribución de Y describe con qué probabilidad aparece cada región de valores. Para un conjunto $B \subseteq \mathbb{R}$, escribimos

$$P_Y(B) = \mathbb{P}(Y \in B).$$

La función de distribución acumulada

$$F_Y(t) = \mathbb{P}(Y \leq t)$$

existe para toda variable aleatoria real y determina su distribución. Si Y es discreta, puede describirse mediante una función de masa

$$p_Y(y) = \mathbb{P}(Y = y), \quad \sum_y p_Y(y) = 1.$$

Si Y es continua y posee densidad f_Y , las probabilidades se obtienen integrando:

$$\mathbb{P}(a < Y \leq b) = \int_a^b f_Y(y) dy.$$

Una densidad puede tomar valores mayores que uno; lo que debe estar entre cero y uno es el área integrada sobre un conjunto. Para una variable continua usual, $\mathbb{P}(Y = y) = 0$ en cada punto aislado aunque los intervalos tengan probabilidad positiva.

Dos distribuciones que reaparecerán

Una variable Bernoulli con parámetro p toma valores 0 y 1:

$$\mathbb{P}(Y = 1) = p, \quad \mathbb{P}(Y = 0) = 1 - p.$$

Se utilizará para representar una clase binaria y también para representar si una predicción fue correcta. Una variable normal

$$Y \sim \mathcal{N}(\mu, \sigma^2)$$

es continua, simétrica alrededor de μ y está determinada por su media y su varianza. Será útil como modelo y como aproximación de ciertas distribuciones muestrales, pero no debe adoptarse por costumbre: valores extremos, asimetría o restricciones del dominio pueden contradecirla.

Esperanza y variación

La esperanza resume el promedio definido por una distribución. Para una variable discreta,

$$\mathbb{E}[Y] = \sum_y y p_Y(y),$$

y, para una variable continua con densidad,

$$\mathbb{E}[Y] = \int_{-\infty}^{\infty} y f_Y(y) dy,$$

si la integral existe. La esperanza no tiene que ser un valor que Y pueda tomar. Una variable Bernoulli solo toma 0 y 1, pero su esperanza es p .

La esperanza es lineal. Si las cantidades involucradas son integrables,

$$\mathbb{E}[aY + bW + c] = a\mathbb{E}[Y] + b\mathbb{E}[W] + c,$$

sin necesidad de independencia. Esta propiedad permitirá convertir un promedio de pérdidas observadas en un estimador de una pérdida esperada.

La varianza mide dispersión cuadrática alrededor de la media:

$$\text{Var}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \mathbb{E}[Y^2] - \mathbb{E}[Y]^2.$$

Su raíz cuadrada es la desviación estándar. Dos distribuciones pueden tener la misma media y la misma varianza y ser muy diferentes; estos momentos son resúmenes, no descripciones completas.

Distribuciones conjuntas, independencia y covarianza

El par (X_1, X_2) posee una distribución conjunta. De ella se obtienen las distribuciones marginales de cada componente. Decir que X_1 y X_2 son independientes significa que, para conjuntos apropiados A y B ,

$$\mathbb{P}(X_1 \in A, X_2 \in B) = \mathbb{P}(X_1 \in A)\mathbb{P}(X_2 \in B).$$

La covarianza mide asociación lineal:

$$\text{Cov}(X_1, X_2) = \mathbb{E}[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])].$$

Si las variables tienen desviaciones estándar positivas, su correlación es

$$\text{Corr}(X_1, X_2) = \frac{\text{Cov}(X_1, X_2)}{\text{sd}(X_1)\text{sd}(X_2)}.$$

La independencia implica covarianza cero cuando existen segundos momentos. La conversas es falsa: una relación no lineal puede tener covarianza cero. Tampoco la covarianza distingue causalidad de asociación.

Para un vector aleatorio $X \in \mathbb{R}^d$, la matriz de covarianza

$$\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^\top], \quad \mu = \mathbb{E}[X],$$

reúne varianzas en la diagonal y covarianzas fuera de ella. Más adelante, PCA buscará direcciones determinadas por esta estructura.

En la población sintética de regresión, $\mathbf{x}_2$ fue construido a partir de $\mathbf{x}_1$ más ruido. Por ello ambas variables están asociadas. El hecho de conocer el mecanismo generador permite explicar esa asociación. En un dataset observacional, una covarianza por sí sola no revelaría el mecanismo.

De la población a una muestra

Representamos una muestra aleatoria de tamaño n mediante

$$D_n = (Z_1, \dots, Z_n).$$

Antes de observarla, D_n es aleatoria. Después obtenemos la realización

$$d_n = (z_1, \dots, z_n),$$

que puede almacenarse como una tabla. Escribir

$$Z_1, \dots, Z_n \stackrel{\text{iid}}{\sim} P$$

afirma dos cosas: las observaciones son independientes y todas tienen la misma distribución P . No es una propiedad del formato CSV; es un supuesto sobre el procedimiento que produjo las filas.

Mediciones repetidas de una persona, observaciones sucesivas de una serie y estudiantes dentro de un mismo colegio pueden depender entre sí. Una recolección que excluye sistemáticamente parte de la población puede producir observaciones con una distribución distinta de la población objetivo. En cualquiera de esos casos, la notación iid requiere modificación o una justificación limitada.

El caso de las subzonas de Bogotá

Las 32 subzonas del capítulo anterior no están documentadas como una muestra aleatoria de todas las subzonas, de todos los proyectos ni de las viviendas de Bogotá. Cada fila es además un resumen agregado. Podemos describir la distribución empírica de sus columnas, pero no convertirla automáticamente en una distribución poblacional de viviendas.

Esta distinción permanecería aunque el archivo tuviera 3200 subzonas. Un tamaño grande reduce algunas formas de variación muestral bajo un diseño apropiado; no repara una unidad equivocada ni un mecanismo de selección desconocido.

Distribución empírica y estadísticos

La distribución empírica asigna masa $1/n$ a cada observación:

$$\hat{P}_n = \frac{1}{n} \sum_{i=1}^n \delta_{z_i}.$$

Para una variable numérica, su función de distribución empírica es

$$\hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{y_i \leq t\}.$$

La media y la varianza empíricas son

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad s_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2.$$

La primera aproxima una esperanza bajo condiciones de muestreo. La segunda usa $n - 1$ para estimar la varianza poblacional sin sesgo bajo el modelo iid con segundo momento finito.

Estadístico. Un estadístico es una función de la muestra que no depende de cantidades poblacionales desconocidas:

$$T_n = T(D_n).$$

Como D_n es aleatoria, T_n también lo es. Su distribución bajo repetición del muestreo se llama distribución muestral. Después de observar d_n , el estadístico toma el valor $t_n = T(d_n)$. Los cuatro promedios que abrieron el capítulo son cuatro realizaciones del mismo estadístico.

Por qué se estabiliza un promedio

Supongamos que $Y_1, \dots, Y_n$ son iid, con media μ y varianza $\sigma^2 < \infty$. Entonces

$$\mathbb{E}[\bar{Y}_n] = \mu$$

y, por independencia,

$$\text{Var}(\bar{Y}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{\sigma^2}{n}.$$

La desviación estándar del promedio decrece como $1/\sqrt{n}$. Para reducirla a la mitad se necesita, bajo estos supuestos, multiplicar el tamaño por cuatro.

Ley de los grandes números. Si $Y_1, Y_2, \dots$ son iid y tienen esperanza finita, entonces

$$\bar{Y}_n \xrightarrow{\mathbb{P}} \mathbb{E}[Y].$$

La ley justifica aproximar una esperanza mediante un promedio cuando el modelo de muestreo es apropiado. No corrige sesgo de selección, dependencia, errores de medición ni cambio de población.

El siguiente experimento repite el cálculo que abrió el capítulo:

```
import numpy as np
import pandas as pd

tabla = pd.read_csv("datos/regresion_lineal_sintetica.csv")

for n in [8, 20, 80]:
    medias = [
        tabla.sample(n=n, replace=True, random_state=2105 + b)["target"].mean()
        for b in range(1000)
    ]
    print(n, np.mean(medias), np.std(medias, ddof=1))
```

Al aumentar n , las medias simuladas se concentran alrededor del promedio de la población sintética. La simulación ilustra la proposición; no demuestra que las 32 subzonas de Bogotá sean iid.

Síntesis

Una variable aleatoria representa una cantidad antes de observarla y una realización es el valor registrado. Su distribución describe las posibilidades; la esperanza, la varianza y la covarianza resumen aspectos de esa distribución.

Una muestra aleatoria también es un objeto aleatorio. Por ello cambian sus promedios, covarianzas, coeficientes ajustados y métricas. La distribución empírica describe la tabla disponible; conectarla con una población exige un supuesto sobre muestreo o sobre el proceso que genera nuevas observaciones.

La ley de los grandes números explica por qué un promedio puede estabilizarse. Su conclusión depende de las condiciones del muestreo y no convierte un archivo grande en una muestra representativa.

Problemas integrados

1. Muestras de una población conocida

Use `regresion_lineal_sintetica.csv` como una población finita.

1. Calcule la media, varianza y cuartiles de `target` en las 160 filas.
2. Extraiga 500 muestras con reemplazo para cada tamaño $n \in \{8, 20, 80\}$ y calcule sus medias.
3. Compare la media y la desviación estándar de las tres distribuciones muestrales con $\sigma/\sqrt{n}$.
4. Repita el experimento con la mediana. Explique qué parte del argumento de la varianza del promedio ya no puede reutilizarse directamente.
5. Escriba una conclusión que distinga la población sintética, una muestra y el estadístico calculado.

2. Qué distribución describen las subzonas

Use `vivienda_nueva_bogota_subzonas.csv`.

1. Construya la distribución empírica de `area_promedio` y reporte media, desviación estándar y mediana.
2. Identifique la unidad de observación y explique por qué esos resúmenes no son la distribución de áreas de viviendas individuales.
3. Escriba una población respecto a la cual el promedio tendría sentido y la información de muestreo que faltaría para justificarla.
4. Describa una posible dependencia entre subzonas que haría dudosa la independencia.
5. Redacte una conclusión descriptiva admisible y una generalización que el archivo no permite.

3. Bernoulli, indicadores y promedios

Sea $Y_i \sim \text{Bernoulli}(0.3)$.

1. Demuestre que $\mathbb{E}[Y_i] = 0.3$ y $\text{Var}(Y_i) = 0.3(0.7)$.
2. Interprete $\bar{Y}_n$ como una proporción.
3. Calcule la desviación estándar teórica de esa proporción para $n = 25, 100, 400$.
4. Verifique los tres valores mediante 5000 simulaciones.
5. Explique por qué la concordancia con la teoría no prueba que una proporción observada en datos reales provenga de ensayos iid.

4. Covarianza no significa independencia

Sea X uniforme en $\{-1, 0, 1\}$ y $Y = X^2$.

1. Escriba la distribución conjunta de (X, Y) .
2. Calcule $\mathbb{E}[X]$, $\mathbb{E}[Y]$ y $\text{Cov}(X, Y)$.
3. Muestre que la covarianza es cero.
4. Pruebe que X y Y no son independientes.
5. Explique qué advertencia ofrece este ejemplo al interpretar una matriz de correlaciones antes de ajustar un modelo.

Respuestas seleccionadas

Problema 3. Como $Y_i^2 = Y_i$,

$$\mathbb{E}[Y_i] = 0.3, \quad \text{Var}(Y_i) = 0.3 - 0.3^2 = 0.21.$$

Por tanto,

$$\text{sd}(\bar{Y}_n) = \sqrt{0.21/n},$$

que vale aproximadamente 0.0917, 0.0458 y 0.0229 para los tres tamaños.

Problema 4. Se tiene $\mathbb{E}[X] = 0$, $\mathbb{E}[XY] = \mathbb{E}[X^3] = 0$, luego la covarianza es cero. Sin embargo, Y queda determinado por X ; por ejemplo, $\mathbb{P}(Y = 0 \mid X = 0) = 1 \neq \mathbb{P}(Y = 0) = 1/3$. No son independientes.

Condicionamiento, estimación y riesgo

Qué aprende un modelo de una muestra y qué cantidad intenta aproximar

El conjunto sintético de regresión contiene 160 observaciones. Como conocemos el mecanismo que lo produjo, podemos tratar esas filas como una población finita y comparar dos reglas de predicción. La primera ignora las entradas y asigna a toda observación el promedio de `target`, que es 4.121. Su error cuadrático medio en la población es 5.277. La segunda utiliza la función con la que se generaron los datos,

$$m(x) = 4 + 2.5x_1 - 1.2x_2 + 0.7x_3.$$

Su error cuadrático medio es 0.289. La diferencia no proviene de que el segundo número haya sido calculado con más filas: ambas reglas se evaluaron sobre las mismas 160 observaciones. Proviene de usar información sobre $X = (X_1, X_2, X_3)$ para describir cómo cambia Y .

En datos reales no conocemos de antemano la función m . Tenemos una muestra y un procedimiento que produce una aproximación. Para entender qué significa ese ajuste debemos separar tres niveles: la distribución poblacional, el estimador que actúa sobre una muestra y el valor concreto obtenido con los datos observados. El condicionamiento y el riesgo permiten expresar esa separación.

Lo que cambia al conocer las entradas

Si A y B son eventos con $\mathbb{P}(B) > 0$, la probabilidad condicional de A dado B es

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

El denominador restringe el espacio de comparación a los resultados compatibles con B . Por ejemplo, una proporción calculada entre observaciones con $X_1 > 0$ aproxima una cantidad diferente de la proporción calculada en toda la población.

De esta definición se obtiene la regla del producto,

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B)\mathbb{P}(B),$$

y, si $B_1, \dots, B_K$ forman una partición del espacio, la ley de probabilidad total,

$$\mathbb{P}(A) = \sum_{k=1}^K \mathbb{P}(A | B_k) \mathbb{P}(B_k).$$

Estas identidades distinguen la frecuencia de un resultado dentro de cada grupo de la frecuencia con la que los grupos aparecen en la población.

Una prueba en una población de baja prevalencia. Supongamos que una condición está presente en el 1 % de una población. Una prueba resulta positiva en el 95 % de quienes tienen la condición y en el 5 % de quienes no la tienen. La fórmula de Bayes da

$$\mathbb{P}(C | +) = \frac{0.95(0.01)}{0.95(0.01) + 0.05(0.99)} \approx 0.161.$$

La sensibilidad de 0.95 no es la probabilidad de tener la condición después de un resultado positivo. La prevalencia también interviene.

Distribuciones y esperanzas condicionales

Para variables discretas X y Y , la distribución condicional puede escribirse como

$$p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}, \quad p_X(x) > 0.$$

Si las variables poseen densidades, la razón correspondiente es

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}, \quad f_X(x) > 0.$$

Cuando X es continua, normalmente $\mathbb{P}(X = x) = 0$. La densidad condicional no se obtiene dividiendo por esa probabilidad puntual. En lo que sigue suponemos que existe una versión de la distribución condicional para los valores de interés.

Esperanza condicional. Si Y es integrable, la esperanza condicional de Y dado X se representa por

$$\mathbb{E}[Y | X].$$

En condiciones usuales es una función de X . Escribimos

$$m(x) = \mathbb{E}[Y | X = x]$$

para la función de regresión poblacional.

La palabra *regresión* no implica aquí que m sea lineal. La linealidad será una restricción de la familia de funciones con la que intentaremos aproximarla.

Dos identidades sitúan la media condicional dentro de la distribución conjunta. La ley de la esperanza total establece

$$\mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[Y],$$

y, si existe el segundo momento, la ley de la varianza total afirma

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$

El primer término mide la variación promedio que permanece al fijar las entradas. El segundo mide cuánto cambian las medias condicionales entre entradas. La identidad es probabilística; no convierte una asociación en una explicación causal.

Por qué aparece la media condicional en regresión

La comparación inicial entre el promedio y $m(x)$ puede formularse como un problema de optimización poblacional.

La media condicional minimiza la pérdida cuadrática. Si Y y $g(X)$ tienen segundo momento finito, entonces

$$\begin{aligned} \mathbb{E}[(Y - g(X))^2 | X] &= \text{Var}(Y | X) \\ &\quad + (\mathbb{E}[Y | X] - g(X))^2. \end{aligned}$$

Por tanto, $g^*(x) = m(x)$ minimiza el error cuadrático esperado entre todas las funciones admisibles.

Se suma y resta $m(X)$:

$$Y - g(X) = Y - m(X) + m(X) - g(X).$$

Al elevar al cuadrado y condicionar en X , el término cruzado tiene esperanza cero porque

$$\mathbb{E}[Y - m(X) | X] = 0.$$

Quedan la varianza condicional y un cuadrado no negativo. Este último se anula cuando $g(X) = m(X)$.

En la población sintética,

$$Y = m(X) + \varepsilon, \quad \mathbb{E}[\varepsilon | X] = 0.$$

El MSE 0.289 de la regla conocida no es un fallo del algoritmo: refleja la variación de ε que permanece incluso al conocer las entradas. El MSE 5.277 del promedio mezcla esa variación con las diferencias sistemáticas entre medias condicionales.

El análogo binario

Si $Y \in \{0, 1\}$, la media condicional coincide con una probabilidad:

$$\eta(x) = \mathbb{E}[Y \mid X = x] = \mathbb{P}(Y = 1 \mid X = x).$$

Una predicción probabilística $q \in (0, 1)$ puede evaluarse mediante la pérdida logarítmica

$$\ell(q, y) = -y \log q - (1 - y) \log(1 - q).$$

Condicionado en $X = x$, su esperanza es

$$L_x(q) = -\eta(x) \log q - (1 - \eta(x)) \log(1 - q).$$

Su derivada se anula únicamente en $q = \eta(x)$ y la segunda derivada es positiva. Así, la probabilidad condicional es también el objetivo poblacional natural de la log-loss. Una regla de clasificación requiere además un umbral y una descripción de los costos de los dos tipos de error; esa decisión se estudiará en el capítulo de regresión logística.

De la cantidad poblacional al valor calculado

El promedio de **target**, un coeficiente de regresión y el riesgo de una regla no son objetos del mismo tipo. Para distinguirlos conviene reservar tres palabras.

Estimando, estimador y estimación. Un *estimando* es una cantidad definida por la población, por ejemplo $\mu = \mathbb{E}[Y]$ o un parámetro θ^* que minimiza un riesgo. Un *estimador* es una función de la muestra, como

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Una *estimación* es el valor que toma el estimador después de observar los datos, por ejemplo $\hat{\mu}_n = 4.600$ en una muestra particular.

Antes de observar $D_n = (Z_1, \dots, Z_n)$, el estimador $\hat{\mu}_n(D_n)$ es aleatorio. Repetir el muestreo produce una distribución muestral. Esa distribución describe la variación del procedimiento, no la distribución de los valores individuales de Y .

En regresión lineal, el estimando puede definirse sin suponer que la media condicional sea exactamente lineal:

$$\theta^* \in \arg \min_{\theta \in \mathbb{R}^p} \mathbb{E} \left[\frac{1}{2} (Y - \phi(X)^\top \theta)^2 \right],$$

donde $\phi(X)$ incluye el intercepto y las características utilizadas. El estimador de mínimos cuadrados reemplaza la esperanza por un promedio de muestra. El capítulo siguiente derivará su forma.

Sesgo, varianza y error cuadrático medio

Sea T un estimando escalar y $\hat{T}_n$ un estimador. Su sesgo es

$$\text{Bias}(\hat{T}_n; T) = \mathbb{E}[\hat{T}_n] - T.$$

El error cuadrático medio del estimador se descompone como

$$\mathbb{E}[(\hat{T}_n - T)^2] = \text{Var}(\hat{T}_n) + \text{Bias}(\hat{T}_n; T)^2.$$

Esta igualdad se obtiene escribiendo $\hat{T}_n - T = (\hat{T}_n - \mathbb{E}[\hat{T}_n]) + (\mathbb{E}[\hat{T}_n] - T)$ y observando que el término cruzado tiene esperanza cero.

Un estimador insesgado puede variar demasiado para ser útil, y un estimador con un sesgo pequeño puede tener menor error cuadrático medio. Esta tensión reaparece con Ridge y Lasso: se introduce sesgo para reducir la sensibilidad del ajuste a la muestra.

Estabilidad no equivale a pertinencia. Un estimador puede producir valores muy semejantes en muestras repetidas y, aun así, estimar una cantidad distinta de la pregunta sustantiva. Promediar `precio_reportado` en las 32 subzonas es un cálculo estable si se repite sobre las mismas filas; no estima por ello el precio medio de una vivienda en Bogotá. La unidad y el mecanismo de selección definen el estimando antes de que una fórmula pueda estimarlo.

Pérdida, riesgo y aprendizaje a partir de una muestra

Una pérdida compara una acción o predicción con el resultado observado. Para una regla f y una observación $Z = (X, Y)$ escribimos

$$\ell(f; Z) = \ell(f(X), Y).$$

Riesgo esperado. El riesgo de f bajo la distribución poblacional P es

$$R_P(f) = \mathbb{E}_P[\ell(f; Z)].$$

Es una propiedad conjunta de la regla, la pérdida y la población.

El subíndice P importa. Una misma regla puede tener riesgos distintos en dos poblaciones, aun cuando su código no cambie. Cuando la distribución sea clara escribiremos simplemente $R(f)$.

Como P suele ser desconocida, calculamos el riesgo empírico

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f; z_i).$$

Para derivar mínimos cuadrados utilizaremos $\ell(f_\theta; z_i) = \frac{1}{2}(f_\theta(x_i) - y_i)^2$. Por tanto,

$$\widehat{R}_n(\theta) = \frac{1}{2n} \|\mathbf{X}\theta - \mathbf{y}\|_2^2.$$

El MSE que se reporta como métrica es

$$\text{MSE}_n(\theta) = \frac{1}{n} \|\mathbf{X}\theta - \mathbf{y}\|_2^2 = 2\widehat{R}_n(\theta).$$

El factor $1/2$ no cambia el minimizador; simplifica el gradiente. Mantener la distinción evita comparar accidentalmente pérdidas con escalas diferentes.

El riesgo empírico de una regla fija estima su riesgo esperado. Si $Z_1, \dots, Z_n$ son iid y f se elige sin utilizar esa muestra, entonces

$$\mathbb{E}[\widehat{R}_n(f)] = R(f),$$

si la pérdida es integrable.

Por linealidad de la esperanza y porque cada Z_i tiene distribución P ,

$$\mathbb{E}[\widehat{R}_n(f)] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\ell(f; Z_i)] = R(f).$$

La condición de que f sea fija es decisiva. Si el mismo conjunto de datos se usa para escoger f , la regla ajustada depende de cada Z_i . La demostración anterior ya no se aplica directamente y el error de entrenamiento puede ser optimista. Las particiones de entrenamiento, validación y prueba se introducirán cuando la selección de complejidad haga visible este conflicto.

Minimización empírica y baseline

Una familia de modelos $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$ convierte el aprendizaje en el problema

$$\widehat{\theta} \in \arg \min_{\theta \in \Theta} \widehat{R}_n(\theta).$$

El algoritmo busca un minimizador o una aproximación; los datos determinan cuál miembro de la familia resulta elegido. Cambiar la muestra puede cambiar $\widehat{\theta}$ aunque el algoritmo sea idéntico.

Un baseline es una regla sencilla que fija una comparación mínima. Bajo pérdida cuadrática, la mejor predicción constante en una muestra es $\bar{y}$. Demostrarlo requiere minimizar

$$\frac{1}{n} \sum_{i=1}^n (c - y_i)^2$$

respecto de c , cuya derivada se anula en $c = \bar{y}$. Un modelo que no mejora esta regla no ha utilizado de manera efectiva las entradas.

Cuatro muestras, cuatro ajustes

Tomemos cuatro muestras de 40 filas de la población sintética y ajustemos por mínimos cuadrados un intercepto y tres coeficientes. Los resultados son:

semilla	intercepto	coeficiente 1	coeficiente 2	coeficiente 3	MSE muestra	MSE población
11	4.069	2.487	-1.220	0.790	0.324	0.297
29	4.203	2.468	-1.025	0.717	0.334	0.344
47	4.094	2.569	-1.313	0.640	0.292	0.308
83	3.941	2.411	-1.135	0.633	0.237	0.311

La cuarta muestra obtiene el menor MSE de entrenamiento, pero no el menor MSE en la población. Los coeficientes varían porque cada ajuste es una realización del estimador. En este ejemplo podemos calcular el MSE poblacional porque conservamos las 160 filas; en una aplicación ordinaria esa cantidad permanece desconocida.

El cálculo se reproduce con:

```
import numpy as np
import pandas as pd

tabla = pd.read_csv("datos/regresion_lineal_sintetica.csv")
X_poblacion = np.column_stack(
    [np.ones(len(tabla)), tabla[["x1", "x2", "x3"]].to_numpy()]
)
y_poblacion = tabla["target"].to_numpy()

for semilla in [11, 29, 47, 83]:
    muestra = tabla.sample(n=40, replace=False, random_state=semilla)
    X = np.column_stack(
        [np.ones(len(muestra)), muestra[["x1", "x2", "x3"]].to_numpy()]
    )
    y = muestra["target"].to_numpy()
    theta = np.linalg.lstsq(X, y, rcond=None)[0]
    mse_muestra = np.mean((X @ theta - y) ** 2)
    mse_poblacion = np.mean((X_poblacion @ theta - y_poblacion) ** 2)
    print(semilla, theta, mse_muestra, mse_poblacion)
```

El ejemplo separa dos preguntas. La optimización determina qué parámetro reduce la pérdida en la muestra. La evaluación pregunta cómo se comporta la regla fuera de las observaciones utilizadas para ajustarla. El primer problema conduce a mínimos cuadrados y descenso del gradiente; el segundo, a validación y análisis de incertidumbre.

Regreso a las subzonas de Bogotá

Podríamos usar `area_promedio`, `estrato_promedio` y otras columnas para predecir `precio_reportado`, calcular residuales y comparar el resultado con el baseline de la media. El procedimiento sería matemáticamente válido para las 32 filas. Su interpretación seguiría limitada por dos hechos anteriores al ajuste:

1. una fila representa una subzona y no una vivienda;
2. la unidad de `precio_reportado` no está documentada en el recurso congelado.

Reducir el MSE describiría una asociación entre indicadores de las subzonas incluidas. No estimaría automáticamente el precio de una vivienda ni justificaría una conclusión para todas las subzonas futuras. El riesgo siempre se refiere a una distribución y a una pérdida; si la población de uso no está definida, un número de evaluación queda incompleto.

Síntesis

El condicionamiento describe cómo cambia la distribución de la respuesta cuando se conocen las entradas. Bajo pérdida cuadrática, la media condicional es la predicción poblacional óptima; para una respuesta binaria, esa misma media es la probabilidad condicional de la clase positiva.

Un estimando pertenece a la población, un estimador actúa sobre una muestra y una estimación es el valor observado. La variación entre muestras se transmite a los coeficientes y a las predicciones. El riesgo esperado expresa el objetivo poblacional y el riesgo empírico proporciona una cantidad calculable. Ambos solo coinciden de manera controlada bajo supuestos sobre el muestreo y sobre cómo se eligió la regla.

El capítulo siguiente comenzará con los residuales de una regresión de una sola variable. Allí el riesgo empírico cuadrático se convertirá en una función explícita de θ y podremos derivar el algoritmo de mínimos cuadrados.

Problemas integrados

1. De un baseline a una función condicional

Use `regresion_lineal_sintetica.csv` como población finita.

1. Calcule el promedio de `target` y el MSE del predictor constante.
2. Calcule las predicciones de $m(x) = 4 + 2.5x_1 - 1.2x_2 + 0.7x_3$ y su MSE.
3. Use la descomposición de varianza total para explicar conceptualmente la diferencia entre ambos errores.
4. Extraiga 200 muestras de tamaño 40, ajuste por `np.linalg.lstsq` y conserve los cuatro coeficientes de cada ajuste.
5. Grafique sus distribuciones muestrales y compare sus promedios con $(4, 2.5, -1.2, 0.7)$.
6. Para cada ajuste, compare el MSE de la muestra con el MSE en las 160 filas. Explique por qué el menor error de entrenamiento no identifica necesariamente el mejor ajuste poblacional.

2. Una media marginal puede ocultar grupos

Una población contiene dos grupos. Se tiene $\mathbb{P}(X = 0) = 0.7$, $\mathbb{P}(X = 1) = 0.3$, $\mathbb{E}[Y | X = 0] = 2$ y $\mathbb{E}[Y | X = 1] = 8$.

1. Calcule $\mathbb{E}[Y]$.
2. Compare el riesgo cuadrático del predictor constante $g_0(x) = \mathbb{E}[Y]$ con el de $g_1(x) = \mathbb{E}[Y | X = x]$.
3. Expresar la diferencia mediante $\text{Var}(\mathbb{E}[Y | X])$.
4. Suponga ahora que los grupos aparecen en proporciones 0.4 y 0.6 en la población de uso. Identifique qué cantidades cambian aunque las medias condicionales permanezcan iguales.
5. Explique qué información adicional necesitaría para calcular los dos riesgos numéricamente.

3. Probabilidad, log-loss y umbral

Para una entrada fija se sabe que $\eta(x) = \mathbb{P}(Y = 1 | X = x) = 0.8$.

1. Calcule la log-loss condicional esperada para $q = 0.8$, $q = 0.6$ y $q = 0.95$.
2. Verifique mediante derivación que el mínimo ocurre en $q = 0.8$.
3. Compare las clases producidas por umbrales 0.5 y 0.9.
4. Construya un ejemplo de costos en el que sea razonable usar cada umbral.
5. Explique por qué estimar una probabilidad y escoger una acción son problemas relacionados, pero distintos.

4. Qué se estaría estimando en Bogotá

Use `vivienda_nueva_bogota_subzonas.csv`.

1. Defina con precisión el estimando correspondiente al promedio de `precio_reportado` si las 32 filas se consideran una población finita.
2. Proponga un estimando diferente referido a todas las viviendas nuevas de Bogotá y enumere la información que falta para conectarlo con el archivo.
3. Ajuste una regresión de `precio_reportado` sobre `area_promedio` y compare su MSE con el baseline constante.
4. Examine el gráfico de residuales e identifique una observación que merezca revisión documental.
5. Redacte una conclusión admisible sobre las 32 subzonas y otra conclusión que los datos no permiten sostener.

Respuestas seleccionadas

Problema 2. La esperanza marginal es

$$\mathbb{E}[Y] = 0.7(2) + 0.3(8) = 3.8.$$

La diferencia entre el riesgo del predictor constante y el de la media condicional es

$$\text{Var}(\mathbb{E}[Y \mid X]) = 0.7(2 - 3.8)^2 + 0.3(8 - 3.8)^2 = 7.56.$$

Para obtener cada riesgo por separado hace falta conocer además $\mathbb{E}[\text{Var}(Y \mid X)]$.

Problema 3. El riesgo condicional es

$$L(q) = -0.8 \log q - 0.2 \log(1 - q).$$

Sus valores aproximados son 0.500 para $q = 0.8$, 0.592 para $q = 0.6$ y 0.641 para $q = 0.95$. El umbral 0.5 asigna la clase positiva y el umbral 0.9 la clase negativa; ninguna de esas acciones modifica la probabilidad estimada.

Guía de orientación de la Semana 1

Contrato de trabajo del curso

Cómo usar esta guía

Esta guía complementa el capítulo de estudio. El capítulo desarrolla conceptos, ejemplos y ejercicios; esta guía explica cómo se trabajará en el curso y qué se espera de ti desde la primera semana.

Lectura recomendada:

1. Lee primero `capitulo00_libro_estudiantes.qmd`.
2. Lee esta guía para entender el contrato de trabajo.
3. Después abre el laboratorio diagnóstico.

Los capítulos `capitulo00b_incertidumbre_datos.qmd` y `capitulo00c_estimacion_riesgo_incertidumbre.qmd` reúnen las herramientas probabilísticas y estadísticas del libro. No son lecturas completas de la primera semana: la ruta del curso indicará qué secciones consultar a medida que aparezcan en regresión, clasificación, validación y aprendizaje no supervisado.

La promesa del curso

MATE-2105 no es un curso para aprender a llamar funciones de una librería. Tampoco es un curso de teoría matemática desconectado de datos reales. La meta es más exigente:

Entender los algoritmos desde su estructura matemática, implementarlos de forma básica, usarlos sobre datos reales, diagnosticar sus fallas y comunicar decisiones técnicas con criterio.

Durante el semestre vas a ver varias veces el mismo ciclo:

1. **Pregunta.** Qué queremos predecir, clasificar, reducir, agrupar o recomendar?
2. **Datos.** Qué observamos? Qué representa cada fila? Qué representa cada columna?
3. **Modelo.** Qué familia de funciones usaremos para aproximar la relación en los datos?
4. **Pérdida.** Qué significa equivocarse?
5. **Algoritmo.** Cómo encontramos parámetros adecuados?
6. **Métrica.** Cómo medimos si el resultado sirve para la pregunta?
7. **Diagnóstico.** Dónde falla? Por qué falla? Qué evidencia tenemos?
8. **Decisión.** Qué recomendación técnica se puede defender?

La palabra **aplicada** no significa “usar una librería sin entenderla”. En este curso significa que el modelo debe enfrentarse a datos, métricas, restricciones e interpretaciones reales.

El contrato intelectual del curso

En cada algoritmo haremos, cuando sea razonable, cuatro cosas:

1. Derivar la idea matemática.
2. Implementar una versión desde cero.
3. Comparar contra una herramienta profesional.
4. Aplicar sobre datos reales.

Esto puede sentirse más lento que usar directamente `scikit-learn` o `PyTorch`. La razón es deliberada: si solo usas herramientas, puedes obtener resultados sin entender su fragilidad. Si solo haces teoría, puedes entender modelos idealizados sin reconocer lo que ocurre con datos reales. El curso busca unir esas dos competencias.

En varias actividades empezaremos con ejemplos pequeños y controlados. Su función es permitir revisar el código y entender qué debería ocurrir antes de pasar a un contexto más abierto. Luego trabajaremos con datasets reales o públicos, donde aparecen escalas distintas, ruido, particiones, métricas, errores, sesgos y limitaciones.

Qué esperamos de ti

No se espera que llegues sabiendo machine learning. Sí se espera que estés dispuesto a:

- escribir código y depurarlo;
- leer fórmulas con cuidado;
- justificar pasos matemáticos;
- aceptar que un resultado numérico no es una conclusión automática;
- explicar tus decisiones técnicas;
- trabajar con datos incómodos, imperfectos o ambiguos.

En este curso, “me dio 0.91” no es una conclusión. Una conclusión técnica debe decir:

- qué se midió;
- con qué datos;
- contra qué baseline;
- con qué limitaciones;
- qué decisión razonable se desprende.

Lenguaje mínimo de la semana

Dataset

Un dataset es una colección organizada de observaciones. En la mayoría de ejemplos iniciales, cada fila representa una observación y cada columna representa una variable.

Ejemplo:

fila	significado posible
1	un paciente
2	una vivienda
3	una imagen
4	una transacción

Variable de entrada y variable objetivo

En aprendizaje supervisado distinguimos:

- X : variables de entrada o características.
- y : variable objetivo o etiqueta.

La pregunta básica es:

Podemos usar X para aproximar, predecir o clasificar y ?

Modelo

Un modelo es una familia de funciones con parámetros ajustables. Por ejemplo, una regresión lineal usa funciones de la forma:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d.$$

Todavía no vamos a derivar este modelo en la Semana 1. Lo haremos en el Módulo 1. Por ahora nos interesa entender dónde aparece dentro del flujo aplicado.

Pérdida

La pérdida mide qué tan mal predice el modelo en una observación o conjunto de observaciones. En regresión, una pérdida común es el error cuadrático. En clasificación, una pérdida común es la entropía cruzada.

Métrica

La métrica es la forma en que reportamos desempeño para tomar una decisión. La pérdida se usa con frecuencia para entrenar; la métrica se usa para evaluar y comunicar.

Ejemplos:

- MSE o MAE para regresión.
- Accuracy, precision, recall, F1 o ROC-AUC para clasificación.

La métrica debe elegirse según la pregunta. No hay una métrica universalmente correcta.

Baseline

Un baseline es un punto de comparación simple. Antes de celebrar un modelo complejo, hay que preguntarse:

Supera algo simple?

En clasificación, un baseline puede ser predecir siempre la clase más frecuente. En regresión, puede ser predecir siempre el promedio.

Train/test

Separar datos de entrenamiento y prueba es una forma básica de estimar si el modelo generaliza. El modelo aprende con entrenamiento; la prueba se reserva para evaluar datos no usados en el ajuste.

La partición no resuelve todos los problemas, pero evita uno de los errores más graves: evaluar el modelo sobre los mismos datos que usó para aprender.

Primer ejemplo: clasificar vinos

En la primera semana usaremos un dataset clásico incluido en `scikit-learn`: `load_wine`. Cada observación corresponde a un vino; las variables describen mediciones químicas; la etiqueta indica una de tres clases.

No vamos a presentar este ejemplo como si fuera una aplicación industrial completa. Lo usaremos como primer laboratorio controlado con datos reales: suficientemente pequeño para trabajar en clase, pero suficientemente real para discutir variables, clases, métricas y limitaciones.

El flujo será:

1. Cargar los datos.
2. Inspeccionar filas, columnas y clases.
3. Crear una partición de entrenamiento y prueba.
4. Construir un baseline.
5. Entrenar un modelo de referencia.
6. Comparar métricas.
7. Escribir una conclusión técnica breve.

Un primer fragmento de código

El siguiente código muestra el tipo de flujo que usaremos. No necesitas entender todavía cada detalle; lo iremos desarmando durante el curso.

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.dummy import DummyClassifier
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

data = load_wine(as_frame=True)
X = data.data
y = data.target

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=2105, stratify=y
)

baseline = DummyClassifier(strategy="most_frequent")
baseline.fit(X_train, y_train)
baseline_pred = baseline.predict(X_test)

model = make_pipeline(
    StandardScaler(),
    LogisticRegression(max_iter=2000)
)
model.fit(X_train, y_train)
model_pred = model.predict(X_test)

print("Baseline accuracy:", accuracy_score(y_test, baseline_pred))
print("Model accuracy:", accuracy_score(y_test, model_pred))
```

La pregunta importante no es solo si el segundo número es mayor. Las preguntas importantes son:

- Cuál era el baseline?
- La partición fue razonable?
- La métrica es adecuada?
- Qué errores comete el modelo?
- Qué tan confiable es esta evaluación con un dataset pequeño?

- Qué le diríamos a alguien que quiere usar el modelo?

Cómo se verá una semana típica

La mayoría de semanas seguirá una estructura estable:

1. Problema aplicado.
2. Formulación matemática.
3. Derivación.
4. Implementación desde cero.
5. Verificación con un ejemplo controlado.
6. Aplicación con datos reales.
7. Comparación con librería profesional.
8. Diagnóstico.
9. Cierre interpretativo.

No todas las semanas tendrán el mismo peso en cada componente. Por ejemplo, algunas semanas tendrán más derivación; otras tendrán más diagnóstico o trabajo de proyecto. Pero el ciclo completo debe estar siempre visible.

Proyecto final desde la primera semana

El proyecto final empieza temprano porque la ciencia de datos aplicada no se aprende solo con ejercicios aislados. Durante el semestre, tu grupo debe convertir una pregunta real en un flujo reproducible:

1. Elegir un dataset real.
2. Formular una pregunta modelable.
3. Proponer una métrica.
4. Construir un baseline.
5. Comparar modelos.
6. Diagnosticar errores.
7. Documentar decisiones.
8. Comunicar resultados y limitaciones.

En la Semana 1 no tienes que decidir el proyecto. Pero si debes empezar a mirar el mundo con esta pregunta:

Qué problema con datos reales me interesaría modelar de manera responsable?

Entrega de la semana

La entrega de esta semana es diagnóstica y de bajo riesgo. Debe mostrar que puedes:

- abrir el entorno;
- cargar el dataset;
- correr el flujo básico;
- responder preguntas de interpretación;
- proponer dos posibles áreas de proyecto.

Entrega recomendada:

```
apellido_nombre_semana01_lab.ipynb
```

Si tuviste problemas técnicos, entrega el archivo con el error documentado y responde las partes conceptuales que puedas.

No buscamos perfección técnica en la primera semana. Buscamos establecer el modo de trabajo del curso.

Cierre

La ciencia de datos aplicada no se reduce a entrenar modelos. Un modelo sin pregunta es un ejercicio. Una métrica sin baseline es difícil de interpretar. Un resultado sin diagnóstico es frágil. Una conclusión sin limitaciones no es profesional.

Desde la primera semana, el curso te pedirá pensar como alguien que entiende el algoritmo y también entiende que los datos vienen del mundo real.

Configuración del entorno de trabajo

Objetivo

Esta guía te ayuda a preparar el entorno mínimo para la Semana 1. Si algo falla, no lo ocultes: documenta el error y llévalo a clase. El laboratorio diagnóstico también sirve para identificar problemas técnicos temprano.

Versión de Python

El entorno completo del semestre está probado con **Python 3.11 o 3.12**. No uses Python 3.13 o 3.14 para este curso: el Módulo 2 fija una versión de PyTorch compatible con el entorno comprobado.

Verifica primero:

```
python3 --version
```

Opción recomendada: entorno semestral

Descarga `requirements_curso.txt` y `check_env_curso.py` desde la [página de configuración](#). En la carpeta de descarga, ejecuta:

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -r requirements_curso.txt
python check_env_curso.py
```

Esta instalación deja listos los módulos 0-5.

Alternativa ligera para la Semana 1

Desde la carpeta modulo00_arranque, ejecuta:

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
python scripts/check_env.py
```

En Windows, la activación suele ser:

```
.venv\Scripts\activate
```

Si usas un Jupyter instalado fuera de este entorno virtual y no ves el kernel correcto, registra el entorno como kernel opcional:

```
python -m ipykernel install --user --name mate2105 --display-name "Python (MATE-2105)"
```

Verificación esperada

Si todo está bien, `python scripts/check_env.py` debe imprimir algo parecido a:

```
Python: ...
numpy: ...
pandas: ...
scikit-learn: ...
Dataset wine: 178 observaciones, 13 variables
Conteo por clase: {0: 59, 1: 71, 2: 48}
Chequeo completado correctamente.
```

Las versiones pueden variar dentro de los intervalos fijados en `requirements.txt`. Si el dataset carga y los paquetes importan, el entorno ligero está listo para la Semana 1; antes de la Semana 7 debes completar el entorno semestral para disponer de PyTorch.

Cómo abrir el laboratorio

Puedes trabajar el laboratorio de dos maneras:

1. **Jupyter:** abre `laboratorios/semana01_lab.ipynb`.
2. **Quarto/HTML:** lee `laboratorios/semana01_lab.qmd` o la versión renderizada, y copia el código a tu notebook.

La entrega recomendada es el archivo `.ipynb`, porque permite ver código, resultados y respuestas en un solo lugar.

Si algo falla

No borres el error. Copia:

1. el comando que ejecutaste;
2. el mensaje de error completo;
3. tu sistema operativo;
4. la versión de Python, si aparece;
5. qué intentaste para resolverlo.

Ejemplo de reporte útil:

```
Comando: python scripts/check_env.py
Error: ModuleNotFoundError: No module named 'sklearn'
Sistema: macOS
Python: 3.11.8
Intento: ejecuté pip install -r requirements.txt, pero falló en scikit-learn.
```

Un reporte así permite resolver el problema rápido. Un mensaje como “no me funciona” no contiene información suficiente.

Fallback temporal

Si no logras configurar el entorno antes de clase:

- trabaja con un compañero durante el live coding;
- completa las respuestas conceptuales del laboratorio;
- entrega el notebook con el error documentado;
- agenda soporte con el asistente.

El objetivo de la Semana 1 es detectar y resolver estos problemas, no castigarlos.

Errores frecuentes

ModuleNotFoundError

Significa que falta instalar un paquete o que estás usando un kernel distinto al entorno donde instalaste los paquetes.

Solución usual:

```
source .venv/bin/activate
python -m pip install -r requirements.txt
python -m ipykernel install --user --name mate2105 --display-name "Python (MATE-2105)"
```

Después, en Jupyter, selecciona el kernel del entorno virtual o, si lo registraste manualmente, Python (MATE-2105).

El notebook abre pero no ejecuta

Verifica que el kernel esté seleccionado. En Jupyter normalmente aparece en la esquina superior derecha.

python no existe

En algunos sistemas el comando correcto es python3.

Prueba:

```
python3 --version
```

Instalación muy lenta

Espera a que termine. Si falla, copia el error completo. No cierras la terminal sin guardar el mensaje.

Laboratorio diagnóstico 1

Población, muestra, riesgo y primer flujo aplicado

Objetivo

Este laboratorio es diagnóstico. Su propósito es verificar que puedes abrir el entorno y conectar cuatro niveles que usaremos durante todo el curso: población, muestra aleatoria, estimador y valor calculado. Después ejecutarás un primer flujo de clasificación y escribirás una interpretación técnica breve.

Trabajaremos con el dataset `load_wine` de `scikit-learn`. El objetivo será clasificar vinos en tres clases a partir de mediciones químicas.

No necesitas entender aún la matemática de la regresión logística. La usaremos como modelo de referencia; el objeto matemático central de esta actividad es la relación entre riesgo esperado y riesgo empírico.

Entrega

Entrega preferiblemente el archivo `semana01_lab.ipynb` ejecutado. Si trabajas desde esta versión Quarto, copia el código y tus respuestas a un notebook o a un documento con resultados visibles.

Nombre recomendado:

```
apellido_nombre_semana01_lab.ipynb
```

La entrega debe incluir:

- código ejecutado;
- salidas principales;
- respuestas de interpretación;
- conclusión técnica;
- dos ideas iniciales de proyecto;
- declaración breve de uso de IA, si aplica.

Parte 0: preparación

Ejecuta las siguientes importaciones. Si esta celda falla, revisa `recursos/configuracion_entorno.qmd`.

```
import numpy as np
import pandas as pd

from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.dummy import DummyClassifier
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
```

Parte 1: población, muestra y riesgo

Considera una población en la que

$$Y \sim \text{Bernoulli}(0.7).$$

Una regla f_1 predice siempre 1 y usa pérdida cero-uno. Su riesgo esperado es

$$R_P(f_1) = \mathbb{P}(Y \neq 1) = 0.3.$$

Genera una muestra de tamaño 20 y calcula el riesgo empírico.

```
rng = np.random.default_rng(2105)
p_clase_1 = 0.7
m = 20

muestra = rng.binomial(1, p_clase_1, size=m)
riesgo_esperado = 1 - p_clase_1
riesgo_empirico = np.mean(muestra != 1)

print("Muestra:", muestra)
print(f"Riesgo esperado: {riesgo_esperado:.3f}")
print(f"Riesgo empírico: {riesgo_empirico:.3f}")
```

Ahora repite el muestreo 2000 veces.

```
riesgos_repetidos = np.array([
    np.mean(rng.binomial(1, p_clase_1, size=m) != 1)
    for _ in range(2_000)
])

media_simulada = riesgos_repetidos.mean()
sd_simulada = riesgos_repetidos.std(ddof=1)
se_teorico = np.sqrt(riesgo_esperado * (1 - riesgo_esperado) / m)

print(f"Media de riesgos empíricos: {media_simulada:.3f}")
print(f"SD simulada: {sd_simulada:.3f}")
print(f"Error estándar teórico: {se_teorico:.3f}")
```

Auto-chequeo esperado:

- `riesgo_esperado` debe ser 0.3;
- la media simulada debe quedar cerca de 0.3;
- la desviación simulada debe quedar cerca del error estándar teórico;
- repetir con la misma semilla debe producir los mismos números.

Pregunta probabilística

Responde con cuatro frases separadas:

1. ¿Cuál es el objeto poblacional que queremos conocer?
2. ¿Cuál es la muestra aleatoria y cuál es su realización observada?
3. ¿Cuál es el estimador y cuál es la estimación obtenida en la primera muestra?
4. ¿Por qué `riesgo_empirico` no tiene que ser exactamente 0.3?

Respuesta:

Escribe aquí.

Parte 2: cargar e inspeccionar datos

```
data = load_wine(as_frame=True)

X = data.data
y = data.target

X.head()
```

Responde:

1. Qué representa una fila?
2. Cuántas variables de entrada tiene el dataset?
3. Cuántas clases hay?

```
print("Forma de X:", X.shape)
print("Forma de y:", y.shape)
print("Clases:", data.target_names)
print("Conteo por clase:")
print(y.value_counts().sort_index())
```

Auto-chequeo esperado:

- X debe tener 178 filas y 13 columnas.
- y debe tener 178 valores.
- Los conteos por clase deben ser 59, 71 y 48.

Pregunta de interpretación 1

Escribe dos frases:

- una sobre la estructura de los datos;
- otra sobre si las clases parecen balanceadas.

Respuesta:

Escribe aquí.

Parte 3: partición de datos

Vamos a separar entrenamiento y prueba.

```
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.25,
    random_state=2105,
    stratify=y
)

print("Entrenamiento:", X_train.shape)
print("Prueba:", X_test.shape)
print("Clases en entrenamiento:")
print(y_train.value_counts(normalize=True).sort_index())
print("Clases en prueba:")
print(y_test.value_counts(normalize=True).sort_index())
```

Auto-chequeo esperado:

- El conjunto de entrenamiento debe tener 133 observaciones.
- El conjunto de prueba debe tener 45 observaciones.
- Las proporciones de clase deben ser parecidas en entrenamiento y prueba.

Pregunta de interpretación 2

Por qué usamos `stratify=y`? Responde en una o dos frases.

Respuesta:

Escribe aquí.

Parte 4: baseline

Antes de entrenar un modelo, necesitamos una referencia simple.

```
baseline = DummyClassifier(strategy="most_frequent")
baseline.fit(X_train, y_train)

baseline_pred = baseline.predict(X_test)
baseline_acc = accuracy_score(y_test, baseline_pred)

baseline_acc
```

Auto-chequeo esperado:

- El baseline predice siempre la clase más frecuente en entrenamiento.
- Con esta partición, la accuracy del baseline debería estar alrededor de 0.40.

Pregunta de interpretación 3

Qué significa este baseline? Qué tendría que lograr un modelo para ser mejor que esta referencia?

Respuesta:

Escribe aquí.

Parte 5: modelo de referencia

Entrenaremos una regresión logística con escalamiento de variables.

```
model = make_pipeline(  
    StandardScaler(),  
    LogisticRegression(max_iter=2000)  
)  
  
model.fit(X_train, y_train)  
model_pred = model.predict(X_test)  
model_acc = accuracy_score(y_test, model_pred)  
  
model_acc
```

Compara:

```
print(f"Baseline accuracy: {baseline_acc:.3f}")  
print(f"Model accuracy:    {model_acc:.3f}")  
print(f"Improvement:      {model_acc - baseline_acc:.3f}")
```

Auto-chequeo:

- El modelo debería superar claramente al baseline.
- Si no lo supera, revisa si ejecutaste las celdas en orden y si el pipeline incluye `StandardScaler`.

Parte 6: errores

La accuracy resume desempeño en un número, pero no muestra que errores comete el modelo.

```
cm = confusion_matrix(y_test, model_pred)
cm
```

```
print(classification_report(y_test, model_pred, target_names=data.target_names))
```

Pregunta de interpretación 4

Observa la matriz de confusion y el reporte. Escribe:

1. Qué clase parece más fácil o más difícil de clasificar?
2. Qué limitacion tiene esta conclusión?

Respuesta:

```
Escribe aquí.
```

Parte 7: accuracy como estimación y conclusión técnica

La accuracy observada es un promedio de indicadores de acierto. Calcula su error estándar *plug-in*:

```
model_acc_se = np.sqrt(model_acc * (1 - model_acc) / len(y_test))
print(f"Accuracy observada: {model_acc:.3f}")
print(f"Error estándar plug-in: {model_acc_se:.3f}")
```

Esta cuenta supone observaciones de test independientes y una misma probabilidad de acierto. No incorpora cambio de población, búsqueda de modelos ni dependencia entre observaciones.

Completa el siguiente párrafo. Debe mencionar baseline, métrica, incertidumbre, datos y limitación.

En este experimento inicial, el modelo de referencia supera / no supera el baseline porque _____. La accuracy observada es _____ y su error estándar *plug-in* es _____. Esta cantidad intenta estimar _____. Sin embargo, la conclusión está limitada por _____.

Respuesta final:

Escribe aquí.

Parte 8: dos ideas iniciales de proyecto

Propone dos áreas o datasets que podrían interesarte para el proyecto final.

Para cada idea responde:

1. ¿Cuál sería la población de interés?
2. ¿Cuál sería la unidad de observación y cómo se obtendría la muestra?
3. ¿Cuál sería la pregunta aplicada?
4. ¿Habría variable objetivo? Si sí, ¿cuál?
5. ¿Qué cantidad poblacional o riesgo intentaría estimar?
6. ¿Qué limitación o fuente de incertidumbre anticipas?

Idea 1

Escribe aquí.

Idea 2

Escribe aquí.

Este laboratorio es diagnóstico. La prioridad es que muestres el flujo de trabajo y que identifiques dudas temprano.

Checklist antes de entregar

Marca mentalmente cada punto:

- Pude importar los paquetes o documente el error.
- Distinguí población, muestra, estimador y estimación.
- Comparé riesgo esperado y riesgo empírico mediante simulación.
- Identifique filas, columnas y clases.
- Explique por qué se usa `stratify=y`.
- Calcule baseline y modelo.
- Compare modelo contra baseline.
- Escribí una conclusión con métrica, incertidumbre, datos, baseline y limitación.
- Propuse dos ideas iniciales de proyecto.
- Declare uso sustancial de IA, si aplica.

Guía inicial del proyecto final

Proposito del proyecto

El proyecto final es el eje aplicado del curso. Su objetivo no es producir el modelo más complejo, sino construir un flujo de ciencia de datos defendible:

pregunta -> población y muestra -> estimando -> baseline -> modelos -> incertidumbre -> conclus

Cada grupo trabajará con un dataset real y una pregunta aplicada. Al final, el grupo entregará un producto técnico reproducible y cada estudiante defenderá oralmente decisiones específicas del proyecto.

Contrato operativo

La página [Proyecto final](#) reúne la especificación vigente de grupos, tareas de Bloque Neón, fechas, horas, nombres de archivo, puntajes, rúbricas y kit descargable. Esta guía ayuda a escoger y formular el tema; no reemplaza ese contrato.

Qué cuenta como buen proyecto

Un buen proyecto tiene:

- una pregunta concreta;
- datos disponibles y documentados;
- población objetivo y mecanismo de muestreo u observación explícitos;
- unidad de observación clara;
- estimando poblacional y estimador identificados;
- métrica defendible;
- baseline razonable;
- al menos dos modelos comparables;
- diagnóstico de errores;
- incertidumbre de las métricas o estabilidad entre muestras;
- limitaciones explícitas;
- código reproducible;
- conclusión orientada a decisión.

Un proyecto débil suele empezar con una herramienta en vez de una pregunta:

- “queremos usar redes neuronales”;
- “queremos hacer deep learning”;
- “queremos usar un dataset grande”;
- “queremos predecir algo financiero sin definir horizonte ni evaluación”;
- “queremos analizar sentimientos” sin definir decisión, idioma, sesgos o métrica.

La herramienta viene después de la pregunta.

Preguntas para elegir tema

Antes de proponer un proyecto, respondan:

1. Qué decisión podría mejorar con datos?
2. Quien usaria el resultado?
3. Qué representa una fila del dataset?
4. ¿Cuál es la población sobre la que se quiere concluir y cómo llegó la muestra?
5. ¿Cuál es el estimando: media condicional, riesgo, probabilidad, covarianza o distorsión?
- 6.Cuál es la variable objetivo, si existe?
7. Qué variables de entrada estarian disponibles antes de tomar la decisión?
8. Qué error sería más costoso?
9. Qué baseline simple tendría sentido?
10. ¿Cómo cuantificarán variación muestral, dependencia o estabilidad?
11. Qué limitaciones eticas, legales o de sesgo pueden aparecer?

Tipos de proyecto permitidos

Predicción o regresión

Ejemplos:

- predecir precio, demanda, tiempo, riesgo o puntaje;
- estimar una variable continua a partir de variables observables.

Métricas posibles:

- MAE;
- RMSE;
- MAPE, con cuidado;
- R^2 , como métrica secundaria.

Clasificación

Ejemplos:

- clasificar riesgo alto/bajo;
- detectar una categoría;
- identificar una clase de documento, imagen o registro.

Métricas posibles:

- accuracy;
- precision;
- recall;
- F1;
- ROC-AUC;
- matriz de confusión.

No supervisado

Ejemplos:

- segmentar usuarios;
- reducir dimensión para exploración;
- identificar grupos de observaciones;

- recomendar ítems con información limitada.

Métricas y evidencia:

- interpretabilidad de clusters;
- estabilidad;
- visualización;
- comparación cualitativa;
- utilidad para una decisión posterior.

Criterios de dataset

El dataset debe:

- tener fuente clara;
- poder compartirse o describirse legalmente;
- tener tamaño manejable;
- permitir una pregunta modelable;
- no requerir infraestructura compleja;
- tener diccionario de variables o documentacion suficiente.
- permitir describir qué unidades quedaron incluidas, excluidas o sobrerrepresentadas.

Eviten inicialmente:

- datos con restricciones legales ambiguas;
- datos personales sensibles sin anonimizacion;
- datasets demasiado grandes para computadores personales;
- datos que requieren scraping inestable;
- problemas donde la variable objetivo no existe o no se puede construir de forma responsable.

Hitos del proyecto

Semana	Fecha límite	Hito	Producto esperado
1	2026-08-06, 23:59	P00 Exploración inicial	dos ideas dentro del laboratorio diagnóstico
2	2026-08-13, 23:59	P01 Lista corta	grupo##_hito02_datasets.pdf
3	2026-08-20, 23:59	P02 Prepropuesta	grupo##_hito03_prepropuesta.pdf
4	2026-08-27, 23:59	P03 Propuesta	grupo##_hito04_propuesta.pdf
6	2026-09-10, 23:59	P04 Baseline	grupo##_hito06_baseline.zip
9	2026-10-08, 23:59	P05 Checkpoint	grupo##_hito09_checkpoint.zip
12	2026-10-29, 23:59	P06 Análisis estructural	grupo##_hito12_estructura.zip
14	2026-11-12, 23:59	P07 Reproducibilidad	grupo##_hito14_reproducibilida
16	2026-11-22, 23:59	P09 Entrega final	grupo##_proyecto_final.zip

Todas las horas son hora de Bogotá. Los detalles y puntajes están en la [página canónica del proyecto](#).

Producto final

El producto final debe incluir:

1. Repositorio o carpeta reproducible.
2. Reporte técnico.
3. Presentación breve.
4. Evidencia de experimentos.
5. Defensa oral individual.
6. Ficha probabilística: población, muestra, estimando, estimador, estimación, incertidumbre y alcance.

Defensa oral individual

Cada estudiante debe poder responder:

- Qué parte del proyecto construiste o lideraste?
- Por qué eligieron esa métrica?
- Cuál fue el baseline?
- Qué modelo funcionó mejor y por qué creen que ocurrió?
- Dónde falla el modelo?
- Qué limitaciones comunicarías antes de usarlo?
- ¿Qué cantidad poblacional estimaron y por qué su procedimiento la aproxima?
- ¿Qué variación proviene de muestra y cuál de algoritmo o partición?
- ¿Qué cambiaría si se recolectara una nueva muestra?
- Qué cambiarías con más tiempo o mejores datos?

Entrega inicial de Semana 1

Para la proxima semana, cada estudiante debe traer dos ideas iniciales. Estas ideas no comprometen todavía el tema final; sirven para empezar a discutir viabilidad, datos, métrica y decisión.

Para cada idea:

1. Tema o dataset.
2. Fuente posible.
3. Unidad de observación.
4. Población de interés.
5. Mecanismo posible de muestreo u observación.
6. Pregunta aplicada y estimando poblacional.
7. Uso que podría tener la respuesta.
8. Fuente de incertidumbre o limitación anticipada.

La entrega de estas ideas se hace dentro del laboratorio diagnóstico de Semana 1.

Ejemplos de transformación

Idea inicial débil	Versión más modelable
Quiero analizar futbol	Quiero predecir el resultado o goles esperados de un partido usando estadísticas previas
Quiero usar datos de salud	Quiero clasificar riesgo alto/bajo de reingreso usando variables disponibles al alta
Quiero hacer NLP	Quiero clasificar quejas de usuarios por tema para priorizar respuesta
Quiero usar imágenes	Quiero clasificar defectos visibles en imágenes de piezas manufacturadas

En todos los casos falta verificar si los datos existen, si pueden usarse legalmente y si la métrica tiene sentido para la decisión.

Política preliminar de uso de IA

Principio general

El uso de IA generativa está permitido como apoyo, pero no reemplaza la responsabilidad técnica del estudiante.

La regla central del curso es:

Puedes usar ayuda, pero debes poder explicar, modificar y defender cada línea relevante de código, cada métrica y cada conclusión que entregues.

Usos permitidos

Puedes usar IA para:

- explicar mensajes de error;
- sugerir pruebas pequeñas;
- revisar estilo de código;
- proponer alternativas de visualización;
- resumir documentación;
- ayudarte a entender una fórmula;
- revisar claridad de una conclusión escrita;
- generar preguntas de estudio.

Usos no permitidos

No está permitido:

- entregar código que no entiendes;
- entregar interpretaciones generadas sin verificación;
- inventar resultados, fuentes o métricas;
- pedir una solución completa de un laboratorio y presentarla como propia;
- ocultar uso sustancial de IA en un proyecto;
- usar IA para evadir la defensa oral individual.

Declaración de uso

En laboratorios y proyecto, cuando el uso de IA sea sustancial, incluye una nota breve:

Use IA para: depurar un error en la función de costo y revisar redaccion de la conclusión.
Verifique el resultado mediante: tests del laboratorio y comparación con scikit-learn.

No es necesario declarar usos menores como autocompletar una línea simple o corregir ortografía.

Responsabilidad

Si entregas código incorrecto generado por IA, la responsabilidad es tuya. Si entregas una conclusión exagerada o falsa sugerida por IA, la responsabilidad es tuya. Si no puedes explicar tu propio notebook en una defensa oral, el trabajo no cumple el estándar del curso.

Defensa oral

La defensa oral individual es parte del diseño de evaluación. Su función es verificar que cada estudiante entiende:

- los datos;
- el modelo;
- la métrica;
- los errores;
- las limitaciones;
- las decisiones técnicas.

La IA puede ayudarte a estudiar, pero no puede defender el proyecto por ti.

Uso recomendado

Un buen uso de IA se parece a trabajar con un asistente técnico:

1. Haces una pregunta concreta.
2. Revisas la respuesta.
3. Pruebas con código o matemáticas.
4. Comparas con fuentes o resultados esperados.
5. Documentas si el uso fue sustancial.

Un mal uso de IA se parece a delegar el criterio:

1. Pides una solución completa.
2. Copias sin entender.
3. No pruebas.
4. No verificas.
5. No puedes defender.

Criterio práctico

Antes de entregar, preguntate:

Si el profesor me pide explicar esta línea, esta métrica o esta conclusión sin mirar la IA, puedo hacerlo?

Si la respuesta es no, no está listo para entregar.